

数据管线练习详解

第005单元 逐项核对信息与数值

本答案使用讲义中的原始合成数据与固定名单。数字核对只能说明这份小实验内部一致；不会把它变成真实设备性能或统计推断的证据。

一 字段的可用时间

允许进入X的是knob1和knob2，按此顺序，时间为09:00。post_reading与target在09:05才可用，所以不能用于09:00预测。record_id用于连接和名单，device_id用于实体分组，时间字段用于审计。这些列在文件里都存在，不意味着它们都应成为特征。

对已知设备未来预测，device_id可能是合法输入，但必须保证身份历史只来自当时已知记录。本讲的新设备主任务不把编号送入X。判断依据是任务和可用时间，不能一概说“所有ID永远都不准使用”。

二 重复与冲突

13行减去一份A02重复导入，得到12条观测，仍有6台设备，每台两次。按device_id去重会把每台设备的第二次合法观测删掉，只剩6条，改变问题和数据量。

A02两个版本内容不同时，本实验报错并要求核查。不应悄悄保留第一条或选择让结果好看的那条。两个不同设备恰好特征相同也不是重复观测。相同设备和预测时点出现新ID，在本案例业务约定下需要核查；其他采集系统可能允许更细的事件键。

三 三份名单与目标

训练为A01、A02、B01、B02、C01、C02；验证为D01、D02；测试为E01、E02、F01、F02。记录无交叉，合起来覆盖12条，设备集合{A,B,C}、{D}、{E,F}也不交叉。

若改为同设备下一天预测，历史和未来可以包含同一设备，不能因此判定泄漏。但训练数据以及训练所用标签必须在预测前到达，未来输入和未来标签不能倒流。可用第一天训练、第二天验证、第三天测试的结构说明规则；随附数据没有第三天，因此不能凭两天文件声称完成这种三份时间评价。

实体留出没有验证时间漂移，时间留出没有自动验证新实体。若要两者同时成立，应同时约束时间与身份，并说明相应目标，而不是只选择分数较好的名单。

四 描述数值与分母

旋钮1: 6个已观测数, 和21, 平均 $21/6=3.5$, 最小1, 最大6, 无缺失。旋钮2: 5个已观测数, 和190, 平均 $190/5=38$, 最小10, 最大60, 1条缺失。缺失比例为 $1/6$, 约16.7%。平均的分母5数的是可用数, 比例的分母6数的是全部观测。

直方图区间[1,3)、[3,5)、[5,7]分别包含{1,2}、{3,4}、{5,6}, 各2条。每个数只计一次。散点图缺A02是因为第二列没有坐标, 不能画成(2,0)来伪装实际观测。图形中的线性排列来自合成生成方式, 不是发现了现实规律。

五 填补与缩放

训练平均为[3.5,38], 训练最小[1,10], 最大[6,60], 跨度[5,50]。先填缺失, 再逐列计算“减去训练最小、除以训练跨度”。

观测	填补后两列	缩放后两列
A02	(2,38)	$((2-1)/5, (38-10)/50) = (0.2, 0.56)$
D01	(7,70)	$((7-1)/5, (70-10)/50) = (1.2, 1.2)$
D02	(8,38)	$((8-1)/5, (38-10)/50) = (1.4, 0.56)$

若验证旋钮1为0, 则缩放为 $(0-1)/5=-0.2$ 。负数只说明低于训练最小值, 不是必须裁到0。裁剪会丢失超出范围的差别, 是另一项需要明说的策略。验证值大于1也同理, 不应该重新fit验证集来强行压回0到1。

A02的填补数38不是对其真实缺失值的恢复。生成器知道那次完整旋钮2应为20, 但预测输入里没有它; 本任务不允许利用生成器隐藏值当作现实可用输入。

六 全量拟合的泄漏路径

训练已观测值和190, 再加验证/测试已观测70、90、100、110、120, 合计680; 观测个数由5变10, 因此全量平均为68。用68填补训练A02, 意味着留出输入影响了训练输入, 即使整个过程没有读target。

验证自己的两行也不应单独求填补平均。D01旋钮2为70, D02缺失, 若在验证侧fit就把D02填为70, 与部署应沿用的38不同。同一个缺失样本会因同批次其他行变化而得到不同表示。

检验来源的方法是保存fit_record_ids, 并把所有留出输入改成极端数后重新运行正式训练拟合。均值、极值与跨度都必须保持不变。函数只有数组时无法自动知道这些数来自哪份名单, 调用顺序和来源记录仍然重要。

七 标签连接与剩余风险

标签文件倒序不应改变连接结果。必须先拒绝重复标签ID，再核对输入与标签ID集合相同，最后依据 `record_id` 取目标。A01应得到2；直接取标签第一行会得到F02的47。两个数组都长12，`shape`检查发现不了这一点。

若A01对应的标签值被人工错误写成20，ID仍然正确，键检查不能发现内容错标。需要核查原始资料、单位、标签形成过程或独立标注。在本教材里还可用生成公式核对，但不能据此推断真实数据都有已知正确公式。

八 身份记忆反例

每台设备第一次用于训练、第二次留出时，训练字典拥有全部六台的恒定读数，留出六条绝对误差都为0，所以MAE为0。

按设备隔离，用A/B/C训练，标签2、5、11各重复两次。平均为 $(2+2+5+5+11+11)/6=6$ 。对D/E/F每条都预测6，绝对误差依次为11、23、37，每项出现两次，平均为 $(22+46+74)/6=71/3$ ，约23.667。

它反驳的是“随机拆行上的完美误差足以证明新设备能力”。它没有证明所有随机拆分都无效、所有身份特征都不合法、所有真实任务都有23.667的误差，也没有估计换拆分造成的普遍性能损失。两个分数对应不同部署问题。

九 边界测试的预期

训练列全缺失：没有可求平均的数，报错。训练列常量：跨度为0，报错。无穷数：不等于允许的缺失编码，报错。未来字段或顺序变更：不符合两列允许名单，报错。训练输入非二维、不是两列、为空：报错。

验证一列全缺失可沿用已经保存的训练平均，因此与“训练全缺失”不同。改变验证值后`state`不应改变，重新拟合训练也不应改变。测试中还会保留特征相同但身份不同的记录，防止把“数一样”误判为重复。

最终应在`outputs`与`notebook_outputs`看到相同的正式参数和张量账本。失败案例被明确捕获才算测试通过；若程序只是把错误吃掉而返回空列表，不算正确处理。