

第一次可重跑的研究练习详解

一 要保存哪些决定

至少包括预测任务与时点、按设备拆分的名单、训练子集大小、全部预定种子与主种子、候选模型与偏移量、指标、同分规则、数据版本、代码版本和环境版本。偏移量1本身无法说明它从哪八条数据、哪三个候选或哪次比较中产生。

还应保存实际入选编号与逐条预测。配置是计划，记录是执行证据，两者需要对应。没有执行过的检查不能仅因为写在计划里就标记完成。

二 主运行的完整算术

八条标签依次是7、7、3、5、10、3、4、9，总和48。偏移量0的预测为6、6、2、4、8、2、4、8，绝对误差1、1、1、1、2、1、0、1，总和8，MAE为1。

偏移量1的预测为7、7、3、5、9、3、5、9，绝对误差0、0、0、0、1、0、1、0，总和2，MAE为0.25。偏移量2的预测为8、8、4、6、10、4、6、10，绝对误差1、1、1、1、0、1、2、1，总和8，MAE为1。因此选择偏移量1。

常数基线为48除以8等于6，误差为1、1、3、1、4、3、2、3，总和18，MAE为2.25。这个基线使用训练均值，只是易核对的参照，不能未经分析就称为MAE意义下最优常数。

三 同分不同预测

验证标签为3、5、7、9。常数5.375的四条误差是2.375、0.375、1.625、3.625，总和8，平均2。常数6.5的误差是3.5、1.5、0.5、2.5，总和也是8，平均仍为2。

两种常数对每个输入的预测不同，错误分布也不同。平均指标将多条信息压成一个数，可能把变化互相补偿后的结果隐藏起来。逐条记录与汇总应一起保留。

四 种子不是全部状态

sample选择的是输入序列中的条目。即使种子相同，训练列表顺序改变后，被选位置对应的记录可能不同。软件版本或调用顺序改变也不能未经核对就假定结果逐项一致。

应保存种子、发生器使用方式、数据摘要、原始行序、实际入选编号、子集大小和Python版本。固定种子解决部分重跑问题，不保证代表性、独立性或科学结论的可靠性。

五 摘要与含义

多加一个换行会改变原始字节，因此SHA-256摘要改变；如果解析后的记录完全相同，模型输出可能不变。摘要告诉我们不是同一份字节文件，不直接告诉我们科学含义是否改变。

修改标签则可能改变参数、选择或评价。训练标签改变可能影响拟合；验证标签改变可能影响模型类型选择；测试标签改变只应影响冻结之后的分数，不应反过来改变已保存的模型和预测。必须检查实际信息流。

六 删除未选结果的问题

协议提前规定主种子101，并保留101、102、103三次描述结果。事后挑最小训练误差并删除其余两次，改变了选择规则，也隐藏了尝试范围。即使这里恰好仍选到101，过程仍与原协议不一致。

正确做法是保留全部运行，说明预设主运行与探索记录。若要设计新的选择规则，应在新实验中写明，并安排适当评价，不能把事后选择包装成从未看过结果的计划。

七 从观察走向检查

具体观察：“设备F四个给定位置的冻结预测都比公开标签低2，测试MAE为2；设备E四行验证MAE为0。”这句话能从逐条文件核对，没有外推到其他设备。

在真实任务中，可能解释包括设备标定偏移、标签转换规则变化、输入单位不一致或模型遗漏了设备相关信息。当前四行不够区分这些原因。下一步可核对原始测量和单位流程，并在未参与改模的新设备记录上检验预先提出的修正假设。

不能仅把偏移量改成3后继续将F这四行称为独立最终测试。它们已经提供修改方向。对合成教材，我们知道作者的设计；对真实研究，相似图形仍需独立证据。

八 交付验收

确认配置可读、输入和源码版本可核对、三次运行无遗漏、主运行选择遵守约定、测试预测在揭示标签前保存、每条误差与编号对应、日志与产物一致、重跑经过实际执行。缺一个部分就明确记录缺口，不用一张漂亮分数截图替代它。