

雅可比与矩阵求导练习详解

正文第1题 三个输出的局部变化

对 $f=(x_1x_2, x_1+x_2, x_1^2)$ ，在 $(2,3)$ 处按输出行、输入列得到 $J=[[3,2],[1,1],[4,0]]$ 。对于 $v=(2,1)$ ，列式 $Jv^T=(8,3,8)^T$ ；返回行则为 $(8,3,8)$ 。 $c=(1,0,-1)$ 给 $cJ=(-1,2)$ 。配对左侧 $c \cdot (8,3,8)=0$ ，右侧 $(-1,2) \cdot (2,1)=0$ 。

可以逐项从差商确认：乘法沿该路线成为 $(2+2t)(3+t)=6+8t+2t^2$ ，除去原值再除 t ， t 趋0得到8。平方沿路线为 $4+8t+4t^2$ ，得到8。实际有限变化还有二次项，所以 t 不为0时不能把JVP直接称为精确变化。

正文第2题 行与列的约定

δx 为 $(1,n)$ ， J 为 (m,n) ，所以 $\delta x J^T$ 是 $(1,m)$ 。把两边转置得到 $\delta y^T \approx J \delta x^T$ 。若另一本材料把导数表定义为输入作行、输出作列，就把那张表记作 $K=J^T$ ，行式变成 $\delta x K$ 。只改名称却继续套用原转置会造成维度错误；当 $m=n$ 时甚至可能维度恰好允许而数值错误。

标量损失的梯度可以按行或列约定书写；本课统一为行。矩阵参数则让梯度保持参数shape，以 $dL=\Sigma G_{ij} dQ_{ij}$ 定义其意义。不同布局可以互相转换，但必须同时改变相乘顺序和转置位置。

正文第3题 仿射层的元素证明

$Z_{ik}=\Sigma_j U_{ij} W_{jk}+b_{1k}$ 。固定 W_{jk} 时，每个样本 i 的局部系数为 U_{ij} ，因此 $G_{W,jk}=\Sigma_i G_{Z,ik} U_{ij}$ ，即 $U^T G_Z$ ， $\text{shape}(D,H)$ 。固定 U_{ij} 时，需收集输出 k 的路径： $G_{U,ij}=\Sigma_k G_{Z,ik} W_{jk}$ ，即 $G_Z W^T$ ， $\text{shape}(N,D)$ 。

固定 b_{1k} 时，它在所有样本第 k 列被重复使用，每条系数为1，因此 $G_{b,1k}=\Sigma_i G_{Z,ik}$ ， $\text{shape}(1,H)$ 。偏置的列索引 k 必须保留。 $\text{sum}(\text{axis}=1)$ 会对同一个样本的不同参数求和，不是这条求导式。

正文第4题 两层的完整计算

$A=[[2,1.5],[-0.5,2.5]]$ ， $H=[[4,2.25],[0.25,6.25]]$ ， $P=[[0],[-11.75]]$ ， $E=[[-1],[-10.75]]$ 。

$L=(1+115.5625)/4=29.140625$ 。 $G_P=E/2=[[-0.5],[-5.375]]$ 。

$G_{W_2}=[[-3.34375],[-34.71875]]$ ， $G_{b_2}=[[-5.875]]$ 。 $G_H=[[-0.5,1],[-5.375,10.75]]$ ，按对应位置乘 $2A$ ，得到 $G_A=[[-2,3],[5.375,53.75]]$ 。因此：

$$G_{W_1} = \begin{pmatrix} -7.375 & -50.75 \\ 1.375 & 59.75 \end{pmatrix}, \quad G_{b_1} = \begin{pmatrix} 3.375 & 56.75 \end{pmatrix}.$$

$G_X=[[-5,2],[-48.375,56.4375]]$ 。例如 G_X 第二行第二项是 $5.375 \times 0.5 + 53.75 \times 1 = 56.4375$ ； G_{W_1} 第一行第二项为 $1 \times 3 + (-1) \times 53.75 = -50.75$ 。两种矩阵乘法收集的是不同的索引，不能靠“总要放一个转置”的经验猜。

正文第5题 多除一次批次数

正确 G_{b_1} 为 $[[3.375, 56.75]]$ 。错误mean给 $[[1.6875, 28.375]]$ ，恰好为一半，因为 $N=2$ 。损失平均系数已经包含在 G_P 中，并随链式法则传到 G_A 。如果改损失定义为未平均的平方和再乘一半，则起始 $G_P=E$ ，后续仍沿样本求sum，而不是随意在某层补mean。

正文第6题 平方的对角结构

把 NH 个元素按同一顺序展开，输出第 r 项是输入第 r 项的平方，因此同位置导数为 $2A_r$ ，不同位置导数为0。完整 J 是以 $2A$ 展开值为对角线的矩阵。对角矩阵乘向量只需把每个元素乘自己的对角系数，所以 JVP 为 $2A \odot dA$ ， VJP 为 $G_H \odot 2A$ ，不必创建 NH 的平方个存储位置。主例 A 中有负数，所以对角系数也有负数。

正文第7题 九参数雅可比的负号

参数顺序为 W_1 的 $(1,1),(1,2),(2,1),(2,2)$ ， b_1 的两项， W_2 的两项， b_2 。第二个预测对 W_{11} 的导数是 $X_{21} \times 2A_{21} \times W_{21} = (-1) \times (-1) \times 1 = 1$ ；对 W_1 第2行第1列的导数是 $X_{22} \times 2A_{21} \times W_{21} = 1 \times (-1) \times 1 = -1$ 。前者两个负号抵消，后者只有平方局部导数为负。

完整第二行是 $(1, 10, -1, -10, -1, -10, 0.25, 6.25, 1)$ 。把它与第一行分别乘上游 -5.375 和 -0.5 后相加，得到参数梯度 $(-7.375, -50.75, 1.375, 59.75, 3.375, 56.75, -3.34375, -34.71875, -5.875)$ 。

正文第8题 同时改变全部参数

dW_1 、 db_1 、 dW_2 、 db_2 各元素都为0.1， X 固定。 $dA = [[0.4, 0.4], [0.1, 0.1]]$ ； $dH = 2A \odot dA = [[1.6, 1.2], [-0.1, 0.5]]$ 。第一输出的变化为 $1.6 - 2.4 + 0.4 + 0.225 + 0.1 = -0.075$ ；第二输出为 $-0.1 - 1 + 0.025 + 0.625 + 0.1 = -0.35$ 。

权重 $(1,2)$ 配对得到 $-0.075 - 0.7 = -0.775$ 。等价地，显式 J 先左乘 $(1,2)$ 得到 $(6, 14, 6, -32, 2, -26, 4.5, 14.75, 3)$ ，这些项之和为 -7.75 ，再与全部0.1的方向相乘得 -0.775 。注意 VJP 的权重此处不是损失权重 G_P ，因而其结果也不是主损失梯度。

正文第9题 复制批次

把两行数据和目标各重复一次， N 从2变4，平方和翻倍，因此平均损失不变。每份样本的上游权重减半，但共享参数收到两份相同贡献，最终参数梯度不变。 G_X 现在有四行，每个独立输入位置仅收到原值的一半；若进一步把两份输入明确绑定为同一个变量，才会把这两条路径加回去。

仅置换批次顺序时，损失与参数梯度不变， G_X 按相同置换移动。测试同时覆盖这些结构性关系，以补充单个静态数值例子的局限。

正文第10题 输出维平均

若损失变为 $\sum_i c_i E_i c_i^2 / (2NC)$ ，则起点 $G_P = E / (NC)$ ，后面所有层公式保持不变。相对于本课定义，所有梯度额外缩小C倍。C=1时两定义相同，无法发现这一错误，所以测试的100个随机有理数夹具中包含C=2的矩形输出。

正文第11题 数组字节数

N=64时，展开输入8192项，展开输出16384项。稠密输入雅可比含134217728个float64数，乘8得1073741824字节，即1024 MiB或1 GiB。一次乘积的输入与输出数组合计24576项，乘8得196608字节，即192 KiB。

从N=32变64，稠密表两条轴都翻倍，大小翻四倍；两份乘积数组只翻两倍。前者是稠密假设下的元素数公式，不表示实际算法一定分配它；后者也没有包括X、W、前向A/H、反向临时量和库开销，因此不能据此声称峰值内存减少了精确多少倍。

正文第12题 有针对性的错误测试

bias轴检查要选N与H不同的输入，核对结果shape为(1,H)，再用单独扰动 b_1 某一项的差分核对它收集全部样本。平方规则检查要使A同时有正、负、零元素，以免错误导数在特殊输入恰好碰巧一致。归一化检查可以整批复制样本，验证平均损失和共享参数梯度不变；多输出平均的定义则需 $C > 1$ 。

差分步长过大有截断误差，过小有消减或无法分辨的输入变化；一个步长通过不能证明所有坐标或所有尺度正确。shape、手算、独立精确oracle、不同shape夹具和多个步长互相补充，但都不声称替代数学证明。

实验各阶段的检查结果

A到C应得到前向A/H/P及损失29.140625。系数1/2与平方求导的2抵消，因此 $G_P = E / N$ 。D两份外积分别是 $[-2, 3], [-4, 6]$ 与 $[-5.375, -53.75], [5.375, 53.75]$ ，相加得到 G_{W_1} ；偏置错误mean是正确值一半。

E使用 $h = 1e-5$ 检查9个参数加4个输入，最大绝对误差应小于 $2e-8$ 。具体末位随平台可能略变；不能把本次最优h写成一般默认保证。步长 $1e-17$ 拒绝后空误差字段表示没有有效比较，不表示零误差。

F显式J是 2×9 ，两种乘积与局部传播结果一致，配对值约-0.775。G复制批次后共享参数梯度不变，而四个输入行各减半。H中错误逐元素乘法 $X.T * G_A$ 得到 $[-2, -3], [10.75, 53.75]$ ，虽然shape也是(2,2)，与正确 G_{W_1} 不同；漏平方导数得到 G_A 错误值 G_H ，也能被独立差分发现。

I应保留实际运行版本与三种核验路线，不只提交截图或一段“运行成功”。随附Notebook已从空状态执行，脚本与其三份输出一致；未验证浏览器Jupyter界面、跨进程socket内核或全新Anaconda安装。所有实验都是小规模合成数学例子。