

浮点数与稳定数值计算练习详解

第1题 有限二进制小数

$0.625=5/8=1/2+1/8$ ，所以二进制为 0.101_2 。有限二进制小数乘上某个2的幂后必须成为整数；约分后的分母只能含因子2。 $0.1=1/10$ ，分母含5，因此不能精确有限表示。把显示字符串写成“0.1”不改变实际存储的有理数。

第2题 指数改变间隔

3有效位格式在 $[1,2)$ 为1、1.25、1.5、1.75，乘4后在 $[4,8)$ 为4、5、6、7，间隔1。区间内有效位组合数没变，绝对尺度变大。更多有效位增加细度，更多指数位扩展范围；二者共同决定一种格式，不能把最大可表示数当作精度指标。

第3题 几个容易混用的界限

NumPy `eps`是1之后向上邻数与1的差；本讲unit roundoff记 $u=eps/2$ ，描述最近舍入条件下正规范范围内的相对误差界。最小正正规数是正规编码的下边界；最小正次正规数更小，并不是同一个tiny。最大有限数是上范围边界，超出它可能产生inf。`eps`与最小正数不可互换，位数与动态范围也不可互换。不同文献对machine epsilon命名有差异，应看具体定义。

第4题 加法的括号

$(a+b)+c=(10^{16}-10^{16})+1=1$ ，在这一路计算中中间结果0可精确表示。 $b+c$ 先算时， -10^{16} 附近无法保留加上1，舍入后仍为 -10^{16} ，最终 $a+(-10^{16})=0$ 。所有结果都有限，`isfinite`返回真；因此它是异常值检查，不是精度证明。当前`math.fsum([10^{16}, -10^{16}, 1])`得到1，通过更细致跟踪小项改善求和。

第5题 有理化的条件

把 $\sqrt{1+x}-1$ 乘以共轭分式，分子成为 $(1+x)-1=x$ ，分母为 $\sqrt{1+x}+1$ 。 $x \geq -1$ 时平方根存在，且分母 ≥ 1 ，所以没有新引入的零分母。 $x=-1$ 时两式均为-1， $x=0$ 时均为0。小 x 直接式可能先把 $1+x$ 舍入到1而返回0；有理化式保留分子的小 x ，但仍有输入及运算舍入，不能笼统称为精确计算。

第6题 稳定归一化和LSE

$m=1001$ ，`shifted` $=(-1,0,-2)$ ，指数约 $(0.3678794412, 1, 0.1353352832)$ ， $S \approx 1.5032147244$ 。权重为 $(0.2447284711, 0.6652409558, 0.0900305732)$ ，和在舍入容差内接近1。
 $LSE=1001+\log S \approx 1001.4076059644444$ 。

最大指数平移后为1，其余位于(0,1]，所以 $1 \leq S \leq K$ ，取log得 $0 \leq \log S \leq \log K$ ，加m得到范围 $[1001, 1001 + \log 3]$ 。实数公式严格成立；浮点检查应留合适容差，不要求每一步无舍入地满足符号等式。

第7题 平移恒等式与实际输入

分子和分母同时除以正数 e^m ，比例不变，故精确实数softmax对共同平移不变。但是float32先把1000000000和1000000001映射成同一个值，差1已丢失；转换再平移不能恢复差别。此时稳定结果(0.5,0.5)对已存输入是合理计算，对原十进制任务则丢了信息。把已损失数组升为float64仍得到两个相同的1000000000。

第8题 尾项下溢与对数

$e^{-200} \approx 1.38390 \times 10^{-87}$ ，远小于float32最小正次正规数，因此第二个指数可舍入为0，归一化尾概率为0。精确log权重是 $-200 - \log(1 + e^{-200})$ ，非常接近-200；这个大小容易表示。先取概率再log会做log0，而直接计算shifted-logS避开了这次信息丢失。float64在该例中还能保留非零尾概率。

第9题 三次多项式的精确误差

$(x+h)^3 = x^3 + 3x^2h + 3xh^2 + h^3$ ； $(x-h)^3 = x^3 - 3x^2h + 3xh^2 - h^3$ 。相减得到 $6x^2h + 2h^3$ ，除以 $2h$ 得到 $3x^2 + h^2$ 。相对导数 $3x^2$ ，截断误差为 h^2 ，前提 $h \neq 0$ 且这里使用精确实数算术。浮点采样、相减和除法还会带来其他误差。一个步长产生零观察误差，可能是舍入抵消或特殊多项式结构，不能推广。

第10题 一个局部误差模型的最小点

设A、B、u均为正且在考虑范围内不随h变化， $E(h) = Ah^2 + Bu/h$ ， $h > 0$ 。用010的幂函数求导规则， $E'(h) = 2Ah - Bu/h^2$ 。令其为0，得到 $2Ah^3 = Bu$ ，因此：

$$h_* = \left(\frac{Bu}{2A} \right)^{1/3}.$$

当步长小于上述最优值时导数为负；当步长大于上述最优值时导数为正，所以这是该模型在正轴的最小点。这里A与截断误差相关，B与函数值、坐标和舍入相关；它们不是通用已知常数。若三阶导数为0、输入无法分辨、有下溢、非光滑或模型假设不满足，不能继续机械使用u的三次方根。

第11题 三种步长与两个参考点

requested_h是配置里的请求值，stored_h是转换到当前dtype后的值，actual_plus_step和actual_minus_step是实际完成 $x \pm h$ 运算后与原x的差。每一步可能舍入，它们不一定相等。例如float32中0.7实际为约0.699999988079071， $h=0.1$ 存为约0.10000000149011612，两侧实际间隔约0.10000002384185791。

float64存储的0.7又是另一个精确有理数。若要专门分析差分误差，就在各自实际x处计算导数参考；若要评估原十进制任务的总误差，则还要另外计入输入误差。混淆参考点会让误差解释不清。本课CSV在无法完成采样时保留拒绝状态并留空数值，不将其冒充成功。

第12题 dtype变更验收记录

每条记录应包含原输入、实际dtype和存值、计算公式、定义域与范围检查、参考来源与精度、输出误差、失败状态。例子至少覆盖：正常范围中的有限误差；巨大正分数使朴素exp上溢；巨大负分数全下溢；稳定尾项仍下溢但log值有限；分数在转换时变相同；差分步长无法分辨。

有限输出只通过了异常值检查，是否可用仍看误差与任务容忍度。该小实验没有训练性能证据，所以不能据此声称float32训练总是无损，也不能笼统否定它。低精度选择应在实际任务中单独验证。

实验检查点

A应观察到float32 $\text{eps}=2^{-23}$ ，float64 $\text{eps}=2^{-52}$ ，2附近向上间隔为1附近两倍。B中两个朴素softmax均产生非有限结果，平移后两种dtype返回近似一致权重。C中float32尾概率0、log尾值约-200，float64尾概率约 1.38390×10^{-87} 。D中已损失的差1无法靠后续升精度恢复。

E中float64的 $x=10^{-16}$ 直接式为0，有理化式约 5×10^{-17} ；直接式相对误差约1，即100%。F中最佳的测试步长依赖dtype和当前采样，不预先指定一个普适数。float32在配置的1e-8及更小步长无法分辨，float64在1e-17无法分辨；这些行不参与有效误差的最小值比较。

G应有9组测试、200个向量dtype案例、82个导数参考和23项拒绝，6段文档代码均实际执行；脚本与Notebook三文件一致。记录说明新进程真实InProcessKernel执行通过，也明确没有浏览器界面、外进程socket内核、新装Anaconda、其他硬件及实际训练速度验证。