

局部近似与优化几何

第015单元 曲率怎样限制步长

曲率、步长和参数尺度怎样共同影响优化？本讲的答案可以在一个二维碗形函数里完整算出：梯度说明此刻朝哪里下降，Hessian说明不同方向的斜率改变得多快；固定步长要照顾最陡的方向，温和方向却可能因此前进缓慢。改变坐标尺度还会改变“相同步长”的实际含义。只有把这些条件写清，观察到的下降曲线才有可解释的数学含义。

先修011和013。我们使用011的偏导、全微分、行梯度、链式法则，以及013的正交基、对称矩阵特征方向和条件数。011的先修链已提供一元导数与积分。本讲不依赖014，也不使用尚未学习的随机梯度、自动微分或优化器。实验只包含明确给出的合成函数，没有样本抽取，更没有真实神经网络。

参数 θ 、增量 δ 、梯度 g 都采用 $\text{shape}(1,2)$ 的行向量。Hessian H 是 $\text{shape}(2,2)$ 的矩阵； $g\delta^T$ 和 $\delta H\delta^T$ 都是 $\text{shape}(1,1)$ 的乘积，取唯一元素得到标量。推广到 d 维时分别为 $(1,d)$ 、 (d,d) 。本讲坐标和目标值均无量纲。如果真实参数带不同单位，梯度第 j 项的单位是目标单位除以参数 j 单位， H 的 ij 项是目标单位除以两种参数单位的乘积；比较曲率大小前必须声明尺度。

读完后，你应能解释三个不同层次的结论：一点附近的近似；沿一次更新线段的下降保证；某类函数上对所有初值的收敛保证。它们的前提越来越强，不能互相替代。

一 一阶模型为什么会漏掉回弹

011告诉我们，在可微点 p 附近，函数有线性模型：

$$f(p + \delta) = f(p) + g\delta^T + r_1(\delta), \quad \frac{r_1(\delta)}{\|\delta\|_2} \rightarrow 0.$$

这里 $g = \nabla f(p)$ ，极限要求 δ 从任何方向趋于0。线性部分适合描述很小的移动，但它的斜率不会随 δ 改变。若一直沿负梯度走，线性模型便一直预测下降；真实函数的坡可能逐渐变平、越过谷底再变陡。因此我们需要一个能表示“斜率也在变化”的下一层模型。

对一阶导数再求导，得到二阶导数 f'' ，它描述斜率的变化率。先看一元 $f(x)=x^4$ ，在 $p=1$ 处 $f=1$ 、 $f'=4$ 、 $f''=12$ 。把 $x=1+h$ 代入并逐项展开：

$$(1+h)^4 = 1 + 4h + 6h^2 + 4h^3 + h^4.$$

一阶模型是 $1+4h$ ；二阶模型是 $1+4h+6h^2$ 。为什么 h^2 的系数是 $f''/2$ ，而不是 f'' ？因为 $6h^2$ 求两次导数后为12。对小 h ，二阶模型多记住了斜率的变化；对远处的 h ，三次与四次项仍可能重要。




图1 原创函数 x^4 在 $x=1$ 处的局部模型。两种模型在基点具有相同函数值与斜率；二阶模型还匹配二阶导数。右侧范围扩大后，两种近似都会偏离，二阶并不意味着任意远都准确。

这里的“曲率”指沿直线方向二阶导数，是优化中的用法。它不是微分几何中还要按曲线弧长归一化的曲率。负二阶导数表示向下弯曲，并不直接表示当前函数正在下降：下降还取决于一阶导数。

二 沿一条线推导Taylor二阶式

Taylor近似是一种在基点匹配导数的局部多项式近似。本节不是假设函数有无限级数，而是只要求二阶连续可微，记作 C^2 ：直到二阶的偏导都存在且连续。

把多维增量固定下来，定义一元函数 $\varphi(t)=f(p+t\delta)$ ，其中 $0 \leq t \leq 1$ 。假设这条线段及其附近都在 f 的定义域中，且 f 在那里为 C^2 。由011的路径链式法则， $\varphi'(0)=g\delta^T$ 。先不展开 φ'' ，利用010的积分基本定理：

$$\varphi(1) - \varphi(0) = \int_0^1 \varphi'(t) dt, \quad \varphi'(t) = \varphi'(0) + \int_0^t \varphi''(s) ds.$$

把第二式代入第一式。连续函数在三角形 $0 \leq s \leq t \leq 1$ 上交换积分顺序，内层关于 t 的长度是 $1-s$ ，得到：

$$\varphi(1) = \varphi(0) + \varphi'(0) + \int_0^1 (1-s)\varphi''(s) ds.$$

也可不使用二重积分语言：对 $(1-s)\varphi''(s)$ 求导并积分，整理后得到同一个式子。前面只是解释权重 $1-s$ 从哪里来。若 φ'' 恰好不变，最后一项就是 $\varphi''/2$ ，因为从0到1积分 $1-s$ 得到 $1/2$ 。

第二次使用链式法则时， δ 是固定的速度，不随 t 变化。因此只须再求各个梯度分量的变化：

$$\varphi''(t) = \sum_{i,j} \delta_i \frac{\partial^2 f}{\partial \theta_i \partial \theta_j}(p+t\delta) \delta_j = \delta H(p+t\delta) \delta^T.$$

由此得到精确的积分余项表达式，以及常用的局部二阶模型：

$$f(p+\delta) = f(p) + g\delta^T + \frac{1}{2} \delta H(p) \delta^T + r_2(\delta),$$

$$r_2(\delta) = \int_0^1 (1-s) \delta [H(p+s\delta) - H(p)] \delta^T ds.$$

定义矩阵算子范数为它对单位向量长度的最大放大倍数，与013一致。内积不等式给出：

$$|r_2(\delta)| \leq \frac{1}{2} \|\delta\|_2^2 \max_{0 \leq s \leq 1} \|H(p + s\delta) - H(p)\|_2.$$

H 在 p 连续，足够短的整条线段都落在 p 附近，最大差趋向0。因此 $r_2/\|\delta\|^2$ 趋向0，记为 $r_2=o(\|\delta\|^2)$ 。符号 o 表达一个极限性质，不表示余项严格等于0。 C^2 条件本身也没有承诺统一的三次误差界；若另外知道 H 在邻域满足 $\|H(a)-H(b)\|_2 \leq K\|a-b\|_2$ ，才可把积分继续界成 $K\|\delta\|^3/6$ 。符号 $O(\|\delta\|^3)$ 表示足够小时被某个固定常数乘 $\|\delta\|^3$ 控制，与表示比值趋零的 o 不同。[1]

三 Hessian把二阶偏导放到同一张表

Hessian是由二阶偏导组成的矩阵。本讲采用 $H_{ij} = \partial g_i / \partial \theta_j$ ，其中 $g_i = \partial f / \partial \theta_i$ 。二维写成：

$$H = \begin{pmatrix} f_{xx} & f_{xy} \\ f_{yx} & f_{yy} \end{pmatrix}.$$

f_{xx} 衡量沿 x 移动时 x 方向斜率怎样变， f_{xy} 衡量沿 y 移动时 x 方向斜率怎样变。在 C^2 假设下，混合偏导相等， $H=H^T$ 。这是标准的混合偏导交换定理；本讲引用它，不声称仅凭排成矩阵就能证明对称性。[1,3]

例如 $f(x,y)=x^2+3xy+2y^2$ 。先求行梯度 $g=(2x+3y, 3x+4y)$ ，再对每个分量逐坐标求导，得到 $H=[[2,3], [3,4]]$ 。二阶变化是：

$$\frac{1}{2} \delta H \delta^T = \delta_x^2 + 3\delta_x \delta_y + 2\delta_y^2.$$

两个非对角元素共同贡献 $6\delta_x \delta_y$ ，再乘1/2得到 $3\delta_x \delta_y$ 。只保留 H 的对角线会漏掉联合变化。更重要的是，这个 H 的两个对角数都是正数，却沿 $\delta=(3,-2)$ 给出 $\delta H \delta^T = -2$ 。只看坐标轴二阶导数，不能判断所有方向的弯曲。

“求两次导数”还要求当前位置确实存在这些导数。 $|x|$ 在0不可导，不能随意填一个0作为它的经典Hessian。程序可能有自己的约定，但那必须与数学定义分开描述。有限差分也不能消除不可微点。

四 二次型和主方向怎样画出谷地

固定对称矩阵 H 后， $\delta H \delta^T$ 称为二次型：每一项都是两个坐标增量的乘积。对单位行方向 u ，沿 $p+tu$ 的二阶导数为 uHu^T ，所以它测量每单位距离的方向曲率。

013已经介绍实对称矩阵有正交特征基。写 $H=Q\Lambda Q^T$ ， Q 的第 i 列是单位特征向量 q_i ， Λ 对角上是实数 λ_i 。采用行坐标 $z=\delta Q$ ，则 $\delta=zQ^T$ ，且长度不变。于是：

$$\delta H \delta^T = z \Lambda z^T = \sum_i \lambda_i z_i^2.$$

这一步将混合项变成互不耦合的方向贡献。 λ_i 是沿 q_i^T 的二阶导数；正负号能保留下来。奇异值总是非负，若 H 不定，用奇异值代替特征值会丢掉上弯与下弯的信息。

全讲的优化主例是：

$$q(\theta) = \frac{1}{2} \theta H \theta^T, \quad H = \begin{pmatrix} 13 & -12 \\ -12 & 13 \end{pmatrix}, \quad \theta = (x, y).$$

直接相乘， $H(1,1)^T = (1,1)^T$ ， $H(1,-1)^T = 25(1,-1)^T$ 。两个归一化方向为 $q_1 = (1,1)^T / \sqrt{2}$ 、 $q_2 = (1,-1)^T / \sqrt{2}$ 。因此 $\lambda_1 = 1$ 、 $\lambda_2 = 25$ ， $z_1 = (x+y)/\sqrt{2}$ 、 $z_2 = (x-y)/\sqrt{2}$ ，并且 $q = (z_1^2 + 25z_2^2)/2$ 。




图2 主例等高线与Hessian的两个正交主方向。沿绿色和方向曲率为1，沿红色差方向曲率为25。等高线 $q=c$ 在两方向的半轴分别为 $\sqrt{(2c)}$ 与 $\sqrt{(2c/25)}$ ，长短轴比为5，不是25。

所有 $\lambda_i > 0$ 称H正定；所有 $\lambda_i \geq 0$ 称半正定；既有正值又有负值称不定。负定与半负定类似地用负号定义。等价地，正定要求任意非零 δ 的二次型都 >0 ，半正定允许某些非零方向为0。主例H正定，条件数 $\kappa = \lambda_{\max} / \lambda_{\min} = 25$ ；这里与013的算子2范数条件数一致，因为正定矩阵的奇异值就是正特征值。

五 把近似误差也算出来

为了验证二阶近似，而不是只测试它在二次函数上的恒等式，选另一个函数 $F(x,y) = x^4 + y^2/2$ ，在 $p = (1,1)$ 取 $\delta = (h, 2h)$ 。基点 $F = 1.5$ ， $g = (4,1)$ ， $H = \text{diag}(12,1)$ 。

内积 $g\delta^T = 6h$ ；二次项 $\delta H \delta^T / 2 = (12h^2 + 4h^2)/2 = 8h^2$ 。直接展开原函数得到：

$$F(1+h, 1+2h) = 1.5 + 6h + 8h^2 + 4h^3 + h^4.$$

所以一阶误差为 $8h^2 + 4h^3 + h^4$ ，二阶误差为 $4h^3 + h^4$ 。 $h = 0.1$ 时，真实值2.1841，一阶预测2.1，二阶预测2.18，误差分别0.0841和0.0041。 h 减半到0.05时，误差分别0.02050625和0.00050625。它们没有严格按4与8倍变化，因为更高项仍在；趋向0时比率才分别趋向4与8。




图3 沿 $\delta=(h,2h)$ 的两种近似误差。左图给出真实值和两个模型；右图使用对数坐标比较误差。有限点的趋势与本例的精确多项式余项一致，但图本身不能证明一般函数的误差阶。

在真正的二次函数 q 上， H 处处不变，积分余项恰为0，二阶模型在整个定义域都精确。这是主例能够得到全局更新公式的特殊原因。不能从这个特例推出神经网络损失在远处仍是同一个碗。

六 驻点和极值先按定义区分

若可微函数在定义域内部某点 p 满足 $g=0$ ，称 p 为驻点。若存在 $r>0$ ，使所有距离 p 小于 r 的定义域内点满足 $f(\theta)\geq f(p)$ ，称 p 是局部最小点；去掉 $\theta=p$ 后全都严格大于时是严格局部最小。全局最小则要求定义域内所有点都满足不等式。局部最大把不等号反向。

可微的内部局部最小点必为驻点：若 $g\neq 0$ ，沿 $-g$ 移动足够短会降低函数，与局部最小矛盾。注意“内部”和“可微”都不能省略。比如在区间 $[0,1]$ 最小化 $f(x)=x$ ，最小在边界0，但导数是1； $|x|$ 在0最小，却不可导。

若 p 是驻点且 f 在其邻域 C^2 ，可以利用二阶模型。设 $H(p)$ 的最小特征值 $m>0$ ，则 $\delta H \delta^T \geq m \|\delta\|^2$ 。因为余项除以 $\|\delta\|^2$ 趋0，足够小时 $|r_2| \leq m \|\delta\|^2/4$ ，于是 $f(p+\delta)-f(p) \geq m \|\delta\|^2/4 > 0$ 。这样证明了 H 正定推出严格局部最小，而不只是凭“碗形”的图猜测。

同理， H 负定推出严格局部最大。若 H 不定，取正、负特征方向，二阶主项一正一负，足够短时余项改变不了这两个符号；每个邻域里都有更高与更低值， p 是鞍点。这里“鞍点”专指这种既不是局部最大也不是局部最小的驻点。




图4 三个驻点在原点的局部形状。 x^2+y^2 为严格最小， $-x^2-y^2$ 为严格最大， x^2-y^2 为鞍点。右图的两条轴切片分别上弯与下弯，零梯度只说明一阶不变。

若H半正定但有零特征值，结论不充分。例如 x^4+y^2 在原点严格最小， $-x^4+y^2$ 在原点是鞍点；两者梯度均为0，H却同为 $\text{diag}(0,2)$ 。更高阶项决定平坦方向的行为。反过来， C^2 内部局部最小的H必须半正定，因为局部最小时 $f(p+tu)+f(p-tu)-2f(p) \geq 0$ ，除以 t^2 并令 $t \rightarrow 0$ 便得 $uH(p)u^T \geq 0$ ；但不必正定。[3]

即使H正定，也只得到局部结论。 $G(x,y)=x^2-3x^4+x^6+y^2$ 在原点 $g=0$ 、 $H=2I$ ，因此原点是严格局部最小，值为0；然而 $G(1,0)=-1$ 更小。一个明确的远处点就足以否定原点的全球最优性。

七 凸性为什么能够连接局部和全局

集合D称为凸集，如果任意 $a, b \in D$ 及 $0 \leq t \leq 1$ 都有 $(1-t)a+tb \in D$ 。函数f在凸集D上称为凸函数，如果：

$$f((1-t)a+tb) \leq (1-t)f(a) + tf(b).$$

右边是端点函数值的线性插值，即连线高度。凸函数的图形不超过这条弦。定义不是“只有一个谷底”；常数函数凸，却每一点都最优。严格凸把不同端点与 $0 < t < 1$ 时的不等式改为严格，若最小值存在，则最小点至多一个。




图5 凸函数的弦在线条上方。左图 x^2 满足定义，右图 $x^2-3x^4+x^6$ 用端点-1和1给出反例：两端值-1，中心值0，中心高于弦，因此不是凸函数。

对于凸集内部的可微凸函数，由定义取靠近a的线段点，整理为 $[f(a+t(b-a))-f(a)]/t \leq f(b)-f(a)$ 。令t从正侧趋向0，得到一阶支撑不等式：

$$f(b) \geq f(a) + \nabla f(a)(b - a)^T.$$

所以若 $\nabla f(a)=0$ ，便有所有 b 的 $f(b) \geq f(a)$ ， a 是全局最小。这里真正跨越局部与全局的是“在整个凸定义域上凸”，而不是单点梯度为0。

开放表示每个域内点周围都有一个仍在域内的小球。在开放凸定义域上， C^2 函数凸，当且仅当 H 在每一点半正定。这是可沿线段理解的： $\phi''(t)=\delta H \delta^T \geq 0$ 意味着一维切片的斜率不减，积分后弦总在函数上方；反过来，一维凸切片的二阶导数若存在便不能为负，否则在足够短的对称区间会违反中点不等式。[2] 这项判据量化的是整个定义域，不是只抽查一个点。

主例 q 的 H 处处为同一个正定矩阵， $q \geq \|\theta\|^2/2$ ，且只在 $\theta=0$ 取到0。因此0是唯一全局最小点。一般凸性不保证最小点存在，例如 e^x 在实数轴上趋近0却不能取到0；更不自动保证某个固定步长算法会收敛。目标性质与更新规则仍需分别分析。

八 二次主例的一次更新可以精确展开

对 $q=\theta H \theta^T/2$ ，因 H 对称，求偏导得到行梯度 $g=\theta H$ 。梯度下降用正步长 η 更新：

$$\theta_{k+1} = \theta_k - \eta g_k = \theta_k (I - \eta H).$$

k 是从0开始的迭代编号，每一步都在当前点重算梯度。 η 并不是移动的实际距离，实际距离为 $\eta \|g_k\|$ 。固定 η 不意味着每次走同样远。

将 $\delta=-\eta g$ 代入精确的二阶式：

$$q(\theta - \eta g) - q(\theta) = -\eta \|g\|_2^2 + \frac{\eta^2}{2} g H g^T.$$

第一项是沿负梯度的线性收益，第二项是正曲率带来的回弹。当 $g \neq 0$ 且 H 正定时，一次严格下降等价于 $0 < \eta < 2 \|g\|^2 / (g H g^T)$ 。这是当前点、当前梯度方向的精确区间，其上界可以大于 $2/\lambda_{\max}$ 。

若希望同一个步长对任意非最优点都严格下降，利用 $g H g^T \leq \lambda_{\max} \|g\|^2$ ，便得到统一充分条件 $0 < \eta < 2/\lambda_{\max}$ 。对正定二次函数，这也是保证所有初值收敛所需要的精确范围，下一节证明必要性。一个初值走得好，不能代替“任意初值”的量词。

从 $\theta_0=(2,0)$ 出发， $g_0=(26,-24)$ ， $q_0=26$ ， $\|g_0\|^2=1252$ ， $g_0 H g_0^T=31252$ 。因此首步的下降上界为 $2504/31252 \approx 0.0801229$ 。比如 $\eta=0.08005$ 首步仍下降，但已超过统一稳定上界0.08，非零陡峭分量最终会增长。这也说明首步下降不足以判定长期稳定。

九 从特征方向推导稳定区间

令 $z_k=\theta_k Q$ 。把上一节更新式右乘 Q ，使用 $HQ=Q\Lambda$ ，得到每个坐标独立的递推：

$$z_{i,k+1} = (1 - \eta \lambda_i) z_{i,k}, \quad z_{i,k} = (1 - \eta \lambda_i)^k z_{i,0}.$$

每轮只是乘同一个数 $a_i=1-\eta\lambda_i$ 。若 $|a_i|<1$ ，反复相乘趋向0；若 a_i 为负，符号每步翻转但绝对值仍可缩小。若 $a_i=-1$ 则等幅交替，若 $|a_i|>1$ 则非零分量增长。把 $|1-\eta\lambda_i|<1$ 两边解开，在 $\lambda_i>0$ 时得到 $0<\eta<2/\lambda_i$ 。

要让所有方向都收敛，就取这些区间的交集：

$$0 < \eta < \frac{2}{\lambda_{\max}}.$$

本例 $\lambda_{\max}=25$ ，所以范围是 $0<\eta<0.08$ 。证明的条件是：无约束全空间、固定对称正定 H 、精确全梯度、固定 η ，以及实数精确算术。浮点计算还需检查数值范围，真实神经网络也通常没有全局不变的 H 。




图6 两个主方向的每步乘数随 η 变化。横向虚线为 ± 1 ；两条线都严格落在带内才对所有初值收敛。 $\eta=0.04$ 使陡峭方向乘数为0， $\eta=0.08$ 使它等于-1而不衰减。

必要性也要说清：当 $\eta \geq 2/\lambda_{\max}$ ，选择初值恰在最大特征方向上且非零，它的乘数绝对值 ≥ 1 ，因此不能趋向0。 $\eta=0$ 完全不动， $\eta<0$ 使所有正曲率方向的乘数 >1 。个别初值若没有不稳定方向分量，可能仍收敛；这不反驳“不能保证所有初值”。

如果 H 只有半正定，零特征方向的乘数恒为1，参数会保留初始零空间分量。对 $q=\theta H \theta^T/2$ ，这些方向不影响损失；适当步长下可以达到某个全局最小点，但不保证参数趋向0，更没有唯一最小点。如果 H 不定，则负特征方向的乘数 $1-\eta\lambda>1$ ，本讲正定收敛定理不能套用。

十 狭长谷地为何出现折返

主例用同一个 $\theta_0=(2,0)$ ，比较五个步长。表中每行都是独立运行的第一步。

η	两方向乘数	第一步参数	第一步损失
0.02	0.98, 0.5	(1.48, 0.48)	7.2104
0.04	0.96, 0	(0.96, 0.96)	0.9216

η	两方向乘数	第一步参数	第一步损失
0.075	0.925, -0.875	(0.05, 1.8)	19.99625
0.08	0.92, -1	(-0.08, 1.92)	25.8464
0.09	0.91, -1.25	(-0.34, 2.16)	39.8906




图7 同一狭长谷地的迭代轨迹。 $\eta=0.02$ 快速削弱陡峭分量，却沿温和方向缓慢移动； $\eta=0.075$ 在两侧折返但振幅缩小； $\eta=0.09$ 越过稳定上界，折返振幅扩大。三图坐标等比例，迭代编号从同一起点0开始。

$\eta=0.04$ 把陡峭方向一步消为0，之后只沿温和方向以0.96的比例收缩。 $\eta=0.075$ 首步改善较小，但两个方向都收缩得较快；在60步时，损失约 8.9246×10^{-5} ，小于 $\eta=0.04$ 的0.00745672。首步最好的步长不一定在指定迭代次数后最好。

$\eta=0.08$ 更值得警惕。初始 $z_1=z_2=\sqrt{2}$ ，所以第 k 步的损失精确为 $0.92^{2k}+25$ 。它每一步仍降低，却趋向25而不是最小值0；陡峭方向一直交替。损失单调下降，甚至越来越“平稳”，也不能证明参数收敛或全局最优。




图8 左图展示60步损失，含发散的 $\eta=0.09$ ；右图单独画边界步长0.08下的主方向坐标。温和分量趋0，陡峭分量保持 $\pm\sqrt{2}$ ，所以只看左图尾部容易把25的平台误认成最优。

对任意正定二次函数，设最小曲率 m 、最大曲率 M 。每步参数误差的最坏方向收缩因子 $\rho(\eta)=\max_i |1-\eta\lambda_i|$ 。所有特征值在 $[m, M]$ 内，绝对值线性函数在区间端点达到最大，所以 $\rho=\max(|1-\eta m|, |1-\eta M|)$ 。令两端大小平衡， $1-\eta m=-(1-\eta M)$ ，得到 η 最优 $=2/(m+M)$ 与 ρ 最优 $=(M-m)/(M+m)=(\kappa-1)/(\kappa+1)$ 。

本例 η 最优 $=1/13 \approx 0.0769231$ 、 ρ 最优 $=12/13 \approx 0.923077$ 。误差长度至多每步乘 ρ 最优，损失至多每步乘 ρ 最优²。这里“最优”专指固定步长下、对所有初始方向的最坏收缩因子最小；它不是说对某一个初值、某一个步数或非二次函数都最好。

十一 改变参数尺度会改变更新路径

正交旋转只改变观察方向，保持长度，不会改变 H 的特征值。本例 θ 转成 $z=\theta Q$ 后，谷地仍有曲率1和25。进一步令 $w=(z_1, 5z_2)$ ，即 $w=zS$ ， $S=\text{diag}(1, 5)$ ，则 $z=wS^{-1}$ ， $\theta=wS^{-1}Q^T$ ，目标变为 $q=(w_1^2+w_2^2)/2$ 。

这个变换让等高线变圆，但也改变了坐标中的欧氏距离。用分量链式法则可得行梯度 $g_w=g_\theta QS^{-1}$ ；在 w 中做 $w_{\text{新}}=w-\eta g_w$ ，再变回 θ ，得到：

$$\theta_{\text{new}} = \theta - \eta g_\theta Q S^{-2} Q^T.$$

其中 $S^{-2}=\text{diag}(1, 1/25)$ 。温和方向仍按原比例移动，陡峭方向缩小到原来的1/25。本例 $QS^{-2}Q^T=H^{-1}$ ，所以 $\eta=1$ 可一步到0。我们没有改变函数在对应点的值，但改变了算法对“单位距离”的解释。




图9 左侧是 θ 坐标的狭长谷地，右侧是 w 坐标的圆形等高线。对应初值从(2,0)变成 $(\sqrt{2}, 5\sqrt{2})$ 。在 w 中用 $\eta=1$ 的一步更新，映回 θ 恰到原点；这依赖已知的固定二次结构。

这解释了为什么参数尺度会影响梯度法，也说明为什么不能简单比较两个坐标系里同一数字的 η 。真实问题可能没有可廉价获取的全局 H ， H 可能随位置变化或不定，数据特征缩放也不等同于精确的参数曲率变换。本例只证明已知二次函数上的机制，不承诺某种归一化总能消除深度网络的优化困难。

十二 单点Hessian不能当成整段上界

对于一般 C^2 函数，沿更新 $\delta=-\eta g$ 的线段，假设每一点都满足 $u^T H(\theta) u \leq M \|u\|^2$ ， $M>0$ 。这里是对所有方向 u 的统一上界，等价于沿整段的最大特征值不超过 M 。积分余项式便给出：

$$f(p - \eta g) \leq f(p) - \eta \left(1 - \frac{M\eta}{2}\right) \|g\|_2^2.$$

因而当 $g \neq 0$ 、 $0 < \eta < 2/M$ 且整条更新线段都在满足条件的区域内时，这一步严格下降。这个论证不要求 H 正定；它控制上弯速度。但它也没有证明后续迭代留在区域内、参数序列收敛、或达到全局最小。

为何不能直接把 M 设为 $H(p)$ 的最大特征值？考虑 $R(x,y)=x+x^2/2+10x^4+y^2/2$ 。在 $p=(0,0)$ ， $g=(1,0)$ 、 $H=I$ ，单点最大特征值为1。 $\eta=1$ 满足 $1 < 2/1$ ，更新到 $(-1,0)$ ，却有 $R_{\text{新}}=-1+0.5+10=9.5$ ，大于旧值0。




图10 只看原点的二阶模型会预测 $\eta=1$ 使 R 降低到-0.5，真实函数却达到9.5。右图沿线段的 x 方向曲率为 $1+120x^2$ ，从1增长到121；原点的1不是整个更新线段的上界。

在该线段可用 $M=121$ ，于是统一下降充分范围仅为 $0 < \eta < 2/121$ ，但这仍需注意：如果换 η ，线段也随之改变。实践中检查一次实际损失变化可以发现错误步长，却不能替代无限时间的收敛证明。后续学习具体优化器时，要继续追问它使用哪些信息、检查哪些条件、声称哪一层保证。

十三 实验如何成为证据

实验脚本先验证输入shape和有限值，再生成逐步轨迹、Taylor误差表与结果摘要。核心梯度用 $\theta @ H$ ；独立测试用手写标量公式 $(13x-12y, -12x+13y)$ 和有理数递推核对，避免拿同一段实现验证自己。非二次例子还用精确多项式展开验证余项。

Hessian数值检查对梯度做逐坐标中心差分： $H_{ij} \approx [g_i(p+he_j) - g_i(p-he_j)] / (2h)$ 。先修011已讨论有限差分的截断与舍入。本例的二次函数梯度为线性，精确算术下差分没有截断误差； F 的 H_{11} 差分多出 $4h^2$ ，因此不能要求所有 h 都完全相等。

程序拒绝把(2,)或(2,1)猜成行向量，也拒绝布尔值、字符串、复数、非有限数、不对称 H 与越出float64范围的结果。过小 h 若不能改变输入，或 $2h$ 溢出，就明确失败。已经被外部程序提升为数值数组的布尔来源无法事后恢复，这项限制在实验指南中说明。有限性检查不能消除舍入、相消和所有下溢；极小非零损失可能显示为0，不能据此宣称数学上已到最优。

同一目标下降、达到该目标的全局最小、在未见数据泛化、在真实场景有用，是不同问题。本单元只证明和检验前两者在声明条件下的关系；没有测试集，也没有任何证据能支持泛化或非凸网络全局收敛的结论。

十四 练习与验收

1. 从 x^4 在1处的展开求一阶和二阶模型，解释 $1/2$ 来自哪里，并比较 $h=0.1$ 时的误差。
2. 以 $\phi(t)=f(p+t\delta)$ 推导积分余项式，逐项写出shape。 C^2 为何只直接保证 $o(\|\delta\|^2)$ ，不能直接声称 $O(\|\delta\|^3)$ ？
3. 对 $f=x^2+3xy+2y^2$ 求梯度与H，计算 $\delta=(3,-2)$ 的二次型，说明正对角不够。
4. 手算主例两个特征方向、曲率、 $q=1$ 等高线半轴与条件数。为什么半轴比是5？
5. 完成F在 $p=(1,1)$ 、 $\delta=(h,2h)$ 的精确余项，计算 $h=0.1$ 和 0.05 的误差比。
6. 用定义和二阶条件判断 x^2+y^2 、 $-x^2-y^2$ 、 x^2-y^2 、 x^4+y^2 、 $-x^4+y^2$ 在原点的类型。哪些结论不能只看H？
7. 证明 $G=x^2-3x^4+x^6+y^2$ 的原点严格局部最小但不是全局最小；用凸性定义找出一个反例线段。
8. 推导二次目标的一次下降区间与所有初值稳定区间，核算首步 $\theta_0=(2,0)$ 、 $\eta=0.075$ ，并说明 $\eta=0.08005$ 的陷阱。
9. 从递推式解释 $\eta=0.08$ 的损失平台25。给出 $\eta=0.09$ 仍收敛的特殊非零初值，并解释为何不违背统一界。
10. 推导 η 最优 $=2/(m+M)$ 和 ρ 最优，说明最优所针对的量词。分别取 $\kappa=1$ 、25、100解释病态的影响。
11. 用 $w=zS$ 推导映回 θ 的更新，说明坐标尺度为何改变梯度路径；核算 w 初值和 $\eta=1$ 的结果。
12. 核算R的错误局部步长规则与正确线段曲率上界。最后列出“二阶模型准确”“损失下降”“参数收敛”“全局最优”“泛化良好”各需要什么额外证据。

验收要求不是记住0.08，而是能从H、步长与初始方向重新推导这个数，能解释边界步长的反例，并从清空状态顺序运行实验。全部详解另见answers，操作步骤另见lab。

来源与边界

- [1] Goodfellow、Bengio、Courville，作者公开的[Deep Learning](#) 第4章 [Numerical Computation](#)，核对Hessian、二阶近似、条件数与局部优化边界。本讲二次主例、余项推导、图形与实验独立编写，未复制原图。
- [2] Boyd、Vandenberghe，作者公开的[Convex Optimization](#) 课程讲义，Convex functions与Unconstrained minimization部分，核对凸性、一阶二阶条件及下降分析。一般定理的条件在正文写明；二维固定二次目标的收敛区间在本讲完整推导。
- [3] OpenStax作者教材，[Calculus Volume 3](#) 第4.7节 [Maxima/Minima Problems](#)，核对驻点、局部极值与二阶判别的边界。[4] NumPy 2.3官方文档，[eigh](#)，核对对称矩阵特征值按升序返回、特征向量按列返回。数据和图均为原创合成机制演示。