

分布密度与似然 实验指南

实验目标与两个入口

实验A只以016为直接先修，用有限编号盒生成Bernoulli结果，并把固定观测转成似然函数。实验B进入前先补010，再用中点矩形检查Gaussian面积。不要因Notebook可以一键运行，就跳过两个部分之间的概念门槛。全部输入均为原创合成数据，不涉及真实设备或用户。

需要提交的证据是：手算与程序对照的候选似然、端点结果、显式先验的后验、连续段的密度及面积、两个数值失败解释。程序跑通但不能解释横轴是谁，尚未完成实验。

一 文件和运行路径

experiment.py是核心实现，只依赖Python标准库；test_experiment.py包含独立Fraction及90位Decimal参考。experiment.ipynb按本指南顺序运行，并调用同目录脚本。data/observations.csv固定四条有序观测1110。outputs/是随课程提供的脚本输出示例；Notebook重跑时另生成notebook_outputs/，不覆盖示例。

在终端进入本单元目录后运行：

```
python experiment.py
python -m unittest -v test_experiment.py
```

脚本可从任意工作目录启动，它以自身文件位置寻找data；也可用--output-dir把结果写到另外一个目录。脚本不读网络、不需要GPU、不读取其他单元的数据。测试会启动两个新Python子进程，将全部三个结果文件逐字节比较；它还与随包示例核对，防止把旧输出误当作这次结果。

Notebook需要可用的Jupyter与ipykernel。可在Anaconda中用conda env create -f environment.yml建立独立环境，再conda activate dl017，最后启动JupyterLab。在浏览器中打开本单元Notebook，重启内核并运行全部单元。环境文件是建议配置；作者实际验证了现有Linux Python环境中的新进程和真实InProcessKernel，没有实际测试Anaconda新安装、浏览器UI或独立进程的socket内核传输。

实验A 离散概率与似然

二 先读取观测 不要把它当参数

CSV有trial和y两列，trial为1到4，y依次是1、1、1、0。读取后打印列表、长度n及k=sum(y)，应得到n=4、k=3。这里sum是把0/1相加得到成功次数，不是018的期望。长度n的数据序列shape为(n,)，p则是标量。脚本不接受二维嵌套列表，不做隐含广播。

先画一张两行小表： $p=3/4$ 时， $y=0$ 的质量为 $1/4$ ， $y=1$ 的质量为 $3/4$ 。检查它们相加为1。再看 `bernoulli_mass(y,p)`；它输入一个合法标签和一个参数，返回单个概率。函数只接收定义内标签0或1，非法标签报错；正文中对全实数 y 写的质量函数在其他点为0，两者的接口约定不同。

三 用有限编号实现生成器

调用 `bernoulli_sample(12, 3, 4, seed=17)`。 $M=4$ 、 $k=3$ 说明每次抽一个0到3的等可能编号，编号小于3才记1。实际序列应为 $[0,1,1,1,1,1,1,1,0,0,1]$ 。再调用一次得到同一结果。换一个种子通常会得到另一序列，但每次抽取的模型参数仍为 $3/4$ 。

不要用十二条结果恰好有九个1来定义生成器是否正确。本次恰好得到 $9/12$ ，不是每次都会这样。测试另用替身编号生成器穷举 $M=1$ 到20的所有 k ：每个编号都走一次，检查恰好有 k 个编号映射为1。这是映射规则的精确检查，不是用一次模拟宣称现实独立性成立。

检查 $k=0$ 和 $k=M$ 分别生成全0和全1； $n=0$ 返回空列表； $k>M$ 、负数 M 、布尔 n 均须被拒绝。生成时的空输出有用，但计算似然的空观测被本讲API拒绝。要能说出两种接口为什么选择不同。

四 固定1110比较候选参数

先不要看输出，手算 $L(1/4)$ 、 $L(1/2)$ 、 $L(3/4)$ 。再运行 `bernoulli_likelihood(y,p)` 与 `bernoulli_log_likelihood(y,p)`。结果应如下：

p	有序观测1110的似然	对数似然 近似
0	0	$-\infty$
1/4	$3/256$	-4.4465651558
1/2	$1/16$	-2.7725887222
3/4	$27/256$	-2.2493405785
1	0	$-\infty$

再枚举四个恰好三个1的序列，把它们的联合概率相加。 $p=3/4$ 时得到 $27/64$ 。回答：为什么它和 $27/256$ 不相等？为什么两种数据摘要仍给相同候选排序？不要把乘数4叫作“无所谓”；它对实际事件概率有影响，只在参数排序中为共同因子。

五 检查端点与下溢

分别检查四种调用：全0在 $p=0$ 、全1在 $p=1$ 得到 $\ell=0$ ；混合观测在两个端点都得到 $-\infty$ 。阅读分支位置，确认程序在调用log以前已处理端点。再故意输入 $p=1.01$ 、 $y=[\text{True},0]$ 和空列表，记录异常类型。

把观测换成2000个1， $p=1/2$ 。直接乘积返回0，但对数似然约-1386.2943611199。手写“数学上 2^{-2000} 严格为正”，并解释为何`log(bernoulli_likelihood(...))`不能挽救信息。CSV把数学零支持的log值保存成字符串-`inf`，summary JSON只保存有限数值，避免输出非标准JSON数值。

六 用显式先验计算有限后验

候选只有 $1/4$ 和 $3/4$ ，先验先设 $[0.5, 0.5]$ ，应得到后验 $[0.1, 0.9]$ ；再设 $[0.9, 0.1]$ ，应得到约 $[0.5, 0.5]$ 。浮点输出可能为 0.5000000000000002 ，不要求字符串恰好相等，应使用数值容差或Fraction手算核对。

函数为避免各条路径同时下溢，先在log空间相加，再减去最大的log分数后取exp，最后归一化。减去同一个量对应所有路径同时乘同一个正因子，因此不会改变比例。极小的最终后验仍可能舍入成0；它不代表数学后验恰好为0。测试里的长样本正用于检查这种有限精度表现。

把候选设为 $[0, 1]$ ，仍使用混合观测1110，应报错：两个候选都赋予数据零概率，Bayes分母为0。不能用平均分配0.5来掩盖模型与观测的矛盾。

实验A检查点：不用积分，说明生成器、质量函数、似然和后验各自固定什么、返回什么。完成练习1至6后再进入实验B。

实验B 连续密度与积分 先补010

七 高度大于1仍然合法

计算`gaussian_density(0, mu=0, sigma=0.1)`，应得到约 3.9894228040 。它是密度高度，不是 $P(X=0)$ 。随后用2000个中点计算区间 $[-0.1, 0.1]$ 的积分，应得到约 0.6826895123 ；独立高精度参考为 0.6826894921 ，二者差别来自有限网格。

先手算另一个密度：在 $[0, 1/4]$ 上高度4，外侧高度0。求全区间面积及 $[0.05, 0.15]$ 面积，分别应为1和0.4。如果单位为秒，把横轴改成毫秒，区间变为 $[0, 250]$ 、高度变为0.004每毫秒。解释为什么概率保持不变。

八 同时改变积分范围和网格密度

读取`gaussian_integrals.csv`的12行，按bound分组观察20、200、2000面板。bound表示对称区间 $[-bound, bound]$ 。在相同bound内比较网格；在相近足够细的网格下再比较范围。不要把两个因素同时改变后的差异全归为“模型更准确”。

对 $[-2, 2]$ 用4个面板手算 0.9631658450 ，再核对程序。对2000面板，结果更接近参考 0.9544997361 ，但仍明显小于1，主要因为区间外还有尾部。对 $[-6, 6]$ ，参考约 0.9999999980 。检查时应写明“有限区间的近似面积”，不能写成“已经证明无穷区间积分精确为1”。

测试中的Gaussian参考不是再调用同一个积分函数。它用90位Decimal、独立Machin公式计算 π ，并用exp的幂级数积分计算对称区间面积；点密度用Decimal `exp/ln`独立核验。学习者只需理解独立参考的作用，幂级数算法不作为本讲新增先修。

九 故意让网格错过窄峰

固定 $\mu=0$ 、 $\sigma=0.01$ 、积分区间 $[-1, 1]$ 。20个中点的结果约 0.0000297344 ，2000个中点约1。查看图8，写出最近中点 ± 0.05 距离中心为 5σ 。现在把“积分范围很宽，所以数值一定正确”改写成带条件的判断。

另输入 $\sigma=0$ 和 $\sigma=-1$ ，都应立即报错。对 $x=40$ 的标准Gaussian，普通密度返回0，对数密度仍约-800.9189385332；这个0来自exp下溢。对 $x=1e308$ 、 $\mu=-1e308$ 会在减法超出范围时拒绝。不要把参数错误、数值范围错误、合法分布的尾部下溢混成同一种情况。

十 固定观测比较连续似然

对 $x=[-0.1, 0.1]$ 、 $\sigma=0.1$ ，比较 $\mu=0$ 与 $\mu=0.1$ 。分别写出标准化残差 $[-1, 1]$ 与 $[-2, 0]$ ，得到平方和2与4。 $\log$ 似然前者比后者大1，似然比e。把数据和两个参数统一换算成毫秒， $\log$ 似然都下降 $2\ln 1000$ ，差仍为1。

最后用一条观测 $x=1$ ，把 μ 固定为1， σ 从0.1减到0.01。密度增大10倍。由此解释为什么允许尺度无限缩小时，最大化训练似然可以没有有限最优参数； $\sigma=0$ 并不能作为合法解补进去。

十一 提交结果与验收

提交候选似然手算、端点表、两个先验下的后验、单位变换及积分失败解释。Notebook从重启内核开始顺序运行，并保留输出。两条运行路线的三份结果文件应逐字节相同；这只检验复现一致性，数学正确性仍要靠独立参考、定义域检查及推导。已验证范围与未测项目见README和verification.json。

练习

1. 写出 $p=1/4$ 的质量函数，对事件 $Y \in \{0, 1\}$ 求和。解释“概率柱子宽一倍”为什么不应使概率翻倍。
2. 在共享 p 且独立的模型下，为有序1110计算 $p=1/4$ 、 $1/2$ 、 $3/4$ 的似然与似然比。若只观察成功次数3，有限和怎样改变？
3. 四次观测来自一次B的复制，B取0和1各一半。计算1110与1111的概率，与独立模型比较。
4. 为全0、全1、混合观测分别列出 $p=0$ 和1时的L及 ℓ 。解释隐藏裁剪改变了什么。
5. 为什么2000个1的直接乘积会为0，而 $\log$ 似然仍有限？结果0是否说明观测不可能？
6. 用候选 $1/4$ 与 $3/4$ 、先验 $9/10$ 与 $1/10$ 计算1110的后验，再说明等权先验为何得到另一答案。
7. 补010后：对高度4、区间 $[0, 1/4]$ 的密度，计算三个事件 $X=0.1$ 、 $0.05 \leq X \leq 0.15$ 、 $X \leq 1/4$ 的概率，并换算成毫秒。
8. 写出Gaussian位置尺度变换的面积抵消过程。 $\sigma=0.1$ 时峰高为何可大于1？
9. 手算标准Gaussian在 $[-2, 2]$ 上的4面板中点近似，区分截断与离散化误差。
10. 解释 $\sigma=0.01$ 时20面板漏峰的原因，以及增加范围为何未必解决问题。
11. 对 $[-0.1, 0.1]$ 比较两个位置参数的 $\log$ 似然，说明统一换单位后为何差值不变。
12. 一条精确观测时让位置对准数据、尺度趋近0，似然怎样变化？它为什么不是参数后验越来越确定的证明？