

分布密度与似然

第017单元 模型给出的数究竟是什么

一个二分类器输出0.75，一个连续测量模型输出3.99。前者可能表示某个事件的概率；后者也可能完全合法，却不能读成399%的概率。再把同一公式画成参数的函数，曲线又成了似然。数字相似，不代表它们回答相同的问题。本讲的中心问题是：**模型输出概率或密度时，它究竟在假设什么？**

本讲分成两个有明确入口的部分。第一部分只以016为直接先修，从有限样本空间建立Bernoulli分布、生成器、有限和、似然及对数似然；不需要导数和积分。第二部分开始前必须补完010《导数积分与局部变化》，再学习密度的面积与Gaussian归一化。018才正式学习期望、方差等摘要，本讲不把它们当作已知。正文、实验和练习都有相同的分段标记，可以先完成第一部分再返回连续段。

所有例子和图都是原创合成教学实验。四次二值观测固定为(1,1,1,0)，连续测量的单位先约定为秒。它们不证明真实检查器、分类器或传感器满足本讲模型。

第一部分 离散分布 仅需016

一 先分清生成机制和观测记录

016中随机变量是从样本点到数值的函数。现在把它用于一个只有两种结果的记录： $Y=1$ 表示我们定义的“成功”， $Y=0$ 表示相反事件。“成功”可以指检查器触发，也可以指某个按钮被点击，不表示事情一定有益。一个概率模型必须先确定一次观测是什么、0和1对应什么事件、什么条件已知。

用一个标量 p 表示 $P(Y=1)$ 。标量就是单个数，不是列表； p 的定义域为闭区间 $[0,1]$ ，没有单位。定义域指允许输入的集合。参数是用于指定模型的量：固定 p 就选定一种分布，换一个 p 就得到另一种。参数 p 不是本次抽到的 Y ，也不是伪随机种子。种子只决定程序从哪段可复现序列开始。

先看纯有限的生成方法。有 M 个等可能编号0到 $M-1$ ，其中 k 个被标记，规定抽中编号小于 k 时记1。 k 和 M 是整数， $M>0$ ， $0\leq k\leq M$ ，于是 $p=k/M$ 。给定 $p=3/4$ ，可以令 $M=4$ 、 $k=3$ 。抽到0、1、2都记1，抽到3记0。产生观测的顺序是“确定机制，抽编号，记录结果”。



生成时先定参数；计算似然时先固定已经看到的数据。

图1 有限生成器只需要016的等可能抽样。先选参数 $p=k/M$ ，再把编号映射成0或1。得到数据后，可以固定这些数据，反过来比较不同参数。

程序的randrange(M)返回一个0到M-1的伪随机整数。我们用独立抽取来模拟“每次重新从同一编号盒抽一个”的模型，不把编号拿走；固定seed可复现演示。[1] 真正的物理随机性、跨样本独立性，以及概率是否长期不变，都不是一段代码自动保证的。本讲生成器只接受明确的有理数k/M，不悄悄把任意实数p四舍五入成有限网格。

二 分布是各个可能值上的概率安排

一个有限随机变量的概率质量函数给每个可能值分配概率。记 $q_p(y) = P_p(Y=y)$ ，下标p提醒我们它依赖参数。Bernoulli模型把全部质量放在0和1：[2]

$$q_p(y) = \begin{cases} 1-p, & y=0, \\ p, & y=1, \\ 0, & y \notin \{0,1\}. \end{cases}$$

非负性由 $0 \leq p \leq 1$ 保证，总和是 $(1-p)+p=1$ 。这里的归一化是对**数据所有可能取值**求和，参数p固定。事件A若包含若干可能值， $P_p(Y \in A) = \sum_{y \in A} q_p(y)$ 。例如 $p=3/4$ 时， $P(Y=1)=3/4$ ， $P(Y=0)=1/4$ ， $P(Y \in \{0,1\})=1$ 。每个点已经有完整质量，不需要再乘柱子的绘图宽度。

在 $0 < p < 1$ 、 $y \in \{0,1\}$ 时，可把两种情况合成 $q_p(y) = p^y(1-p)^{1-y}$ 。将 $y=1$ 代入，指数分别为1和0；将 $y=0$ 代入，指数交换。这个写法方便相乘，但端点 $p=0$ 或 1 会出现形式上的 0^0 。分段定义始终清楚，程序也应依照分段规则，不靠某个语言对 0^0 的特殊约定理解模型。

$p=0$ 是“永远记录0”的退化分布， $p=1$ 是“永远记录1”。它们合法，只是把质量全部放在一个值上。常见混淆是把数学定义域 $[0,1]$ 误缩成 $(0,1)$ ，或反过来在对数函数里无条件代入端点。分布可以允许端点，某个计算公式却可能需要单独处理端点。

三 多次观测的联合模型不是自动得到的

设我们记录n次， Y_1 到 Y_n 是抽样前的随机变量， $y=(y_1, \dots, y_n)$ 是抽样后固定下来的观测。 y 是长度n的一维序列，可记shape为(n,); 这里仅用这个记号说明长度，不要求NumPy。n是正整数，所有 y_i 必须为0或1。一次返回的联合概率是一个标量。

若假定各次观测互相独立，并且共享同一个p，联合概率才可写成：

$$P_p(Y_1 = y_1, \dots, Y_n = y_n) = \prod_{i=1}^n q_p(y_i).$$

大写 Π 表示把指定范围内的项相乘； Σ 则表示相加。独立负责把联合概率拆成单次概率的乘积；共享p负责让各项使用同一个参数。两种假设缺一不可。独立但每次概率不同，需要 p_1 到 p_n ；每次边缘概率相同但有依赖，也不能直接相乘。

检查归一化可以从 $n=2$ 看起。可能序列为00、01、10、11，权重分别为 $(1-p)^2$ 、 $(1-p)p$ 、 $p(1-p)$ 、 p^2 。相加等于 $[(1-p)+p]^2=1$ 。n次时，展开 $[(1-p)+p]^n$ ，就是对所有 2^n 个序列的概率求有限和，因此仍为1。这解释了为什么“联合概率乘积”与“所有结果概率之和为1”相容。

一个失败反例很重要：先只抽一次公平的B，再把它复制到四个位置，令 $Y_1=Y_2=Y_3=Y_4=B$ 。每个 Y_i 单看仍有 $P(Y_i=1)=1/2$ ，但只有0000与1111各有概率 $1/2$ ，1110概率为0。若错误地使用独立模型，就会给1110概率 $1/16$ 。只核对单点分布无法验证联合假设，重复样本也不能当作四份独立证据。

四 同一公式换一个固定对象就成为似然

现在真正看到 $y=(1,1,1,0)$ 。我们不再沿着所有可能数据求和，而是问：**若候选参数为 p ，这个固定观测在模型中得到多大支持？**把观测固定、把参数作为自变量，得到似然函数：

$$L(p; y) = \prod_{i=1}^n q_p(y_i).$$

若 $k=\sum_i y_i$ 是成功次数，则内部参数 $0 < p < 1$ 时有 $L(p; y) = p^k(1-p)^{n-k}$ 。成功的每一项贡献 p ，失败的每一项贡献 $1-p$ ；将相同因子合并即可，不需要导数。本例 $n=4$ 、 $k=3$ ，所以 $L(p; y) = p^3(1-p)$ 。符号“ $;$ ”提醒我们 y 是当前固定输入， p 是被比较的量。




图2 左图固定 $p=3/4$ ，横轴是数据 y ，两个质量相加为1。右图固定观测1110，横轴是参数 p 。右图没有要求沿参数方向相加或积分等于1。

手算三个候选值： $L(1/4)=3/256=0.01171875$ ； $L(1/2)=1/16=0.0625$ ； $L(3/4)=27/256=0.10546875$ 。因而对同一数据和同一独立模型， $p=3/4$ 的似是是 $p=1/4$ 的9倍。在这三个候选值里它最高。这不是“ $p=3/4$ 正确的概率为0.10546875”，也不意味着它在所有可能现实机制中最好。

如果只知道“四次中成功三次”，没有记录顺序，那么观测事件包含1110、1101、1011、0111四个互斥序列。事件概率是四项有限和，即 $4p^3(1-p)$ 。对 $p=3/4$ ，它等于 $27/64$ ，而不是 $27/256$ 。因为乘上的4不依赖 p ，这两个观测方式给候选参数相同的似然排序；它们的事件概率却不同。必须先说明究竟观察了一个序列，还是一个计数事件。

似然的绝对数值也依赖数据规模。多看很多合理观测后，联合概率通常很小；不能拿十条数据的似然与一千条数据的似然直接比“哪个模型更好”。比较必须固定观测对象、样本和记录单位，还要清楚是否忽略了与参数无关的常数。

五 对数似然把长乘积变成有限和

对数是007学过的自然对数，记 $\ln$ 或 $\log$ 。对正数乘积有 $\ln(ab)=\ln a+\ln b$ ，且 $\ln$ 严格递增。因此似然为正时，对数不会改变候选参数的排序。定义 $\ell(p; y)=\ln L(p; y)$ ，便有：

$$\ell(p; y) = \sum_{i=1}^n \ln q_p(y_i) = k \ln p + (n - k) \ln(1 - p), \quad 0 < p < 1.$$

这里没有使用求导。对本例 $p=3/4$, $\ell=3\ln(3/4)+\ln(1/4)\approx-2.2493405785$; $p=1/2$ 时 $\ell=4\ln(1/2)\approx-2.7725887222$ 。较大的-2.249仍对应较大的似然。负数更接近0才更大, 不应只比较绝对值。

2000次都记录1且 $p=1/2$ 时, 数学上的似然为 $2^{-2000}>0$ 。普通浮点数的最小可表示正数有限, 直接相乘最终得到0, 这叫下溢。先算log得到 $-2000\ln 2\approx-1386.2943611199$, 仍是正常有限数。 $\log(\text{product})$ 已经来不及: 一旦product变成0, 之前的信息已丢失。应逐项取log再相加。

若把 ℓ 取相反数, 得到负对数似然。最大化 ℓ 等价于最小化 $-\ell$; 这是后续训练目标的一条来源。本讲还不讨论优化算法, 也不把“某种误差函数”自动解释成某种真实概率模型。离散概率质量 ≤ 1 , 所以这里 $\ell\leq 0$; 连续密度不受这个高度限制, 连续段的对数密度可以为正。

六 边界必须按事件支持处理

$p=0$ 时, 若所有观测都是0, $L=1$ 、 $\ell=0$; 只要出现一个1, $L=0$, 扩展记号 $\ell=-\infty$ 。 $p=1$ 时情况反过来。 $-\infty$ 在此是“模型给这个观测零概率”的计算记号, 并不是某个很大的负有限数; 也不是普通实数 $\ln 0$ 已经有定义。




图3 全0、混合和全1样本有不同的端点行为。右图为显示趋势只画内部参数; 真正的端点必须按左图的零或一处理, 不能从有限画布高度猜值。

正确程序先检查端点, 再在内部使用对数。它不先计算 $k * \log(p)$, 因此不会在 $k=0$ 、 $p=0$ 时产生“0乘未定义”。 $\text{math.log1p}(-p)$ 专门计算 $\ln(1-p)$, 当 p 很小时通常比先做 $1-p$ 再取log保留更多有效数字。

[3] 但浮点数仍有范围与舍入限制, 这不把机器计算变成精确实数运算。

一种常见修补是把 p 夹到 $[\epsilon, 1-\epsilon]$ 。它可能是某个明确设计的近似, 却改变了模型: $p=0$ 时本不可能的1会得到 $\epsilon>0$ 的概率。本讲不做隐藏裁剪。非法 $p=1.01$ 、NaN、布尔标签、嵌套列表、空观测会显式报错。数学上可定义空乘积为1, 但空样本没有证据, 本讲API选择拒绝它; 生成器允许 $n=0$, 用于检查返回空列表这一边界。

七 似然不自动给出参数后验

参数可以只是一个未知但固定的数。在这种表述下， $L(p; y)$ 不是参数的概率分布。若想对参数本身赋概率，需要增加一个模型：参数随机变量 Θ 可能取哪些值，以及观察前给各值多大权重。这些观察前的权重叫先验；观察后的条件概率叫后验。016的Bayes公式足以处理有限候选集。

令 Θ 只取1/4和3/4。若先验分别为9/10和1/10，固定观测仍是1110，则两条“先验 $\times$ 似然”路径分别为：

$$\frac{9}{10} \frac{3}{256} = \frac{27}{2560}, \quad \frac{1}{10} \frac{27}{256} = \frac{27}{2560}.$$

分母是两项和54/2560，所以两个后验概率都为1/2。虽然似然比支持3/4达到9:1，先验却给1/4以9:1的权重，二者抵消。如果先验改为各1/2，后验才变成1/10与9/10。仅把两个似然除以它们的和，已经偷偷选择了这个有限集合上的等权先验。




图4 同一份数据，归一化似然给0.1与0.9；显式先验为0.9与0.1时，真正后验是0.5与0.5。少写先验并不会使它失去影响。

一般的有限式为 $P(\Theta=p_i|y)=L(p_i; y)\pi_i/\sum_r L(p_r; y)\pi_r$ ，要求 π_i 非负、和为1，分母为正。若所有有正先验的候选都给观测零概率，分母为0，不能再归一化。本讲程序会报错。它用共同的对数平移防止很小的乘积同时下溢；这一数值技巧不会消除先验，也不改变Bayes公式。

到这里可以暂停。应能不用积分解释：生成时固定什么、似然时固定什么、为什么要有独立假设、如何计算离散事件的有限和、为什么log端点要分支。完成实验A和练习1至6，再补010进入下一部分。

第二部分 连续密度 进入前补完010

八 区间概率需要面积

现在记录一个连续测量 X ，例如偏差的秒数。我们采用具有密度的连续模型：用非负函数 $f(x)$ 分配小区间的概率，满足全实线面积为1。严格说，这里研究的是具有密度的一类连续分布，不声称所有数学上的分布都能用一条普通密度曲线表示。

回想010：把区间 $[a, b]$ 分成小段，每段宽 Δx ，在代表位置 x_j 取函数高度。小矩形面积是 $f(x_j)\Delta x$ ；细分后面积和的极限为积分。在具有密度的模型中，我们定义：

$$P(a \leq X \leq b) = \int_a^b f(x) dx, \quad f(x) \geq 0, \quad \int_{-\infty}^{\infty} f(x) dx = 1.$$

最后一个无穷区间积分表示逐步向左右扩大有限区间所得到的极限，不是让计算机在一个“无穷长数组”上相加。对非负密度，区间扩大时积累的质量不会减少。某个单点区间宽为0，积分为0，所以 $P(X=x)=0$ ；这不表示 X 不能取得一个值，而是每个指定单点不承载正概率质量。

一个完全能手算的密度是 $f(x)=4$ ，当 $0 \leq x \leq 1/4$ ；区间外为0。总面积 $4 \times 1/4=1$ ，合法。事件 $0.05 \leq X \leq 0.15$ 的概率是 $4 \times 0.10=0.4$ ，而 $f(0.10)=4$ 。高度大于1没有矛盾，因为概率是面积。若 X 单位为秒， f 的单位为每秒， $f(x)dx$ 才没有单位。




图5 概率质量可直接对点相加；密度要乘横轴宽度再积累。右图的4是每秒的密度，高度4与宽度0.1秒得到无单位概率0.4。

仪器显示“0.10秒”通常还意味着某个舍入区间，例如 $[0.095, 0.105)$ 。若模型为上面的均匀密度，这个显示事件概率是 $4 \times 0.01=0.04$ 。把显示小数当成精确实数点会忽视记录精度；把密度4直接当成该显示值的概率则忽视了整个区间宽度。端点是否包含在具有密度的模型中不改变区间概率，但在离散模型中可能改变。

九 从一个形状建立Gaussian密度

Gaussian也叫正态分布。先看一个非负钟形函数 $g(z)=\exp(-z^2/2)$ 。 z 是无单位实数， $z=0$ 时高度为1，离0越远越低。但非负还不够：若总面积不是1，就不是归一化密度。

令 C 为 g 在全实线的积分，再定义 $\phi(z)=g(z)/C$ ，面积自然变为1。这里 C 确实正且有限：在 $[-1,1]$ 上 $g \leq 1$ ，外侧 $|z| \geq 1$ 时有 $z^2 \geq |z|$ ，因而 $g(z) \leq \exp(-|z|/2)$ ，后者两边尾部的面积有限。利用010的指数积分可给出上界 $C \leq 2+4\exp(-1/2)$ ，足以说明除数存在；这个上界不是 C 的准确值。

经典Gaussian积分定理给出 $C=\sqrt{2\pi}$ ，因此标准形状为：

$$\phi(z) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{z^2}{2}\right).$$

这里明确引用Gaussian积分的标准结果，不把数值积分当作它的证明。常数闭式的完整证明通常引入额外的分析工具，本讲不要求先修这些工具。NIST给出标准Gaussian密度；DLMF的误差函数积分定义及无穷远极限也可核对这个常数。[4][5] 学习本讲的关键是知道为什么必须除以总面积，能够检查这种归一化在位置尺度变化后仍成立。

引入位置参数 $\mu \in \text{实数}$ 和尺度参数 $\sigma > 0$ ，令 $z = (x - \mu)/\sigma$ ，得到：

$$f(x; \mu, \sigma) = \frac{1}{\sigma\sqrt{2\pi}} \exp \left[-\frac{1}{2} \left(\frac{x - \mu}{\sigma} \right)^2 \right].$$

x 、 μ 、 σ 都是标量， x 和两个参数使用相同测量单位；因此 z 和指数无单位， f 的单位是测量单位的倒数。 μ 把曲线中心平移， σ 控制横向伸缩。此处只用位置和尺度这两个定义；018学习期望方差后，才解释为什么Gaussian的 μ 与 σ^2 又可分别作为那些摘要。不要借这些尚未定义的术语替代对公式的理解。[6]

十 为什么缩放横轴还要改变高度

若只把 x 换成 $(x - \mu)/\sigma$ ，横轴拉宽 σ 倍，面积也拉宽 σ 倍。为了保留总面积1，纵轴必须除以 σ 。可以用中点矩形理解： z 方向小宽度 Δz 对应 x 方向宽度 $\Delta x = \sigma \Delta z$ ； f 的高度为 $\phi(z)/\sigma$ ，二者相乘仍是 $\phi(z)\Delta z$ 。让网格细化即得到积分中的换元：

$$\int_{-\infty}^{\infty} f(x; \mu, \sigma) dx = \int_{-\infty}^{\infty} \frac{\phi(z)}{\sigma} \sigma dz = 1.$$

σ 必须为正； $\sigma=0$ 不能放入公式，负尺度也不符合本讲参数约定。当 σ 趋近0时曲线越来越尖，不意味着把0代入仍得到普通Gaussian密度。




图6 改变 μ 只平移曲线；缩小 σ 同时压窄横轴并抬高纵轴。 $\mu=0$ 、 $\sigma=0.1$ 时峰高约3.989，但全曲线面积仍为1。

峰位在 $x = \mu$ ，因为指数中的非负平方此时为0。峰高 $1/(\sigma\sqrt{2\pi})$ ，当 $\sigma < 1/\sqrt{2\pi}$ 时数值大于1。例如以秒计量， $\sigma=0.1$ 秒，峰高约3.9894每秒；区间 $[-0.1, 0.1]$ 在 $\mu=0$ 时的概率约0.6826895，并非3.9894，也不是精确等于峰高乘0.2得到的0.7978846，因为区间内曲线有弯曲。

换单位也会改变高度。把秒换成毫秒， x 、 μ 、 σ 都乘1000，密度数值除1000；同一个物理区间的宽度乘1000，所以面积不变。因此跨单位比较密度绝对大小没有意义。似然比较也要固定数据的记录单位，不能给一个候选用秒，另一个候选用毫秒。

十一 数值积分检查的两种误差

实验使用中点矩形法。把 $[a, b]$ 等分 m 段， $h = (b - a)/m$ ，第 j 段中点 $x_j = a + (j + 1/2)h$ ，其中 j 从0到 $m - 1$ 。近似积分是 $h \sum f(x_j)$ 。 m 越大通常更细，但有限网格的结果始终是近似数。

标准Gaussian在 $[-2,2]$ 上，4个中点为 -1.5 、 -0.5 、 0.5 、 1.5 ， $h=1$ 。利用对称性，只需算两种高度： $\phi(0.5) \approx 0.3520653268$ ， $\phi(1.5) \approx 0.1295175957$ 。四矩形面积为 $2 \times (0.3520653268 + 0.1295175957) \approx 0.9631658450$ 。独立高精度积分参考约为 0.9544997361 ，说明粗网格在这里略高估面积。




图7 同一有限区间上的中点矩形。增加面板主要减少离散化误差，但不会把 $[-2,2]$ 外的尾部面积补回来。

要验证归一化，应分开两项误差。**截断误差**来自只积分有限区间，漏掉尾部；**离散化误差**来自把有限区间曲线替换成矩形。把 m 从200改为2000只能处理后者；把区间从 $[-2,2]$ 扩大到 $[-6,6]$ 主要处理前者，却也可能在面板数不变时使网格变粗。

对标准Gaussian，参考面积分别约为：对称界限1时 0.6826894921 ；界限2时 0.9544997361 ；界限4时 0.9999366575 ；界限6时 0.9999999980 。脚本对每个界限计算20、200、2000个面板，与测试中的独立高精度参考比对。它并不把一个接近1的浮点结果宣布为数学证明。

一个更危险的失败例是 $\mu=0$ 、 $\sigma=0.01$ ，在 $[-1,1]$ 使用20个中点。最近的中点是 ± 0.05 ，已经离峰中心5个尺度，整条尖峰几乎落在两个采样位置之间，所得面积约 0.0000297344 。若改为2000个面板，结果约为1。区间看起来“够宽”也不能弥补网格错过峰的问题。




图8 蓝线为同一个窄Gaussian，红点为积分取值位置。左图20个面板几乎完全漏掉峰，右图2000个面板才解析出峰。显示范围放大，不代表积分区间被改变。

十二 连续似然用密度 不是精确点事件的概率

给定独立连续观测 $x=(x_1, \dots, x_n)$ ，长度 n 、shape为 $(n,)$ ，并假定它们共享 μ 、 σ ，定义密度似然：

$$L(\mu, \sigma; x) = \prod_{i=1}^n f(x_i; \mu, \sigma),$$

$$\ell(\mu, \sigma; x) = -n \ln \sigma - \frac{n}{2} \ln(2\pi) - \frac{1}{2} \sum_{i=1}^n \left(\frac{x_i - \mu}{\sigma} \right)^2.$$

公式来自对每一项密度取log再相加。固定测量单位后可以计算这些数值；若x有单位，密度似然的单位是该单位的 $-n$ 次方，因此log数值也依赖所采用的单位约定。将所有观测统一由秒换成毫秒，并相应改变 μ 、 σ ， ℓ 减少 $n \ln 1000$ ；候选参数的排序在这种共同转换下不变。

既然连续模型中精确点概率为0，为什么密度还能用来比较参数？想象每个记录实际代表相同的很窄区间，宽 δ 。密度连续时，区间概率约为 $f(x_i; \mu, \sigma) \delta$ ；独立记录联合概率约为 $L(\mu, \sigma; x) \delta^n$ 。如果所有候选使用同一记录精度， δ^n 是共同因子，不改变比较。当区间不够窄、精度随模型改变、或区间跨过快速变化部分时，应直接积分求区间概率，不能随意丢掉观测过程。




图9 左图固定参数，密度沿数据轴归一化。右图固定两次数据(1,1)和 $\sigma=0.5$ ，似然沿 μ 变化；两条曲线的横轴角色不同。右图沿 μ 的积分为 $1/\sqrt{\pi}$ ，约0.5642，不是1。

手算数据 $x=(-0.1, 0.1)$ 、 $\sigma=0.1$ ，比较 $\mu=0$ 与 $\mu=0.1$ 。前者标准化残差为-1、1，平方和2；后者为-2、0，平方和4。共同的两项对数尺度常数相同，因此 $\ell(0, 0.1; x) - \ell(0.1, 0.1; x) = 1$ ，似然比为 $e \approx 2.7183$ 。它只说明在这个独立Gaussian家族和固定尺度下的相对支持，不给出 μ 的后验概率。

若只有一条观测 x_1 ，而让 $\mu=x_1$ 、 σ 不断减小，峰高随 $1/\sigma$ 不断增大，似然没有有限最大值。它提醒我们“尽量使训练数据密度大”需要合适的模型限制、数据量和问题定义。更复杂模型还可能对少数样本制造尖峰；高训练似然本身没有完成现实有效性的验证。

十三 模型假设和程序合同一起检查

二分类输出 p 时，至少约定了标签事件、条件信息和两种质量 p 与 $1-p$ 。如果把 n 条记录的概率相乘，还增加了给定模型下的独立假设。现实中每条样本可由其特征得到不同 p_i ；只有明确每个 p_i 对应哪条观测，才能逐项求和得到对数似然，不能错把长度 n 的标签与另一排列的概率配对。

Gaussian输出 μ 、 σ 时，约定了连续值域、对称钟形、位置尺度、记录单位，以及若干观测之间的联合关系。并非看到小数就必须使用Gaussian；非负且偏斜的测量、离散计数、带尖峰或饱和截断的读数，都需要重新检查这种选择。输出合法参数只是数学可用，不是现实假设已经成立。

本讲程序要求标量为内置int或float，拒绝bool和非有限值；序列必须平坦，不做隐含广播。Gaussian使用log公式，避免先构造 $\sigma \sqrt{2\pi}$ 导致不必要的溢出。但 $x-\mu$ 、标准化残差及平方若仍超出有限浮点范围，会显式报ArithmeticError。返回有限log密度再取exp仍可能下溢为0，例如标准Gaussian在 $x=40$ 处的密度；数学上该密度严格为正，log密度约-800.91894。代码中的0必须结合计算路径解释。

本讲结束时，应先问“横轴是谁，固定了谁，在哪个空间归一化”，再解释模型输出。概率质量对数据点求和，连续密度对数据区间积分，似然固定数据比较参数；参数后验还需先验和Bayes归一化。这些区别为后续损失函数和概率模型奠定基础，也给018的分布摘要留下清楚的前提。

资料与阅读范围

1. [Python random 官方文档](#)：独立Random实例、randrange及可复现说明。程序示例自行编写。
2. [Marco Taboga 的 Bernoulli distribution](#)：作者公开材料，用于核查二值分布的定义；NIST二项质量公式的 $n=1$ 情形也给出同一结果。本讲不预用期望方差章节。
3. [Python math 官方文档](#)：log1p、fsum、exp及有限数判断的接口。
4. [NIST Normal Distribution](#)：核查Gaussian密度的常数和定义域。
5. [NIST DLMF 7.2](#)：7.2.1、7.2.2与7.2.4核查Gaussian积分对应的标准常数；不要求学习复数部分。
6. [NIST Location and Scale Parameters](#)：核查平移、缩放以及密度中的倒尺度系数。
7. [NIST Maximum likelihood estimation](#)：核对固定样本后的参数函数，以及完整连续观测的密度乘积；不采用其中渐近性质作为本讲结论。

数学示例、图、失败案例与练习解答均为本课程独立推导，不复制来源中的题目或图片。数值核验只覆盖公开列明的教学范围；没有做真实数据拟合、跨平台安装、浏览器Notebook交互或性能基准测试。