

期望方差与抽样误差详解

一 期望与方差的变换

第1题：主例 $E[X]=2$, $\text{Var}(X)=6$ 。线性期望得 $E[3X+5]=3 \times 2+5=11$ 。中心化后 $3X+5-11=3(X-2)$ ，平方加权得 $\text{Var}(3X+5)=9 \times 6=54$ 。标准差为 $\sqrt{54}=3\sqrt{6}$ 。均值与标准差保留变换后数值单位，方差带该单位的平方；常数5改变位置，不改变分散。

第2题： $E[X^2]=0^2 \times 1/2 + 2^2 \times 1/4 + 6^2 \times 1/4 = 10$ ，而 $(E[X])^2=4$ 。两者差为 $\text{Var}(X)=6$ 。对于有限模型，二者相等当且仅当 $\text{Var}(X)=0$ ，即所有正概率取值相同。不能把“平方可以移到期望外”当一般规则；条件 $E[X^2]$ 存在时同样的等式仍把差刻画为方差。

二 零协方差为何仍可能依赖

第3题： X 均匀取-1、0、1， Y 分别为1、0、1。 $E[X]=0$ ； $E[Y]=2/3$ ； $E[XY]=(-1+0+1)/3=0$ 。 $\text{Cov}(X,Y)=0-0 \times 2/3=0$ 。事件 $\{X=0,Y=0\}$ 概率 $1/3$ ，而 $P(X=0)P(Y=0)=1/9$ ，因此不独立。或用条件证据 $P(Y=0|X=0)=1$ 而无条件为 $1/3$ 。仅检查线性相关系数会遗漏这里确定的非线性关系。

三 均值分布与独立抽样

第4题：四个编号虽有重复取值，但各自权重 $1/4$ ，因此16个有序编号对等权。按均值聚合后的计数为4、4、1、4、2、1，和16。期望为 $(0 \times 4 + 1 \times 4 + 2 \times 1 + 3 \times 4 + 4 \times 2 + 6 \times 1)/16 = 32/16 = 2$ 。平方偏离加权分子为 $4 \times 4 + 1 \times 4 + 0 \times 1 + 1 \times 4 + 4 \times 2 + 16 \times 1 = 48$ ，故方差3，与 $6/2$ 吻合。按三个不同数值均匀枚举9对则是另一个实验。

第5题： $n=64$ 时 $SE=\sqrt{6/8} \approx 0.306186$ ； $n=256$ 时 $SE=\sqrt{6/16} \approx 0.153093$ ，是原先的一半。这里比较的是重复抽样分布的宽度。单条累计路径加入一个远离当前平均的新观测，可能暂时增大实际偏差。因此“大数趋近”不是每一步严格改进的保证，也不是大样本不能出现离群平均。

四 同组复制的两种推导

第6题：第一条路线直接化简。8组各8行，总均值为 $(8 \sum Z_g)/64 = \sum Z_g/8$ 。组值IID、方差6，故均值方差 $6/8=3/4$ ， $SE=\sqrt{3/2} \approx 0.866025$ 。64行IID时方差 $6/64=3/32$ ，所以真实方差之比8、真实SE之比 $\sqrt{8}$ 。

第二条路线数协方差。64行方差之和是 $64 \times 6 = 384$ 。每组有 $8 \times 7/2 = 28$ 对，总计224对，每对 $\text{Cov}=6$ 。和的方差为 $384 + 2 \times 224 \times 6 = 3072$ ；均值再除 $64^2 = 4096$ ，得 $3/4$ 。不同组 $\text{Cov}=0$ ，不能把同组224对也当作0。

第7题：8组固定样本和16，均值2；偏离为-2、-2、0、4、-2、0、-2、4，平方和 $4+4+0+16+4+0+4+16=48$ 。 $s_Z^2=48/7$ ，估计均值方差 $s_Z^2/8=6/7$ ，估计 $SE \approx 0.925820$ 。复制后中心不变，平方和乘8为384， $s_{row}^2=384/63=128/21$ ，错误均值方差为 $2/21$ ， $SE \approx 0.308607$ 。估计方差比 $(6/7)/(2/21)=9$ ，对应SE比3。

这个9不与上一题真实方差比8冲突：上一题比较两个随机生成机制；此题比较同一批已观测组值按两种自由度分母作出的估计。真实组机制SE约0.866，而单批估计约0.926，本来就不必相等。

第8题：对G个IID组，令 $n=Gm$ 。复制后的均值就是组均值 Z ，平方偏离和为 $m\sum(Zg-Z)^2$ 。组内样本方差无偏给 $E[\sum(Zg-Z)^2]=(G-1)\sigma^2$ ，因此：

$$E[s_{row}^2] = \frac{m(G-1)}{Gm-1}\sigma^2.$$

错误逐行均值方差估计再除 Gm ，其期望为 $(G-1)\sigma^2/[G(Gm-1)]$ 。真实方差为 σ^2/G ；两者比为 $(G-1)/(Gm-1)$ 。本例 $G=m=8$ ，比为 $7/63=1/9$ 。所以模拟中错误SE平方平均再开方应接近真实SE/ $3 \approx 0.288675$ ，观察值0.289475与之相符。正确逐组 s_Z^2/G 的期望恰是 σ^2/G 。此推导依赖等组大小、完全复制及组间IID。

五 不放回抽样会减少方差

第9题：用编号A、B、C、D分别表示0、0、2、6，两个0仍须分别计数。12个不同编号有序对按均值聚合为：0有AB、BA两对；1有AC、CA、BC、CB四对；3有AD、DA、BD、DB四对；4有CD、DC两对。均值期望 $(0 \times 2 + 1 \times 4 + 3 \times 4 + 4 \times 2)/12=2$ 。方差为 $[4 \times 2 + 1 \times 4 + 1 \times 4 + 4 \times 2]/12=2$ 。

总体 $\sigma_N^2=6$ ， $N=4$ ， $n=2$ 代有限总体修正公式为 $6 \times (4-2)/[2 \times (4-1)]=2$ ，与枚举一致。放回独立抽2个时方差为3。一般证明可用 $\sum_i(x_i-\mu)=0$ ，所以 $\sum_i \neq_j (x_i-\mu)(x_j-\mu)=-\sum_i(x_i-\mu)^2=-N\sigma_N^2$ ；除 $N(N-1)$ 得每对不同位置的协方差 $-\sigma_N^2/(N-1)$ ，再代均值方差公式即可。

六 模拟和真实数据的误差不是同一层

第10题： n 是每批行数，复制情形 $G=n/8$ 是独立组数； $R=4000$ 是重新抽整批的次数。单批真实SE来自设计，如 $n=64$ 复制机制为 $\sqrt{(6/8)} \approx 0.86603$ 。4000个批均值的样本SD约0.87756，作为该真实SE的模拟估计。把这些均值再平均，其MCSE估计为 $0.87756/\sqrt{4000} \approx 0.01388$ 。

后一数字描述模拟平均的误差，不能用于声称现实一批数据的误差只有0.01388。固定同一真实样本然后重复计算4000次，不会得到4000个独立数据批次。模拟中同一个局部伪随机发生器按顺序产生新抽样，统计假设由生成机制给定；seed仅固定一条可复现实验轨迹。

第11题：对 $p=0.001$ 、 $n=100$ ，全零概率为 $(999/1000)^{100} \approx 0.904792$ 。全零样本均值与样本方差均0，因此估计 $SE=0$ ，但已知模型真实 $SE=\sqrt{(0.001 \times 0.999/100)} \approx 0.003161$ 。无偏声明 $E[s^2]=p(1-p)$ 对所有批次加权平均，不能推出每一批的 s^2 接近真值；少数非零批次提供较大值平衡大量的0。

正确结论是“这批没观察到该事件，经验SE不可靠”，而不是“事件不可能发生”。本课没有建立零计数的置信上界方法，不能擅自附上未经推导的百分比保证。

七 大数定律与中心极限定理的边界

第12题：永久复制时所有 $X_i=Z$ ，所以 $X_n=Z$ 。主例 Z 取0、2、6，概率1/2、1/4、1/4； $\varepsilon=1$ 时，偏差至少1的事件是 $Z=0$ 或6，概率3/4，对所有 n 不变。它不趋于0，因此不满足均值向2的依概率收敛。反例只否定“相同边缘分布就够了”；某些依赖随间隔衰减的序列仍可在额外条件下满足大数定律，不能一概否定。

正文用有限方差推得 $P(|X-\mu|\geq\varepsilon)\leq\sigma^2/(n\varepsilon^2)$ 。主例 $n=64$ 、 $\varepsilon=0.5$ 时界0.375，是上界而非精确比例。一般IID可积版本并不要求有限方差，但其证明不在本讲完成。

第13题：分子 $\sqrt{n}(X-\mu)$ 先扣除中心，再放大随样本量缩小的波动；除 σ 将尺度归一，使 Z_n 方差为1。经典IID CLT要求独立同分布、有限均值及有限正方差，结论是 Z_n 的累积分布趋近标准正态。不是原始样本分布变正态，不是 Z_n 逐点趋向0，不是 $n\geq 30$ 普遍足够，也不是所有尾部或罕见事件都已有精确近似。

如果 $\sigma^2=0$ ，则 X 在正概率支持上为常数，均值没有随机波动；CLT的标准化会除0，不能硬套。若二阶矩无限，则不能把有限样本 s 写成已经存在的总体 σ ，经典版本前提不成立。

八 连续选做

第14题： $[0,2]$ 上密度1/2的总面积为1。 $E[X]=(1/2)[x^2/2]_0^2=1$ ； $E[X^2]=(1/2)[x^3/3]_0^2=4/3$ ，所以方差1/3。 n 个IID观测的均值方差 $1/(3n)$ ，不是总体方差随着样本量改变。

对 $x\geq 1$ 上 $f(x)=\frac{3}{2}x^{-5/2}$ ，归一化积分为：

$$\frac{3}{2} \int_1^\infty x^{-5/2} dx = \frac{3}{2} \left[-\frac{2}{3} x^{-3/2} \right]_1^\infty = 1.$$

均值积分为 $\frac{3}{2}[-2x^{-1/2}]_1^\infty=3$ 。二阶矩积分到上界 M 为 $3(\sqrt{M}-1)$ ，随 M 增大无界，故不存在有限方差。经典有限方差CLT和 $\sigma/\sqrt{n}$ 不可用；由于 $E|X|=3$ 有限且假设IID，大数定律仍适用。

实验诊断的最低要求

完整报告必须写出抽样单位、目标分布、实际重复层次与所算误差对象。正确算出小数但删除组ID、把重复行当独立证据、把SE=0当无不确定性，仍未完成本讲目标。程序拒绝输入的测试保护计算接口，不证明数据生成假设符合现实。