

熵交叉熵与KL散度详解

第019单元 完整推导与失败分析

本文件对应正文14道练习及实验中的解释题。默认 $\ln$ 给出nat；用bit时显式写 $\log_2$ 。正向始终指目标P提供权重的 $D(P \parallel Q)$ 。所有状态空间有限，同一个数组位置必须代表同一个状态。

一 主例逐项贡献

$P=(1/2, 1/4, 1/4)$, $Q=(1/4, 1/4, 1/2)$ 。对应的 $-\log_2 p$ 为1、2、2， $-\log_2 q$ 为2、2、1。乘P得到熵贡献1/2、1/2、1/2，交叉熵贡献1、1/2、1/4；KL是后者逐项减去前者，得到1/2、0、-1/4。

所以 $H_2(P)=3/2$, $H_2(P,Q)=7/4$, $D_2(P \parallel Q)=1/4$ 。乘 $\ln 2$ 得到nat值分别1.0397207708399179、1.2130075659799042、0.17328679513998632。交叉熵减熵等于KL，第三个状态的KL项虽负，总和仍为正。

错误答案若给出0.75 bit的KL，通常把-0.25取了绝对值；若交叉熵给1.5 bit，可能误用了Q自己的权重。检错时先看每一项，不要只看总数。

二 四状态熵与前缀码

概率为1/8、1/8、1/4、1/2，对应bit信息量为3、3、2、1。加权和为 $3/8+3/8+1/2+1/2=7/4=1.75$ bit，nat为 $(7/4)\ln 2 \approx 1.213007566$ 。

可给四个状态依次分配110、111、10、0。没有任何码字是另一个码字的前缀，所以连续拼接可唯一读出；码长依次3、3、2、1，其期望正好1.75。这是二进制可精确实现的特殊例子，不能用它证明所有分布都有整数码长恰好等于 $-\log_2 p$ 。

三 对数不等式的完整路径

设 $t>0$, $g(t)=t-1-\ln t$ 。正文已经补充导数概念及 $d(\ln t)/dt=1/t$ 、导数符号判单调性的基本工具。 $g'(t)=(t-1)/t$ ，在 $(0,1)$ 负，在 $(1,\infty)$ 正，所以 g 在1处取得唯一最小值。 $g(1)=0$ ，于是 $\ln t \leq t-1$ 且仅 $t=1$ 取等号。

也可用有向面积作交叉检查。 $t>1$ 时，曲线 $1/u$ 在区间 $[1,t]$ 内不超过1，所以 $\ln t$ 不超过宽 $t-1$ 、高1的矩形面积； $t<1$ 时曲线在 $[t,1]$ 上不低于1，给面积加负号后不等式方向仍为 $\ln t \leq t-1$ 。除 $t=1$ 以外都有严格不等的区间。两条路线都需要明确 $t>0$ ，不能把 $t=0$ 代入 $\ln$ 。

四 支持集与等号不能省略

记 $A=\{j:p_j>0\}$ 。若某个 $j\in A$ 满足 $q_j=0$ ，KL为 $+\infty$ ，非负成立且不能等于0。否则对所有 $j\in A$ 应用 $-\ln(q_j/p_j)\geq 1-q_j/p_j$ ，乘 p_j 后求和：

$$D(P\|Q) \geq 1 - \sum_{j\in A} q_j = \sum_{j\notin A} q_j \geq 0.$$

右侧最后一步利用Q在整个状态空间上归一化。D=0要求两个条件同时成立：A外的Q质量为0；A内每个 $q_j/p_j=1$ 。由于 $p_j>0$ ，任何一处严格对数不等式都会贡献正缺口，无法由其他项抵消，因此这些条件必要。二者合起来等价于 $P=Q$ ；相同分布又显然使KL为0，所以是充要条件。

令 $U_j=1/K$ ，直接代入 $D(P\|U)=\sum p_j \ln p_j + \ln K = \ln K - H(P)$ ，由非负性推出 $H(P)\leq \ln K$ 。等号条件为 $P=U$ 。下界 $H(P)\geq 0$ 来自每个 $-p_j \ln p_j \geq 0$ ，等号要求P为单点质量。

五 零概率的四种角色

$P=(1/2, 1/2, 0)$ 、 $Q=(1, 0, 0)$ 。A项交叉熵为 $-(1/2)\ln 1=0$ ；B项为 $+\infty$ ；C项因P权重0而定义为0。故 $H(P, Q)=+\infty$ ， $D(P\|Q)=+\infty$ 。

反向只按Q的支持A求和，所以 $D(Q\|P)=\ln 2 \approx 0.6931471806$ 。共同零状态C不进行 $\ln 0$ 或 $0/0$ 运算。不能因为两个分布都在C为0，就拒绝这两个合法概率向量；也不能因Q在B为0而把B从P的求和里删掉。

有限性条件为 $\text{supp}(P)\subseteq \text{supp}(Q)$ ；反方向则交换两边。在有限状态空间上，这既必要也充分，因为通过检查后仅剩有限个有限对数项。

六 特殊对称不代表一般对称

主例交换A和C就交换P与Q，这种状态重命名不改变求和，所以两方向恰好都为 $(1/4)\ln 2$ 。不是KL定义具有一般对称性。

取二分类 $P=(3/4, 1/4)$ 、 $Q=(1/2, 1/2)$ ，正向为 $(3/4)\ln(3/2)+(1/4)\ln(1/2)\approx 0.1308120359$ ；反向为 $(1/2)\ln(2/3)+(1/2)\ln 2\approx 0.1438410362$ 。差值约0.0130290003，远大于浮点舍入。加上练习五的有限与无限反例，方向差别尤其清楚。

七 三角不等式的反例

令 $P=(0.1, 0.9)$ 、 $Q=(0.5, 0.5)$ 、 $R=(0.9, 0.1)$ 。逐项计算得到：

$$D(P\|R) = 0.1 \ln(1/9) + 0.9 \ln 9 = 0.8 \ln 9 \approx 1.7577796619.$$

$$D(P\|Q) = 0.1 \ln 0.2 + 0.9 \ln 1.8 \approx 0.3680642072.$$

$$D(Q\|R) = 0.5 \ln(5/9) + 0.5 \ln 5 \approx 0.5108256238.$$

后两项之和约0.8788898310，小于第一项。因此 $D(P \parallel R) \leq D(P \parallel Q) + D(Q \parallel R)$ 被这个例子直接否定。证明某性质不总成立只需一个合法反例；不能反过来说所有三分布都必然违反三角不等式。

八 三候选方向比较

目标 $P=(0.49, 0.02, 0.49)$ ，宽候选各1/3。正向 $D(P \parallel$

$Q_B)=2 \times 0.49 \ln 1.47 + 0.02 \ln 0.06 \approx 0.3212889384$ ；反向 $D(Q_B \parallel P)=(2/3) \ln[(1/3)/0.49] + (1/3) \ln[(1/3)/0.02] \approx 0.6809619717$ 。

左候选 $(0.96, 0.02, 0.02)$ 。正向为 $0.49 \ln(49/96) + 0.49 \ln(49/2) \approx 1.2378111599$ ；中间比值为1，所以省略的项确实为0。反向为 $0.96 \ln(96/49) + 0.02 \ln(2/49) \approx 0.5816533153$ 。右候选由交换A和C获得，由目标对称性，两个方向分别与左候选相同。

所以在这三个候选中正向唯一选宽；反向左并列。若加入P，两个方向都有 $D(P \parallel P)=0$ ，其他候选均不等于P，KL严格为正，因此P唯一最优。这个反事实检查能避免把方向偏好误写成普遍寻峰定律；模型族和目标的形状限制必须一起说。

九 经验交叉熵与均值NLL

标签[A,A,B,C]对应 $P=(2/4, 1/4, 1/4)$ 。 $Q=(1/4, 1/4, 1/2)$ 的四条bit损失为2、2、2、1，平均7/4。按类别合并后是 $(2/4) \times 2 + (1/4) \times 2 + (1/4) \times 1 = 7/4$ ，nat同乘 $\ln 2$ 。

把求和按标签重新分组是代数恒等式，不需要IID。若想进一步说经验损失接近某个总体期望，则需要确定目标P、评价模型Q、抽样机制以及可积条件。本讲有限状态且Q覆盖P支持时，固定Q的损失有界；IID大数定律适用。Q若使用同一数据选出，则训练平均的解释不能原样代入固定Q的论证，需独立评估或另行分析。

若把数据复制一遍，经验频率和均值损失不变，但没有增加新的独立信息。复制同一个标签很多次则连经验频率也变了，得到的是另一个加权对象。

十 one-hot与总体条件不确定性

标签B对应 $e_B=(0, 1, 0)$ 。 $H(e_B)=0$ ， $H(e_B, Q)=-\ln(1/4)=\ln 4 \approx 1.3862943611$ nat。KL $D(e_B \parallel Q)$ 也为 $\ln 4$ ，与交叉熵分解一致。

one-hot描述“这一次观察到B”的训练目标，而 $P(Y|x)$ 描述重复面对同类输入时标签的总体概率。如果相同x下A与B各有1/2真实可能性，每次观察仍是一个one-hot标签，但总体条件熵为 $\ln 2$ 而非0。一个样本的确定记录，不能替代生成机制的条件分布。

十一 稀有未见与总体无穷

真实罕见概率0.001，100次IID完全不见罕见状态的概率为 $(1-0.001)^{100} \approx 0.9047921471$ 。因此约90.48%的此类批次， $Q=(1, 0)$ 对全部观察赋予概率1，经验平均 $-\ln 1=0$ 。

但总体平均含 $0.001 \times (-\ln 0) = +\infty$ 。有限样本漏看了正质量状态，无法证明它真的不可能。前面有限损失大数定律论证要求 Q 在 P 支持上为正，而这里不满足，所以不存在矛盾。人为平滑 Q 可令损失有限，但必须承认模型已经改变。

十二 逼近零与精确零

$P=(1/2, 1/2)$ 、 $Q_\varepsilon=(1-\varepsilon, \varepsilon)$ ， $0<\varepsilon<1$ 。交叉熵为 $-(1/2)\ln[\varepsilon(1-\varepsilon)]$ ，正向KL再减 $\ln 2$ 。当 $\varepsilon \rightarrow 0$ 时 $\ln \varepsilon \rightarrow -\infty$ 、 $\ln(1-\varepsilon) \rightarrow 0$ ，所以正向发散。

反向为 $(1-\varepsilon)\ln[2(1-\varepsilon)] + \varepsilon\ln(2\varepsilon)$ 。第一项趋于 $\ln 2$ ；第二项趋于 0。若担心 $\varepsilon \ln \varepsilon$ 的边界，可用已证对数不等式作不依赖求导的界：对 $0<\varepsilon<1$ ，

$$0 \leq -\varepsilon \ln \varepsilon = 2\varepsilon \ln(1/\sqrt{\varepsilon}) \leq 2\sqrt{\varepsilon} - 2\varepsilon \rightarrow 0.$$

所以反向趋于 $\ln 2$ 。将一个仍为正的 ε 直接设为 0，会把正向一个很大但有限的数改成无穷，属于支持集变化。若这种 0 来自浮点下溢，结果反映的是计算机已接收的概率，不再精确对应原数学概率。

十三 归一化平滑的实际代价

$Q=(1, 0, 0)$ 、 $\alpha=0.02$ 、 $U=(1/3, 1/3, 1/3)$ ，所以 $Q'=(0.98+0.02/3, 0.02/3, 0.02/3)=(74/75, 1/150, 1/150)$ 。和为 $148/150+1/150+1/150=1$ ，且每项正。

对 $P=(1/2, 1/2, 0)$ ， $H(P, Q') = -(1/2)\ln(74/75) - (1/2)\ln(1/150) \approx 2.5120291572$ nat。原 Q 下是无限，两者不同是因为模型改了，不是数学定义对同一个模型给出两个答案。

直接取 $\max(q_j, 0.01)$ 得到 $(1, 0.01, 0.01)$ ，总和 1.02，函数应拒绝。若除以 1.02 归一化，得到 $(50/51, 1/102, 1/102)$ ，虽合法，却不是上面的 $\alpha=0.02$ 均匀混合；它有自己的不同交叉熵。任何裁剪或混合参数都应写入结果记录。

十四 按状态名对齐的语义测试

仅检查 $\text{len}(P) == \text{len}(Q)$ 不能发现类别顺序错配。设计一个已知单标签 A 的测试：模型字典应为 $\{A:0.25, B:0.25, C:0.5\}$ ， A 的期望损失应为 $\ln 4$ 。若误把 C 的 0.5 放到 A 位置，计算会给 $\ln 2$ ，测试立即失败。

可靠转换步骤是先固定 `canonical_labels=[A,B,C]`，再按这些键读每个分布，并检验键集合相同、无重复或遗漏；最后才转换为数值向量。本课 CSV 固定列名并检查表头，演示了结构验证，但无法察觉原始数据提供方把类别含义写错。这个剩余限制需要数据字典与上游语义检查，而不是更小的数值容差。

实验验收的解释题

非法概率、错误标签和不匹配维度应拒绝；合法支持集不匹配应返回正无穷；共同零状态应跳过。三种行为不能混为一谈。对数比用 $\ln p - \ln q$ 可减少中间比值溢出，但不能恢复已经丢失的概率精度。