

# 熵交叉熵与KL散度

## 第019单元 对数损失究竟在比较什么

分类器把正确类别的概率从0.6提高到0.99，分类准确率可能完全不变，交叉熵却明显下降。另一台生成器只生成某一种很逼真的样本，是否就等于学会了整个数据分布？这两个问题看起来不同，却都要求分清：由谁提供概率权重，由谁接受评价，以及模型把哪些可能事件说成了不可能。

本讲围绕“分类损失、分布匹配和生成目标为何常出现对数”。先修为017与018的离散主线：概率质量、独立似然、对数乘积规则、有限期望与抽样误差。所有主要结论都在同一个有限状态空间上建立，不要求连续密度或神经网络。证明非负性前会显式补充所需的最小导数工具；不把Jensen不等式当作已学知识。

学习后应能从定义逐项计算熵、交叉熵和两个方向的KL；证明交叉熵分解和KL非负；在动手取对数前发现支持集问题；解释有限候选实验能说明什么、不能说明什么。数据、图和代码均为原创合成教学材料，不评价真实模型性能。

## 一 从一条预测的分数开始

设一次观察的正确类别为 $y$ ，模型给它的概率是 $q_y$ 。定义这条观察的负对数损失为 $-\ln q_y$ 。当 $q_y=1$ 时损失为0；当 $q_y$ 很小时损失很大；若 $q_y=0$ 而这条观察确实发生，损失定义为正无穷。这里“正确类别”是已观测标签，不表示标签生成过程必然无噪声。

为什么用对数？017中独立观察的联合似然是概率相乘。对 $n$ 个标签，模型在第 $i$ 条输入上给出 $q(y_i|x_i)$ ，则负对数把乘积改写成求和：

$$-\ln \prod_{i=1}^n q(y_i | x_i) = \sum_{i=1}^n -\ln q(y_i | x_i).$$

这是使用对数的一个直接原因：最大化同一个似然等价于最小化它的负对数，单个样本贡献可以相加。若数据模型不独立，则必须使用正确的联合概率或条件分解，不能靠取对数把依赖关系删掉。对数不是所有学习目标唯一合法的选择；选择它意味着采用一种明确的概率评价方式。




图1 左图标出正确类别概率0.6和0.99的负对数损失。右图显示同一个已观测类别的两份预测，两者都可能把它排第一，但损失不同。纵轴以nat计； $q=0$ 处的无穷不画成一个有限端点。

$-\ln 0.6 \approx 0.510826$ ， $-\ln 0.99 \approx 0.010050$ 。若模型自信地错了，给真实类别0.01，则损失  $-\ln 0.01 \approx 4.605170$ 。准确率只记录最高概率类别是否正确，而这个分数记录给真实结果留了多少概率。单条损失小，不足以证明概率校准或泛化好，仍要在符合目标分布的数据上评估。

## 二 先约定状态空间与对数单位

令状态集合为  $S=\{A,B,C\}$ ，更一般地有  $K$  个状态。P与Q是同一个有序集合上的概率分布， $p_j=P(Y=j)$ ， $q_j=Q(Y=j)$ 。每个数非负，两组数各自求和为1。下标  $j$  代表状态，不是训练样本编号。若两个文件的类别顺序不同，即使数组同形状，也不能直接做逐项比较。

P暂称评价分布，Q暂称待评价分布。很多任务里P是目标总体分布、Q是模型；在实际训练里P也可能是经验分布或人为设计的软标签。名称不改变数学定义，必须先说清楚当前到底是哪一种。

自然对数  $\ln$  的底是  $e$ ，所得单位称 nat。若使用  $\log_2$ ，单位称 bit。换底关系是  $\log_2 t = \ln t / \ln 2$ ，因此所有熵、交叉熵与KL的bit值都是nat值除以  $\ln 2$ 。统一换底只乘同一个正常数，不改变候选排序。把不同底数的损失放在同一表里直接比较，会制造虚假的差异。

本讲固定的手算分布为：

| 状态 | A   | B   | C   | 总和 |
|----|-----|-----|-----|----|
| P  | 1/2 | 1/4 | 1/4 | 1  |
| Q  | 1/4 | 1/4 | 1/2 | 1  |




图2 左图是同一状态轴上的P与Q。右图以bit列出P加权的自信息和预测损失。比较损失时权重始终来自P；把柱子的颜色交换并不只是改图例，而是换了问题。

### 三 熵是分布自身的平均不确定性

单个结果在P下的自信息是 $-\ln p_j$ 。按P发生概率加权，得到熵：

$$H(P) = E_{Y \sim P}[-\ln p_Y] = - \sum_{j: p_j > 0} p_j \ln p_j.$$

求和只包含正概率状态，因此无需真的计算 $\ln 0$ 。常用简写是规定 $0 \ln 0 = 0$ ；这是带权项的边界约定，不是说 $\ln 0 = 0$ 。对有限分布，熵总是有限且非负：每个正概率 $p_j \leq 1$ ，故 $-\ln p_j \geq 0$ 。熵为0当且仅当所有质量都在一个状态上，因为任何 $0 < p_j < 1$ 的项都严格为正。[1]

主例用bit特别容易手算。A的信息量为1，B和C均为2，故 $H_2(P) = (1/2) \times 1 + (1/4) \times 2 + (1/4) \times 2 = 1.5$  bit，换成nat为 $1.5 \ln 2 \approx 1.039721$ 。熵描述分布，不是某条样本的信息量；A的一条观察为1 bit，不能把它写成“总体熵1 bit”。

编码提供一个具体解释：给A码字0，B码字10，C码字11，就能无歧义地拼接读出，平均长度恰为1.5 bit。这里概率恰好是2的负整数次幂，理想长度与整数码长一致。一般的 $-\log_2 p_j$ 并非整数，不能直接当成某个逐符号码字长度；一般编码定理及其条件不在本讲证明范围内。

均匀分布U在K个状态上各有 $1/K$ ，直接代入得到 $H(U) = \ln K$ 。为什么任何P都不超过它？先记下这个问题，等证明KL非负后，只需一行就能回答；现在不提前使用尚未证明的结论。

### 四 交叉熵把权重与评分规则分开

当结果仍由P产生，但用Q的概率评分，平均损失叫交叉熵：

$$H(P, Q) = E_{Y \sim P}[-\ln q_Y] = - \sum_{j: p_j > 0} p_j \ln q_j.$$

若有 $p_j > 0$ 而 $q_j = 0$ ，这个量为正无穷；否则有限。 $H(P)$ 是“P加权、P评分”， $H(P, Q)$ 是“P加权、Q评分”。因此 $H(P, Q)$ 并不等于 $H(Q)$ ，也一般不等于 $H(Q, P)$ 。只报一个交叉熵数值而没有说明权重分布，会丢掉它最重要的含义。

对主例，Q给A、B的负 $\log_2$ 概率均为2，给C为1。按P加权， $H_2(P,Q)=(1/2) \times 2 + (1/4) \times 2 + (1/4) \times 1 = 1.75$  bit。相对于用P本身评分，平均多0.25 bit，但C这一状态反而少付了1 bit；全局差异不能理解为每个状态都变坏。

如果固定P，只能在某个模型集合内选择Q，交叉熵就是对这个集合的比较标准。更换任务总体P或更换标签处理方式，会同时改变比较基线，原来的数值不一定可横向比较。例如几乎确定的二分类任务和标签本来模糊的任务，即便都达到各自最优，最优损失也可能不同。

## 五 KL是平均对数概率比

Kullback-Leibler散度简记 $D(P \parallel Q)$ ，本讲采用方向约定：竖线左边的分布提供求和权重。

$$D(P \parallel Q) = \sum_{j: p_j > 0} p_j \ln \frac{p_j}{q_j}.$$

定义仍须先判断分母：若某个 $p_j > 0$ 但 $q_j = 0$ ，则 $D(P \parallel Q) = +\infty$ 。若 $p_j = 0$ ，则该状态项定义为0，包括 $p_j = q_j = 0$ 的情形。不能先在电脑里做0/0再盼望乘0把NaN消掉。有限情形可把比值的对数写成 $\ln p_j - \ln q_j$ ，避免中间比值溢出。[2]

主例的bit贡献分别是 $(1/2)\log_2 2 = 1/2$ ， $(1/4)\log_2 1 = 0$ ， $(1/4)\log_2 (1/2) = -1/4$ ，因此 $D_2(P \parallel Q) = 1/4$  bit。第三项为负完全正常；非负性是对总和的结论。逐项取绝对值或把每个负贡献裁成0，会定义另一个量。

把有限交叉熵中加入并减去同一项，得到核心分解：

$$\begin{aligned} H(P, Q) &= - \sum_{p_j > 0} p_j \ln q_j \\ &= - \sum_{p_j > 0} p_j \ln p_j + \sum_{p_j > 0} p_j (\ln p_j - \ln q_j) \\ &= H(P) + D(P \parallel Q). \end{aligned}$$




图3 主例交叉熵1.75 bit由熵1.5 bit与KL 0.25 bit组成。图右同时保留KL的正负分项，说明“总额外代价非负”不等于每个类别都付正的额外代价。

若支持集不匹配，有限 $H(P)$ 加上 $+\infty$ 仍是 $+\infty$ ，上述等式可按扩展实数解释；不要倒过来计算 $\infty - \infty$ 。在本讲有限状态下 $H(P)$ 必有限，所以 $D = H(P,Q) - H(P)$ 没有 $\infty - \infty$ 问题；进入无限或连续情形时不能自动沿用这个保证。

## 六 证明前补齐一个对数不等式

下面需要 $\ln t \leq t-1$ ，且仅在 $t=1$ 时取等号。为避免把它当作黑箱，这里给出最小导数工具后证明它。导数 $f'(t)$ 表示在 $t$ 附近变化量 $\Delta t$ 趋于0时，比值 $[f(t+\Delta t)-f(t)]/\Delta t$ 的极限，即局部变化率。这里仅使用三个基本事实：常数导数为0， $t$ 的导数为1； $\ln t$ 在 $t>0$ 上导数为 $1/t$ ；某段上导数严格为正则函数严格递增，严格为负则严格递减。最后一个事实是单变量微积分的单调性判别。

这些事实是本节明确补充的证明工具，不假定017或018已经教过导数。 $\ln$ 的导数也可由几何理解：把 $\ln t$ 视为曲线 $1/u$ 从1到 $t$ 的有向面积；在 $t$ 附近增加一个宽度 $\Delta t$ 的窄条，其平均高度夹在两端的 $1/u$ 之间， $\Delta t$ 趋于0时两端都趋于 $1/t$ 。无需计算任何连续概率积分。需要系统学习这些基础时可回看010，但后续有限求和推导不再使用导数。

令 $g(t)=t-1-\ln t$ ，定义域为 $t>0$ 。逐项求导有 $g'(t)=1-1/t=(t-1)/t$ 。于是 $0<t<1$ 时 $g$ 递减， $t>1$ 时 $g$ 递增，最低点为 $t=1$ ；又 $g(1)=0$ ，所以 $g(t) \geq 0$ ，等号仅在 $t=1$ 成立。这就完整建立了所需不等式，而不是用Jensen的名字代替证明。




图4 蓝线为 $\ln t$ ，橙线为 $t-1$ ，二者只在 $t=1$ 相接。右图是差 $g(t)$ ，在1两侧均为正。图为直观检查；结论来自正文的导数符号与等号分析，不能由有限采样图证明。

也可直接用刚才的面积解释检查方向： $t>1$ 时， $1/u \leq 1$ ，面积不超过宽 $t-1$ 的矩形； $0<t<1$ 时， $\ln t$ 等于从 $t$ 到1的面积加负号，而该区间 $1/u \geq 1$ ，故仍有 $\ln t \leq t-1$ 。 $t \neq 1$ 时都有一段严格不等，因而不等式严格。这个几何检查尤其能防止把负号方向弄反。

## 七 带着零概率证明KL非负

令 $A=\{j:p_j>0\}$ ，称为 $P$ 的支持集。分两种情形。若存在 $j \in A$ 使 $q_j=0$ ， $D=+\infty$ ，非负性已经成立且不可能等于0。否则所有 $j \in A$ 的比值 $q_j/p_j$ 都为正，才可以代入上一节不等式：

$$-\ln \frac{q_j}{p_j} \geq 1 - \frac{q_j}{p_j}.$$

乘以正数 $p_j$ 并在 $A$ 上求和，保留每一步的求和范围：

$$D(P\|Q) \geq \sum_{j \in A} (p_j - q_j) = 1 - \sum_{j \in A} q_j = \sum_{j \notin A} q_j \geq 0.$$

容易漏掉的地方是 $\sum_{j \in A} q_j$ 不一定为1: Q可能把质量放在P支持集外。这个剩余质量恰好构成非负的下界。如果直接把两组受限求和都写成1, 证明就缺了一步。

等号也要检查两层。若 $D=0$ , 则Q在A外的总质量必须为0; 每个正权重的对数不等式也必须取等号, 所以 $q_j/p_j=1$ , 即A内逐项相等。合起来得到整个S上 $P=Q$ 。反过来 $P=Q$ 时, 每个正支持项都是 $p_j \ln 1=0$ , 共同零项也按定义为0。因此 $D(P \parallel Q) \geq 0$ , 且等号当且仅当 $P=Q$ 。

于是固定P时,  $H(P, Q) \geq H(P)$ , 在允许选择全部概率分布时唯一最优 $Q=P$ 。若模型集合不含P, 只能在集合内比较, 不能声称一定达到 $H(P)$ 。把Q取为K状态均匀分布U, 还得到 $D(P \parallel U) = \ln K - H(P) \geq 0$ , 即 $0 \leq H(P) \leq \ln K$ ; 上界等号要求 $P=U$ 。这个推导同时解释了熵的最大值, 而无需另外求一个多变量极值。

## 八 支持集比数值大小更早决定结果

$D(P \parallel Q)$ 有限的充要条件是在本讲有限状态中 $\text{supp}(P) \subseteq \text{supp}(Q)$ 。反方向有限则要求 $\text{supp}(Q) \subseteq \text{supp}(P)$ 。想要两个方向都有限, 支持集必须相同。两个分布只要同在S上并不意味着支持集相同: S包含可列举的状态, 支持集只保留正质量状态。

| 某一状态的概率    | 交叉熵该项      | $D(P \parallel Q)$ 该项 | 处理顺序      |
|------------|------------|-----------------------|-----------|
| $p>0, q>0$ | $-p \ln q$ | $p(\ln p - \ln q)$    | 正常计算      |
| $p>0, q=0$ | $+\infty$  | $+\infty$             | 返回无穷      |
| $p=0, q>0$ | 0          | 0                     | 跳过该项      |
| $p=0, q=0$ | 0          | 0                     | 跳过, 勿求0/0 |




图5  $P=(1/2, 1/2, 0)$ ,  $Q=(1, 0, 0)$ 。P要求覆盖B而Q没有任何质量, 因此正向KL为无穷; 反向只按Q实际支持的A加权, 数值是 $\ln 2$ 。共同为零的C不产生NaN或额外惩罚。

对图5手算,  $D(P \parallel Q)$ 有 $(1/2) \ln[(1/2)/0]$ , 所以为无穷。 $D(Q \parallel P) = 1 \times \ln[1/(1/2)] = \ln 2 \approx 0.693147$ 。这里两方向差异不是微小数值误差, 而是一个有限、一个无限。Q没有在B放质量, 反向求和不会在那里直接付分; 但这不意味着它已匹配P, 反向总值仍大于0。

把Q改为 $Q_\epsilon=(1-\epsilon, \epsilon)$ ，让 $P=(1/2, 1/2)$ ， $0 < \epsilon < 1$ 。逐项得到 $H(P, Q_\epsilon) = -(1/2)\ln[\epsilon(1-\epsilon)]$ ， $D(P \parallel Q_\epsilon) = H(P, Q_\epsilon) - \ln 2$ ； $\epsilon$ 趋于0时二者发散。反方向为 $(1-\epsilon)\ln[2(1-\epsilon)] + \epsilon\ln(2\epsilon)$ ，却趋向 $\ln 2$ 。极限方向差异来自加权分布变化，而非画图尺度的选择。




图6 横轴是 $-\log_{10} \epsilon$ ，右移表示小概率每次再缩小10倍。正向KL持续增长，反向KL趋近 $\ln 2$ 。绘制范围只到 $\epsilon=10^{-12}$ ；真正 $\epsilon=0$ 的正向值为无穷，不能把图的最高点当作它。

## 九 KL不是对称距离

主例 $P=(1/2, 1/4, 1/4)$ 、 $Q=(1/4, 1/4, 1/2)$ 恰好在互换状态后对称，所以两个方向都为0.25 bit。这只是特殊相等，不能从一组实验概括出对称性。换成 $P=(3/4, 1/4)$ 、 $Q=(1/2, 1/2)$ ，有：

$$D(P \parallel Q) = \frac{3}{4} \ln(3/2) + \frac{1}{4} \ln(1/2) \approx 0.130812,$$

$$D(Q \parallel P) = \frac{1}{2} \ln(2/3) + \frac{1}{2} \ln 2 \approx 0.143841.$$

二者不同，足以反驳“KL是对称距离”。KL也不满足一般距离需要的三角不等式；详解用三个二分类分布给出数值反例。非负、相同分布时为0，只是距离所需的一部分性质。把它称作散度能提醒我们，每次必须写清方向，不能像普通长度那样任意交换端点。

术语“正向”“反向”也要附带约定。本讲以目标P和模型Q为固定角色，称 $D(P \parallel Q)$ 为正向、 $D(Q \parallel P)$ 为反向。另一篇文章若交换p、q的命名，单凭词语可能误读；先看谁在期望符号下面、谁在对数分母里。

## 十 有限受限模型怎样展示方向选择

为避免把复杂生成模型讲成口号，我们只设计一个可枚举的模型集合。状态A、B、C沿一条轴排列，目标 $P=(0.49, 0.02, 0.49)$ 在两端有高质量，中间是低谷。模型只允许下面三个固定候选，不能任意移动或改变概率：宽候选 $Q_B=(1/3, 1/3, 1/3)$ ，左候选 $Q_L=(0.96, 0.02, 0.02)$ ，右候选 $Q_R=(0.02, 0.02, 0.96)$ 。






图7 左侧按状态对照目标与三个允许候选，所有分布都在三个状态上归一化。右侧比较同一候选的两个KL方向：正向选宽候选，反向在左、右两个候选间并列。这里只比较三个明确列出的分布，绝不是对所有单峰模型做全局优化。

以左候选为例，正向是 $0.49\ln(0.49/0.96)+0.02\ln 1+0.49\ln(0.49/0.02)\approx 1.237811$ ；反向是 $0.96\ln(0.96/0.49)+0.02\ln 1+0.02\ln(0.02/0.49)\approx 0.581653$ 。宽候选对应正向0.321289、反向0.680962。因此正向宁可把更多质量放到中间，也不愿明显低估另一端；反向在这个集合内宁可选一端，也不愿把1/3质量放在目标只有0.02的低谷。

这说明“覆盖多处目标质量”与“避免在低目标质量处放模型质量”可能出现不同取舍。它没有证明反向KL总会寻峰、总会丢模式或总会低估方差。结论依赖目标、允许模型集合和优化是否找到最小值。如果把P本身加入候选集合，两方向立刻都选P且最小值0；如果允许所有分布，两方向的全局唯一最优本来就是P。不要拿无约束最优的一条简单曲线冒充模式行为的证据。

## 十一 从总体交叉熵走到训练损失

先考虑模型不区分输入、只给同一个类别分布Q的情形。n条已观察标签中，类别j出现 $n_j$ 次，定义经验概率 $\hat{p}_j=n_j/n$ 。把相同标签的项合并，就有一个纯代数恒等式：

$$\frac{1}{n} \sum_{i=1}^n -\ln q_{y_i} = -\sum_j \frac{n_j}{n} \ln q_j = H(\hat{P}, Q).$$

不论标签是否独立，这个重排求和都成立。但要把经验平均当作总体 $H(P, Q)$ 的估计，就需要018的抽样条件。固定Q、IID抽样且Q在P支持上为正时，因为状态有限，所有损失有限，样本均值可由大数定律趋近 $H(P, Q)$ 。若Q是看过同一批训练标签才拟合出的，不能把这个固定Q论证直接当作训练误差的泛化保证。

主例标签序列[A,A,B,C]，计数为[2,1,1]，恰好得到 $\hat{p}=P$ 。四条bit损失是[2,2,2,1]，平均7/4=1.75。一次样本频率刚好等于总体是我们为手算设计的条件，不能期望真实小批次也精确相等。

对普通分类器，Q依赖输入x。对 $P(X=x)>0$ 的输入，目标条件分布是 $P(Y|x)$ ，模型是 $Q(Y|x)$ ，我们在每个x上使用同一个分解，再对输入分布加权：

$$E_X[H(P(\cdot | X), Q(\cdot | X))] = E_X[H(P(\cdot | X))] + E_X[D(P(\cdot | X) \| Q(\cdot | X))].$$



本讲把 $X$ 也限于有限取值，以上只是两重有限求和。真实总体的条件熵项不随 $Q$ 改变，但每个输入只观察一个标签时，并不知道其真实条件分布。训练中用one-hot向量 $e_y$ ，只有真实标签位置为1，其熵0且 $H(e_y, Q) = -\ln q_y$ 。one-hot目标熵0，不意味着总体标签条件熵一定0。

若提供软标签 $t_j \geq 0$ 、 $\sum t_j = 1$ ，损失为 $-\sum t_j \ln q_j$ ，仍是交叉熵。软标签来自教师预测、标注比例还是人为平滑，会改变评价对象。这里不假设它自动更真实，也不提前讨论具体训练框架接口。

## 十二 有限样本会遮住无限总体损失

令真实 $P=(0.999, 0.001)$ ，模型 $Q=(1, 0)$ 。真实交叉熵为无穷，因为罕见事件在 $P$ 下有正概率，在 $Q$ 下却完全不可能。独立抽100次，完全没见罕见事件的概率是 $0.999^{100} \approx 0.904792$ 。遇到这样的批次，经验交叉熵是0，看起来“完美”。




图8 左侧是100次独立抽样是否至少看到一次罕见事件的精确概率。右侧区分已观察经验损失与总体损失；没有观察到某状态，并不能把它的总体概率宣布为0。

这不违反大数定律：上一节要求固定 $Q$ 在 $P$ 支持上为正，从而有限损失，而这里恰好违反。一次小测试集没有报错，也无法排除漏覆盖。实际评价应保留对异常大损失、未覆盖状态与分组抽样机制的检查；只有一个总平均不足以诊断原因。

把 $Q$ 平滑为 $Q'=(1-\alpha)Q+\alpha U$ ，其中 $0<\alpha\leq 1$ 且 $U$ 在每个状态上均匀，能令所有 $q'_j \geq \alpha/K > 0$ 。它确实使有限状态交叉熵变为有限，但改变了模型。对三状态 $Q=(1, 0, 0)$ 、 $\alpha=0.02$ ，有 $Q'=(74/75, 1/150, 1/150)$ ，对 $P=(1/2, 1/2, 0)$ 的交叉熵约2.512029 nat。这个数不是原来无限损失的“更准确计算”。

单纯把 $q_j$ 替换成 $\max(q_j, \epsilon)$ 却不重新归一化，得到的向量一般总和超过1，不再是概率分布。即使归一化了，也应把修改后的 $Q$ 写明。把0改成一个极小正数有时是实际建模决策，有时是数值防护，不能用同一句“防止报错”掩盖二者区别。

## 十三 计算实现必须忠实于数学边界

核心脚本先验证同序状态、概率范围与总和，再处理 $p=0$ 和 $q=0$ ，最后才取对数。正常正值使用 $\ln p - \ln q$ ，不直接形成 $p/q$ ；例如 $p=1$ 、 $q=10^{-300}$ 时对数比有限，而其他更极端中间比值可能溢出。只要正数可在浮点中表示，极小概率不等于数学上的零；数据在进入函数前已经下溢为0时，函数无法猜出原来的值。

输入允许最多64个状态；总和误差不超过 $10^{-12}$ 时进行明确的舍入级归一化，超过则拒绝。布尔值、负概率、NaN、无穷和空向量都拒绝。正 $\alpha$ 的均匀混合份额若下溢到0，平滑接口会拒绝，避免丢失应有的正支持。代码不是通用概率库，尤其不承诺超出浮点精度的任意高精度区分。某些接近相等的分布可能因舍入得到数量级约 $10^{-16}$ 的负KL，测试采用明确容差，不把所有负数静默裁成0。[3]

输出JSON用字符串“Infinity”表示正无穷，以保持标准JSON；它不是一个有限数，也不是缺失值。Notebook与脚本读同样的CSV并生成同名结果，再逐字节比较。独立测试另用80位Decimal对数与有理数分布核算，而非只把同一个函数运行两遍。

## 十四 回答开头的问题并划清外推边界

分类损失中出现对数，是因为对模型赋予已观察标签的概率进行评分，并把联合似然乘积改为可加贡献。分布匹配里出现对数概率比，是因为交叉熵相对目标自身熵的额外部分恰好是KL。生成任务若采用似然或KL目标，也会继承这些结构；具体生成算法、隐藏变量和其他散度要在后续课程中另行建立，不能把所有生成目标都统称为交叉熵。

本文所有熵结论限定为有限离散分布。连续密度可以大于1，所以 $-\ln$ 密度可能为负，微分熵也可负，并随坐标单位变化。连续KL需要积分、支持与可积条件，不能直接把概率质量的表格换成密度值后求和。有限分布的 $0 \leq H(P) \leq \ln K$ 以及经验计数解释，不应原样搬到连续模型。

最重要的检查顺序是：先确认状态与权重，再确认支持集，接着写清对数单位与KL方向，最后讨论模型集合和有限样本。若这些都明确，交叉熵分解只是几行代数；若其中一个含糊，再多小数位也不能挽救结论。

## 练习

1. 用bit与nat手算主例的 $H(P)$ 、 $H(P,Q)$ 与 $D(P \parallel Q)$ ，列出每个状态贡献。
2. 对 $P=(1/8, 1/8, 1/4, 1/2)$ ，计算熵；为它写一个平均长度等于熵的前缀码。
3. 不引用Jensen，写出 $\ln t \leq t-1$ 的证明，并指出等号条件。
4. 补齐KL非负证明中的支持集求和和两个等号条件；再推出 $H(P) \leq \ln K$ 。
5. 对 $P=(1/2, 1/2, 0)$ 、 $Q=(1, 0, 0)$ ，分别求两方向KL、 $H(P,Q)$ 及共同零状态的贡献。
6. 解释主例为何两方向恰好相等；用二分类反例推翻一般对称性。
7. 验证 $P=(0.1, 0.9)$ 、 $Q=(0.5, 0.5)$ 、 $R=(0.9, 0.1)$ 违反KL的三角不等式。
8. 手算三个受限候选的正反KL并选最优；把P加入后会怎样？这是否证明一般的模式寻求定律？
9. 对标签[A,A,B,C]写出均值负对数似然与经验交叉熵的等式，说明哪些步骤不需要独立、哪些解释需要。
10. 对单条标签B、预测 $Q=(1/4, 1/4, 1/2)$ ，写出one-hot交叉熵；解释它的熵为0为什么不证明真实条件熵为0。
11. 计算罕见事件实验中100次完全没观察到事件的概率，解释经验0与总体无穷为何可以同时出现。

12. 推导 $Q_\varepsilon$ 的两个方向KL的端点行为；说明把极小值改成0会造成什么变化。
13. 对三状态零模型做 $\alpha=0.02$ 均匀混合平滑，核对归一化和交叉熵；说明直接截断不归一化的问题。
14. 写出一个能检测状态顺序错误的测试设计；说明单看数组长度为何不够。

## 来源与方法边界

[1] Claude E. Shannon, 1948, [A Mathematical Theory of Communication](#), 第6节核对离散熵、对数底与不确定性性质。本文概率、码字与图独立设计，不转载原图。

[2] Ian Goodfellow、Yoshua Bengio、Aaron Courville, [作者公开的第3章](#), 第3.13节核对KL方向、交叉熵分解、零项约定，以及受限近似族的重要性。本文有限三候选比较自行逐项计算，不复制其连续Gaussian示意图。

[3] Python官方[math文档](#)，核对log、fsum与无穷接口；Python官方[decimal文档](#)，核对独立高精度ln接口。接口核对不等于已验证任意平台的安装或数值表现。

所有引用均只用于核对定义和工具语义；推导、手算、代码、图与练习为本讲独立撰写。来源访问状态和具体核对范围另记于source\_checks.md。