

经验风险与泛化详解

一 从联合质量计算风险

第1题： 对每个 x ， $P(X=x)=1/8$ 。前四个 x 有 $P(x,1)=1/80$ 、 $P(x,0)=9/80$ ；后四个相反。每个 x 的两质量和 $10/80$ ，八组和 1 。预测 0 时只在 $Y=1$ 出错，贡献 $\eta(x)/8$ ；预测 1 时只在 $Y=0$ 出错，贡献 $[1-\eta(x)]/8$ 。对八个 x 相加即正文风险公式。不能把 16 个不同组合各赋 $1/16$ ，因为条件概率并不均匀。

第2题： 对每个输入，总体多数方向的条件错误率为 0.1 ，反向为 0.9 ，增加 0.8 。输入质量 $1/8$ ，故一个位置反向增加 0.1 ， k 个位置增加 $0.1k$ 。 h^* 八个位置都选多数方向，风险 0.1 。常数 0 错后四个多数方向，风险 0.5 ；常数 1 错前四个，同样 0.5 。所有可能规则中的最小错误并非 0 ，因为标签含噪声。

二 三个训练解

第3题： 固定 D 为 $(0,0)$ 、 $(1,1)$ 、 $(4,1)$ 、 $(5,0)$ 。常数 0 错中间两条，常数 1 错首尾，训练风险都 $1/2$ ，按字典序选 0 。阈值 $t=1$ 的预测 $(0,1,1,1,1,1,1)$ ，只错 $x=5$ ，训练 $1/4$ ；与 h^* 在 1 、 2 、 3 处不同，总体 $2/5$ 。

查表各输入局部ERM： $x=0$ 选 0 、 $x=1$ 选 1 、 $x=4$ 选 1 、 $x=5$ 选 0 ；其余未见位置按并列选 0 ，得 $(0,1,0,0,1,0,0)$ 。训练为 0 ，与 h^* 在 1 、 5 、 6 、 7 处不同，总体 $1/2$ 。查表训练为 0 依赖当前数据中没有同一 x 的冲突标签；不能声称任何噪声训练集都能在这个有限输入表上零误差。

第4题： $t=4$ 在 $x=1$ 与 5 这两条少数标签上出错，训练风险 $1/2$ ； $t=1$ 训练风险 $1/4$ ，所以经验优化差为 $1/4$ 。总体风险差 $R(h_4)-R(h_1)=1/10-2/5=-3/10$ 。它为负说明两个目标不同，不说明随机返回训练坏解就会更好；若返回另一条很差规则，总体也可能更差。实践仍需清楚目标和独立评价。

三 选择效应与误差分解

第5题： 单样本训练时，常数类ERM直接复制观察标签，训练错误永远 0 。主例无条件标签均衡，所以无论返回 0 还是 1 ，新样本错误概率都 $1/2$ 。对预先固定的 $h=0$ ，训练错误 Y 期望 $1/2$ ，确实无偏；但 $\hat{h}_D$ 由同一个 Y 选择，损失 $1\{\hat{h}_D \neq Y\}$ 恒为 0 。不能把固定 h 的期望结论未经处理地代入依赖 D 的 $\hat{h}_D$ 。

第6题： $R^*=1/10$ 。常数类最优 $1/2$ ，所以近似误差 $2/5$ ，所选常数仍达类内最优，估计误差 0 。阈值类包含 h_4 ，所以近似 0 ；所选 h_1 风险 $2/5$ ，估计误差 $3/10$ 。查表类也包含 h^* ，近似 0 ，当前选择风险 $1/2$ ，估计误差 $2/5$ 。

固定数据下常数规则训练与总体同为 $1/2$ ，泛化差距 0 ，却比最优风险高 $2/5$ 。泛化差距描述训练评价的代表性，不能代替“总体表现是否足够好”。扩大嵌套 H 不会使类内最优总体风险上升，也不会使最小训练风险上升，但所选模型的总体风险可上升或下降。

第7题： 对 H 内每条规则有 $R \leq \hat{R} + \epsilon_D$ 和 $\hat{R} \leq R + \epsilon_D$ 。第一步应用于实际解 $\tilde{h}$ ；第二步用 $\hat{R}(\tilde{h}) = \min_H \hat{R} + \delta_{\text{opt}} \leq \hat{R}(h_H^*) + \delta_{\text{opt}}$ ；第三步应用于总体类内最优 h_H^* 。相减 R^* 得到：

$$R_P(\tilde{h}) - R^* \leq [R_P(h_H^*) - R^*] + \delta_{\text{opt}} + 2\varepsilon_D.$$

必须同时约束实际数据选出的 $\tilde{h}$ 与作为比较对象的 h_H^* ，不能仅证明任意一条“先固定后抽样”的 h 平均无偏就结束。本例阈值 $\varepsilon_D=11/20$ ，ERM的 $\delta_{\text{opt}}=0$ ，近似0，界11/10明显松；真正超额风险是3/10。界不是等式，也没有因为写出它就知道真实未知总体的 ε_D 。

第8题： 对固定 h ，单样本0-1损失均值 R 、方差 $R(1-R)=1/4-(R-1/2)^2 \leq 1/4$ 。 n 个IID平均的方差 $\leq 1/(4n)$ 。Chebyshev给超过 ε 的概率 $\leq 1/(4n\varepsilon^2)$ 。 H 有限时，把“存在至少一条偏差大”的事件写成 $|H|$ 个事件的并集，概率不超过各事件概率相加，得 $|H|/(4n\varepsilon^2)$ 。并集界不要求候选失败事件互相独立。

该界大于1时只能用平凡概率上界1，不能宣称失败概率大于100%。对无限 H 不能直接把候选数代入，需要其他理论。使用更锋利的集中界能改进数值，但不能取消采样与模型选择假设。

四 保留独立评价

第9题： 训练 D 决定每类模型；验证 V 决定选择哪类；测试 T 在决定后评估冻结规则。选中模型已依赖 V ，故其验证误差可能利用 V 的偶然偏低，不是同等独立证据。模型若从未读取 T 且 T 与 D 、 V 独立同分布，则条件于这个冻结模型，测试平均对其总体风险无偏。反复看测试后修改模型会破坏这一条件。

本课总体真值是生成器审计，不进入fit或selected。真实研究不能用未知总体风险选超参数。样本文件不同也不能自动证明独立；同一实体跨集合、时间倒置或全量预处理可能泄漏，须在021具体检查。

第10题： 常数类 n 从8到128，平均训练错误由约0.36781上升到0.46435，总体一直0.5。小样本时训练多数票更容易利用偶然偏斜；样本增长使这种乐观减少，不是算法变坏。查表小样本训练更低而总体更高， $n=128$ 与阈值几乎一致，表明本有限问题的容量代价与样本量有关，不能推出任何任务的统一规模法则。

800次中的精确总体风险是随机训练集产生的800个数。其平均的MCSE用这800个数的样本SD除 $\sqrt{800}$ ，例如 $n=8$ 阈值约0.00384。它不是某一个冻结模型的性能区间，也不是该模型256条测试数据的SE，更不包含真实分布不匹配。

五 平方损失的偏差方差

第11题： 固定 x ，记 $m=E_D[f_D(x)]$ ， $\eta=E[Y|x]$ 。将 f_D-Y 拆成 $(f_D-m)+(m-\eta)-\epsilon$ 。三项平方展开后，第一个中心化项和 ϵ 均值为0；新标签独立于 D ，所以它们的乘积期望也为0；与常数 $m-\eta$ 的交叉项同样消失。剩下预测方差、偏差平方与条件标签方差。

$x=4$ 处 $\eta=9/10$ ，噪声方差 $\eta(1-\eta)=9/100$ 。只用一个同 x 训练标签预测，平均为 η ，偏差0，预测方差 $9/100$ ，总平方风险 $18/100=9/50$ 。预测恒为 $1/2$ 时，偏差为 $-2/5$ ，平方 $4/25$ ，预测方差0，总风险 $4/25+9/100=1/4$ 。知道 η 时只剩 $9/100$ 。

此处的两层随机性分别是训练标签和未来标签，若直接拿同一个标签既拟合又评价，平方误差可以为0，独立性消除交叉项的论证不再适用。这个分解针对平方损失，不能原样套给0-1错误率、F1或所有生成指标。

六 目标改变时重新说清总体

第12题： 冻结 h_4 。源条件多数方向与它一致，各 x 错误0.1，风险0.1。目标条件概率反转后每个 x 错误0.9，输入权重仍 $1/8$ ，所以目标风险0.9。源目标已最优，下降源经验损失不是这个机制变化的解释。

只改变输入质量时，学出的 h_1 在 $x=1, 2, 3$ 错误率0.9，这三类相对质量各3，共9；其余五类质量各1，错误率0.1。总质量14，总风险 $(9 \times 0.9 + 5 \times 0.1)/14 = 8.6/14 = 43/70$ 。前者改 $P(Y|X)$ ，后者改 $P(X)$ 。现实原因未知时需更多证据，不能把合成反例当成诊断结论。

完成本单元的标志是能指出哪个量随机、哪个规则已冻结、哪个分布是目标，以及每一项计算允许依赖哪些数据。只把训练曲线下降解释为“已经泛化”，仍未回答开头的问题。