

021 指标拆分与可信评价详解

本文件给出正文 14 题和实验 A 至 D 的完整解答。先完成手算，再核对代码。计数约定统一为真实类在行、预测类在列；二分类正类为 1；本讲 zero_division=0 只负责数值填充，未定义状态单独保留。

1 四格计数与条件分母

阈值 0.5 得预测 (1, 1, 1, 1, 0, 0, 0, 0)。第 1、3 条为 TP，第 2、4 条为 FP，第 5 条为 FN，第 6、7、8 条为 TN。四格和为 $2 + 2 + 1 + 3 = 8$ 。

$\text{precision} = 2 / (2 + 2) = 1/2$ ，分母是四次告警； $\text{recall} = 2 / (2 + 1) = 2/3$ ，分母是三个真实事件； $\text{F1} = 4 / (4 + 2 + 1) = 4/7$ ；准确率 $= (2 + 3) / 8 = 5/8$ 。平均代价 $= (3 \times 1 + 2) / 8 = 5/8$ 。准确率与本例平均成本数值偶然相同，概念不同，不能混用。

2 失衡的全负基线

TP=0、FP=0、FN=5、TN=95。准确率 $= 95 / 100 = 0.95$ ； $\text{recall} = 0 / 5 = 0$ ； $\text{F1} = 0 / (0 + 0 + 5) = 0$ 。precision 分母为 0，所以未定义，程序填 0 并标记 precision。标签全集里明明有正类，不能把“始终不告警”说成解决了告警任务。

3 F1 推导及边界

当 $\text{TP} > 0$ 时， $1/P = (TP + FP)/TP$ ， $1/R = (TP + FN)/TP$ 。相加得 $(2TP + FP + FN)/TP$ ，将其倒数乘 2，得 $2TP/(2TP + FP + FN)$ 。

当 TP=0、FP+FN>0 时，直接使用计数式得 0，不使用除以 TP 的中间式。当 TP=FP=FN=0 时分母为零，F1 无定义；zero_division 约定必须披露。若整个评价集为空，连准确率都无定义，本程序直接拒绝空输入。

4 更改业务代价后重新选择

若事先规定漏报成本 1、误报成本 3，各阈值总成本依次为：

阈值	新总成本	推导
0.3	9	$1 \times 0 + 3 \times 3$
0.4	6	$1 \times 0 + 3 \times 2$
0.5	7	$1 \times 1 + 3 \times 2$
0.7	4	$1 \times 1 + 3 \times 1$
0.9	2	$1 \times 2 + 3 \times 0$

新协议选择 0.9。这不是原规则犯错，而是目标改变。成本应来自任务后果与资源要求，而非看到测试集哪一类错误多就重新定义。若成本确实发生外部变化，可建立新版本，但原测试已经是已知资料，下一轮独立评价需另作安排。

5 微 F1 与准确率

单标签且全部类别纳入时，令正确数为 c ，每条正确记录给某类贡献一个 TP，故 $\sum TP_k = c$ 。每条错误记录同时带来一类 FP 与另一类 FN，故 $\sum FP_k = \sum FN_k = n - c$ 。

$$F_{\text{micro}} = \frac{2c}{2c + (n - c) + (n - c)} = \frac{c}{n}.$$

本例 $c = 8 + 1 + 1 = 10, n = 13$ 。多标签时一条记录可以贡献多次 TP/FP/FN；只统计类别子集时一次错误也未必在纳入的类中同时出现 FP 和 FN。两种情况均不能直接套此等式。

6 宏 P 与宏 R 的调和平均不是宏 F1

逐类 precision 为 $(1, 1/2, 1/3)$ ，宏 P 为 $11/18$ 。逐类 recall 为 $(4/5, 1/2, 1)$ ，宏 R 为 $23/30$ 。再取调和平均得：

$$\frac{2(11/18)(23/30)}{11/18 + 23/30} = \frac{253}{372} \approx 0.6801.$$

逐类 F1 是 $(8/9, 1/2, 1/2)$ ，平均为 $17/27 \approx 0.6296$ 。平均与非线性比值操作不能任意交换。两种数可定义为不同汇总，只有后一种是本讲定义的宏 F1。

7 缺失类别

新类 3 的 TP、FP、FN 均为零，precision、recall、F1 均未定义。取 zero_division=0，四类宏 F1 为 $(8/9 + 1/2 + 1/2 + 0)/4 = 17/36 \approx 0.4722$ 。

取 zero_division=1，结果为 $(8/9 + 1/2 + 1/2 + 1)/4 = 13/18 \approx 0.7222$ 。增加缺失类不改变任何原始计数，所以完整单标签微 F1 仍为 $10/13$ 。这说明报告不能只列一个宏平均数，必须同时列 label 集合、缺失类和计算约定。

8 回归手算与平移

误差为 $(1, 0, -2, 1)$ ，平均带符号误差为 0；绝对误差和为 4， $MAE=1$ ；平方和为 6， $MSE=1.5$ ， $RMSE=\sqrt{1.5} \approx 1.2247$ 。真实均值为 5，离均差平方和为 $9 + 1 + 1 + 9 = 20$ ，故 $R^2 = 1 - 6/20 = 0.7$ 。

同时给目标和预测加 100，误差不变，评价均值也加 100，离均差不变，因此上述指标全部不变。若只给预测加 100 则不是换原点，而是系统性预测偏差，结果当然改变。

9 负 R^2 和常数目标

取 $y = (0, 1)$ ，预测 $(10, 10)$ 。平方误差和为 $100 + 81 = 181$ ，真实均值 0.5，离均差平方和为 0.5，所以 $R^2 = 1 - 181/0.5 = -361$ 。这个规则比评价集均值基准差得多。

$y = (5, 5)$ 时分母为零，不能直接作比值。本讲返回 null 与说明，无论预测是否完美。常数目标上仍可报告 MAE、MSE 等绝对误差。其他软件可能为搜索便利将完美预测替换成 1、不完美替换成 0，对照时需明确配置，而非认定有一种默认值等于原公式。

10 校准分箱算术

箱	概率	标签	平均概率	正例频率	绝对差
[0,0.25)	0, 0.2	0, 0	0.1	0	0.1
[0.25,0.5)	0.25, 0.45	1, 0	0.35	0.5	0.15
[0.5,0.75)	0.5, 0.65	1, 0	0.575	0.5	0.075
[0.75,1]	0.75, 1	1, 1	0.875	1	0.125

四箱权重都是 1/4，所以 $ECE=(0.1 + 0.15 + 0.075 + 0.125)/4 = 0.1125 = 9/80$ 。边界归属保证没有重复或遗漏。

Brier 的八项平方误差分别为 0、0.04、0.5625、0.2025、0.25、0.4225、0.0625、0，总和 1.54，除以 8 得 0.1925，即 77/400。ECE 与 Brier 不是同一个量，不能相互当作计算核验式。

11 相同 precision 不同概率承诺

对 $(1, 0, 1, 0)$ ，四个概率都为 0.6 或都为 0.9，阈值 0.5 都产生四次告警，其中两次为真，precision=1/2。前一组的平均预测概率与频率差为 0.1，后一组为 0.4，Brier 分别为 0.26 和 0.41。

这里能确定的是这四条数据上的概率误差不同。样本小，且构造例没有总体抽样过程，因此不能用它证明某个真实系统的总体校准优劣。

12 实体与时间拆分

按实体把 A 的三条放训练、B 放验证、C 放测试，实体互斥，但各部分都包含时点 1、2、3。它适合检验这些抽样条件下对新实体的表现，不能证明前推时间的有效性。

按时点把 1 放训练、2 放验证、3 放测试，时间先后分离，但 A、B、C 都跨集合重复。它可能适合已知实体的未来记录，不能评价全新实体。

一个同时不合格的按行拆法是训练 {A1,B2,C3}，验证 {A2,B3,C1}，测试 {A3,B1,C2}。三部分都包含 A、B、C，也都混有时点 1、2、3。记录 ID 不重复仍不足以证明信息隔离。

13 复制记录不创造独立证据

原测试 A 组有 TP=2、FN=0；B 组 TP=0、FN=1。把 B 的整组四条复制十遍，以十份替代原来一份，A 仍有四行，B 变为四十行。总体 TP=2、FN=10，逐行 recall 从 $2/3$ 变为 $2/12 = 1/6$ 。

这只改变行权重。原先 B 组所代表的实体和事件并未增加，复制的观察完全依赖原数据，不能把它当成更多独立证据。若是在原一份之外再额外复制十份，B 共十一份，recall 会变为 $2/13$ ；报告必须说明“十遍”的具体含义。

14 测试后的调整如何报告

保留最初冻结结果，注明其方案版本。改阈值后的结果标为“使用原测试集进行的探索”，不可只保留最好的那一个并叫最终测试。随后冻结新方案，在新收集或先前未使用且适合目标的数据上再评价。若没有新数据，诚实报告独立证据尚缺，不通过改文件名或重新随机划分已反复查看的数据来宣称恢复独立性。

实验 A 比较符号

阈值 0.5 下本例没有分数恰好为 0.5，因此该阈值的计数不变；阈值 0.4 下第五条分数恰为 0.4 且标签为 1，用严格 $>$ 会把它从 TP 改为 FN，成本从 2 变为 5。其它候选阈值也可能对应相等分数。结论不是“比较符号总会影响结果”，而是边界语义须固定并测试。

实验 B 冻结后的测试结论

阈值 0.4 下主测试前四项判正，产生 TP=2、FP=2、FN=1、TN=3；在八条合成测试记录、三个真实示例中找到了两个，recall=2/3；四次告警中两次为真，precision=1/2；F1=4/7，平均成本=5/8。

若固定标签而所有分数不增加，正预测集合不会扩大，TP、FP 都不增加，FN、TN 都不减少；具体改变取决于是否跨过阈值。主验证与测试标签、实体和时段是两套记录，不能将它们当成逐条配对的干预实验。冻结后不能为了让结果好看再选阈值。

实验 C 改为两个箱

$[0, 0.5)$ 包含前四项, 平均概率 $(0 + 0.2 + 0.25 + 0.45)/4 = 0.225$, 正例频率 $1/4=0.25$, 绝对差 0.025 。 $[0.5, 1]$ 包含后四项, 平均概率 $(0.5 + 0.65 + 0.75 + 1)/4 = 0.725$, 频率 $3/4=0.75$, 差也是 0.025 。新 $ECE=0.025$ 。

原先不同小箱中方向相反的偏离, 在大箱里部分抵消, 导致 ECE 降低。这不是增加了预测信息, 也不能说明概率质量因换箱而改善。Brier 仍为 0.1925 , 因为它不依赖这些分箱。

实验 D 新实体未来记录

新实体与未来时段是两个要求。主实验同时使用互斥实体和严格递增的时间区间, 得到 $8/8/8$ 行、 $4/4/4$ 实体。九条 panel 数据只能分别展示两种拆分, 不能在不丢弃记录且按整实体划分的同时, 形成三个时间严格先后分离的非空集合。

主实验的每实体两行仍可能相关; 没有建模标签延迟、滚动特征窗口、机器类型漂移或目标人群抽样。通过隔离检查是必要的协议检查, 不是总体有效性证明。需要在真实任务中先补全这些信息, 再设计真正的评价样本。