

022 练习与实验详解

所有结果针对正文合成设计；答案中的区间计算不自行证明抽样假设成立。需要同时读计算步骤与适用条件。

1 三个目标

固定D、T时，多种子估计的是 $E_S[L_A - L_B \mid D, T]$ ，只反映此固定数据条件下训练随机性的平均效果。固定模型、重采测试实体时，估计两个冻结模型在目标实体总体上的评价差异；训练过程没有重复。重采数据并重新训练时，目标包含数据与训练的联合变化。前者的种子SE没有估计数据抽样部分；把它解释成第三个目标会遗漏不确定性。

2 配对方差的推导

令 $A' = A - EA$ 、 $B' = B - EB$ 。则 $E[(A' - B')^2] = E[(A')^2] + E[(B')^2] - 2E[A'B']$ 。这是单行方差式，不需要行内独立。再写均值的方差为 $n^{-2} \sum_i \sum_j \text{Cov}(d_i, d_j)$ ；只有不同行独立（或协方差确为0且相应条件足够）时交叉项消失。同分布使每项方差相同，得到 σ_d^2/n 。负的行内协方差使 $-2 \text{Cov}(A, B)$ 为正，因此可能比独立两组的方差和更大。

3 手算与单位

差异之和16，均值2；离差平方依次为 (0, 4, 4, 16, 16, 4, 0, 4)，总和48。故 $s_d^2 = 48/7$ ， $s_d = \sqrt{48/7}$ ，均值标准误 $\sqrt{6/7} \approx 0.92582$ 。A的均值30，B的均值28，所以绝对下降2个百分点，相对A均值下降 $2/30 = 1/15 \approx 6.67\%$ 。这是“两个均值的相对变化”，不等于逐种子相对变化再平均。

4 样本恒等式与非法重配

样本离差满足 $d_i - \bar{d} = (a_i - \bar{a}) - (b_i - \bar{b})$ ，平方求和再除以 $n - 1$ ，得到 $s_d^2 = s_A^2 + s_B^2 - 2s_{AB}$ 。代入 $(450 + 738 - 2 \times 570)/7 = 48/7$ 。分别排序不改变两列均值，却改变哪些A/B属于一行，因而改变协方差与差异分布。真实配对身份由设计确定，不能为了缩窄SE在观察后重排。

5 区间的移项及限制

若标准化统计量满足 $P(-c \leq (\bar{d} - \mu)/SE \leq c) = 0.95$ ，且SE为正，则乘SE、再移项得到 $P(\bar{d} - cSE \leq \mu \leq \bar{d} + cSE) = 0.95$ 。正态总体、独立差异时，用样本标准差形成的比值是 t_{n-1} ，所以八行用自由度7的临界值；2.365是该临界值的表格舍入。结果为 $2 \pm 2.365\sqrt{6/7}$ ，约 $[-0.18956, 4.18956]$ 。

用1.96给 $[0.18539, 3.81461]$ ，但这是另一条近似路径。t的有限样本精确保证要求独立同分布正态差异、正方差与准确临界值；不是“八个数代入就必有95%覆盖”。若观察值全相同，程序返回点区间作为算术结果，不能由此断言真实方差为零。频率学派95%描述重复抽样方法，不是参数的后验概率。

6 重采样索引

索引(3,3,0,4,1,6,2,7)对应差异 $(6, 6, 2, -2, 4, 2, 0, 0)$ ，总和18，均值9/4。种子3被重复选中两次，是在经验分布下有放回抽样；它仍是原来的那条观察，不是新增一次训练。若分别给A和B抽不同索引，就改变了配对结构。

7 条件bootstrap方差

固定原数据后，一个索引均匀取0到 $n - 1$ 。所以 $E_* d_I = \sum_i d_i / n = \bar{d}$ ，而 $\text{Var}_*(d_I) = \sum_i (d_i - \bar{d})^2 / n$ 。独立抽n次再取平均，方差再除n，得到 $(n - 1)s_d^2 / n^2$ 。本例是 $7(48/7)/64 = 3/4$ ； $s_d^2/n = 6/7$ 使用了不同的有限样本修正。两者差为 $3/28$ ，并非程序浮点误差。

8 计数卷积

一轮抽样有n个等概率位置，即使两个位置的值相同，它们仍是两种选择。对每个已有和，再接一个位置，就把长度k的有序抽样扩成长度k+1。把相同和合并只减少存储，不丢计数；总计数每轮乘n，最终 n^n 。八行得到16777216种，精确2.5%/97.5%离散分位是1/4和15/4。它穷尽经验分布的重采样，消除了Monte Carlo误差，却没有证明经验分布接近真实总体。

9 稀有事件的精确覆盖

全零概率是 $0.99^8 = 0.9227446944279201$ 。全零时区间[0,0]漏掉均值0.2，因此覆盖最多 $1 - 0.99^8 \approx 0.07725531$ 。进一步， $K \sim \text{Binomial}(8, 0.01)$ ；给定K，重采样稀有数 $K^* \sim \text{Binomial}(8, K/8)$ 。逐个算离散分位，只在K=1或2时覆盖。

$$P(\text{覆盖}) = 8(0.01)(0.99)^7 + 28(0.01)^2(0.99)^6 \approx 0.07720137225.$$

该值小于上界，因为K≥3的少数样本也不覆盖。增大bootstrap次数无法让全零经验分布出现20。需要讨论更多真实独立观察、对稀有机制的先验知识或有相应保证的不同区间方法，不能仅说“再重采样一百万次”。

10 实体复制及权重

四实体均值为1，平方离差为 $(9, 1, 1, 9)$ ，总和20，所以实体级样本方差20/3、均值方差5/3。复制八倍后32行均值仍为1，平方离差和160；错误独立公式给样本方差160/31、均值方差5/31。方差估计比值为31/3，标准误比值为 $\sqrt{31/3}$ 。

若实体大小不同，逐实体均值平均是实体等权目标，所有行总损失除总行数是行等权目标，数值可能不同。整组bootstrap应在每次抽到实体后按照事先声明的目标重新聚合，不能无声地换目标。对本例等概率四值总体，真实方差5；四独立实体均值方差5/4，32独立实体才是5/32。这一真实比值8与前述估计比值不同。

11 嵌套数据和种子

求所有 $d_{rs} = \mu + U_r + \varepsilon_{rs}$ 的平均时，同一个 U_r 被加S次，因此其系数为1/R，不是1/(RS)。独立、零均值条件使交叉协方差消失，得到 $\sigma_U^2/R + \sigma_\varepsilon^2/(RS)$ 。增加S不能消除第一项。若只有一份固定数据，观察到的种子变动通常只约束条件训练变动；也无法仅凭种子差异估计 σ_U^2 。真实相关或交互结构不同，应重建方差模型，不把这条简单公式当万用定律。

12 多重比较

独立时全部不误报概率为 0.95^{20} ，至少一次误报约0.64151408。独立性不是默认事实：同一数据集上的候选往往相关。无需独立性的并集界是 $P(\cup_j E_j) \leq \sum_j P(E_j)$ ；每项有效误报上界为 α/m 时，家族上界为 α 。若单项方法本来就不具名义覆盖，或研究者只登记有利的一部分比较，这个计算不能自动提供所声称的保护。

13 选择与复测

所有验证噪声都为-1的概率是 2^{-m} ；其余情况最大值为+1。因此期望为 $(-1)2^{-m} + 1(1 - 2^{-m}) = 1 - 2^{1-m}$ 。独立复测对任一所选候选的条件均值都是0，按条件期望再平均仍为0。选择使验证噪声偏正，并不创造方法效果。

该实验没有定义由统计检验计算的p值，也没有以0.05为拒绝门槛；不能把它的正最大值比例称为显著性误报率。正文另一幅多重检验概率曲线采用“每个检验有效且独立”的不同假设，两者共同说明挑选风险，但数值含义不同。

14 等效与消融

区间[-10,10]含0，也容许大幅伤害和改进，故“不显著”不足以证明等效。预定等效范围±3后，若适当有效区间是[-0.5,0.5]，才支持效果较小的有条件结论。主表t计算的[-0.18956,4.18956]既跨0又越过3，不能确认达到实际改进门槛，也不能确认落在±3内。

P在Q关闭时的损失减少为10-8=2；Q开启时为9-4=5；交互对比为5-2=3。P的效果依赖Q，不能用一个脱离上下文的“贡献分”概括。四格本身没有重复和不确定性；合理归因还需检查数据、预算、优化与调参是否一致，以及删除组件是否改变其他因素。支持范围限于相应受控协议，不等同普遍机制定律。

实验A：人为恒差与负协方差

可取 $A=(10,20,30,40)$, $B=(8,18,28,38)$ 。差异恒2，配对样本方差为0，但两列各自变化。这个零值是人为表的事实，不能说明真实总体方差已知为0。

反例取 $A=(0,10,20,30)$, $B=(30,20,10,0)$ 。两列样本方差均 $500/3$ ，协方差为 $-500/3$ ；差异为 $(-30,-10,10,30)$ ，方差 $2000/3$ 。配对方差和为独立公式方差和 $1000/3$ 的两倍。因此正协方差是常见配对增益的原因，不是“有配对”三个字本身。

实验B：改变Monte Carlo次数

应保留原config，分别另存200次与12000次输出，记录相同的种子与分位数定义。可比较每个可能均值的相对频率与精确计数质量。一般更多重复减少Monte Carlo波动，但单次端点误差不保证严格单调，离散端点可能多次完全不动。原始独立配对仍然只有八个，没有变成12000个。

实验C：完整有限覆盖核对

CSV九行按 $K=0$ 到8覆盖全部互斥事件。把sample_probability按Fraction求和应恰为1；将它乘covers_true_mean再求和，应恰为 $38600686125441/5000000000000000$ 。与实验中4000次经验bootstrap不同，这张表的概率来自指定真实Bernoulli机制，是精确抽样覆盖计算。

实验D：枚举三个候选

8个等概率 ± 1 向量中，只有 $(-1,-1,-1)$ 的最大值为 -1 ，其余7个为 $+1$ ，平均 $6/8=3/4$ ，与 $1 - 2^{1-3}$ 一致。对每个向量分别配独立复测 -1 和 $+1$ ，16种等概率组合的复测和为0。每个候选都没有真实优势，只是在验证中挑过了。

一段完整报告可写：固定同一教学数据与八个预定种子配对，B相比A的平均错误率下降2个百分点，种子差异SE约0.92582；舍入t计算区间约 $[-0.18956, 4.18956]$ ，percentile经验bootstrap区间 $[0.25, 3.75]$ 。八行是人工合成例，未验证正态抽样条件；未量化数据重采样的不确定性，且没有达到“稳定超过3个百分点”的证据。两区间不一致须连同条件报告，不能择优宣称方法获胜。