

线性模型训练闭环详解

第023单元 正文与实验完整答案

以下采用正文的残差符号 $r = \hat{y} - y$ ，目标为半MSE，参数偏置放最后。若使用相反残差符号，梯度式也必须相应换号；只换一个地方会把下降写成上升。数值末位依浮点实现可轻微变化，精确分数用于手算对照。

一 正文练习1至4

1 形状。 $n = 7, d = 3, p = 4$ 。数学上 $X: 7 \times 3, A: 7 \times 4, \theta: 4 \times 1, y, r: 7 \times 1, g: 4 \times 1$ ；本讲NumPy相应为 $(7, 3), (7, 4), (4,), (7,), (7,), (4,)$ 。偏置也要训练，所以 $p = d + 1$ 。若直接把每行最后一列当标签同时又放进 X ，就是另一种严重错误：目标泄漏进输入，形状正确仍可做错任务。

2 逐项求导。 对第 i 条样本， $r_i = \sum_k x_{ik} w_k + b - y_i$ 。固定训练数据， $\partial(r_i^2)/\partial w_j = 2r_i x_{ij}$ ， $\partial(r_i^2)/\partial b = 2r_i$ 。乘 $1/(2n)$ 后加上全部样本，得到 $g_{w_j} = n^{-1} \sum_i r_i x_{ij}$ 和 $g_b = n^{-1} \sum_i r_i$ 。 $X^\top r$ 的第 j 个分量正是 $\sum_i x_{ij} r_i$ ，故矩阵式只是分量式的压缩，没有额外假设。平均来自目标定义，不能在更新时凭记忆漏掉。

3 一步手算。 初始 $\hat{y}_0 = (0, 0, 0)^\top$ ， $r_0 = (1, -1, -3)^\top$ ， $L_0 = 11/6$ 。两个梯度是 $(-1 \times 1 + 0 \times (-1) + 1 \times (-3))/3 = -4/3$ ，以及 $(1 - 1 - 3)/3 = -1$ 。所以 $\theta_1 = (0, 0)^\top - (1/2)(-4/3, -1)^\top = (2/3, 1/2)^\top$ 。

逐行代入，预测为 $(-1/6, 1/2, 7/6)^\top$ ，减标签后残差为 $(5/6, -1/2, -11/6)^\top$ 。平方和为 $(25 + 9 + 121)/36 = 155/36$ ，除以 $2n = 6$ 得到 $155/216 \approx 0.717593$ 。若报告MSE则乘2，不能把0.717593直接与另一处完整MSE比较。

4 重复数据。 设原平方和为 S ，梯度分子为 $v = \sum_i a_i r_i$ 。复制5次后变成 $5S$ 、 $5v$ 与 $5n$ ，所以 $5S/(2 \cdot 5n) = S/(2n)$ 、 $5v/(5n) = v/n$ 。若使用总和和目标不除以 n ，目标和梯度都放大5倍；若只在代码中忘了除以 n ，就与声明的平均目标不一致。同一学习率下更新也放大5倍，原本合适的步长可能不再稳定。

二 正文练习5至9

5 常数基线。 写 $y_i = \bar{y} + (y_i - \bar{y})$ 并展开，有：

$$\frac{1}{n} \sum_i (c - y_i)^2 = (c - \bar{y})^2 + \frac{1}{n} \sum_i (y_i - \bar{y})^2,$$

因为 $\sum_i (y_i - \bar{y}) = 0$ ，交叉项为零。第一项非负且仅 $c = \bar{y}$ 时为零，证明均值是唯一最佳常数。主例训练均值为2.5，最佳常数训练MSE为 $2963/240 \approx 12.3458333333$ 。零预测MSE多出 $2.5^2 = 6.25$ ，因此为 $4463/240 \approx 18.5958333333$ 。使用零基线会夸大“利用输入”相对一个已经可以从训练标签学习的基线的收益。

6 损失缩放。 新目标 $M = 2L$ ，新梯度 $\nabla M = 2g$ 。希望参数变化仍为 $-\eta g$ ，应令新学习率 $\eta_M = \eta/2$ ，于是 $-\eta_M(2g) = -\eta g$ 。最小值对应的参数不变，并不代表使用同一学习率的训练轨迹也不变。

7 梯度检查。 非最优点能产生非零导数，比较符号、尺度与各坐标；只在最优点测可能让全零错误梯度“过关”。二次函数展开中，中心差分相减后常数项和二次项抵消，只留下 $2hg_j$ ，因此精确算术下没有截断误差。浮点仍会舍入，两次损失相近时相减会消减，极小 h 还可能无法改变参数。本讲缩放误差包含绝对尺度1，应同时看原始梯度与绝对误差。

8 同步与顺序更新。 一条样本下 $L = (w + b - 1)^2/2$ ，初始两个梯度均为-1。同步更新得到 $(0.1, 0.1)$ 。若先得到 $w = 0.1$ ，重算残差为-0.9，再更新偏置，得到 $(0.1, 0.09)$ 。后者不是原定义的一次全批次向量梯度下降；虽然本次也下降，不能用它证明同步实现正确。

9 步长。 $e_0 = b_0 - 1 = -1$ ，且 $e_t = (1 - \eta)^t e_0$ ，所以 $L_t = (1 - \eta)^{2t}/2$ 。步长0.5使误差每步减半；步长2使 b 在0与2之间交替，损失始终1/2；步长2.1使误差长度每步乘1.1，损失每步乘1.21。负梯度只控制一阶变化，实际有限步还需控制二次项。对一般设计矩阵，本讲的 $0 < \eta < 2/B$ 是一个足够小的保守条件，并非全部稳定步长的精确集合。

三 正文练习10至14

10 全局最优与唯一性。 若 $A^\top r = 0$ ，则 $g = 0$ ，对任意 Δ 都有 $L(\theta + \Delta) - L(\theta) = \|A\Delta\|_2^2/(2n) \geq 0$ ，故是全局最小。反过来，若某坐标导数非零，沿其反方向取足够小的步子可降低目标，故无约束可微最小点必须梯度为零。 $A^\top r = 0$ 只规定若干内积为零；样本空间中可以有不属于设计列张成空间的非零残差。

若 A 列满秩， $A\Delta = 0$ 只有零解，任意非零变化严格增加损失，参数唯一。列相关时存在非零零空间方向，沿它移动参数不改变训练预测。注意这只谈给定设计行上的预测；换到不满足相同列关系的新输入，不同参数可能给不同预测。

11 主例精确解。 在 $x_2 = \pm 1$ 的成对训练点中， $q = 0.2x_2(x_1 - 0.5)$ 关于 x_2 反号，所以 $\sum q = \sum x_1 q = 0$ 。又有 $\sum x_2 q = 0.4 \sum_{x_1} (x_1 - 0.5) = 0$ 。取 $(w_1, w_2, b) = (2, -3/4, 3/2)$ 时 $r = -q$ ，故 $A^\top r = 0$ 。三列独立：若 $ux_1 + vx_2 + c = 0$ 对全部网格点成立，同一 x_1 取两种 x_2 相减给 $v = 0$ ，两个不同 x_1 相减给 $u = 0$ ，继而 $c = 0$ ，所以解唯一。

平方偏差依次为 $25/4, 9/4, 1/4, 1/4, 9/4, 25/4$ ，总和 $35/2$ ； q^2 再乘 $1/25$ 与两个 x_2 ，得到 $7/5$ 。除以12就是训练MSE $7/60$ ，半MSE $7/120$ 。未建模的交互项有规律且不为零；继续同一模型训练不会把这一项消除。

12 重复特征。两个梯度相同，记为 h_t ，则更新后差值

$(w_{1,t} - \eta h_t) - (w_{2,t} - \eta h_t) = w_{1,t} - w_{2,t} = 6$ 。最优要求权重和为2、偏置为1，同时解得 $(4, -2, 1)$ 。最小范数参照为 $(1, 1, 1)$ 。二者对 $x_1 = x_2$ 的训练/同结构新输入预测相同。可比较预测、目标和梯度，不应强迫参数逐坐标相等。若测试输入破坏两列相同关系，则训练数据无法告诉我们哪个外推更合理。

13 验证低于训练。主例验证 x_2 仅为 ± 0.5 ，交互残差幅度相应缩小，且 x_1 网格也不同。误差较低可由这个已知机制解释；不是“训练一定比验证难”，也不是独立排除过拟合或泄漏的证据。数据构造、预处理、模型选择与执行路径需各自审查。只凭一个大小关系无法完成这些审查。

14 诊断顺序。

- 目标不降：核对残差符号、 $1/n$ 、学习率、同步更新、日志时点；先用三点手算与二次展开，后考虑增加轮数
- 非数或无穷：检查输入有限性、特征尺度、更新量、溢出的第一步；不要把非数替换为0继续训练
- 参数不同而预测相同：检查数值秩、重复/近重复列、初值中的零空间分量及最小范数约定
- 程序运行但MSE离奇：检查预测与标签shape、行ID对齐、半MSE与MSE混用、单位变化和评价拆分

修复后重新执行独立测试及Notebook，不能只截一张看似恢复的曲线作为验收。

四 实验A答案

A1的全部手算见练习3。A2输出轨迹第0行对应初始状态，第1行对应一次更新后的状态；参数与该行目标同时计算，避免一轮偏移。一般 T 轮保存 $T + 1$ 行，末行不再执行下一轮更新。

A3中 $\text{pred[:,None]} - y$ 是 3×3 矩阵：

$$\begin{bmatrix} 0 & -2 & -4 \\ 2 & 0 & -2 \\ 4 & 2 & 0 \end{bmatrix}.$$

九个平方之和为48，错误MSE为 $48/9 = 16/3$ ；正确逐条残差全为零。NumPy广播只保证形状运算规则相容，不知道哪些行是同一条样本。

五 实验B答案

B1训练均值为2.5，最佳常数的证明见练习5。B2必须使用这个已从训练学得的常数，对验证/测试重新算均值等于重新拟合。基线和模型应使用同一批评价样本、同一目标定义，不能给其中一方额外标签信息。

B3训练 x_1^2 平均为 $(4 + 1 + 0 + 1 + 4 + 9)/6 = 19/6$, x_2^2 平均为1, 偏置列平方平均也为1, 所以 $B = 31/6$ 。充分上界 $2/B = 12/31 \approx 0.387097$, 0.1小于它。由逐行不等式得到的 B 可能大于真正最陡方向的曲率, 因此0.387097不是本问题的精确发散边界。

六 实验C答案

C1梯度检查点为(0.4, -0.2, 0.7), 训练设计的平均二次系数为:

$$\frac{A^T A}{n} = \begin{bmatrix} 19/6 & 0 & 1/2 \\ 0 & 1 & 0 \\ 1/2 & 0 & 1 \end{bmatrix}.$$

把参数与最优参数之差 $(-1.6, 0.55, -0.8)$ 乘上该矩阵, 得解析梯度 $(-82/15, 11/20, -8/5)$, 约 $(-5.466666667, 0.55, -1.6)$ 。差分列应与之接近; 绝对误差是坐标差, 缩放误差除以 $\max(1, |g|, |g^{FD}|)$ 。默认最大缩放误差约 3.25×10^{-11} , 只衡量本次导数核对。

C2在这些非零参数附近, 10^{-100} 远小于浮点数的可分辨间距, `theta+h`与`theta`完全相同。程序应拒绝, 而非用相同的两次目标值制造零导数。C3显式求逆会额外放大数值困难且无法覆盖秩不足; 直接用最小二乘接口并核对数值秩更合适。返回的残差摘要有空数组的接口约定, 必须重算实际残差。

C4作者运行: 初始半MSE约9.297916667, 最终约0.05833333333333337, 参照约0.05833333333333329; 最终梯度范数约 6.58×10^{-13} 。全部301行的目标在浮点容差内不增, 训练预测最大差约 1.05×10^{-12} 。不要要求最终半MSE为0, 也不要仅凭曲线肉眼变平判断所有参数位都已精确。

C5线性模型的训练/验证/测试MSE分别是7/60, 9/320, 2/25; 训练均值常数对应2963/240, 1827/160, 3457/400。逐样本误差平方求和再除以各自样本数即可复算。合格结论例如: 在固定网格上, 该线性模型已达到最小二乘参照并优于训练均值常数; 保留的交互残差表明模型并未表达全部合成机制; 确定性拆分与小样本不构成未知总体泛化保证。

七 实验D答案与验收边界

D1取 $x=[0]$ 使权重不影响预测, 只剩偏置。步长0.5稳定缩小误差, 2振荡, 2.1增大, 递推见练习9。

D2权重差6保留, 参照选择不同, 见练习12。D3配置更改后的运行是合法自定义数值实验; 固定图/Notebook专门拒绝非默认配置及不匹配结果, 防止标签与数值脱节。可以自己写新的解释与图, 但不能静默替换固定图的依据。

D4测试中坏输入、计算溢出及序列化失败都在创建输出目录或改写旧文件之前触发; 符号链接目标和输入冲突也被拒绝。应观察到旧文件逐字节不变, 新目录不存在。路径防护不能覆盖其他进程在检查后突然更改文件、磁盘写入失败或电源中断; 本实验没有声称跨文件事务性。

验收还包括脚本的新进程执行、不同当前目录执行、真实InProcessKernel顺序执行, 并对四个结果文件逐字节比较。Notebook内嵌输出不是浏览器端安装测试; 实际Anaconda新环境、Jupyter浏览器UI、跨进程socket以及跨平台依赖安装仍需学习者在自己的环境验证。