

024 练习与实验详解

这里的梯度默认单例或明确写出的batch mean，无类别权重和忽略标签。所有概率结论先在精确数学下推导，再单独说明浮点实现。

1 sigmoid来自对数优势

$\log[p/(1-p)] = z$ 意味着 $p = e^z(1-p)$ ，所以 $p(1+e^z) = e^z$ ，得到 $p = 1/(1+e^{-z})$ 。z=log3给p=3/4。默认阈值0.5判为类1；阈值若由成本另定，硬决策可能不同。sigmoid输出不自动等于校准概率。

2 BCE与链式法则

Bernoulli质量为 $p^y(1-p)^{1-y}$ ，负对数为 $-y\log p - (1-y)\log(1-p)$ 。对p求导得 $-y/p + (1-y)/(1-p)$ ，再乘 $p(1-p)$ ，得到 $-y(1-p) + (1-y)p = p - y$ 。所以额外再乘一次 $p(1-p)$ 会错误缩放梯度；该因子已经被分母消去。

用 $\log p = z - \log(1 + e^z)$ 代回，也得 $\ell = \log(1 + e^z) - yz$ ；其导数直接是sigmoid(z)-y，两个路径相符。

3 二分类整步手算

z=0、p=1/2、损失log2。对w的梯度为 $(p-y)x = (-1, 1/2)$ ；对b为-1/2。更新 $w' = w - 0.2g_w = (0.2, -0.1)$ ， $b' = 0.1$ 。新z=2 × 0.2 + (-1)(-0.1) + 0.1 = 0.6， $p \approx 0.6456563062$ ，损失 $\log(1 + e^{-0.6}) \approx 0.4374879505$ 。不是只更新权重而漏掉偏置，也不是用新w计算一半梯度再更新剩余参数。

4 稳定数值表达

对y=1损失是softplus(-z)，y=0为softplus(z)。令a=(1-2y)z，写成max(a,0)+log1p(exp(-|a|))，指数输入不为正，又避免先求巨大softplus再相减。sigmoid按符号分支，避免exp(-z)上溢。

z=37时p可能舍入成1，直接p-1为0； $-\sigma(-37)$ 仍约-8.5330476257e-17。z=1000时exp(-1000)超出float64可表示的正数下限，稳定式也可能是0。它避免了可避免的上溢/抵消，没有消除表示范围限制。

5 平移与二类等价

$\exp(z_k + c) / \sum_j \exp(z_j + c)$ 中公因子 e^c 抵消，故概率不变。二类时 $p_1 = e^{z_1} / (e^{z_0} + e^{z_1}) = 1 / (1 + e^{-(z_1 - z_0)})$ 。给两个分数同时加常数没有可观察的概率变化；只有它们的差有意义。

6 三类损失、梯度与雅可比

指数比2:1:1给 $p=(1/2, 1/4, 1/4)$ 。标签0时 $\text{loss}=\log 2$ 、梯度 $(-1/2, 1/4, 1/4)$ ；标签1时 $\text{loss}=\log 4$ 、梯度 $(1/2, -3/4, 1/4)$ 。雅可比对角项为 $p(1-p)$ ，非对角为负乘积，因此

$$J = \begin{pmatrix} 1/4 & -1/8 & -1/8 \\ -1/8 & 3/16 & -1/16 \\ -1/8 & -1/16 & 3/16 \end{pmatrix}.$$

每行、每列和均为0；这与共同平移方向不改变概率相符。单例梯度也和为0。

7 软目标质量条件

令 $\ell = -\sum_k q_k \log p_k$ ，且 q 不随 z 变化。由 $\partial \log p_k / \partial z_r = \delta_{kr} - p_r$ ，有 $\partial \ell / \partial z_r = -q_r + p_r \sum_k q_k$ 。当总质量1时为 $p-q$ ；总质量 c 时为 $cp-q$ 。 q 非负且和为1才是一个概率目标。程序只支持硬标签，不允许任意实向量冒充合法类别编号。

8 全部shape与参数梯度

$\tilde{X} : (N, d+1)$ 、 $W : (d+1, K)$ 、 $Z/P/Q : (N, K)$ 、 $y : (N,)$ 、标量 L 。mean梯度 $G_Z = (P - Q)/N$ 。由 $\partial z_{ik} / \partial W_{jr} = \tilde{X}_{ij} \mathbf{1}\{k=r\}$ ，对样本求和得 $G_W = \tilde{X}^T G_Z$ ， $\text{shape}(d+1, K)$ 。偏置已在最后一行，不需再复制一份更新。

$\text{axis}=1$ 沿每例 K 类归一化，行和1。 $\text{axis}=0$ 沿不同样本归一化，列和1，比较对象换了。除 N 也只应发生一次，不能先把 G_Z 除 N 、参数梯度又除一次。

9 零参数第一步

初始每类概率1/3。第一特征总和0，类0/1/2和为-5、5、0，所以梯度 $(5/9, -5/9, 0)$ 。第二特征总和8，各类和1、1、6，给 $(8/3 - 1, 8/3 - 1, 8/3 - 6)/9 = (5/27, 5/27, -10/27)$ 。常数类各类计数均3，偏置梯度0。

乘负步长0.3，得到第一行 $(-1/6, 1/6, 0)$ 、第二行 $(-1/18, -1/18, 1/9)$ 、第三行0。对 $(-2, 0, 1)$ 点乘，logits为 $(1/3, -1/3, 0)$ 。这里只核对演示一步，不是把主实验0.25改为0.3。

10 sum、mean与正则

无权重、无忽略标签时 $L_{\text{sum}} = N L_{\text{mean}}$ ，梯度也乘 N 。故同一初值下 $W - (\eta/N) G_{\text{sum}} = W - \eta G_{\text{mean}}$ 。若两边都只加同一个 $\lambda \|W\|^2/2$ ，sum目标不再等于 N 倍mean目标；学习率除 N 后，sum方案的正则更新变成 $\eta \lambda W/N$ ，小于mean方案的 $\eta \lambda W$ 。要恢复整个目标的 N 倍关系，正则项也须相应缩放，不能只说“最优点总一样”。

11 决策边界与冗余

softmax单调保持同一行内的分数顺序， $\arg\max p$ 等于 $\arg\max z$ 。两类分界由 $z_a = z_b$ 给出 $(w_a - w_b)^T x + (b_a - b_b) = 0$ ，仍为直线/超平面。多个线性分界围成分段区域，但不等于任意曲线表达能力。

给全部列加同一参数向量，只增加每例相同的分数，概率不变。当前特征正则会影响共同特征移动的目标值，但共同偏置未被惩罚，仍有冗余；因此不能由概率确定唯一参数矩阵。

12 极端logit与对数域

减去1001得到(-1,0,-2001)。真实类2的log概率为 $-2001 - \log(1 + e^{-1} + e^{-2001})$ ，损失约2001.3132616875。概率 $\exp(\log p)$ 可能下溢成0，先 $\exp$ 再 $\log$ 便丢失了有限 $\log p$ 。稳定实现直接保存对数信息，梯度约(0.26894142, 0.73105858, -1)。不需要人为把 p 截断为 ϵ 来获得有限损失；截断会改变原目标。

13 错误双softmax

先令 $p = \text{softmax}(z)$ ，再将 p 当logits，得到 $\tilde{L} = -\log(\text{softmax}(p)_y)$ 。当正确类概率趋近1、两错误类趋近0时，第二次softmax给正确类 $e/(e+2)$ ，所以损失趋近 $\log(e+2) - 1 \approx 0.551444714$ ，而正确损失趋近0。

链式法则给 $\nabla_z \tilde{L} = J(p)^T (\text{softmax}(p) - q)$ ，多出了耦合雅可比，既不是原来的梯度也不只是一个固定倍数。第二次softmax仍保持排序，故分类可能看似正常；检查准确率不会发现损失语义已经变了。

14 可分一维例

对称四点产生两个相同的 $|x|=1$ 项和两个 $|x|=2$ 项，平均后即正文 $L(w)$ 。导数为 $-\frac{1}{2}\sigma(-w) - \sigma(-2w)$ ，对任何有限 w 严格负；有限 w 损失严格正， w 趋无穷时损失趋0。因此下确界0没有有限达到点。 $w>0$ 时分类已经全对，准确率不再变化，但损失和参数仍能变化。

这不证明所有无正则分类任务都发散，只证明本例的可分似然目标无有限最优权重。加正则会引起增大的惩罚项，改变目标；早停给一个有限迭代解，不等于原无正则问题突然有了有限零损失解。

15 曲率与下降

对方向 V ，单例分数方向 v 由线性点积给出。交叉熵沿该方向的二阶导数等于 p 权重下 v 的方差，非负并不超过 $\sum_k v_k^2$ 。逐类用Cauchy再求和，界为 $\|\tilde{x}\|^2 \|V\|_F^2$ 。平均样本加正则后可取 $L = 43/9 + 0.03$ 。

沿 $W - tG$ 积分二阶导数上界： $J(W - \eta G) \leq J(W) - \eta \|G\|^2 + L\eta^2 \|G\|^2/2$ 。当 $\eta < 2/L$ 时，非零梯度对应下降；这里 $2/L \approx 0.4160$ ，0.25满足充分条件。它控制带正则的总目标，不要求每步纯CE都下降；该界偏松，也没有证明所有更大步长必定失败。

实验A：浮点抵消

对 $y=1$, $z=37$ 时比较直接 $\text{sigmoid}-1$ 和补形式 $-\text{sigmoid}(-z)$ 。前者舍入为0, 后者保持负微小量。 $z=1000$ 两个式子都可能为0, 因为需要表示的量约 e^{-1000} 已超出float64范围。测试用100位Decimal与稳定库核对适当尺度, 但Decimal也有有限精度; 不能把某个参照的零无条件视为精确数学零。

实验B：两类错误要分开

极端错类损失2001.31326169与第三类概率0同时出现, 是概率下溢而log信息仍可计算。 $z=(8,0,0)$ 时, 正确损失0.000670700286, 错误双softmax为0.551871142253, 这是目标被替换, 不是单纯精度问题。数值稳定和接口语义要分别检查。

实验C：步长等价的范围

九行无正则数据下sum梯度 $=9 \times \text{mean}$ 梯度, 所以mean步长0.25对应sum步长0.25/9。若同 $\lambda=0.03$, sum方案的正则作用也随步长除9, 已非原更新。应写清比较的是数据损失还是完整目标、batch大小是否固定, 不能只凭两条下降曲线认为实现等价。

实验D：如实解释完整运行

w 从0开始, 第一次更新变为正后四例准确率已为1。400步时 $w \approx 4.00124$, 损失 ≈ 0.0092311 , 梯度 ≈ -0.00931668 , 仍非零。三类主例9/9训练、6/6测试正确, 只说明这些固定点被正确分类; 不能推断真实数据分布上必有100%准确率、概率已校准或当前参数唯一。