

024 逻辑回归与softmax分类

从分数到概率再到损失的每一步是怎样来的？

023已把线性预测、平方损失、梯度和更新接起来。但分类标签0、1、2不是三个有等距关系的测量值：把“类别2”预测成1，不能仅凭编号差1就说比预测成0更合理。本讲保留线性分数，重新建立分类的概率模型与训练目标，再用可核对的梯度连接程序。

先修023的矩阵训练闭环、017的似然、019的交叉熵和021的指标解释。通过023已用到稳定数值计算与向量链式法则。我们从二分类开始，再推广为互斥的K类。实验是原创、固定小型合成数据，不把训练准确率或六个测试点的全对当成真实泛化证据。

1 分数不是概率

一条输入 $x \in \mathbb{R}^d$ 经线性分数得到 $z = w^T x + b$ ，其中 $w \in \mathbb{R}^d$ 、 $b \in \mathbb{R}$ 、 $z \in \mathbb{R}$ 。z可以是-100或100，不满足概率的范围。二分类令 $p = P_\theta(Y = 1 | x)$ ，其中 θ 统称参数 (w, b) ，并定义概率优势odds为 $p/(1-p)$ 。若希望对数优势等于线性分数：

$$\log \frac{p}{1-p} = z,$$

先指数化为 $p/(1-p) = e^z$ ，再解方程，得到

$$p = \sigma(z) = \frac{e^z}{1 + e^z} = \frac{1}{1 + e^{-z}}.$$

这个函数叫sigmoid或logistic函数。它把有限实数映到(0,1)，且单调递增； $z = 0$ 时 $p=1/2$ ， $z = \log 3$ 时 $p=3/4$ 。logit也可指概率的对数优势变换；神经网络里通常把尚未归一化的分类分数统称logits，阅读接口时必须分清输入对象。[1]




图1 分数、概率与阈值。左图sigmoid单调转换，右图是两个标签对应的单例负对数似然；阈值决策与连续训练损失不是同一对象。

概率形式是模型假设，不等于概率已经校准。默认以 $p \geq 1/2$ 判正，相当于 $z \geq 0$ ；若漏报和误报成本不同，评价协议可以使用其他阈值，不能把0.5说成普遍最优。

2 由Bernoulli似然推导二分类损失

标签 $y \in \{0, 1\}$ 。条件概率可统一写为 $P(y | x) = p^y(1 - p)^{1-y}$ ： $y=1$ 时只取 p ， $y=0$ 时只取 $1-p$ 。单例负对数似然为

$$\ell(z, y) = -y \log p - (1 - y) \log(1 - p).$$

这是二分类交叉熵，记作BCE。 $\log p = z - \log(1 + e^z)$ ， $\log(1 - p) = -\log(1 + e^z)$ ，代回后两个对数系数相加为1：

$$\ell(z, y) = \log(1 + e^z) - yz.$$

这是数学等价式，不能直接据它写出对任何 z 都稳定的程序。若样本在给定参数与输入后条件独立，联合似然是各项乘积，联合负对数似然就是各项之和。 N 表示本批样本数，训练常取平均 $L = \frac{1}{N} \sum_i \ell_i$ ，它和求和有相同的无正则最优解，但梯度尺度相差 N 。

梯度为什么简化成 $p-y$

对sigmoid使用商法则： $\sigma'(z) = e^z / (1 + e^z)^2 = p(1 - p)$ 。再从BCE对 p 求导：

$$\frac{\partial \ell}{\partial p} = -\frac{y}{p} + \frac{1 - y}{1 - p}.$$

乘上 $dp/dz = p(1 - p)$ ，分母消去，得到 $-y(1 - p) + (1 - y)p = p - y$ 。也可直接对 $\log(1 + e^z) - yz$ 求导核对。于是

$$\nabla_w L = \frac{1}{N} \sum_i x_i (p_i - y_i), \quad \frac{\partial L}{\partial b} = \frac{1}{N} \sum_i (p_i - y_i).$$

当模型给正例的 p 偏低， $p-y$ 为负；沿负梯度更新会提高该样本分数。这里没有再额外乘一次sigmoid导数，它已经在链式推导中相消。若改用平方损失拟合概率，导数则是另一个表达式，不能把两个目标的梯度混用。

手算 $x = (2, -1)$ 、 $w = (0, 0)$ 、 $b = 0$ 、 $y=1$ ： $z=0$ ， $p=1/2$ ，损失 $\log 2$ ；权重梯度 $(-1, 1/2)$ ，偏置梯度 $-1/2$ 。学习率0.2更新后 $w = (0.2, -0.1)$ ， $b = 0.1$ ，同一点的新 $z=0.6$ 、 $p \approx 0.645656$ 、损失 ≈ 0.437488 ，低于原 $\log 2$ 。每个符号都对应一次具体计算，而不是只记“ p 减 y ”。

3 二分类也需要稳定实现

直接 $\exp(1000)$ 会溢出；直接 $\log(\text{sigmoid}(-1000))$ 可能取到 $\log 0$ 。对 $a = (1 - 2y)z$ ，单例损失可改写为

$$\ell = \max(a, 0) + \log(1 + e^{-|a|}).$$

计算时用 $\log 1p$ ，即专门计算小 u 下的 $\log(1+u)$ ，避免先把 $1+u$ 舍入成1。这个式子也避免先算巨大 softplus 再减巨大 yz 。sigmoid本身按 z 正负分支： z 非负时算 $1/(1 + e^{-z})$ ，负时算 $e^z/(1 + e^z)$ ，所有指数自变量均不为正。

二分类梯度也要注意舍入：当 $y=1$ 时，使用 $-\sigma(-z)$ 与数学上的 $\sigma(z) - 1$ 相同，却避免“接近1再减1”的抵消。例如 $z=37$ ，float64的sigmoid可能已舍入为1，直接减1变成0；本实现保留约 -8.5330×10^{-17} 。当 $z=1000$ 时，这个真实极小量仍可能下溢为0；稳定不意味着无限精度。[2]




图2 极端分数下的数值路径。中等正 z 时正确类梯度需避免1-1抵消；极大错类logit的损失仍有限。图中的0可能是浮点下溢，不代表数学概率精确为0。

实现只接受有限且绝对值不超过一百万的logit，拒绝NaN、无穷、bool和错误shape。它是一套有边界的教学接口，不声称支持任意dtype、无限大的浮点输入或所有硬件行为。

4 多分类：一行K个分数

互斥K类中， $y \in \{0, \dots, K-1\}$ ，每例分数 $z \in \mathbb{R}^K$ 。softmax定义为

$$p_k = \frac{e^{z_k}}{\sum_{j=0}^{K-1} e^{z_j}}.$$

每个 p 非负，和为1；在精确实数算术、有限分数下严格为正。softmax给出的是一个概率向量，不是“只保留最大类别”的硬分类。argmax才返回一个类别编号。

$p_0 + p_1 + p_2 = 1$ ；softmax只改变三角形内的位置




图3 从三分数到概率单纯形。三个顶点代表概率全集中于某一类；有限logit对应内部点，蓝色路径把(0,0,0)逐渐改为(t,0,0)。

$K=3$ 时，概率向量位于 $p_0 + p_1 + p_2 = 1$ 的二维三角面，称为概率单纯形。图用三角形的重心坐标展示这三个权重，不是把类别当成三个连续数值目标。

所有分数同时加常数 c ，分子分母都乘 e^c ，概率不变。故softmax只关心分数差，没有唯一的绝对分数原点。 $K=2$ 时

$$p_1 = \frac{1}{1 + e^{-(z_1 - z_0)}} = \sigma(z_1 - z_0).$$

所以单logit二分类等价于两个logit的差。不能把 K 个互斥类别各自sigmoid后当成自动和为1的概率；多标签任务允许多个标签同时成立，常用多个独立Bernoulli输出，是另一种任务模型。

5 稳定log-softmax与交叉熵

令 $m = \max_j z_j$, $s_j = z_j - m \leq 0$ 。从分数差计算

$$\log p_k = s_k - \log \sum_j e^{s_j}, \quad \ell(z, y) = -\log p_y.$$

每个指数不大于1，且至少一个为1，避免指数上溢以及分母全零。[3] 若希望保留正确类特别小的损失，可把一个最大分数位置 a 的指数1单独拿出：

$$\log \sum_j e^{s_j} = \log \left(1 + \sum_{j \neq a} e^{s_j} \right).$$

程序用log1p计算右侧；最大值有并列时只移除其中一个1，其他1仍在求和中。不能把所有最大位置都删去。随后直接从logp取损失，不先把logp指数化再取log。

手算 $z = (\log 2, 0, 0)$, 指数比为 $2:1:1$, 因此 $p = (1/2, 1/4, 1/4)$ 。若标签0, 损失 $\log 2$; 标签1则损失 $\log 4$ 。相同分数产生同一概率, 标签决定哪一个概率进入损失。

极端例 $z = (1000, 1001, -1000)$ 、 $y=2$ 。减最大值得 $(-1, 0, -2001)$, 稳定损失为 $2001 + \log(1 + e^{-1} + e^{-2001}) \approx 2001.31326169$ 。float64的第三类概率下溢为0, 但这个对数损失仍可计算。这正是“先softmax再log”会丢掉的信息。




图4 原始exp可能溢出、概率可能下溢, 但log域仍有答案。右侧比较正确logits损失与把概率误当logits后的损失, 它们不是同一个目标。

6 softmax梯度的逐项推导

令分母 $S = \sum_j e^{z_j}$ 。对第r个分数求导, 商法则给出

$$\frac{\partial p_k}{\partial z_r} = p_k(\delta_{kr} - p_r),$$

其中 δ_{kr} 在 $k=r$ 时为1, 否则为0。于是雅可比矩阵为 $J = \text{diag}(p) - pp^T$, shape是 $K \times K$ 。对角项 $p_k(1 - p_k)$ 为正, 非对角项 $-p_k p_r$ 为负: 提高一个分数会增加该类概率、减少其他类概率。

对硬标签损失 $-\log p_y$, 只要代入 $k=y$:

$$\frac{\partial \ell}{\partial z_r} = -\frac{1}{p_y} p_y(\delta_{yr} - p_r) = p_r - \mathbf{1}\{r = y\}.$$

令one-hot向量 $q \in \mathbb{R}^K$ 在标签位置为1、其他为0, 则梯度是 $p - q$ 。每行梯度之和为0, 与“所有分数共同平移不改变损失”一致。

在手算 $p = (1/2, 1/4, 1/4)$ 、 $y=0$ 时, 梯度为 $(-1/2, 1/4, 1/4)$ 。一步负梯度更新提高正确分数, 降低两个错误分数; 不是只改一个类别。J 本例为

$$J = \begin{pmatrix} 1/4 & -1/8 & -1/8 \\ -1/8 & 3/16 & -1/16 \\ -1/8 & -1/16 & 3/16 \end{pmatrix}.$$




图5 softmax各类耦合。左图是本例雅可比，右图是标签0的logit梯度；每行和为0是可执行的检查条件。

若 q 是事先给定、非负且和为1的软目标，同样推导得到 $p-q$ 。若目标总质量为 c 而不是1，则梯度是 $cp-q$ ，不能忽略归一化条件。本实验只接受硬标签整数向量，软目标推导用于理解公式边界。

数值实现中，标签位置的 $p_y - 1$ 可等价写为 $-\sum_{j \neq y} p_j$ ，保留 p 接近1时的小梯度。本代码使用这个补和形式，不改变数学目标。其他类梯度保持 p ；极小概率仍受浮点范围限制。

7 批次形状与参数梯度

将偏置并入最后一列全1的设计矩阵 $\tilde{X} \in \mathbb{R}^{N \times (d+1)}$ ，参数 $W \in \mathbb{R}^{(d+1) \times K}$ 。每行样本，每列类别：

$$Z = \tilde{X}W \in \mathbb{R}^{N \times K}, \quad P = \text{softmax}(Z, \text{类别轴}), \quad G_Z = \frac{P - Q}{N}.$$

Q 为 $N \times K$ 的one-hot矩阵；公开接口接收的是长度 N 的类别编号 y ，程序内部等效构造相应项。不能让 $(N,1)$ 标签依赖广播悄悄变成 $N \times N$ 比较。

每个参数 W_{jk} 通过 $z_{ik} = \sum_j \tilde{X}_{ij} W_{jk}$ 影响该类分数，故

$$\frac{\partial L}{\partial W_{jk}} = \sum_i \tilde{X}_{ij} (G_Z)_{ik}, \quad G_W = \tilde{X}^T G_Z.$$

矩阵shape为 $(d+1, N)(N, K) = (d+1, K)$ ，恰与 W 相同。softmax沿每行的类别轴归一化，即axis=1；沿批次axis=0归一化会把不同样本放进同一分母。[3]




图6 一次批次前向与反向。图中Xb即公式的增广设计矩阵。框中shape对应本文统一约定；除N只发生一次，偏置梯度已包含在最后一行。

没有类别权重、忽略标签等额外规则时，sum损失与mean损失的梯度相差N；在无正则情形，用sum梯度并将学习率除以N，可得到相同一步更新。如果额外正则项没有同时按N缩放，这个等价不再直接成立。真实库对权重和忽略标签的mean分母有具体规定，必须看接口，不能只猜一个batch size。[4]

8 完整的三类手算第一步

训练集九点，每类三点：类别0为(-2,0)、(-1,0)、(-2,1)；类别1为(2,0)、(1,0)、(2,1)；类别2为(0,2)、(0,1)、(0,3)。最后再补常数1。六个测试点另列于CSV，不参与参数更新、学习率或迭代数选择。

W从 3×3 零矩阵开始，因此每行 $p=(1/3, 1/3, 1/3)$ ，均值交叉熵 $\log 3$ 。x1总和0，各类x1和分别为-5、5、0；x2总和8，各类和为1、1、6。按上一节公式得到

$$G_W = \begin{pmatrix} 5/9 & -5/9 & 0 \\ 5/27 & 5/27 & -10/27 \\ 0 & 0 & 0 \end{pmatrix}.$$

取示范学习率0.3且暂不加正则，第一步 $W_1 = -0.3G_W$ ：

$$W_1 = \begin{pmatrix} -1/6 & 1/6 & 0 \\ -1/18 & -1/18 & 1/9 \\ 0 & 0 & 0 \end{pmatrix}.$$

对输入(-2,0)，分数为(1/3, -1/3, 0)。无须等完整训练后才能核对：第一步的方向已经让它更偏向正确类别0。主实验使用预定学习率0.25，这个0.3手算仅是可单独验证的一步演示，不能混写成主运行配置。

9 训练、决策边界与实际结果

主实验优化平均交叉熵加上 $\lambda \|W_{\text{feature}}\|_F^2 / 2$ ，其中 $\lambda = 0.03$ ，只惩罚前两行特征权重，不惩罚最后一行偏置。Frobenius范数平方就是这些元素的平方和；它的梯度是在特征行加 λW 、偏置行加0。该项抑制分数差无限增长，改变了训练目标，不是数值上“没有影响的修补”。

预定400步、学习率0.25，得到约

$$W = \begin{pmatrix} -1.641729 & 1.641729 & 0 \\ -0.617695 & -0.617695 & 1.235390 \\ 0.198420 & 0.198420 & -0.396841 \end{pmatrix}.$$

训练均值CE约0.123658，测试均值CE约0.068982；九个训练点、六个测试点都分类正确。总目标约0.238855，含正则，所以不等于纯交叉熵。最终梯度范数约0.000309，只是本次停止点的数值，不是已证明到达精确最优或任何真实任务性能保证。




图7 固定训练过程与边界。左图分开画总目标和纯CE，右图颜色区域是该线性softmax规则的argmax，圆点训练、叉点测试。小样本全对不证明泛化。

类别a与b的分数相等时， $(w_a - w_b)^T x + (b_a - b_b) = 0$ ，因此线性softmax的两类边界仍是直线（高维为超平面）。softmax非线性归一化不等于输入空间有了任意弯曲的分类边界；它保持分数排序。将同一向量加到全部权重列、同一常数加到全部偏置，概率不变；未正则化的softmax参数表示因而有冗余。当前不惩罚偏置，仍有共同偏置平移冗余，不能宣称参数唯一。

为什么这个步长有可核对的依据

沿任一参数方向V走标量t，一条样本的分数方向记 $v_k = \tilde{x}^T V_{:k}$ 。交叉熵二阶方向导数为 $\sum_k p_k v_k^2 - (\sum_k p_k v_k)^2$ ，是以p为权重的方差，非负且不超过 $\sum_k v_k^2$ 。由Cauchy不等式，又不超过 $\|\tilde{x}\|^2 \|V\|_F^2$ 。

全批平均再加正则，曲率上界可取 $L = \|\tilde{X}\|_F^2 / N + \lambda = 43/9 + 0.03 \approx 4.80778$ 。沿更新方向对一元函数积分二阶导数界，可得 $J(W - \eta G) \leq J(W) - \eta(1 - L\eta/2)\|G\|_F^2$ ；所以 $0 < \eta < 2/L \approx 0.4160$ 是一个充分下降范围。0.25在其中。这是偏松的全批界，不等于精确最大安全步长，也不是任意数据、任意优化器的通用规则。原始CE在带正则优化后期不必每步下降，真正被优化的是总目标。

10 两个容易误判的现象

先softmax再送给接收logits的损失

如果接口内部已经执行log-softmax，输入应是原始Z。将P当成Z送入后，优化的是 $-\log(\text{softmax}(P)_y)$ ，不是 $-\log P_y$ 。[4] 对 $z=(8,0,0)$ 、 $y=0$ ，正确损失约0.000670700，错误流程却约0.551871。即使 p 趋近 $(1,0,0)$ ，错误损失仍趋近 $\log(e+2)-1 \approx 0.551445$ 。

反向时还多出softmax雅可比：错误目标对 z 的梯度为 $J(p)^T(\text{softmax}(p)-q)$ 。它不是原本的 $p-q$ 。计算能运行、数值有限并不代表接口语义正确。

可分数据上，准确率稳定但权重还在增长

二分类另取 $x=(-2,-1,1,2)$ 、 $y=(0,0,1,1)$ ，无偏置，只训练一个权重 w 且不正则。任意 $w>0$ 已把四个点全部分类正确，但损失为

$$L(w) = \frac{1}{2} \log(1 + e^{-w}) + \frac{1}{2} \log(1 + e^{-2w}).$$

每一项对有限 w 都为正，且随 w 增加而严格减少；当 w 趋向正无穷才趋近0，没有实现零损失的有限最优 w 。400步后 $w \approx 4.00124$ 、 $BCE \approx 0.0092311$ ，仍不是“数学问题已找到有限零梯度解”。




图8 完全可分二分类。权重持续增大，损失继续降低；准确率早已为1。单看准确率停止变化无法解释训练目标。

正则、早停和不可分噪声会改变这个故事。此处只用可证明的一维反例解释机制，不把它推广为所有分类训练都必须发散。概率过于自信、校准、数据偏移仍应按021的评价原则检查。

11 核验梯度与接口

对一个logit或参数元素加减 h ，使用中心差分 $[L(\theta + he_j) - L(\theta - he_j)]/(2h)$ 对照解析梯度。保持同一输入、标签、归约和正则，只改变一个坐标。 h 太大带来截断误差，太小带来抵消；不要仅试一个极端 h 就判断对错。极端饱和区域的微小导数可能低于差分可分辨范围，因此本讲在中等尺度做差分，在极端尺度改用高精度十进制或稳定库参照。




图9 梯度检查的证据。左图中等尺度中心差分误差随 h 变化；右图对照解析梯度与中等步长差分。极端饱和的微小量另用高精度参照，不以此图替代。

运行测试会核对：多类概率和/共同平移不变性、每行梯度、二类/多类手算、mean与sum尺度、Decimal与SciPy稳定结果、参数差分、错误双softmax的链式导数、训练/测试隔离和失败时旧输出保护。SciPy是数值参照，主脚本训练只依赖NumPy；没有运行PyTorch训练或自动微分框架。

12 来源与边界

[1] [SciPy官方expit文档](#)：sigmoid对象与接口。

[2] [PyTorch官方BCEWithLogitsLoss](#)：合并logits损失的稳定性语义。本文自行推导并以NumPy实现，不声称测试过PyTorch执行。

[3] [SciPy官方softmax、logsumexp](#)：轴、平移与log域计算。

[4] [PyTorch官方CrossEntropyLoss](#)：输入是logits、目标类型及归约规则。本文只实现无类别权重、无ignore标签的硬分类子集。

所有正文、合成数据、计算图与例子独立制作。网页对应版本可能高于本地数值参照；本地实际NumPy2.3.5、SciPy1.17.0，以验证记录为准。未测试全新Anaconda、浏览器Jupyter、socket内核、跨平台或GPU表现。

13 练习

1. 从对数优势解出sigmoid，并算 $z=\log 3$ 时的概率与默认类别。
2. 从Bernoulli概率推到BCE，再用链式法则推 $p-y$ ；为什么不用再乘一次sigmoid导数？
3. 完成 $x=(2,-1)$ 、零参数、 $y=1$ 、步长0.2的整步手算，包括新损失。
4. 说明稳定BCE与分支sigmoid如何避免上溢； $z=37, y=1$ 时为何直接 $p-1$ 可能为0？
5. 证明共同平移不改变softmax，推导二类softmax等于一个sigmoid。
6. 算 $z=(\log 2, 0, 0)$ 两种标签的概率、损失与梯度；写出完整雅可比。
7. 推导软目标和为1时 $p-q$ ；总质量 $c \neq 1$ 时为什么变为 $cp-q$ ？
8. 逐项推导批次参数梯度并核对全部shape；axis=0与axis=1有何不同？
9. 用训练点各类坐标和重建零参数梯度矩阵与0.3示范一步。
10. 在无正则下说明sum/mean损失、梯度与等价步长；保留同一个 λ 时该等价为何失效？
11. 从分数相等推导决策边界，解释softmax非线性为什么未让该边界变弯。
12. 对极端 $z=(1000, 1001, -1000), y=2$ 写出稳定损失；概率下溢为何不妨碍log域答案？
13. 推导错误双softmax的损失极限与梯度结构；为什么错误程序仍可能输出看似正常的分类？
14. 证明可分一维例无有限零损失解，区别准确率、交叉熵和参数收敛。
15. 从方向曲率方差推上界 $43/9+0.03$ ，并说明下降保证控制哪个目标。