

027 练习与实验完整详解

本文件对应正文12题及实验A至D。所有梯度对同一个标量目标求导；未特别说明时采用每样本交叉熵的mean。数学偏置为行向量，NumPy偏置为一维数组。

1 默认网络的shape与参数数

批次 $n = 5$ ，宽度 $2 \rightarrow 3 \rightarrow 2 \rightarrow 3$ 。 $H^{(0)} = X$ 为 $(5, 2)$ 。第一层 W, b 为 $(2, 3)$ 、 $(3,)$ ； $Z^{(1)}, H^{(1)}, D^{(1)}$ 均为 $(5, 3)$ 。第二层 W, b 为 $(3, 2)$ 、 $(2,)$ ； $Z^{(2)}, H^{(2)}, D^{(2)}$ 为 $(5, 2)$ 。第三层 W, b 为 $(2, 3)$ 、 $(3,)$ ；logits和 $D^{(3)}$ 为 $(5, 3)$ 。输出层没有额外的隐藏 $H^{(3)}$ 。

每个 G_W, G_b 与相应参数同形， G_X 为 $(5, 2)$ 。参数数分别 $2 \cdot 3 + 3 = 9$ 、 $3 \cdot 2 + 2 = 8$ 、 $2 \cdot 3 + 3 = 9$ ，合计26。批次轴5不参与参数计数。

2 CE起点与两种归约

令 $S = \sum_j e^{z_j}$ 。对 $\ell = \log S - z_y$ ， $\partial \ell / \partial z_k = (1/S)e^{z_k} - \mathbf{1}\{k = y\} = p_k - Y_k$ 。逐行排成矩阵得到sum起点 $P - Y$ ，mean起点 $(P - Y)/n$ 。对某行所有类别导数求和为0，因为给同一行所有logits加相同常数不改变概率。

“对类别求和”已经形成每条 ℓ_i ；“对样本平均”才引入 n 。`-(Y*logP).mean()`在 $n \times C$ 元素上平均，多除一个 C 。这个错误可以让前向和反向一起缩小，而仍通过自洽差分，因此需对照目标定义。

3 两层手算与零梯度的意义

矩阵乘法先给出 $XW^{(1)} = \begin{bmatrix} 1 & 1 \\ -1 & -1 \end{bmatrix}$ ，广播加 $(2, 2)$ 后， $Z^{(1)} = H^{(1)} = \begin{bmatrix} 3 & 3 \\ 1 & 1 \end{bmatrix}$ 。ReLU没有碰到折点，局部导数全1。

第二层每行第一logit是 $h_1 - h_2$ ，第二logit是 $-h_1 + h_2$ ，所以均为0。 P 每行 $(1/2, 1/2)$ ，两个标签都是0，平均损失 $\log 2$ 。起点每行为 $(-1/4, 1/4)$ 。

第二层第 $(0, 0)$ 个权重导数为 $3(-1/4) + 1(-1/4) = -1$ ；其余同理，得到 $G_{W^{(2)}} = \begin{bmatrix} -1 & 1 \\ -1 & 1 \end{bmatrix}$ 。偏置把两行加起来， $G_{b^{(2)}} = (-1/2, 1/2)$ ，不能再除2。

乘 $(W^{(2)})^T$ 后，每行隐藏梯度是 $(-1/2, 1/2)$ 。乘ReLU导数不变。第一层权重梯度的第一行为 $1(-1/2, 1/2) + (-1)(-1/2, 1/2) = (0, 0)$ ；第二行为 $2(-1/2, 1/2) + 1(-1/2, 1/2) = (-3/2, 3/2)$ 。偏置为 $(-1, 1)$ 。

输入梯度的第一个坐标把 $(-1/2, 1/2)$ 与 $(1, 1)$ 内积，等于0；第二坐标的两个第一层权重本来都为0，导数也为0。第一个零是样本贡献抵消； G_X 的零是当前网络两个隐藏通路抵消。它们不表示所有参数导数为0。

改成sum后损失为 $2 \log 2$ ，第二层 G_W 两行变成 $(-2, 2)$ ， $G_b = (-1, 1)$ ；第一层 G_W 第二行变成 $(-3, 3)$ ， $G_b = (-2, 2)$ ，其余零仍为零。每一个梯度均为mean的2倍。

4 仿射反向三个求和

对 $z_{ik} = \sum_r h_{ir} w_{rk} + b_k$ 和上游 D_{ik} ：

$$\frac{\partial J}{\partial w_{rk}} = \sum_i H_{ir} D_{ik}, \quad \frac{\partial J}{\partial b_k} = \sum_i D_{ik}, \quad \frac{\partial J}{\partial h_{ir}} = \sum_k D_{ik} W_{rk}.$$

前两式沿样本 i 累加，因为权重和偏置被每条样本共享；第三式沿输出坐标 k 累加，因为同一输入坐标影响本行多个输出。打包后就是 $H^T D$ 、 $\mathbf{1}^T D$ 、 DW^T 。反传时 W 必须是原前向的参数快照；先更新再用会混合两个不同函数的导数。

5 多轴广播的具体结果

G 的第一块为0至11，第二块为12至23。原shape(4,)左补成(1,1,4)，对轴0和1求和，结果为[60,66,72,78]。例如第一个元素是 $0 + 4 + 8 + 12 + 16 + 20 = 60$ 。

原shape(3,1)补成(1,3,1)，对轴0和2求和，结果为[[60],[92],[124]]。原shape(1,3,1)归约轴相同，数值相同但保持三维，即[[[60],[92],[124]]]。

原shape()是标量，对全部位置求和，得到 $0 + 1 + \dots + 23 = 23 \cdot 24/2 = 276$ 。不要只“压扁再求和”返回一个数作为所有情形的答案，那会丢掉原参数中不同坐标的含义。

6 方形shape也会掩盖错轴

零logits的三类概率均为1/3。对标签(0,0,1)，mean起点为：

$$D = \begin{bmatrix} -2/9 & 1/9 & 1/9 \\ -2/9 & 1/9 & 1/9 \\ 1/9 & -2/9 & 1/9 \end{bmatrix}.$$

按样本轴求和得到正确 $G_b = (-1/3, 0, 1/3)$ 。每行的类别导数和为0，所以错轴sum(axis=1)得到(0,0,0)。两者shape都是(3,)，但含义完全不同。代码可能显示约 10^{-17} 的舍入余量，不改变结论。

7 2+3微批与每条样本的权重

记 $\bar{g}_A = (g_1 + g_2)/2$ ， $\bar{g}_B = (g_3 + g_4 + g_5)/3$ ，则整体 $g = (2\bar{g}_A + 3\bar{g}_B)/5$ 。若误用 $(\bar{g}_A + \bar{g}_B)/2$ ，前两条每条权重1/4，后三条1/6；正确应全为1/5。

默认模型正确组合误差约 3.12×10^{-17} ，错误组合最大坐标差约0.0330774。错误并非总是只放大某个统一学习率，因为不同样本梯度方向可不同，重新加权也可改变方向。

若两个微批之间更新参数，后一批求的是 $\nabla \ell_i(\theta_{\text{new}})$ ；整体批次目标需要所有样本在同一 θ 处的导数，故不再等价。依赖批次统计量的层还可能在拆分后改变前向值。

8 整批复制与正则项

复制3次时，sum损失和梯度均乘3，mean都不变。这个结论来自分子分母同时乘3，适用于复制完整批次而保持相对样本频率不变。

有正则时 $J_m = \frac{1}{n} \sum_i \ell_i + \lambda R$ ， $J_s = \sum_i \ell_i + \lambda R$ 。sum用学习率 η/n 后的步为 $-\eta \frac{1}{n} \sum_i g_i - \eta \lambda \nabla R/n$ ，mean用 η 后的正则部分却是 $-\eta \lambda \nabla R$ 。要让整个目标仅相差 n ，sum中的正则系数也须改为 $n\lambda$ ，不是只改学习率。

9 未归约目标的上游向量

$v = (1, 0, -2)$ 对应标量 $J = \ell_1 - 2\ell_3$ 的VJP，即 $g_1 - 2g_3$ 。第二条不贡献，第三条被负向加权。它不是普通mean CE；第三条损失越大可能使这个新目标越小。给定上游向量在数学上可合法，但必须理解它改变了学习目标。

10 ReLU折点与差分

中心差分在0处为 $[\max(h, 0) - \max(-h, 0)]/(2h) = h/(2h) = 1/2$ ，任意正 h 都如此。左右导数分别0和1，所以普通导数不存在。程序选0只是明确的局部规则，不等于中心差分应为0。

若某个隐藏激活前值接近0，正负参数扰动使它跨过0，有限差分比较的两侧可能属于不同线性片段。应记录被跨越的激活、选择远离折点的参数点或减小步长后重新核验。不能为了让一个中心差分通过，就把整个ReLU负半轴或零点约定随意修改。

11 近零梯度的绝对与相对误差

$g = 10^{-10}$ ， $g_{FD} = 0$ ，绝对误差 $a = 10^{-10}$ ；本讲相对指标 $q = 10^{-10}/10^{-8} = 0.01$ 。判据右侧为 $2 \times 10^{-8} + 2 \times 10^{-5} \cdot 10^{-10}$ ，远大于 a ，因此通过。

若仅要求相对误差小于 10^{-5} ，这对几乎为0的梯度会被判失败。反之也不能只用宽松绝对阈值忽略重要的小梯度，应把目标尺度、数值精度与用途一起考虑。这里的双容差是具体实验约定，不是普适标准。

12 实验A至D结果与完整解释

A 手算

完整过程见第3题。测试同时核对两层权重、两层偏置和输入梯度；该点ReLU全部激活，中心差分不会跨零。把每个样本贡献单列，能直接看到为什么已除2的 D 之后还要求和。

B 全坐标与独立参考

默认mean CE为1.148978865605775, sum为5.744894328028874, 26维梯度范数0.2782642895824935。学习率0.1的单步后mean CE为1.1413798716255645, 只证明这一个单步的损失下降。

26坐标中心差分在 $h = 10^{-5}$ 时全部通过, 最大绝对误差约 1.79715×10^{-11} , 最大相对指标约 1.86463×10^{-9} 。最大绝对误差对应b2[1]: 解析值0.038733312397662145, 数值值0.03873331237969069。逐样本标量循环的平均与矩阵实现最大差约 3.47×10^{-17} 。输入的10个坐标也通过差分核验。

测试进一步在72个不同小网络上使用70位Decimal前向模式求导: 不调用主反传, 不复用主CE实现, 而是从每个独立参数向前传播导数向量, 最后对照目标及所有参数导数。另对36个扰动网络检查全部26参数及10输入坐标。多条核验路线降低共同错误风险, 但不覆盖任意网络和任意输入。

fd_sweep.csv给出 10^{-2} 至 10^{-10} 的9档结果。应按实际表报告误差随步长变化, 不强求最小步长最好。较大步长的截断误差与较小步长的数值相减误差都可能主导; 表内“失败坐标数”记录该步长下的判断结果, 没有把不通过的行删除。

C 故障定位

漏除 n 使默认梯度成为正确值5倍; 已经除 n 后再对偏置求mean, 会把各层偏置错误缩小5倍。如果误把每层传回的delta都再除 n , 更早的层会被多次缩小, 不能用统一学习率修复。

微批2+3正确加权与完整批次的差约 3.12×10^{-17} ; 简单平均差约0.0330774。方形错轴例正确偏置为 $(-1/3, 0, 1/3)$, 错轴近似全0。附带测试有意比较这些错误版本与独立参考, 确认不是“只要函数没错就算通过”。

D 输入失败与结果保护

标签3超出三类索引0至2; 0.0文本不是本CSV要求的整数标签; 布尔学习率不是实数超参数; 1e-400非零文本会在float64下变0, 入口应拒绝。错误发生时, 不创建新最终输出目录, 不改旧五文件。

18种坏CSV/配置各对新旧目录执行一次, 合计36个新进程失败路径通过。参数恰为允许边界10时, 中心差分的正扰动越界, 程序也在替换输出前拒绝; 这说明合法输入不代表所有后续计算都必能在教学域内完成。操作系统级写入失败不在多文件原子保证内。

ReLU在0的差分0.5已由第10题解释。默认平滑tanh实验避开这一歧义; 极端饱和时也可能遇到数值导数为0或不可分辨, 不能据此宣称数学真实导数必为0。

审计提醒

独立测试还包括120个Fraction仿射夹具、7种广播原shape、150组100位Decimal CE/梯度对照、批次复制与行置换、23个数学输入拒绝、转换真零接受以及输入不被原地修改。这些是本版本已执行的作者检查; 独立审阅状态与发布状态由课程总目录管理, 不能把本文件存在视为远端已发布。