

032 练习详解

1 从交叉项推导协方差

令 $U_b = g_{I_b} - \bar{g}$, 则 $E[U_b] = 0$ 。估计误差为 $B^{-1} \sum_b U_b$, 其协方差是 $B^{-2} \sum_{a,b} E[U_a U_b^T]$ 。独立时 $a \neq b$ 的项可拆成 $E[U_a] E[U_b]^T = 0$; B 个自身项各为 Sigma , 所以结果为 Sigma/B 。

若 B 次都使用同一个随机索引 I , 每个 U_b 都等于 U , 交叉项也为 Sigma ; 共有 B^2 项, 除以 B^2 后仍为 Sigma 。均值仍可以无偏, 但方差没有缩小。由此可见, 无偏与独立不是同一条件, 方差缩小也不能只看 batch size 这个数字。

2 六个子集与完整协方差

四个向量为 $(3,1)$ 、 $(1,-1)$ 、 $(-1,2)$ 、 $(-3,-2)$ 。选择两行的六个等概率子集, 平均向量依次为:

子集	平均向量
1、2	(2,0)
1、3	(1,1.5)
1、4	(0,-0.5)
2、3	(0,0.5)
2、4	(-1,-1.5)
3、4	(-2,0)

六向量均值为0。第1坐标平方均值是 $10/6=5/3$; 第2坐标平方均值是 $5/6$; 交叉乘积均值为 $3/6=1/2$ 。因此协方差为 $\begin{pmatrix} 5/3 & 1/2 \\ 1/2 & 5/6 \end{pmatrix}$, 恰等于总体 $\begin{pmatrix} 5 & 3/2 \\ 3/2 & 5/2 \end{pmatrix}$ 乘 $(4-2)/(2(4-1)) = 1/3$ 。

有放回 $B=2$ 则乘 $1/2$ 。总体协方差的分子是4; 不能把分母3的无偏样本协方差直接带进同一个系数。
 $B=N$ 不放回会完全消去抽样方差, 这是检查公式的一个端点; $N=1$ 时另外直接判断方差为0, 不能使用含 $N-1$ 分母的表达式。

3 非均匀抽样与重要性修正

$\theta=0$ 时梯度 $(3,1,-1,-3)$, 概率 $(1/10, 2/10, 3/10, 4/10)$ 。直接估计期望为 $3/10 + 2/10 - 3/10 - 12/10 = -1$, 与均匀目标的0不一致。

除以 $4p_i$ 后的值为 $(15/2, 5/4, -5/6, -15/8)$ 。相应加权贡献为 $(3/4, 1/4, -1/4, -3/4)$, 总和0。普通平均这些修正值没有概率权重, 不是这项随机实验的期望。

若某个 $p_i=0$ ，该行从未出现，除以零未定义，也没有观测能代表它对原目标的贡献。很小但非零的 p_i 会放大贡献，可能使修正后方差大。正确期望不意味着低方差，更不保证一次更新下降。

4 反向的条件偏差例

若第一行目标为-1，初始 $\theta=0$ ，第一梯度为1，学习率1/2给出 $\theta=-1/2$ 。剩余目标为+1，下一梯度为 $-1/2-1=-3/2$ ；此刻全目标梯度为 $\theta=-1/2$ 。给定这个历史后，二者不同。

正反两种顺序的差异符号互相抵消，不能因此宣称每个给定历史下均无偏。随机重排与独立有放回是不同的采样算法，条件偏差只否定某个现成证明步骤，不能单凭这个反例给出性能高低排名。需要对应的优化问题、步长、迭代范围与定理假设。[S2]

5 标量噪声平台

更新式为 $\theta_{t+1} = (1 - \eta)\theta_t + \eta\bar{a}_t$ ，其中本步独立抽样、 $E\bar{a}_t = 0$ 、 $\text{Var}(\bar{a}_t) = 5/B$ 。因此 $m_{t+1} = (1 - \eta)m_t$ ，交叉协方差因独立性为0， $V_{t+1} = (1 - \eta)^2 V_t + 5\eta^2/B$ 。

从确定 $\theta=1$ 出发， $m_t = (1 - \eta)^t$ ， $V_0 = 0$ ；反复展开得到 $V_t = (5\eta^2/B) \sum_{k=0}^{t-1} (1 - \eta)^{2k}$ 。要求 $|1 - \eta| < 1$ 得到 $0 < \eta < 2$ ，这时 $V_\infty = 5\eta/[B(2 - \eta)]$ 。

$\eta=.5$ 、 $B=4$ 时，极限方差为 $5/12$ ，期望超额损失为 $5/24 \approx .208333333$ 。这是相对最小F值2.5的额外量，因此长期期望总损失约2.708333333。均值到0，但参数波动不消失，不能把均值轨迹当每一条运行轨迹。

$\eta=2$ 时方差每步增加 $20/B$ ，不收缩； $\eta>2$ 时几何系数超过1，波动和初始偏差可能扩大。增大B只能减小注入噪声，不能改变 $1-\eta$ 这个确定性系数。

6 同一首批的前向反向与更新

第0行ID25输入 $(-.75, 0)$ ，目标 $-.525$ 。三项仿射值为 $(-.175, .2, \text{约}0)$ ， $\tanh$ 约 $(-.173235158, .197375320, \text{约}0)$ ，预测约 $-.028506659$ ，残差约 $.496493341$ 。 $B=4$ 、损失带1/2，因此该行对预测的梯度为残差/4 $\approx .124123335$ 。

到隐藏单元0的上游量为 $.124123335 \times .4 \approx .049649334$ ；再乘 $\tanh$ 局部导数 $1 - (-.173235158)^2$ ，得到仿射伴随约 $.048159337$ 。对 W_{00} 的局部导数是该行输入 $-.75$ ，贡献约 $-.036119503$ ；对 b_0 的局部导数为1，贡献约 $.048159337$ 。

其余三行对 W_{00} 贡献约 $-.029135525$ 、0、 $-.017130270$ ，合计 $-.082385298$ ；对 b_0 的贡献约 $-.029135525$ 、 $.020913748$ 、 $-.022840360$ ，与首行相加得 $.017097199$ 。 v_0 梯度用每行预测梯度乘对应隐藏激活后求和，约 $-.092502679$ ； c 梯度是四个预测梯度之和，约 $.012869496$ 。全部13梯度按程序打包顺序列在下一式。

$\bar{\theta} = (-.082385298, .042839741, .059778121, -.030500000, -.047614007, .027045223, .017097199, -.014352438, .002829351, -.092502679, .100061751, -.011780831, .012869496).$

每项用 $\theta = .02$ gradient更新。W00约.301647706, v0约.401850054, c约.099742610。固定同一四样本, 新预测约(-.030592170,.484284827,.179496350,.411318705), loss从.06403811492518503降到.06332898042307092。其他各中间量和更新后参数全部保存在first-batch-trace.json; test_02使用独立标量循环对13个参数分别做中心差分, 不只核对一个总loss。

7 预算不同回答不同问题

固定样本呈现次数1280时, $B=1/4/16/32$ 更新步数为1280/320/80/40。固定40步时, 样本呈现次数为40/160/640/1280。若只写“都训练40步”而不报告样本预算, 就隐藏了最多32倍的样本梯度计算差别。

每轮完整风险日志还需要对32行额外前向; 它不更新参数, 不属于本讲定义的训练样本呈现预算。它属于报告生成的额外计算开销。计时分支关闭日志, 但保留同样的数学更新和保护检查, 并核对最终参数完全相同。

按相同样本预算和固定 $\eta = .02$, 小批量有更多更新机会; 改用 $\eta = .02 \times B/4$ 后, 终点训练loss都约.0428。这些只是受控例子。比较最优效率还涉及调参预算、初值重复、统计不确定性、硬件利用率、真实误差目标等, 不允许从一次固定配置外推普遍赢家。

8 线性缩放的失效与可复核记录

在标量模型中, 若 $B=1$ 用 $\eta = .1$, 线性扩到 $B=32$ 会给 $\eta = 3.2$; 此时 $1-\eta = -2.2$, 绝对值超过1, 即使噪声因 B 增大而减小, 确定性更新仍不稳定。故“更大批量允许任意同比更大步长”不成立。

报告必须写清数据与原始ID流、起始参数、损失mean/sum、批量、步长及其单位、更新步数、样本呈现次数、是否重排或有放回、风险评价协议。时间报告还需要设备、线程、dtype、软件版本、预热、重复次数、顺序、计时窗口及原始重复值。[S4][S5]

本次五次观测中的中位耗时随 B 增大而降低, 不能据此宣称GPU也有同样倍数, 或吞吐最大就达到最好统计效果。图中范围是测量最小到最大, 不是置信区间; 再次测量的秒数可以改变而数值参数仍相同。

本讲所有结论限于合成固定训练问题、已执行CPU数值与清楚标注的理论假设。未做真实任务泛化、跨平台性能、GPU吞吐或多worker通信实验。来源和实际读取范围见sources.md。