

032 小批量随机梯度下降

1 少算一些样本为什么仍可能前进

031要求先确认损失和梯度确实实现了预定问题。本讲在这个前提下追问：每一步只计算少量样本的梯度，为什么还可能有效优化？代价体现在哪里？我们要同时区分三个问题：在固定参数点，梯度估计是否无偏；连续更新时，历史怎样改变抽样分布；在相同预算下，哪种实验比较才有明确含义。

先修011偏导梯度与链式法则、018期望方差与抽样误差、031梯度核验与最小调试法。向量按列理解，程序把多个样本沿第0轴堆叠。二阶几何可补读015，但本讲会说明用到的平滑性假设。数据和参数均无量纲，全为CPU合成实验；没有真实任务效果或泛化排名。

设固定训练数据有 N 个样本，参数 $\theta \in \mathbb{R}^d$ ，第 i 行损失为 $f_i(\theta)$ 。目标不是随便抽到哪几行就由哪几行决定，而是事先定义的有限平均：

$$F(\theta) = \frac{1}{N} \sum_{i=1}^N f_i(\theta), \quad \nabla F(\theta) = \frac{1}{N} \sum_{i=1}^N \nabla f_i(\theta).$$

有限和的求导可以逐项进行，前提是这些项在该点可微。记 $g_i = \nabla f_i(\theta)$ 。本节暂时把 θ 固定， g_i 就是 N 个确定向量。它们相互抵消时，全梯度可能为0，但抽到的某一行梯度仍很大。




图1 四个固定梯度向量的均值为零。一个随机向量不等于总体均值；只检查单样本梯度大小也不能判断总体是否驻点。

2 无偏说的是对哪个随机过程求平均

2.1 独立均匀有放回抽样

独立抽取索引 $I_1, \dots, I_B$ ，每次在1到N上均匀取值，允许重复。B为批量大小，批次估计为 $\hat{g}_B = B^{-1} \sum_{b=1}^B g_{I_b}$ 。按期望的有限和定义：

$$E[g_{I_b}] = \sum_{i=1}^N \frac{1}{N} g_i = \nabla F(\theta), \quad E[\hat{g}_B] = \frac{1}{B} \sum_{b=1}^B E[g_{I_b}] = \nabla F(\theta).$$

第二步只需各次抽样边缘均匀；独立性是后面简单方差公式的重要条件，不应偷偷合并成一个条件。无偏也不意味着每次都接近、不意味着每步都会下降，更不意味着训练目标反映了现实任务。

实际算法的 θ 由过去的样本与更新产生。严谨的逐步条件是：给定截至当前的历史，下一批仍按规定从全体数据独立均匀抽取，则 $E[\hat{g}_t | \text{历史}] = \nabla F(\theta_t)$ 。历史包含当前 θ ；不能在 θ 已经依赖抽样结果后，仍机械使用固定 θ 的推导。[S1][S2]

2.2 非均匀抽样改变了什么

若第 i 行以 $p_i > 0$ 抽取，且总和为1，直接用 g_I 得到的期望是 $\sum_i p_i g_i$ 。它对应一个重新加权的目標，不一般等于原先均匀目标。若坚持优化原目标，可用 $g_I / (N p_I)$ ：

$$E \left[\frac{g_I}{N p_I} \right] = \sum_i p_i \frac{g_i}{N p_i} = \frac{1}{N} \sum_i g_i.$$

分母抵消了选择概率，但很小的 p_i 会放大该行贡献，可能增加方差。若某个 $p_i = 0$ 而其梯度不为0，就没有这种有限权重修正；“从不看某些行”不能靠除法补回信息。

手算例： $f_i(\theta) = (\theta - a_i)^2 / 2$ ， $a = (-3, -1, 1, 3)$ ， $\theta=0$ 时梯度是 $(3, 1, -1, -3)$ 。均匀目标梯度为0。取 $p = (0.1, 0.2, 0.3, 0.4)$ ，直接期望为 $0.3 + 0.2 - 0.3 - 1.2 = -1$ 。修正后的四个值为 $(7.5, 1.25, -5/6, -1.875)$ ，按相同 p 加权后恰为0。它们不是未经加权的新数据均值。

3 方差随批量变化需要哪些条件

3.1 向量的协方差写成矩阵

令 $\bar{g} = N^{-1} \sum_i g_i$ ，定义总体协方差 $\Sigma = N^{-1} \sum_i (g_i - \bar{g})(g_i - \bar{g})^T \in \mathbb{R}^{d \times d}$ 。第 j 个对角项是梯度坐标 j 的方差，非对角项描述两坐标的共同变化。这里分母为N，因为我们描述完整有限总体，不是用样本估计总体协方差。

对独立有放回的B次抽样，把误差向量相加后展开外积。交叉项期望为0，因为每项均值为0且相互独立；B个自身外积各给出Sigma。因此：

$$\text{Cov}(\hat{g}_B) = \frac{1}{B^2} \left[B\Sigma + \sum_{a \neq b} E[(g_{I_a} - \bar{g})(g_{I_b} - \bar{g})^T] \right] = \frac{\Sigma}{B}.$$

坐标标准差缩小为 $1/\sqrt{B}$ ，不是 $1/B$ 。整体平方误差期望 $E\|\hat{g}_B - \bar{g}\|^2 = \text{tr}(\Sigma)/B$ ，其中trace是对角项之和。把方差和标准差混用，会严重误判增加批量的收益。

3.2 均匀不放回有有限总体修正

一次从N行中均匀选择B个不同样本，参数仍固定。不同位置的索引不能相同，它们不是独立的。记中心化向量 $u_i = g_i - \bar{g}$ ，有 $\sum_i u_i = 0$ 。两个不同位置的交叉外积期望为：

$$\frac{1}{N(N-1)} \sum_{i \neq j} u_i u_j^T = \frac{-1}{N(N-1)} \sum_i u_i u_i^T = -\frac{\Sigma}{N-1}.$$

中间一步来自 $\sum_{i,j} u_i u_j^T = (\sum_i u_i)(\sum_j u_j)^T = 0$ ，从全体项中减去 $i=j$ 的项，就得到异索引项之和。带回B个自身项和 $B(B-1)$ 个交叉项：

$$\text{Cov}(\hat{g}_B) = \frac{1}{B^2} \left[B\Sigma - \frac{B(B-1)}{N-1} \Sigma \right] = \frac{N-B}{B(N-1)} \Sigma.$$

$N > 1$ 且 $1 \leq B \leq N$ 。B=N时正好用全体，方差为0；B=1时回到Sigma。若采用分母N-1的样本协方差 $S = \frac{N}{N-1} \Sigma$ ，同一公式也可写成 $(1 - B/N)S/B$ ；不要把两种分母混着用。




图2 同一个有限总体的三种抽样协议给出不同方差。完全重复同一索引没有增加独立信息，不能套用Sigma/B。

3.3 用全部可能结果检验公式

图1的四个梯度为 $(3, 1), (1, -1), (-1, 2), (-3, -2)$ 。它们可以具体对应 $f_i(\theta) = \|\theta\|^2/2 + g_i^T \theta$ 在 $\theta=0$ 的梯度，因此不只是脱离函数的四个箭头。均值0，协方差为 $\begin{pmatrix} 5 & 1.5 \\ 1.5 & 2.5 \end{pmatrix}$ 。B=2时，独立有放回第1坐标方差为5/2；不放回为5/3。

不放回的六个子集在第1坐标上的均值是2、1、0、0、-1、-2，均值0，平方均值 $(4 + 1 + 0 + 0 + 1 + 4)/6 = 5/3$ 。有放回有16种等概率有序结果，包括两次抽到同一样本；用同样有限和计算得到5/2。程序用Fraction进行这些有理数运算，不靠Monte Carlo误差“差不多相等”。




图3 同样B=2，有放回与不放回的支持与概率不同。横轴是平均梯度，纵轴是概率，不能把频数不同的柱直接当成同一分布。

实际小网络在固定theta时，先分别计算前8行的13维单样本梯度，再枚举B=1、2、4、8的所有不放回子集，完整协方差矩阵也符合有限总体公式。固定theta很关键：不能把一次训练过程中不同theta处的梯度收在一起，再声称是在测同一个Sigma。




图4 13维网络梯度的协方差迹。枚举与公式重合，只验证这个固定参数点的抽样关系，不是训练全程噪声曲线。

4 每轮打乱不等于每一步条件无偏

DataLoader的shuffle通常表示每个epoch重新排列样本，再逐批读取，不是在每一步独立从全体有放回抽样。[S3] 在固定theta上，一次均匀子集平均仍无偏；但真实训练在上一批后改变了theta，未读取的样本集合与历史相关，因此不能把固定theta结论直接移植到后续条件分布。

最小反例只需两行：目标 $a_1 = -1, a_2 = 1$ ， $f_i(\theta) = (\theta - a_i)^2/2$ ，初始theta=0，学习率1/2，B=1。若先看到+1，梯度为-1，更新到theta=1/2。给定这个历史，剩余只能是-1，下一梯度必为3/2；但此刻全梯度是 $(1.5 - 0.5)/2 = 0.5$ 。二者不同，不存在“再平均两个剩余选择”，因为只剩一个。

不放回训练中的条件偏差：参数已经依赖历史




图5 顺序决定了当前theta，也决定了剩余样本。给定历史以后，下一梯度不能继续按全体均匀索引求期望。

这不表示随机重排一定不好。它只是需要对应的分析，不能冒用独立抽样推导。Shamir的原始论文专门研究不放回方案；本讲读取其设定和相关性说明，不把该文特定凸问题的收敛结论扩展到这里非凸小网络。[S2]

其他会破坏简单估计关系的情况包括：非均匀采样却不修正、按难度选择批次、跨样本相互作用的损失、训练模式BatchNorm让同一行输出依赖同批其他行、不同batch使用不同目标归约。Dropout或数据增强还引入额外随机性，必须说明期望是否也对这些随机源求平均。本讲主网络不含它们，专门隔离样本分组影响。

5 噪声如何出现在一次下降的界中

设 F 连续可微，梯度满足 $\|\nabla F(u) - \nabla F(v)\| \leq L\|u - v\|$ ，即梯度不会随参数任意快变化。 L 是平滑常数，不是损失值。对位移 d ，沿线积分给出 $F(\theta + d) - F(\theta) = \int_0^1 \nabla F(\theta + td)^T d dt$ 。加减 $\nabla F(\theta)$ ，用上述界控制余项，得到：

$$F(\theta + d) \leq F(\theta) + \nabla F(\theta)^T d + \frac{L}{2} \|d\|^2.$$

取 $d = -\eta \hat{g}$ ，给定历史后假设估计无偏，协方差为 C 。把 $E\|\hat{g}\|^2 = \|\nabla F\|^2 + \text{tr}(C)$ 代入，得到：

$$E[F(\theta - \eta \hat{g}) \mid \text{历史}] \leq F(\theta) - \eta \left(1 - \frac{L\eta}{2}\right) \|\nabla F(\theta)\|^2 + \frac{L\eta^2}{2} \text{tr}(C).$$

这里前一个负项是平均梯度带来的下降，后一个正项是噪声的代价；接近驻点时梯度平方变小，固定步长下噪声可能占主导。独立均匀批次使 $C = \text{Sigma}/B$ ，所以增大 B 可以缩小这个项；但不能不受限制地增大学习率，因为下降系数也随 η 变化。[S1]

这是一次条件期望上界，不保证每一次实际下降，也不是全局最优证明。本讲没有给13参数非凸网络估计全局 L ，更没有将0.02宣称为理论保证的最大学习率。随机重排的条件无偏已经失效时，也不能原封不动引用这个不等式的无偏化简。

6 一个能完全解出的噪声平台

继续用四个目标(-3,-1,1,3)和标量模型 $\hat{y} = \theta$ 。全目标为 $F(\theta) = \theta^2/2 + 2.5$ ，最优 $\theta=0$ 、最小值2.5。每步独立有放回抽B个目标，均值 $\bar{a}_t$ 满足期望0、方差 $5/B$ ：

$$\theta_{t+1} = (1 - \eta)\theta_t + \eta\bar{a}_t.$$

由于本步抽样独立于历史，均值 $m_{t+1} = (1 - \eta)m_t$ ；方差 $V_{t+1} = (1 - \eta)^2 V_t + \eta^2(5/B)$ 。从确定 $\theta=1$ 出发， $m_t = (1 - \eta)^t$ ， $V_t = \eta^2(5/B) \sum_{k=0}^{t-1} (1 - \eta)^{2k}$ 。这两式逐步区分了均值收缩和随机波动。

若 $0 < \eta < 2$ ，几何级数收敛， $V_\infty = 5\eta/[B(2 - \eta)]$ ，期望超额损失 $E[F - F^*] = (m_t^2 + V_t)/2$ 趋于 $5\eta/[2B(2 - \eta)]$ 。所以均值到0不代表每条轨迹到0。 $\eta=2$ 时均值交替、方差线性增长； $\eta > 2$ 时收缩系数绝对值超过1，这个模型已不稳定。




图6 精确递推计算的期望超额损失，不是模拟置信带。左图固定步长看批量，右图固定批量看稳定性边界。

把B增加若干倍并同比增加 η ，在 η 很小、曲率效应可忽略的近似里，可能保留某些按样本预算的变化尺度；但精确公式中还有 $2-\eta$ 分母，稳定性边界更不会随B无限移动。后续学习率调度将在033展开，这里只把线性缩放作为待检验的比较协议，不当普遍定律。

7 同一小网络的一次批次更新完整展开

主实验32行固定合成训练数据， $2 \rightarrow 3 \rightarrow 1$ tanh网络，共13参数，无Dropout或BatchNorm。设 $X \in \mathbb{R}^{B \times 2}$ 、 $W \in \mathbb{R}^{3 \times 2}$ 、 $b \in \mathbb{R}^3$ 、 $v \in \mathbb{R}^{1 \times 3}$ 、 c 为标量。前向为 $A = XW^T + b$ 、 $H = \tanh A$ 、 $\hat{Y} = Hv^T + c$ ，目标是 $L_B = \sum_i (\hat{y}_i - y_i)^2 / (2B)$ 。这里特意有1/2，与030定义相差常数，不能沿用未经检查的梯度因子。

参数按W逐行6项、b的3项、v的3项、c的1项打包。初始 $W = \begin{pmatrix} .3 & -.2 \\ -.4 & .1 \\ .2 & .25 \end{pmatrix}$ ， $b = (.05, -.1, .15)$ ，

$v = (.4, -.3, .2)$ ， $c=.1$ 。第一个B=4批次固定ID为25、9、6、4：

ID	x1	x2	y	A的三项	预测
25	-0.75	0	-0.525	(-0.175, 0.2, 约0)	-0.028507
9	1	-1	0.87	(0.55, -0.6, 0.1)	0.481257
6	0	0	-0.03	(0.05, -0.1, 0.15)	0.179661
4	0.75	-0.6	0.675	(0.395, -0.46, 0.15)	0.409067

第0行的仿射第一项为 $(-.75)(.3) + 0(-.2) + .05 = -.175$ ； $\tanh$ 后

$h \approx (-.173235158, .197375320, 0)$ ；输出 $0.4h_0 - 0.3h_1 + 0.2h_2 + 0.1 \approx -.028506659$ 。第三个仿射值在实际float64中约 $-2.78e-17$ ，不把浮点结果谎称为严格实数0。

四个残差依次为 $(.496493341, -.388743446, .209660755, -.265932665)$ ；平方求和除以8得到

$L_B = .06403811492518503$ 。对每个预测的局部梯度是残差除B，所以

$G = \tilde{Y} \approx (.124123335, -.097185862, .052415189, -.066483166)^T$ ，shape 4×1 。

输出仿射的局部导数给出 $\bar{v} = G^T H$ (1×3)、 $\bar{c} = \sum_i G_i$ 、 $\bar{H} = Gv$ (4×3)； $\tanh$ 的局部导数给出 $\bar{A} = \bar{H} \odot (1 - H^2)$ (4×3)；第一层给出 $\bar{W} = \bar{A}^T X$ (3×2)、 $\bar{b} = \sum_i \bar{A}_{i,:}$ (3)、 $\bar{X} = \bar{A}W$ (4×2)。横线表示损失对相应量的导数。

以第0行单元0为例，反向连续乘积为 $.124123335 \times .4 \times (1 - (-.173235158)^2) \approx .048159337$ 。它对 W_{00} 的贡献还要乘输入 $-.75$ ，约 $-.036119503$ 。其他三行贡献为 $-.029135525$ 、0、 $-.017130270$ ；相加得到 $-.082385298$ 。共享参数必须累计四条路径，而不是只用第0行。

参数组	全部梯度
W第0行	(-0.082385298, 0.042839741)
W第1行	(0.059778121, -0.030500000)
W第2行	(-0.047614007, 0.027045223)
b	(0.017097199, -0.014352438, 0.002829351)
v	(-0.092502679, 0.100061751, -0.011780831)
c	0.012869496

学习率.02，不用动量，逐量执行 $\theta' = \theta - .02\bar{\theta}$ 。例如 $W'_{00} = .301647706$ ， $v'_0 = .401850054$ ， $c' = .099742610$ 。同一四行重新前向后预测约 $(-.030592170, .484284827, .179496350, .411318705)$ ，损失约.06332898042307092。

first-batch-trace.json和Notebook保存所有中间量、shape、13梯度及全部更新前后值，包含更新后的所有前向坐标；正文的局部导数与累计规则让这些数字可以逐项追踪。测试用独立标量循环和13坐标有限差分核验，不通过读回同一份缓存来假装独立正确。

8 固定顺序之后还必须固定预算定义

我们预先保存40个打乱epoch，合计1280个样本ID。所有批量方案从同一条ID序列的开头读取，只改变如何分组；没有额外的随机初始化，起始13个参数完全相同。B取1、4、16、32；都用均值损失，不把sum归约导致的倍数变化藏进学习率。[S3]

第一组固定1280次样本呈现、学习率.02。四个B分别更新1280、320、80、40步，终点训练目标约.0108465、.0428222、.0701057、.1385584。第二组固定40步，样本呈现次数变成40、160、640、1280，目标约.1267437、.1385147、.1384830、.1385584。两组回答的问题不同。




图7 左图按样本呈现预算比较，右图按更新步数比较。所有曲线评价同一完整训练目标，不把每个小批次损失混成可直接比较的纵轴。

一次样本呈现指该行参与了一次批次梯度计算，重复epoch会重复计数。它不是独立样本数量，也不是新的数据。完整训练风险日志需要额外前向，报告代码每步计算它以便教学；这些额外评价不计入“训练样本呈现预算”，且在计时程序中关闭，二者都已显式说明。

第三组仍固定1280次样本呈现，但用 $\eta=.02 \times B/4$ ：四个步长为.005、.02、.08、.16，终点训练目标都约.0428，却仍不逐点完全相同。这个例子展示结论对比较协议敏感。我们没有为每种B做独立超参数搜索，没有多个初始化与数据重复，也不使用测试集，因此不能宣称某个B全局更好。[S1]




图8 线性缩放在这小模型与小步长范围内使曲线接近，不证明它能无限扩大，也不替代稳定性与调参检查。

9 计算预算还不等于运行时间

benchmark.py独立测量相同1280次样本预算的四个固定学习率方案。每种先完整预热一次，再重复5次并轮换运行顺序；计时用单调高分辨率perf_counter_ns。固定单CPU线程，记录原始纳秒值、最小/最大、中位数。PyTorch官方基准说明强调预热、线程数与重复测量；本程序使用Python计时器并明确规定自己的测量窗口。[S4][S5]

测量包含一次train(record=False)调用的输入校验、索引展开、线程设置、Tensor初始化、取批、前向、反向、更新与保护检查；不包含导入、读取原始数据、生成顺序、每步完整风险日志、最终核对与文件写入。不能把它说成“纯矩阵乘法时间”。主报告与计时分支的最终参数完全相同。

这次共享CPU观测的中位秒数，B=1、4、16、32依次约.394、.115、.0258、.0134；原始范围明显有波动。图中吞吐只用1280除以各自中位秒数。这里小网络和Python每步开销占有重要地位；没有GPU、设备传输、异步kernel或分布式通信，不能外推大模型吞吐。




图9 计时来自一次真实观测批次。线段表示五次测量的最小到最大范围，不是置信区间；重复运行会得到不同时间。

确定性数值报告与运行时间分开保存。experiment.py不重写measured-timing.json；benchmark.py要求显式给新输出路径。Notebook可以重新计时，但不要求新秒数与旧秒数逐字节一致，也不把复用旧秒数称为重新测量。

10 练习与诊断要求

1. 不用记忆公式，展开B个中心化梯度的外积，推导独立有放回的协方差。若B次都是同一随机索引，哪一步失效？
2. 对四个向量、B=2，列出六个不放回子集的两个坐标均值，算完整协方差并与总体修正一致。
3. 非均匀标量例中推导-1偏差与重要性修正。解释p=0为何不能修复，修正后为何仍可能高方差。
4. 把条件偏差例的第一行改为-1，逐步求theta和下一梯度。为何不能据此断言随机重排一定劣于有放回？
5. 从标量更新式推导均值、方差及稳定区间。eta=.5、B=4时，长期期望超额损失是多少？
6. 沿同一ID25追踪一次2→3→1前向和反向，累计四行得到W00梯度，再做更新后的同批前向。核对全部13坐标，不只看loss。
7. 解释为什么固定40步与固定1280样本的图不能直接支持同一种效率结论。训练风险日志开销算在何处？
8. 怎样让“批量变大就同比增大学习率”的主张在本标量问题上失效？需要报告哪些时序、预算、超参数和时间细节才能让别人复核？

答案给出完整计算，实验指南给出独立运行与失败检查。下一讲继续讨论动量和学习率调度。来源[S1]—[S5]的具体页面与实际阅读范围见sources.md；所有数据、图与数值对照均为本课程原创实验。