

# 034 练习与实验答案

答案沿用正文的记号。网络输出权重写 $u$ ，优化器二阶状态写 $v$ ；源码中的 $v1/v2$ 只是输出权重坐标标签。所有损失均为平均半平方误差，除非明确写出附加惩罚。

## 1 动量与当前梯度可能异号

$\beta=0.8$ ,  $g_1=2$ ,  $g_2=-1$ , 初始 $m_0=0$ 。  $m_1=0.2 \times 2=0.4$ ;  $m_2=0.8 \times 0.4 + 0.2 \times (-1)=0.12$ ; 修正 $m_2=0.12/(1-0.8^2)=0.12/0.36=1/3$ 。当前梯度是负数，修正动量却为正数。若分母为正，Adam此步沿负坐标方向走；只看当前梯度的负号无法推出本次更新方向。

这里第一步修正 $m_1=0.4/2=0.2$ 。第二步历史的归一化权重分别是 $(0.8 \times 0.2)/0.36=4/9$ 、 $0.2/0.36=5/9$ ，故修正动量 $= (4/9) \times 2 + (5/9) \times (-1) = 1/3$ 。

## 2 修正零初始化不等于追上变化的分布

令 $E[g_1]=1$ 、 $E[g_2]=3$ ,  $\beta=0.8$ 。利用期望线性性， $E[m_2]=0.8 \times 0.2 \times 1 + 0.2 \times 3 = 0.76$ ，除以0.36得到 $19/9 \approx 2.1111$ ，而当前 $E[g_2]=3$ 。差异来自历史期望不同，不是少除了一次 $\beta$ 。即使 $g_1$ 与 $g_2$ 相互独立，这个差异仍存在；因此“独立采样”也不能把参数变化造成的分布漂移抹掉。

对二阶状态同理，将 $E[g_k]$ 替换为 $E[g_k^2]$ 即可。若要称为无偏，必须说明针对哪个时刻、哪个分布、条件还是无条件期望。

## 3 两次网络更新的核对点

### 3.1 第1次前向与反向

初始 $Z$ 为 $[[1.2, .8], [-.1, .8]]$ ， $H$ 为 $[[1.2, .8], [0, .8]]$ ，输出 $(.42, -.30)$ ，残差 $(-.28, -.10)$ 。两个半平方误差为.0392与.005，平均 $L_0=.0221$ 。

$dP=(-.14, -.05)$ ， $dH=[[-.084, .070], [-.030, .025]]$ 。乘ReLU掩码 $[[1, 1], [0, 1]]$ 后， $dZ=[[-.084, .070], [0, .025]]$ 。

九个梯度按 $W_{11}$ 、 $W_{12}$ 、 $W_{21}$ 、 $W_{22}$ 、 $b_1$ 、 $b_2$ 、 $u_1$ 、 $u_2$ 、 $c$ 排列为 $(-.084, .045, -.168, .165, -.084, .095, -.168, -.152, -.19)$ 。其中 $W_{12}$ 的两条贡献为 $1 \times .070 = .070$ 与 $(-1) \times .025 = -.025$ ，相加为.045； $u_2$ 为 $(-.14) \times .8 + (-.05) \times .8 = -.152$ 。不能因第2行第1个隐藏单元关闭，就将第2行第2个隐藏单元的贡献也删掉。

### 3.2 第1次Adam更新

取 $\alpha=.02$ 、 $\beta_1=.8/9$ 、 $\epsilon=.001$ 。  $m_1=.2g_1$ 、 $v_1=.1g_1^2$ ，修正后为 $g_1$ 与 $g_1^2$ 。更新后九参数为：

| 参数  | 第1次更新后         |
|-----|----------------|
| W11 | .519764705882  |
| W12 | -.219565217391 |
| W21 | .319881656805  |
| W22 | .380120481928  |
| b1  | .119764705882  |
| b2  | .180208333333  |
| u1  | .619881656805  |
| u2  | -.480130718954 |
| c   | .119895287958  |

例如W12的分母是 $.045+.001=.046$ ，变化量 $-.02 \times .045/.046 = -.0195652173913$ 。u2的分母是 $.152+.001=.153$ ，变化量为 $+.0198692810458$ 。二者符号不同，不能使用绝对梯度直接更新。

### 3.3 第2次前向和两条关键路径

使用全部新参数，Z为 $[[1.279292725, .720884080], [-.080118343, .779894033]]$ ，H只将负值归零，输出 $(.566786791, -.254555795)$ ， $L1=.005180523473031142$ 。

此时 $dP=(-.0666066047073, -.0272778973237)$ ，输出权重已变，因此 $dZ=[[-.0412882124801, .0319798770052], [0, .0130969564536]]$ 。

W12的样本贡献为 $.0319798770052$ 和 $-.0130969564536$ ，合计 $.0188829205516$ 。u2的贡献为 $-.0666066047073 \times .720884079797 = -.0480156409428$ 与 $-.0272778973237 \times .779894032652 = -.0212738693461$ ，合计 $-.0692895102889$ 。

第2步W12原始 $m=.8 \times .009 + .2 \times .0188829205516 = .0109765841103$ ，原始 $v=.9 \times .0002025 + .1 \times .0188829205516^2 = .000217906468856$ 。修正后 $m=.0304905114176$ 、 $v=.00114687615187$ ，分母 $\sqrt{v}+.001=.0348655599669$ 。故 $W12 = -.219565217391 - .02 \times .0304905114176 / .0348655599669 = -.237055549654$ 。

u2原始 $m=-.0381779020578$ 、 $v=.00255946362361$ ，修正后 $m=-.106049727938$ 、 $v=.0134708611769$ ，分母 $.117064039120$ 。更新 $u2 = -.480130718954 - .02 \times (-.106049727938) / .117064039120 = -.462012477223$ 。

其余七个坐标在正文第4.7节均列出原始状态、修正状态、分母与新参数，不需要猜测。完整九个新值为 $(.537997853277, -.237055549654, .338253751553, .361912712513, .137997853277, .162054540115, .638351464670, -.462012477223, .138300135708)$ 。

### 3.4 第3次前向关闭证据链

用以上全部参数得到 $Z = [[1.352503210, .648824415], [-.0617462484, .761022802]]$ 。输出 $(.701907565083, -.213301894398)$ ，残差 $(.00190756508320, -.0133018943978)$ ，逐行半平方为 $.00000181940227333$ 与 $.0000884701972855$ ，平均 $L2 = .00004514479977940921$ 。

第一次梯度算对、第一次Adam算对，还不足以保证第二次正确；忘记清grad、忘记使用新u、重置m/v或将修正指数继续写1，都可能只在第2步暴露。

## 4 epsilon位置和第1步大小

$g = 1e-8$ 、 $\epsilon = 1e-8$ ，修正后 $m = g$ 、 $v = g^2$ 。正确比例是 $g/(\sqrt{v} + \epsilon) = 1e-8/(2e-8) = .5$ ；若写 $\sqrt{v + \epsilon}$ ，比例约 $1e-4$ 。乘上相同alpha后仍相差约5000倍。

前999次梯度0，第1000次1， $\beta = .9/999$ ，则 $m_{1000} = .1$ 、 $v_{1000} = .001$ ；修正 $m = .1/(1 - .9^{1000})$ ，修正 $v = .001/(1 - .999^{1000})$ 。代入根号外 $\epsilon = 1e-8$ ，比例约2.51456608。因此没有无条件“单坐标每步不超过alpha”的保证。本例只给定梯度历史，不证明某个非凸网络必然发散。

## 5 纯衰减的乘积与适用条件

若数据梯度每次为0且 $m_0 = v_0 = 0$ ，两个状态保持0。于是 $\theta_1 = (1 - \alpha_1 - \lambda) \theta_0$ ； $\theta_2 = (1 - \alpha_2 - \lambda)(1 - \alpha_1 - \lambda) \theta_0$ 。归纳可得 $\theta_T = \theta_0$ 乘全部因子。学习率固定时为 $\theta_0(1 - \alpha - \lambda)^T$ 。

已有非零m时，下一次m仍为 $\beta m$ ，修正后通常不为0，还要减去自适应动量步，因此纯衰减公式不能描述整个更新。零梯度不等于零更新。各 $\alpha - \lambda$ 在 $[0, 1)$ 时才是无变号的收缩；近似指数式还要求这些乘积够小。

## 6 三种衰减位置

设 $A_t$ 是由数据梯度历史算出的修正自适应方向。耦合 $L2$ 不是简单写 $\theta - \alpha A_t - \lambda \theta$ ，而是先用 $g + \lambda \theta$ 生成一套不同的 $A_t \wedge L2$ ，再更新 $\theta - \alpha A_t \wedge L2$ 。

对旧参数解耦为 $(1 - \alpha - \lambda) \theta - \alpha A_t$ ；若先做自适应步再把整体收缩，得到 $(1 - \alpha - \lambda)(\theta - \alpha A_t)$ ，展开为前一种结果再加 $\alpha^2 \lambda A_t$ 。它们在一般情形不同。

固定D例子中， $L2$ 与解耦分别得到 $(.97, -3.6)$ 和 $(.97, -3.96)$ 。真实Adam则连 $m/v$ 也不同：二维给定梯度例，第2步坐标1的修正m分别约 $+.0870967742$ 和 $-.1$ ，所以轨迹可以转向相反方向。

## 7 如何解释网格和测试结果

每个配置96步×8行=768次呈现；每家族9配置×3顺序=27训练、2592更新、20736次呈现。三个家族共81次候选训练。另有9次已选配置的轨迹重放，共864步、6912次呈现，是额外诊断成本；此外还运行手算、机制和测试，因此不能把搜索步数当制作全部计算量。

SGD+动量的选中 $\alpha=.03$ ，Adam/AdamW选中 $\alpha=.01$ ，三者都选中衰减0。此时两种Adam完全一样，是预期的退化关系，不能推广到非零衰减。验证均值约.0189195、.0183555、.0183555；冻结后测试均值约.0111594、.0108288、.0108288。只写这些小数差，不能推出显著或普遍优越性。

理由至少包括：只有一个合成拆分；初值固定且三个seed仅改变训练顺序；Adam类的赢家在学习率网格边界；有限候选范围与beta固定；等更新/样本不是等时间。若再看测试扩网格，原测试就已参与研究者选择，后续需要独立封存评价而不能继续自称盲测。

## 8 None与零梯度及恢复

本次PyTorch2.7 AdamW在参数grad=None时跳过该参数，参数、m/v和step都不变；grad为零Tensor则做一步，旧状态衰减、计数增加、参数可因历史动量和weight decay变化。经过一次非零梯度后，例子从.8809900990到.8066182445，后者不是纯衰减的数值。

这个独立恢复例子用学习率.02、betas=.8/.9、epsilon=.001、衰减.1作用于全部九参数，不能误套主训练的偏置排除掩码。完整恢复要保留参数与优化器状态、参数组及其对应顺序。该例在第2步切开、第5步核对，完整内存恢复逐位一致，只恢复参数最大偏差.0428680207。它没有测试磁盘恢复、不同版本或随机采样，更不能从这一个检查点推断所有实际训练都能精确重现。

## 9 合格研究记录应具备什么

读者应能通过你的中间值定位任意一个梯度和更新；能看到全部搜索及明确的选择规则；能区分测试数据与验证数据的职责；能重跑脚本和清空内核的Notebook；能说明自己额外试验是否改变了原协议。报告模型名称、一个最低损失和一张曲线，仍然缺少这些关键证据。