

035 练习详解 激活初始化与信号传播

答案着重解释成立条件。核对数值时先确认对象：激活前还是激活后、中心方差还是二阶矩、任务梯度还是探针梯度、单次运行还是初始化总体。相同数字出现在不同对象上，不能视为同一个结论。

1 三个参数为什么有三个梯度

主例两条样本的输出损失导数分别 $e_1 = 0.025$ 、 $e_2 = 0.1125$ 。输出权重 $u_2 = -0.5$ ，两条样本第二隐藏单元的ReLU门都为1，所以 $\Delta_{2,12} = -0.0125$ 、 $\Delta_{2,22} = -0.05625$ 。

$W_{2,22}$ 乘在第一隐藏层第二单元上；两条输入到这条边的值为0与1.1。因此

$$\frac{\partial L}{\partial W_{2,22}} = (-0.0125) \times 0 + (-0.05625) \times 1.1 = -0.061875.$$

$b_{2,2}$ 对两条仿射输出的局部导数都是1，所以

$$\frac{\partial L}{\partial b_{2,2}} = -0.0125 - 0.05625 = -0.06875.$$

而输出权重 u_2 直接乘在第二隐藏层激活上，两条激活分别0.5与0.75：

$$\frac{\partial L}{\partial u_2} = 0.025 \times 0.5 + 0.1125 \times 0.75 = 0.096875.$$

前两项经过负输出权重而为负，最后一项直接乘正激活而为正。它们的路径和局部输入不同，不能因“都与第二单元有关”就共用一个梯度。

学习率0.1的更新为 $W'_{2,22} = 0.5061875$ 、 $b'_{2,2} = 0.206875$ 、 $u'_2 = -0.5096875$ 。所有其他参数也必须同一步更新，然后在原数据上重算。完整梯度按代码顺序是

$$g = (0.009375, 0.028125, 0.009375, -0.028125, 0.03, 0, -0.015, \dots).$$

其余6项按顺序为 $-0.061875, 0.025, -0.06875, 0.0175, 0.096875, 0.1375$ 。完整索引映射如下。

索引	参数	梯度
0	$W_{1,11}$	0.009375
1	$W_{1,21}$	0.028125
2	$b_{1,1}$	0.009375
3	$b_{1,2}$	-0.028125
4	$W_{2,11}$	0.03
5	$W_{2,12}$	0
6	$W_{2,21}$	-0.015
7	$W_{2,22}$	-0.061875
8	$b_{2,1}$	0.025
9	$b_{2,2}$	-0.06875
10	u_1	0.0175
11	u_2	0.096875
12	c	0.1375

新预测为 $(0.518980491230\dots, -0.304440022717\dots)$ ，新损失 0.009650990940541462 。梯度表有零并不意味着程序错误，但每个零都应能解释。比如 $W_{2,12}$ 的一条路径输入为0，另一条路径门为0。

2 离散ReLU和正态假设

Z 等概率为 $-2, 2$ ，ReLU输出 H 等概率为0、2。因此

$$E[H] = 1, \quad E[H^2] = 2, \quad \text{Var}(H) = 2 - 1^2 = 1.$$

输入 $E[Z] = 0$ 、 $E[Z^2] = 4$ ，所以二阶矩减半仍然精确成立；但用正态均值公式会得到 $\sqrt{4/(2\pi)} \approx 0.797885$ ，不是1。错在将分布对称自动升级成正态。对称只确保正负平方贡献相等，不确定 $E|Z|$ 的具体数值。

进一步，若 Z 在0有质量， $P(Z > 0)$ 可能小于1/2；二阶矩减半仍成立，因为零不贡献平方。反向门的 $E[D^2]$ 却等于 $P(Z > 0)$ （若0处实现取0），这时不能再直接写成1/2。这是前向二阶矩和反向门概率需要分别陈述条件的例子。

3 宽度变化与三种标准差

输入16、输出64， $W \in \mathbb{R}^{64 \times 16}$ 。

方法	权重方差 s^2	标准差 s	前向系数	近似反向系数
Xavier normal, gain=1, 线性化	$2/80 = 0.025$	0.158114	$16s^2 = 0.4$	$64s^2 = 1.6$
He fan_in, ReLU	$2/16 = 0.125$	0.353553	$16s^2/2 = 1$	$64s^2/2 = 4$
He fan_out, ReLU	$2/64 = 0.03125$	0.176777	$16s^2/2 = 0.25$	$64s^2/2 = 1$

第一行的系数针对近似线性激活；若把相同Xavier权重用于ReLU并满足对称条件，还应分别除以2，得到0.2与0.8。不能将不同激活的系数放在同一列后不标条件。

Xavier的两个线性系数平均为1，不是各自为1。He fan_in保前向的简化二阶矩；fan_out保反向的近似二阶矩。哪个适合实际网络还取决于后续结构、损失、输入尺度和训练过程。

若误把 W 当 $[in, out]$ 传入fan_in初始化，会用64替代16，标准差小一半、方差小四倍。二维Xavier的fan之和对转置不变，不会暴露这个错误；不能用“Xavier时好像没事”证明布局正确。

4 leaky ReLU的系数

假设 Z 关于0对称、二阶矩有限，负半轴斜率 a 为固定实数。平方后的正半轴贡献为 $E[Z^2]/2$ ，负半轴为 $a^2 E[Z^2]/2$ ，所以

$$E[\phi(Z)^2] = \frac{1+a^2}{2} E[Z^2].$$

若每层新权重零均值独立且与输入独立、输入坐标共享二阶矩、偏置0，则前向总体递推系数为 $(1+a^2)fan_in s^2/2$ 。令它为1得到 $s = \sqrt{2/[(1+a^2)fan_in]}$ 。

$a = 0.1, fan_in = 64$ 时，方差 $2/(1.01 \times 64) \approx 0.0309405941$ ，标准差约0.175899386。边界 $a = 0$ 回到ReLU的 $\sqrt{2/64}$ ， $a = 1$ 回到线性的 $1/\sqrt{64}$ 。这是激活平方缩放的连续过渡，不依赖把激活均值设为0。

5 相关输入使交叉项抵消或增强

$X_1 = X_2 = T$ 且 $T = \pm 1$ 等概率，取固定 $w = (1, -1)/\sqrt{2}$ 。输出 $Z = (T - T)/\sqrt{2} = 0$ ，故实际方差0。只算对角项得到 $1/2 + 1/2 = 1$ 。

完整展开为

$$\text{Var}(Z) = w_1^2 \text{Var}(X_1) + w_2^2 \text{Var}(X_2) + 2w_1w_2 \text{Cov}(X_1, X_2) = 1 - 1 = 0.$$

若换成正文的 $w = (1, 1)/\sqrt{2}$ ，交叉项为+1，实际方差2。忽略协方差可能高估，也可能低估。

这不推翻新层独立零均值随机权重的总体公式。固定 w 对数据取方差，与对每次新抽的 W 取总体期望，是不同概率实验。在后者中权重交叉项期望为0，在前者中不能这么删。考试或论文里只写一个无下标Var容易隐藏这个区别。

6 ReLU边界的差分核验

在0处, $h > 0$ 时中央差分为

$$\frac{\max(0, h) - \max(0, -h)}{2h} = \frac{1}{2}.$$

左导数0, 右导数1, 常规导数不存在。PyTorch2.7返回0, 符合其对这个算子的边界选择; 中央差分0.5测的是跨越拐点的对称割线。两者不相等不能证明反向错误。

正确检查方式: 选择远离门切换的参数点, 确认足够小扰动不改变门; 同时把不可导边界作为单独的行为测试, 记录框架版本和返回值。不要盲目调大有限差分容差, 让真正的链式法则错误也通过。

7 一段合格的实验结论

可写为: 在固定的128条合成训练样本、12层宽64网络、全批次SGD学习率0.03和3个初始化种子下, ReLU的 $\alpha = \sqrt{2}$ 比 $\alpha = 1$ 更接近保持初始化激活与探针梯度的二阶矩, 100步训练损失中位数也更低。sigmoid的激活二阶矩仍约0.28, 却出现非常小的前层相对探针梯度; 所以输出或激活数值不小不足以排除梯度消失。

同时, tanh的 $\alpha = 2$ 在本次训练中表现较好, 表明较大权重、局部饱和与整体拟合速度的关系不能由单一因素决定。linear的 $\alpha = 1$ 虽有接近保持的初始化平均传播尺度, 仍有两个种子在固定学习率下触发损失停止。因此初始化二阶矩保持不是稳定训练的充分条件。

限制必须一起写: 仅3个初始化重复; 所有数据用于训练; 未针对各配置单独搜索学习率; 没有残差、归一化、注意力、混合精度或GPU; 48配置中有11次停止, 不能将最后记录值当作100步成绩。结果支持这一设置中的机制诊断, 不构成通用激活或初始化排名。

不合格写法包括“sigmoid没有任何学习能力”“He保证梯度不消失”“tanh尺度2总是最好”。它们把有限实验、平均量或有条件推导提升成了普遍保证。

8 一个预先约定的bias实验

固定ReLU、 $\alpha = \sqrt{2}$ 、128条原数据、12层宽64、同一输出头、种子35至54。只把每个隐藏层bias初始化常数改为 $-0.5, 0, +0.5$, 所有权重使用相同种子的标准正态底数。保持无动量SGD学习率0.03和100次更新。输出bias仍为0, 避免把多个因素混在一起。

预先记录初始化和第1、10、100次更新后的 Z, H 均值、中心方差、二阶矩, 以及每单元跨样本的负输入比例、全部样本均关闭的单元比例、任务/探针梯度分布。按种子先计算每种bias相对0的差, 再汇总20个配对差异, 不把8192个位置当独立种子。

主要假设: 负bias会增加初始零门比例; 正bias会改变激活均值, 使零偏置对称递推不再直接适用。判据可以预设为第12层激活二阶矩与输入比超出 $[0.1, 10]$ 的种子比例, 以及第1层相对第12层探针二阶矩低于 10^{-4} 或高于 10^4 的比例。这些阈值是为比较事先定义的教学诊断标准, 不是普遍的“健康区间”。

保留全部停止记录，使用与原实验相同的损失预算和非有限检查。不要在看到结果后更换bias范围、改学习率却仍称为“只改bias”。本题是实验设计答案，这组20种子bias训练没有在交付实验中执行，因此不能写出伪造的结果。

9 实验输出的关键自检

1. 主扫描应有48个case、576条初始化层统计；宽度实验另有48行。完整训练成功37次，损失预算停止11次。停止数量依赖本次固定环境与协议，修改协议后应重新记录。
2. 对每一层， $h_second - h_variance - h_mean^2$ 应接近舍入误差。中心方差的单元内/单元间分解也应吻合。
3. 对正文手算，Fraction与自动微分的13梯度逐项相符；中央差分最大绝对误差受测试阈值 4×10^{-11} 约束。测试阈值不是本次实际误差数值。
4. 输入布尔、字符串、NaN或一维标签应被拒绝；无效steps和不存在数据文件应在写输出前失败；已有哨兵文件应保持字节不变。
5. Notebook重新运行完整扫描并按SHA-256比较5个输出文件；逐单元执行成功与结果一致都要检查，不能只确认ipynb是合法JSON。

在真实项目里，若最后只有输出层梯度记录，就还不能诊断哪一层开始衰减。本讲的最重要习惯是把计算对象、统计轴、成立条件和可重算证据一起写出来。