

036 练习详解 统计组与状态边界

沿用正文三行数据、 $\epsilon=1/3$ 、学习率.1。先自行完成，再对照；小数末位受浮点舍入影响。

1 第一次前向与平均因子

Z三行是(0,-1)、(1,0)、(2,1)，列均值(1,0)，中心化两列都为(-1,0,1)。平方和2，除3得到 $v=2/3$ ；加 $\epsilon=1/3$ 得1，开方仍1。Q两列都是(-1,0,1)。

乘 $\gamma=(1,.5)$ ，加 $\beta=(.25,-.1)$ ，H三行(-.75,-.6)、(.25,-.1)、(1.25,.4)。输出 $u=(.6,-.4)$ 、 $c=.05$ ，所以 $P=(-.16,.24,.64)$ 。误差(-.36,.34,-.16)，半平方误差(.0648,.0578,.0128)，平均 $L=.04513333333333$ 。

dP是误差除3，即(-.12,.1133333333,-.0533333333)。此后不再把dW除3；若预先把每个损失定义为半平方误差除3，其逐损失梯度也已含此因子。

2 删除均值方差路径的错误

第1特征dQ=(-.072,.068,-.032)。如果误把均值方差当常数， $s=1$ ，直接使用 $dZ=dQ$ ，则错误W11梯度为 $(-1)(-.072)+0(.068)+1(-.032)=.04$ 。

正确方差路径是(.0133333333,0,-.0133333333)，均值路径每行.012。三者相加 $dZ=(-.0466666667,.08,-.0333333333)$ ，所以W11梯度=.0133333333。错误不仅让数值不同，还破坏平移不变性：错误b1梯度为-.036，正确为0。

detach统计量会改变反向规则；前向相同不足以说明梯度图相同。

3 跨样本梯度来自共享统计量

样本2的平均损失项有 $dP2=.1133333333$ ，乘 $u1=.6$ 、 $\gamma1=1$ 得 $dQ21=.068$ 。J的第2行第1列 $=-1/3$ ，因此它给样本1第1隐藏输入的贡献为-.0226666667。

样本1参与了 μ 与 v ，样本2的归一化值又依赖这些统计量，所以标签2的误差能沿这条共享路径传回样本1。三项损失对同一Z坐标的贡献须相加，不能逐样本独立归一化后冒充batch反向。

4 Jacobian的两个检查方向

由 $J = (I - \mathbf{1}\mathbf{1}^T/m - q\mathbf{q}^T/m)/s$ ，利用 $\mathbf{1}^T q = 0$ ，可得 $J\mathbf{1} = 0$ 。这对应所有组元素加相同常数时输出不变。

另一方面 $q^T q/m = v/(v + \epsilon)$ ，所以

$$Jq = \frac{1}{s} \left(1 - \frac{v}{v + \epsilon} \right) q = \frac{\epsilon}{s^3} q.$$

epsilon大于0时通常不为零；不可一边保留epsilon一边按0推导。输入全相等时q=0，但去均值扰动的响应仍为 $1/\sqrt{\epsilon}$ 倍。

5 LN数字与D等于1的退化

第一行(1,3)，mu=2、v=1、s= $\sqrt{2}$ ，Q=(-1/ $\sqrt{2}$, 1/ $\sqrt{2}$)。H=(.1- $\sqrt{2}$, -.2+1/ $\sqrt{2}$)，即(-1.31421356, .507106781)。第二行(2,2)，mu2、v0、s1，Q=(0,0)，H=(.1, -.2)。

对第二行，未乘gamma的J是[.5, -.5], [-.5, .5]]。因此H第二行第1特征对同一行两个输入的导数为gamma1=2乘J第1行，即(1, -1)，不是零。程序已实际对框架求得该值。若D=1，J=(1-1-0)/s=0，输出恒为beta；这是不同的退化情形。

LN的反向先把每个上游乘自己的gamma，再做组内J乘积。各坐标gamma不同，不可把一个统一gamma放到求和外。

6 两次运行统计与不反传的前向

第一次批均值(1,0)，分母3方差(2/3, 2/3)，送入运行更新的无偏批方差为3/2乘它，即(1,1)。a=.2、旧运行均值0、旧运行方差1，于是新均值(.2, 0)、新方差(1,1)。

第二次批均值(.9986666667, .0004444444)，无偏批方差(.9946737778, 1.0017785679)。运行均值=.8(.2, 0)+.2(.9986666667, .0004444444)=(.3597333333, .0000888889)。运行方差=.8(1, 1)+.2(.9946737778, 1.0017785679)=(.9989347556, 1.0003557136)。

这段递推发生在训练前向，不属于SGD。no_grad会阻止通常的自动微分图记录，却不阻止这段buffer更新。冻结gamma/beta也不阻止它。反过来eval选择保存统计，但可继续对参数或输入求导。

7 累计批统计不等于拼接统计

两批均值1和11，momentum=None得到(1+11)/2=6；按样本数加权的均值为(2×1+4×11)/6=46/6=23/3。

两批无偏方差2、4/3，累计平均5/3。所有六个数的平方和为492，均值23/3，中心平方和为 $492 - 6(23/3)^2 = 418/3$ 。拼接无偏方差为 $418/15 = 27.86666667$ ，远大于5/3，原因是两批中心相距很远。

只平均批内方差丢掉了批均值之间的变动；同时不等批大小还改变权重。即使批大小相等，平均批方差也不能无条件替代拼接方差。这不是PyTorch算错，而是估计对象不同。

8 BN统计组大小与最后一批

二维(1,C)每通道只有1个数，训练BN拒绝；三维(1,C,2)跨N和L共有2个数，训练BN可计算。判断依据是每个归一化组的元素数，不是只看N。位置若强相关，有效统计信息仍可能很少。

检查数据集大小除batch_size的余数、drop_last、重排及丢弃数。最后单样本不能静默改eval或跳过：这会改变函数或样本预算，须在协议说明并核对部署条件。

9 微批反例不是损失加权错误

四行数据中最后一行是(2,-1)、标签.4。单次4行损失.1623673579816456；两个2行微批都按1/2权重后，损失.23571551260082124。W11梯度分别.0450004127652530和.1336958014823322，差.0886953887170792。

每个微批用自己的均值方差，因此两个目标函数本来不同。正确权重只合并不同微批目标，无法把统计量恢复成大批统计。运行统计也会更新两次而不是一次。若仅在固定eval统计下处理，当前例中归一化成了逐样本仿射运算，才可重新讨论通常的可分损失累积等价性。

10 六次运行与错误验证的修复

不能宣称B=4普遍更好的理由至少有：同一合成数据与固定初始化；只改变三个重排种子；B=4有128次更新而B=16仅32次；运行统计更新次数和每批统计噪声也不同；只使用一个固定学习率、未调优；32行是诊断验证而非独立测试；未做时间预算比较、总体不确定性或真实任务验证。

修复本讲单一模式模型的最小代码如下。若使用混合子模块模式，应逐模块保存和恢复，而不是套用一个根开关。

```
was_training = model.training
try:
    model.eval()
    with torch.no_grad():
        predictions = model(validation_inputs)
finally:
    model.train(was_training)
```

把train误当eval的验证会额外更新8次BN状态；之后即使补eval，也不能还原旧buffer。若已经被污染，应从验证前完整state_dict快照恢复，或从有记录的检查点重新执行。不能只把num_batches_tracked减8而保留已变的均值方差。

六次运行中污染后损失有升有降，分数方向不能辨别协议正确性。未标记数据适应应另立方案，公开允许信息、过程、超参数及独立评价。