

036 实验指南 归一化轴与模型状态

目标是把纸上的归一化变换与实际模块状态逐项对齐。完成后应提交两轮手算核对、BN/LN轴报告、模式四组合、六次训练全部记录以及一个错误验证诊断。任何环节只写“代码跑通”都不足以证明理解。

先读lecture.pdf第1至3节；准备018的方差与030的训练循环知识。这里的96行数据全部合成，无需账号、网络数据、GPU、付费API或下载模型。与035的层传播实验不同，本讲专门检查统计组与运行buffer。

1 环境和文件

先阅读README.md和environment.yml。制作时实际运行Linux CPU、Python3.12.14、NumPy2.3.5、PyTorch2.7.1+cpu、Matplotlib3.10.8, float64、单线程。未声称所有平台的全新Anaconda安装已验证。以下命令在本单元目录执行：

```
conda env create -f environment.yml
conda activate dl-unit-036
python experiment.py --output my-run
python -m unittest -v test_experiment
jupyter lab
```

如果已有独立Python环境，可按README的CPU官方安装方式准备依赖。不要把pip装入另一个解释器。打开experiment.ipynb后重启内核，从首格依次执行；内嵌旧输出仅供核对。首格会检查固定输入和报告摘要，变更fixture后应建立自己的实验，不要复用旧报告。

主要数据文件：hand-example.json保存三行手算、13参数和epsilon；config.json保存采样与重排配置；samples.json包含64训练和32验证记录。全部9份数值产物由脚本重新计算。make_figures.py从有摘要保护的产物重画11图；重画图需要本机中文字体，但阅读现成PDF不需要字体环境或文档构建工具。

2 先遮住答案 完成一次BN闭环

在纸上写出X、W、b、gamma、beta、u、c的shape。逐行计算Z，沿三个样本求mu、分母3的v、s，再计算Q、H、P和平均半MSE。预测应为(-.16,.24,.64)，损失.04513333333333。如果在这里不一致，先修正前向，不要直接去查optimizer。

手算dP后，把局部导数写到每条边上。先得dH、dQ，再分别求方差和均值上游，最后三条路径相加。画出两个 3×3 Jacobian，标出非对角项。用样本1的损失反向一次，检查其对输入行2的第1隐藏特征梯度.024。

把三个损失项对13参数的贡献写成 3×13 表，按列求和。确认b两坐标为零；它是当前训练态BN共享偏置的数学抵消，浮点残余不是学习信号。用学习率.1同时更新13参数，重新前向。第二次损失约.0439707569884。继续第二次完整反向与更新，第三次前向损失约.0430776824061。

Notebook将分格打印全部局部与路径数据。不能只比较三个最终loss，还应核对至少一个跨样本路径、一个W梯度、gamma梯度、beta梯度及输入dX。正文已给所有中间链，无需从JSON自行猜省略步骤。

3 用独立公式对框架的轴

对(2,3,2)张量分别做以下三种处理：BN固定D跨N/T，LN(D)跨末轴，LN((T,D))跨末两轴。预测它们的统计组个数和每组元素数，再运行axes_demo。

```
import experiment as e
import numpy as np
r = e.axes_demo()
print("shape", r["shape_N_T_D"])
print("BN means", r["BN_axes_N_T"]["mu"])
print("LN(D) means", r["LN_axes_D"]["mu"])
print("LN(T,D) means", r["LN_axes_T_D"]["mu"])
print("framework differences", r["torch_max_error"])
if max(r["torch_max_error"]) > 1e-12:
    raise ArithmeticError("Axis comparison failed")
```

BN1d在框架中使用(N,C,L)，这里要把(N,T,D)转成(N,D,T)，再转回；不能直接reshape把轴语义揉在一起。记录两次transpose的形状，不要只观察最后shape一样。

另用 $Z = \begin{bmatrix} 1 & 3 \\ 2 & 2 \end{bmatrix}$ 、epsilon1、gamma=(2,1)、beta=(.1,-.2)手算LN。第二行H=(.1,-.2)并不意味着D=2输入扰动梯度为零；与D=1恒为beta的情况分开。

4 模式四组合与运行统计

执行modes_and_buffers，并填表：归一化用当前批还是运行统计；是否记录梯度；num_batches_tracked是否增加。把“冻结gamma/beta”作为第五种实验，再检查buffer有没有动。解释为什么no_grad不阻止统计更新，eval也不自动关闭输入梯度。

手算a=.2时第一次运行均值(.2,0)，方差(1,1)。第二次必须使用新参数前向的统计；对照正文第6节。不许把用于训练前向的分母3方差直接塞入本版本的running_var更新。

再比较momentum=None的两批[0,2]和[10,10,12,12]：运行均值6，拼接样本均值46/6。计算运行方差与拼接无偏方差，写出“缺了组间均值差”的一段解释。检查state_dict包含哪些buffer，并说明加载后为什么仍要显式eval。

5 小批量和分布变化

对 $B=2/4/8/32$ 各200次固定锚点采样，使用batch-sampling.csv绘制自己的散点或箱线图。报告它是“一个固定锚点加随机同伴”的设计；不要使用完全独立同分布样本均值的标准误公式给它贴标签。把锚点与同伴同时随机化会成为另一个实验，需要另立输出目录和结论。

观察第21批起总体均值从0变3时，运行统计与当前批均值的差。解释EMA旧信息的衰减和新信息的波动之间的权衡。此处不使用验证或测试数据去重新校准一个部署模型，仅观察已明确的合成序列。

对4行微批例，先确认两个微批都大小2，再按1/2累积损失。其梯度仍与单次4行不同。请写出原因是统计组改变，而不是忘记除batch_size。记录最大坐标差约.0886953887。

6 真正训练后 故意复现错误验证

六次运行使用相同初值和同一固定拆分。两种B、三种重排，各8epoch与512次训练呈现。填写 $B=4$ 的128次更新和 $B=16$ 的32次更新，并解释为何这不是等更新预算排名。这里没有超参数选择或封存测试排名，32行仅用于状态诊断。

每个epoch正确使用eval加no_grad。保存参数与所有buffer快照，确认验证前后相等。训练结束另深拷贝模型，故意用train加no_grad分成8批验证；记录预测变化、运行计数多8、running_mean变化。随后再eval观察污染后的输出。

不要因为污染后损失变低就把它当成有效改进。它使用了验证输入改变模型的运行状态。若科研问题是测试时适应，应预先另定协议并重新评价，不能把它混进原来的无更新测试。

7 验收与扩展

提交全部13参数两轮计算、轴语义、四组合表、六次完整训练结果和限制说明。测试程序包含Fraction第一步核对、75位Decimal随机网络差分、所有损失来源路径、80组Jacobian恒等式、480次独立NumPy训练重建；都验证实现，不证明现实泛化。

建议扩展只改一个因素并写新文件：epsilon扫描、相关同伴、最后一批大小或统计更新系数。每次先声明预期改变哪条数学关系，再执行；记录无变化和失败结果。不得篡改固定fixture后继续展示原图。程序在所有计算与序列化通过后才写输出，采用逐文件原子替换，未声称目录级断电事务。