

036 归一化与训练推理状态

这一讲回答：同一个样本为什么会因为“同批次还有谁”而得到不同预测？前035讨论初始化时的信号尺度；现在把依赖当前激活的均值和方差放进计算图，追踪它怎样改变前向、反向和部署状态。读完应能指定BN与LN的归约轴，完整算出一批数据的跨样本梯度，并解释参数没有改变时预测仍会改变的原因。

先修018的均值方差、030的模块与训练循环，以及035的激活尺度。公式约定、三行数据、13个参数和全部中间量都在本讲重新给出，不要求跨讲导入程序。正文中的两步手算是可微机制；后面的CPU合成实验是状态诊断，不能推出哪种归一化在所有任务上更好。

1 先问谁与谁一起计算统计量

张量有形状还不够，还要给每条轴命名。用 $X \in \mathbb{R}^{N \times T \times D}$ 表示N个样本、每个样本T个位置、每个位置D个特征。相同的减均值除尺度公式，用不同轴归约就会成为不同模型。

对二维 $Z \in \mathbb{R}^{B \times C}$ ，训练态BatchNorm逐特征计算统计量：固定列j，跨B行。一个样本改变，其他样本的归一化结果也可能变。对三维序列，PyTorch的BatchNorm1d输入约定是 (N, C, L) ，每个通道跨N与L归约。若数据按 (N, T, D) 保存，要先把D换到通道轴，不能因为D恰好等于T就省略语义检查。

LayerNorm(D)则固定某个样本的某个位置，跨最后D个特征归约。它不会通过这次归一化引入不同样本之间的统计依赖。LayerNorm((T,D))会跨最后两轴，连不同位置也一起处理；这和LayerNorm(D)不是同一个运算。用于预测序列时，若把未来位置也放进统计组，就应重新审查信息是否泄漏。

输入：两个样本，每个3个位置

N0 T0	0	2
N0 T1	1	4
N0 T2	2	6
N1 T0	4	-2
N1 T1	5	0
N1 T2	6	2
	D0	D1

BN：每列跨样本及位置

N0 T0	0	2
N0 T1	1	4
N0 T2	2	6
N1 T0	4	-2
N1 T1	5	0
N1 T2	6	2
	D0	D1

LN(D)：每行跨两个特征

N0 T0	0	2
N0 T1	1	4
N0 T2	2	6
N1 T0	4	-2
N1 T1	5	0
N1 T2	6	2
	D0	D1

图1 每个彩框是一组共享均值方差的数。左图把N和T暂时展开为六行，便于看见数值；代码仍保留三维。中图跨列内六个数，右图每行两个数。读图：更换N1的三个位置会影响N0的BN结果，为什么不会改变N0的LayerNorm(D)结果？

本讲使用BatchNorm原论文的按特征批统计定义，以及LayerNorm原论文第3节的组内定义。原论文提出的动机与特定基准结果，不是本讲小实验已证明的机制解释或普遍收益；这里不把“消除内部协变量偏移”当作已确立的唯一因果解释。

2 从一组数推导归一化

2.1 均值 方差 epsilon 缩放和平移

令一个统计组有 m 个数 $z_1, \dots, z_m$ 。定义

$$\mu = \frac{1}{m} \sum_i z_i, \quad c_i = z_i - \mu, \quad v = \frac{1}{m} \sum_i c_i^2.$$

随后计算 $s = \sqrt{v + \epsilon}$ 、 $q_i = c_i/s$ ，最后 $h_i = \gamma_i q_i + \beta_i$ 。BN同一通道的所有样本共享一个gamma与beta；LN的gamma和beta通常沿所声明的归一化特征形状分别学习。参数不会每个batch重置为1和0；初始化为1和0只是初始选择。

这里 v 的分母是 m ，目的是在当前组内执行一个确定的变换。018为估计总体方差使用的 $m - 1$ 是另一个问题。BN的训练前向与PyTorch保存运行方差采用的估计约定还不同，第6节会用数字分开。归一化逐特征处理，不会消除特征之间的协方差，因此不是完整白化。

因为 $\sum_i c_i = 0$ ， q 的组内均值为0，但组内方差是

$$\frac{1}{m} \sum_i q_i^2 = \frac{v}{v + \epsilon},$$

只在忽略epsilon的极限或近似下才接近1。gamma、beta之后更不能一律称为零均值单位方差。epsilon和 v 量纲相同；把epsilon写到根号外就改变了函数。低精度或极端幅度下仍可能溢出，添加epsilon并不是任意输入都数值安全的证明。

2.2 epsilon怎样改变梯度和不变性

给组内所有 z 加同一常数 a ，中心化会精确抵消 a 。把所有 z 乘正数 a 时， q 变为 $ac/\sqrt{a^2v + \epsilon}$ ；epsilon固定时它并不严格等于原 q 。对负 a 还要考虑符号翻转。不能把“近似尺度不变”写成所有epsilon下的精确等式。

当 $v=0$ 时，所有 $q=0$ 并不意味着对独立输入扰动的导数必为0。只要 m 大于1，扰动其中一个数会使它与均值分开。后面推导的Jacobian为 $(I - \mathbf{1}\mathbf{1}^T/m)/\sqrt{\epsilon}$ ，epsilon越小，这种方向越敏感。 $m=1$ 才是所有输入都被减为0，gamma无从恢复被消掉的信息，输出只有beta。




图2 左图是严格公式 $v/(v+\epsilon)$ ，没有把 ϵ 影响省掉。右图是组内尺度方向的Jacobian特征值 $\epsilon/(v+\epsilon)^{3/2}$ 。极小方差时梯度可能敏感；归一化不等于把所有梯度压成安全大小。手算使用 $\epsilon=1/3$ 是为了算得清楚，不是推荐超参数。

3 归一化为什么必须进入计算图

3.1 把每条局部路径写出来

下面先对一个统计组推导。上游给出 $a_i = \partial L / \partial q_i$ ，从除法开始：

$$\left. \frac{\partial q_i}{\partial c_i} \right|_v = \frac{1}{s}, \quad \left. \frac{\partial q_i}{\partial v} \right|_c = -\frac{c_i}{2(v + \epsilon)^{3/2}}.$$

竖线表示暂时把另一个输入当独立量固定，不是完整导数。方差分支累积为

$$\bar{v} = -\frac{1}{2}(v + \epsilon)^{-3/2} \sum_i a_i c_i.$$

均值的上游要同时接收直接中心化和方差路径：

$$\bar{\mu} = -\sum_i \frac{a_i}{s} + \bar{v} \frac{1}{m} \sum_i (-2c_i).$$

最后的和在精确算术中为0，但保留它能看清路径来自哪里。每个输入收到三项：

$$\bar{z}_i = \frac{a_i}{s} + \bar{v} \frac{2c_i}{m} + \frac{\bar{\mu}}{m}.$$

三项依次是直接路径、方差路径、均值路径。若在代码里把均值与方差detach，便只留下第一项；那不再是原归一化函数的导数。

反向必须同时走直接、均值、方差三条路径




图3 Z同时进入均值与中心化；中心化又进入方差与除法。反向遇到分支就要相加。图上的一条边可以代表一个张量运算，数值局部导数仍由正文逐项展开。

3.2 化成可检查的Jacobian

用 $\partial\mu/\partial z_k = 1/m$ 和 $\partial v/\partial z_k = 2c_k/m$ ，对每个 q_i 求导：

$$J_{ik} = \frac{\partial q_i}{\partial z_k} = \frac{1}{s} \left(\delta_{ik} - \frac{1}{m} - \frac{q_i q_k}{m} \right).$$

这里 δ_{ik} 是i等于k时取1、否则取0的符号。i是归一化输出编号，k是输入编号。反向是 $\bar{z}_k = \sum_i a_i J_{ik}$ ，不是只取 J_{kk} 。BN中这些编号跨样本；LN中它们跨同一个样本内部的特征。矩阵形式可简化为

$$\bar{z}_i = \frac{1}{s} (a_i - \text{mean}(a) - q_i \text{mean}(aq)).$$

这给出两条非常有用的检查。第一， $J\mathbf{1} = 0$ ，所以 $\sum_i \bar{z}_i = 0$ ；训练态BN之前单独加的共享偏置b，其梯度会抵消。结论假定这条BN路径是该偏置影响损失的唯一途径，不含额外惩罚或旁路。第二， $Jq = \epsilon q/s^3$ ，所以epsilon大于0时尺度方向一般不被完全消去。浮点计算里约 10^{-18} 的残余不应被解释为真实信号。

4 三个样本的13参数完整闭环

4.1 固定所有约定

本例有输入仿射层、BN的缩放平移、输出仿射层；暂不加激活函数，以免把归一化路径藏在别的非线性里。BN本身在训练态通过批统计产生非线性与跨样本依赖。输入和标签是

$$X = \begin{pmatrix} -1 & 0 \\ 0 & 1 \\ 1 & 2 \end{pmatrix}, \quad y = (0.2, -0.1, 0.8)^T.$$

$Z = XW + b$ ，W的行对应输入坐标、列对应隐藏特征。初值

$$W = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}, \quad b = (1, -1), \quad \gamma = (1, 0.5), \quad \beta = (0.25, -0.1).$$

$H = \gamma \odot Q + \beta$, $P = Hu + c$, $u = (0.6, -0.4)^T$, $c = 0.05$ 。总共4+2+2+2+2+1=13个参数。取 $\epsilon = 1/3$ 、 $L = \sum_i (P_i - y_i)^2 / (2B)$, $B=3$, SGD学习率0.1, 无动量、无权重衰减。参数只在全部梯度就绪后同时更新。

量	shape	含义
X Z Q H	3×2	三样本 两特征
W	2×2	输入特征到隐藏特征
mu v s gamma beta b	长度2, 广播时 1×2	每特征一项
P y dP	长度3	每样本一项
J	$2 \times 3 \times 3$	每特征一个跨样本Jacobian
逐损失参数贡献	3×13	每个损失项对全部参数的贡献

数据三行只是为精确计算构造的合成例子，输入行具有特殊线性关系。以下数值只验证算法，不借它推断训练可识别性或泛化。

4.2 第一次前向不能跳过均值方差

逐行乘W加b得 $Z_1 = (0, -1)$ 、 $Z_2 = (1, 0)$ 、 $Z_3 = (2, 1)$ 。因此 $\mu = (1, 0)$ ，两列中心化都为 $(-1, 0, 1)$ ，各列平方和2，除以3得 $v = (2/3, 2/3)$ 。再加epsilon=1/3，开方得 $s = (1, 1)$ 。这就是本例选择epsilon的原因。

样本	Z	Q	H	P	误差	半平方误差
1	(0, -1)	(-1, -1)	(-0.75, -0.6)	-0.16	-0.36	0.0648
2	(1, 0)	(0, 0)	(0.25, -0.1)	0.24	0.34	0.0578
3	(2, 1)	(1, 1)	(1.25, 0.4)	0.64	-0.16	0.0128

例如样本1: $P_1 = (-0.75)0.6 + (-0.6)(-0.4) + 0.05 = -0.16$ 。它的误差为-0.36，半平方误差0.0648。三项相加为0.1354，再除3得到 $L_0 = 0.04513333333333$ 。半平方误差不是最终平均损失；下面反向只在 $dP = (P - y)/3$ 处除一次3。

4.3 先到H与Q 再通过三条BN路径

输出层局部导数是 $\partial P_i / \partial H_{ij} = u_j$ 、 $\partial P_i / \partial u_j = H_{ij}$ 、 $\partial P_i / \partial c = 1$ 。BN仿射局部导数是 $\partial H_{ij} / \partial Q_{ij} = \gamma_j$ 、对gamma为 Q_{ij} 、对beta为1。

样本	dP	dH=dP u	dQ=dH gamma
1	-0.12	(-0.072, 0.048)	(-0.072, 0.024)
2	0.113333333	(0.068, -0.0453333333)	(0.068, -0.0226666667)

样本	dP	dH=dP u	dQ=dH gamma
3	-0.0533333333	(-0.032, 0.0213333333)	(-0.032, 0.0106666667)

均值局部导数对每个输入都是1/3；方差对各输入行的局部导数为 $2c_i/3$ ，两列均为 $(-2/3, 0, 2/3)$ 。

$\partial Q/\partial v = -c/2$ 在本次 $s=1$ 时，两列均为 $(0.5, 0, -0.5)$ 。于是

$$\bar{v}_1 = (-0.072)(0.5) + 0.068(0) + (-0.032)(-0.5) = -0.02,$$

$$\bar{v}_2 = 0.024(0.5) + (-0.0226666667)(0) + 0.0106666667(-0.5) = 0.0066666667.$$

两列dQ求和为 $(-0.036, 0.012)$ ，故 $\bar{\mu} = (0.036, -0.012)$ 。现在三条路径逐行相加：

样本	直接dQ/s	方差路径	均值路径	总dZ
1	(-0.072, 0.024)	(0.0133333333, -0.00444444444)	(0.012, -0.004)	(-0.0466666667, 0.0155555556)
2	(0.068, -0.0226666667)	(0, 0)	(0.012, -0.004)	(0.08, -0.0266666667)
3	(-0.032, 0.0106666667)	(-0.0133333333, 0.00444444444)	(0.012, -0.004)	(-0.0333333333, 0.0111111111)

输入梯度为 $dX = dZW^T$ ，初始W为单位矩阵，所以本次dX与上表dZ相同。它们不是需要更新的参数，但显示每个输入对总损失的影响，程序也逐坐标核验了这些数值。

4.4 不能把一行BN独立当成一个样本网络

本次每个特征的Jacobian都为

$$J = \begin{pmatrix} 1/3 & -1/3 & 0 \\ -1/3 & 2/3 & -1/3 \\ 0 & -1/3 & 1/3 \end{pmatrix}.$$

样本1损失给第1特征的上游dQ是-0.072，乘J的第1行，向三个输入行分别贡献 $(-0.024, 0.024, 0)$ 。第2特征是0.024乘同一行，贡献 $(0.008, -0.008, 0)$ 。所以即使只求样本1损失，它也通过均值方差影响输入行2。样本3的对应贡献也不能漏掉。




图4 左图非对角元就是跨样本依赖；第1到第3行的零只属于这组特殊数值，第二步一般不再为零。右图第i行表示损失项i向三个输入行的第1特征传递的梯度，沿列求和才得到总dZ。

第1特征的全部跨样本损失路径如下。每行已经含平均损失的1/3：

损失项	输入行1	输入行2	输入行3
1	-0.024	0.024	0
2	-0.0226666667	0.0453333333	-0.0226666667
3	0	0.0106666667	-0.0106666667

第2特征的全部跨样本损失路径如下。每行已经含平均损失的1/3：

损失项	输入行1	输入行2	输入行3
1	0.008	-0.008	0
2	0.0075555556	-0.0151111111	0.0075555556
3	0	-0.0035555556	0.0035555556

对每个损失项i，先得到它对所有输入行的 $dZ^{(i)}$ ，再算 $dW^{(i)} = X^T dZ^{(i)}$ 、 $db^{(i)} = \sum_k dZ_k^{(i)}$ 。
gamma、beta、u、c的贡献分别为 $dH_i Q_i$ 、 dH_i 、 $dP_i H_i$ 、 dP_i 。下表把13项全部展开，不用“其余类似”省掉它们。

参数	损失1贡献	损失2贡献	损失3贡献	合计梯度
W11	0.024	0	-0.0106666667	0.0133333333
W12	-0.008	0	0.0035555556	-0.0044444444
W21	0.024	0	-0.0106666667	0.0133333333

参数	损失1贡献	损失2贡献	损失3贡献	合计梯度
W22	-0.008	0	0.00355555556	-0.00444444444
b1	0	0	0	0
b2	0	0	0	0
gamma1	0.072	0	-0.032	0.04
gamma2	-0.048	0	0.0213333333	-0.0266666667
beta1	-0.072	0.068	-0.032	-0.036
beta2	0.048	-0.0453333333	0.0213333333	0.024
u1	0.09	0.0283333333	-0.0666666667	0.0516666667
u2	0.072	-0.0113333333	-0.0213333333	0.0393333333
c	-0.12	0.113333333	-0.0533333333	-0.06

例如 $\partial L / \partial W_{11} = (-1)(-0.0466666667) + 0(0.08) + 1(-0.0333333333) = 0.0133333333$ 。

$\partial L / \partial W_{21} = 0(-0.0466666667) + 1(0.08) + 2(-0.0333333333) = 0.0133333333$ 。两者相同源于这组特殊X，不是一般恒等式。b的两项为0，gamma的两项为0.04和-0.0266666667，验证了前面路径求和的含义。

4.5 同时更新13个参数

$$\theta_1 = \theta_0 - 0.1 \nabla L(\theta_0).$$

绝不能更新u后再用新u计算尚未计算的dH。本步所有梯度都来自同一个旧参数快照。

参数	旧值	变化量	新值
W11	1	-0.00133333333	0.998666667
W12	0	0.000444444444	0.000444444444
W21	0	-0.00133333333	-0.00133333333
W22	1	0.000444444444	1.00044444
b1	1	0	1
b2	-1	0	-1
gamma1	1	-0.004	0.996
gamma2	0.5	0.00266666667	0.502666667
beta1	0.25	0.0036	0.2536

参数	旧值	变化量	新值
beta2	-0.1	-0.0024	-0.1024
u1	0.6	-0.00516666667	0.594833333
u2	-0.4	-0.00393333333	-0.403933333
c	0.05	0.006	0.056

4.6 第二次前向重新计算统计量

新W与新b产生新的Z，不能继续套用旧的均值、方差或J。为了把变化看清楚，保留九位有效数字；完整浮点记录见Notebook及hand-trace.json。下表先列每个特征的统计量。

特征	mu	v	s
1	0.998666667	0.663115852	0.998223014
2	0.000444444444	0.667852379	1.00059268

样本	Z	Q	H	P	误差
1	(0.00133333333, -1.00044444)	(-0.999108736, -1.00029603)	(-0.741512301, -0.605215473)	-0.14060953	-0.34060953
2	(0.998666667, 0.000444444444)	(0, 0)	(0.2536, -0.1024)	0.248212507	0.348212507
3	(1.996, 1.00133333)	(0.999108736, 1.00029603)	(1.2487123, 0.400415473)	0.637034544	-0.162965456

三个半平方误差分别是0.0580074261, 0.0606259749, 0.01327887，平均损失为0.043970757。损失下降是这个有限步长实例的观察，不是任意BN网络一步必下降的保证。

4.7 第二次局部导数 路径累积与梯度

第二次的 $\partial P / \partial H = u = (0.594833333, -0.403933333)$ ； $\partial H / \partial Q = \gamma = (0.996, 0.502666667)$ 。对gamma的局部导数就是上一表Q，对u就是H，对beta和c仍为1，对W仍是X，对b仍为1。均值对每个Z仍为1/3。其余BN局部量在新中心化值与新s处重新计算：

样本	dv/dZ	dQ/dv	dP	dH	dQ
1	(-0.664888889, -0.667259259)	(0.501334514, 0.499555687)	-0.11353651	(-0.0675353008, 0.045861181)	(-0.0672651596, 0.023052887)
2	(0, 0)	(0, 0)	0.116070836	(0.069042802, -0.0468848795)	(0.0687666308, -0.0235674661)

样本	dv/dZ	dQ/dv	dP	dH	dQ
3	(0.664888889, 0.667259259)	(-0.501334514, -0.499555687)	-0.0543218188	(-0.0323124285, 0.0219423933)	(-0.0321831788, 0.0110297097)

方差上游 $dvar=(-0.0175878078, 0.00600624658)$ ，均值上游 $d\mu=(0.0307363256, -0.0105089022)$ 。
除法对中心化量的直接导数是 $1/s$ ，约 $(1.00178015, 0.999407671)$ 。对应三条路径为：

样本	直接	经方差	经均值	总 dZ	输入 dX
1	(-0.0673849016, 0.0230392321)	(0.011693938, -0.00400772365)	(0.0102454419, -0.00350296739)	(-0.0454455218, 0.015528541)	(-0.0453780262, 0.0155960366)
2	(0.0688890457, -0.0235535064)	(0, 0)	(0.0102454419, -0.00350296739)	(0.0791344876, -0.0270564738)	(0.0790169498, -0.0271740115)
3	(-0.0322404697, 0.0110231765)	(-0.011693938, 0.00400772365)	(0.0102454419, -0.00350296739)	(-0.0336889658, 0.0115279327)	(-0.0336389236, 0.0115779749)

第二次第1特征的J如下。现在不能把第一步的0随意保留：

输出行	输入1	输入2	输入3
1	0.334521685	-0.333926717	-0.000594968589
2	-0.333926717	0.667853433	-0.333926717
3	-0.000594968589	-0.333926717	0.334521685

第1特征按损失来源的全部路径：

损失项	输入1	输入2	输入3
1	-0.0225016545	0.0224616339	4.00206571e-05
2	-0.0229630152	0.0459260305	-0.0229630152
3	1.91479805e-05	0.0107468232	-0.0107659712

第二次第2特征的J如下。现在不能把第一步的0随意保留：

输出行	输入1	输入2	输入3
1	0.332938623	-0.33313589	0.000197267698
2	-0.33313589	0.66627178	-0.33313589
3	0.000197267698	-0.33313589	0.332938623

第2特征按损失来源的全部路径：

损失项	输入1	输入2	输入3
1	0.00767519644	-0.00767974403	4.54758994e-06
2	0.0078511688	-0.0157023376	0.0078511688
3	2.17580544e-06	-0.00367439216	0.00367221636

参数	损失1贡献	损失2贡献	损失3贡献	合计梯度
W11	0.0225416752	0	-0.0107851192	0.011756556
W12	-0.00767064885	0	0.00367004055	-0.00400060829
W21	0.0225416752	0	-0.0107851192	0.011756556
W22	-0.00767064885	0	0.00367004055	-0.00400060829
b1	0	0	0	0
b2	0	0	0	0
gamma1	0.067475109	0	-0.0322836296	0.0351914794
gamma2	-0.0458747574	0	0.021948889	-0.0239258684
beta1	-0.0675353008	0.069042802	-0.0323124285	-0.0308049273
beta2	0.045861181	-0.0468848795	0.0219423933	0.0209186948
u1	0.0841887189	0.0294355639	-0.0678323233	0.0457919595
u2	0.0687140526	-0.0118856536	-0.0217512967	0.0350771023
c	-0.11353651	0.116070836	-0.0543218188	-0.0517874933

4.8 第二次同时更新后 再做第三次前向

仍用 $\theta_2 = \theta_1 - 0.1g_2$ ；归一化状态与SGD参数是不同对象，第6节再给运行状态对应的具体数字。

参数	旧值	变化量	新值
W11	0.998666667	-0.0011756556	0.997491011
W12	0.000444444444	0.000400060829	0.000844505274
W21	-0.00133333333	-0.0011756556	-0.00250898893
W22	1.00044444	0.000400060829	1.00084451
b1	1	0	1

参数	旧值	变化量	新值
b2	-1	0	-1
gamma1	0.996	-0.00351914794	0.992480852
gamma2	0.502666667	0.00239258684	0.505059254
beta1	0.2536	0.00308049273	0.256680493
beta2	-0.1024	-0.00209186948	-0.104491869
u1	0.594833333	-0.00457919595	0.590254137
u2	-0.403933333	-0.00350771023	-0.407441044
c	0.056	0.00517874933	0.0611787493

第三次纯公式前向的 $\mu=(0.997491011, 0.000844505274)$, $v=(0.659992816, 0.668920583)$, $s=(0.996657489, 1.00112632)$ 。此诊断不更新运行buffer。

样本	Z	Q	H	P	误差	半平方误差
1	(0.00250898893, -1.00084451)	(-0.998318914, -1.00056205)	(-0.734131914, -0.609834993)	-0.123673844	-0.323673844	0.0523823787
2	(0.997491011, 0.000844505274)	(0, 0)	(0.256680493, -0.104491869)	0.255259748	0.355259748	0.0631047445
3	(1.99247303, 1.00253352)	(0.998318914, 1.00056205)	(1.2474929, 0.400851255)	0.634193341	-0.165806659	0.013745924

平均损失为0.0430776824。至此，同一三行数据完成了两轮完整前向、局部求导、所有路径累积、全部参数同时更新和下一轮前向。




图5 左图没有只挑某几个参数展示梯度。b的抵消来自训练态BN的平移不变性，右图显示三次前向损失。误差和更新虽小，每个变量仍有可核对的位置。

5 LN换的是统计组 不是一个随意替换的名称

对 $Z = \begin{pmatrix} 1 & 3 \\ 2 & 2 \end{pmatrix}$ ，LN沿每行两个特征计算。第一行 $\mu=2$ 、 $v=1$ ，第二行 $\mu=2$ 、 $v=0$ 。若 $\epsilon=1$ ，则Q的两行是 $(-1/\sqrt{2}, 1/\sqrt{2})$ 与 $(0,0)$ 。取 $\gamma=(2,1)$ 、 $\beta=(0.1,-0.2)$ ，H分别约 $(-1.31421356, 0.507106781)$ 和 $(0.1,-0.2)$ 。更换第二个样本不会改变第一行统计量。

LN反向仍可使用第3节的J，但这里 m =特征数。若各特征 γ 不同，要先计算 $a_j = \bar{h}_j \gamma_j$ ，再进入J。把 γ 错误地移到整个VJP外面，一般不成立。D=1时层能运行，但每个位置输出只有 β ；“支持batch_size1”不等于任意normalized_shape都保留有用信息。

LN减少了批组成依赖，也改变了保留的信息。对同一行加公共偏移会被消掉；在 ϵ 可忽略时，正比例放大也近似被消掉。如果任务标签与该行的绝对幅度有关，要判断其他路径是否保留幅度，不能只凭训练稳定就认为语义没有损失。

对序列形状(2,3,2)，附带代码分别计算BN跨(0,1)、LN跨(2)、LN跨(1,2)，再与PyTorch逐坐标比较。三种输出shape完全相同却数值不同，这是形状检查必要但不充分的例子。位置之间的连接或上游网络本身仍可能引入依赖；“LN无跨样本统计”仅指这次归一化运算。




图6 固定锚点(0.5,-0.5)，只替换其余两行同伴。BN的两个特征值明显改变，LN保持相同。这里比较同一个归一化操作的统计依赖，不是比较预测准确率。

6 训练态与推理态需要不同的统计策略

6.1 运行统计不是梯度优化的参数

默认PyTorch BN在训练前向时用当前批 μ 和分母 m 的 v 归一化，同时更新运行均值 r_μ 和运行方差 r_v 。它们是buffer，不由optimizer的学习率更新； γ 、 β 才是可训练参数。PyTorch2.7 BatchNorm1d文档明确区分训练前向方差与运行方差估计。 m 大于1时，当前批送入运行方差的数为 $\tilde{v} = mv/(m-1)$ 。

这里把BN的momentum写作 a ，避免与033的优化器动量混淆：

$$r_{\mu,t} = (1-a)r_{\mu,t-1} + a\mu_t, \quad r_{v,t} = (1-a)r_{v,t-1} + a\tilde{v}_t.$$

α 越大越偏重最新批；这与优化器中通常把 β 当旧状态保留系数的记法相反。默认初始均值0、方差1。手算设 $\alpha=.2$ ，第1步 $\mu=(1,0)$ ， $v=(2/3,2/3)$ ，无偏批方差为(1,1)，因此运行均值变(.2,0)，运行方差仍(1,1)。第2步使用更新参数之前的激活统计，得到：

时刻	运行均值	运行方差	计数
1	(0.2, 0)	(1, 1)	1
2	(0.359733333, 8.88888889e-05)	(0.998934756, 1.00035571)	2

先前各节为了看下一次损失而调用的是不带buffer更新的纯数学函数。若直接把训练中的BN模型多前向一次，即使不反传，也可能多更新一次运行统计，不能把调试前向当作无副作用读取。

6.2 eval固定统计 但不关闭求导

默认`track_running_stats=True`时，eval用保存的 r_μ, r_v ：

$$q_i = \frac{z_i - r_\mu}{\sqrt{r_v + \epsilon}}.$$

这时固定统计对输入的Jacobian在同一通道内为对角矩阵 $1/\sqrt{r_v + \epsilon}$ ，没有当前batch的均值方差反向路径。与训练态计算的是不同函数；即使用同一批数据，也不保证输出完全一样。本手算训练两步后，eval使用的运行统计仍包含初始状态与旧参数时期的信息。

同一三行数据在`theta2`处，训练态纯前向 $P=(-0.123673844, 0.255259748, 0.634193341)$ ，eval前向 $P=(0.252311034, 0.578808977, 0.905306921)$ ；eval半MSE=0.0791012699。差异没有经过任何新的SGD更新。

[Module.eval官方说明](#)把它定义为模块模式切换；[no_grad说明](#)控制自动微分记录。二者不能代替。下图在可求导输入和参数存在时实际执行四种组合：

默认 `track_running_stats=True`；存在需梯度输入/参数

模型态与梯度态	归一化使用	更新buffer	建立梯度图
train + grad	当前batch	是	是
train + no_grad	当前batch	是	否
eval + grad	running统计	否	是
eval + no_grad	running统计	否	否

图7 是否改变BN运行buffer由模型训练状态决定，不由是否记录梯度决定。被冻结 γ/β 的训练态BN仍会更新运行统计。eval能保留求导能力，例如计算推理函数的输入敏感性。

若`track_running_stats=False`，BN不保存这两个运行buffer，eval也继续用当前batch统计，因而batch组成仍会影响结果。LayerNorm则在train与eval都使用各自输入组内的统计，归一化这部分公式不因eval切换；整个模型中的其他层仍可能受切换影响。[PyTorch2.7](#) [LayerNorm定义](#)还规定`normalized_shape`决定尾部轴与仿射参数形状。

6.3 运行方差并不等于拼接所有历史数据的方差

即使把momentum设成None，PyTorch也累计平均每个批的统计，不自动把不同批按样本数加权。两批[0,2]与[10,10,12,12]的批均值分别1、11，累计平均为6；六个数的整体样本均值是 $46/6=7.66666667$ 。两批无偏方差分别2、 $4/3$ ，平均为 $5/3$ ；拼接后的方差还包含批均值之间的差异，不能用 $5/3$ 替代。

默认EMA更受顺序、batch大小、最后一批和上游参数移动影响。因此不能在看到eval不佳时，悄悄把测试样本送入训练态“修复”统计。若研究确需校准或适应，应先规定允许的数据来源、模型状态、是否重置、更新规则与评价协议；本讲只演示错误造成的变化，没有进行测试时自适应。




图8 40个32行批次：前20批来自均值0，后20批均值突变为3。橙线运行均值滞后于黑色生成均值。右图是`momentum=.1`的最近30批权重；没有画出的更早历史仍有残余权重。这是固定生成机制下的有限诊断。

7 小批量还有哪些可观察后果

7.1 数学可定义不等于框架接受训练输入

BN训练二维输入(1,C)时，每通道只有一个数。数学式有epsilon仍能得到0，但PyTorch训练BN会拒绝这种每通道统计组只有一个元素的输入。相反(1,C,L)且L大于1时，统计组包含L个元素，单个N也可运行。相关位置不自动等价于同样多的独立样本，018的采样依赖仍要保留。

若最后一批只剩一条记录，检查数据加载器和统计轴，不能只用try/except吞掉。直接`drop_last`会改变哪些记录被训练；改为eval会换成另一函数；改用LN会改变信息归约方式。每个选择都需要在实验协议中说明。

7.2 同一个锚点 因随机同伴而波动

实验固定锚点(0.5,-0.5)，分别加入B-1个独立标准正态同伴，对B=2、4、8、32各做200次。注意整个批不是完全独立同分布，因为第一行被固定。图中箱线只描述该设计的200次观察，不是一般总体置信区间。数值全部保留在batch-sampling.csv。




图9 左图是固定锚点第0特征的归一化结果，右图是同一批的均值。批增大通常让这里的波动减小，但图不能证明任何任务的最佳batch_size，也没有把相关位置当作独立样本。

7.3 梯度累积不再自动等价于大batch

027中按正确样本权重累积微批梯度，可与同一个逐样本可分目标的大批计算一致。BN训练态每次前向都会重新定义统计组，所以把4行一次送入，与分成两个2行微批，即使各微批损失都乘1/2，目标也不同。

本讲另加第4行(2, -1)、标签0.4，仍用手算初值：一次4行损失0.162367358，两个2行正确加权损失0.235715513；13维梯度的最大坐标差0.0886953887。不是平均因子错了，而是均值方差变了。同步统计、冻结BN或其他归一化属于不同方案，需明确实现和实验边界，本讲没有执行分布式同步BN。

8 把模式错误放进真实训练循环

采用另外96行原创合成回归数据，前64行训练、后32行仅做诊断验证，无测试排名或选择。输入来自固定种子的二维标准正态，标签为 $0.7x_1 - 0.4x_2 + 0.3 \tanh(x_1 + x_2) + \xi$, $\xi \sim N(0, 0.08^2)$ 。这个定义不表示现实数据分布。

模型是2→4仿射、BN4、tanh、4→1仿射，共12+8+5=25个参数；BN另有4维运行均值、4维运行方差与计数。固定初值、学习率.03、SGD无动量，无搜索无早停。B取4与16，重排种子360/361/362，各8个epoch、512次训练样本呈现。B=4有128次更新和128次BN统计更新；B=16只有32次。相同样本预算不等于相同优化预算，也不等于时间公平。




图10 左图横轴epoch对应相同样本呈现数，右图横轴是实际optimizer更新数。三条同色细线仅改变样本重排；不能把它们称为三份独立数据集。我们保留所有六次运行，不挑最好seed。

每次epoch后正确eval加no_grad计算验证损失，并逐buffer断言没有改变状态。训练结束后，另深拷贝一个模型，故意只加no_grad却保持train，将32行验证数据分成8个4行批次。这样既改变当前预测，也让运行计数增加8。之后再切eval，统计已经被污染；它的损失偶然更低也不能把这次验证称为纯观察。

B/seed	正确eval	误用train+no_grad	污染后再eval	运行均值最大变化
4/360	0.0479431733	0.123422991	0.0453090134	0.110061871
4/361	0.0453843993	0.128343112	0.0480996149	0.124481908
4/362	0.0545999033	0.128758385	0.0570114013	0.130245623
16/360	0.0553262746	0.135290241	0.0552827801	0.106656367
16/361	0.0549058871	0.134956279	0.0548440552	0.109858231
16/362	0.0549178125	0.135315302	0.0552951587	0.110442175

正确eval把验证数据一次处理与分成4行处理，本环境的预测逐位相同；更一般的硬件和内核下只能期望数值容差内一致，不能许诺跨平台逐位相同。这里的错误验证差异来自归一化状态和统计组变化。代码深拷贝后做错误示范，不污染用于正确报告的模型。




图11 橙柱是错误验证，不是另一种更优评价方法。绿柱使用已经被验证数据改变的buffer；它可能比蓝柱低或高，方向不能证明污染有利。右图测量每次运行中真实发生的buffer变化。

六条轨迹所有480次更新都由独立NumPy公式重建，最终25参数、运行统计和每epoch验证损失与PyTorch比较。手算两步另外用精确分数及75位Decimal差分核验，32个随机13参数网络同时检查参数和输入梯度。两类核验验证实现，不替代科研评价设计。

9 保存和恢复时别漏掉运行状态

只保存gamma、beta、W等参数不够，BN推理还依赖running_mean、running_var与num_batches_tracked。state_dict会包括这些buffer。但模块的training布尔开关不会通过普通state_dict自动恢复；新建模块load_state_dict之后仍应显式设置需要的train或eval。实验确实构造源train、目标eval再载入状态，目标仍保持eval。

可靠评价需要同时明确参数快照、运行buffer、数据拆分、batch组成和模型模式。若一个父模块调用train()，子BN一般也会回到训练态；冻结BN时要确认每个目标子模块的实际training值。冻结参数的requires_grad与冻结运行统计是两件事。涉及混合模式时，临时评价应逐模块记录并恢复各自模式，而不是只恢复一个根布尔值。

10 练习与科研检查单

1. 用三行手算数据，遮住答案重算第一次mu、v、s、P、L，再检查1/3只在何处出现。
2. 只保留直接dQ/s路径，求W11的错误梯度。与0.01333333333比较并解释差异。
3. 写出样本2损失对样本1第1隐藏输入的梯度。为什么样本1不属于该标签，也收到梯度？
4. 推导J乘全1向量以及J乘q的结果，解释epsilon与平移、尺度不变性的区别。
5. 对本讲LN两行例子手算H，说明第二行Q为0时，为什么D=2的输入导数仍可能非零。
6. 计算两次运行均值和方差；解释为什么即使第二次没有backward，训练前向仍能改变buffer。
7. 用[0,2]和[10,10,12,12]核对累计均值与拼接均值、两种方差。哪一步丢失了组间信息？
8. 解释B=1、L=2与B=1二维BN的差别，并写出数据加载最后一批的检查。
9. 重新运行4行微批反例，指出正确损失加权为什么仍无法恢复大batch梯度。
10. 阅读六次训练结果，列出不能据它宣称“B=4普遍更好”的至少四条理由，并修复错误验证代码。

做真实科研时先写清楚：归一化轴、epsilon、仿射形状、是否保存运行统计、统计更新系数与数据来源、训练与验证模式、最后一批、梯度累积、恢复状态。变更这些条件可能改变模型函数或评价协议，应当记录而不是当作无关实现细节。下一讲在此基础上讨论正则化和增强所施加的假设。