

037 正则化与数据增强练习详解

本册对应正文12题。答案既给可核对数字，也保留每个推论的条件。公式与小例子用于定位机制，不能替代独立任务评价。

1 二参数惩罚的精确最优

数据目标为 $L=.5[(w_1-2)^2+.2(w_2+1)^2]$ ，惩罚为 $\lambda(w_1^2+w_2^2)/2$ 。分别求导得 $\partial J/\partial w_1=w_1-2+\lambda w_1$ ， $\partial J/\partial w_2=.2(w_2+1)+\lambda w_2$ 。两个二阶导为 $1+\lambda$ 与 $.2+\lambda$ ， $\lambda \geq 0$ 时都正，所以驻点是唯一全局最优。

$\lambda=.1$ 时 $w_1=2/1.1=20/11 \approx 1.818181818$ ， $w_2=-.2/.3=-2/3 \approx -.666666667$ 。相对于无惩罚 $(2,-1)$ ，两方向保留比例是 $10/11$ 和 $2/3$ 。第二方向数据曲率较小，相同惩罚使它相对收缩更多。

这不是说神经网络所有参数都朝同一原点方向平滑移动；这里只解了一个明确的严格凸二次目标。若输入单位改变，对应参数尺度和惩罚偏好也会改变。

2 重建前向和全部参数梯度

四个仿射值为 $(1.2,.8,-.1,.8)$ ，ReLU后为 $(1.2,.8,0,.8)$ 。掩码为 $[[1,0],[1,1]]$ ， $q=.5$ ，因此保留位置乘2，得到两行 $(2.4,0)$ 、 $(0,1.6)$ 。输出为 $(1.54,-.7)$ ，残差 $(.84,-.5)$ ，半平方 $(.3528,.125)$ ，平均 $L=.2389$ ，惩罚 $\Omega=.0575$ ，总目标.2964。

平均损失给输出梯度 $(.42,-.25)$ 。乘输出权重后，dropout输出梯度两行为 $(.252,-.21)$ 、 $(-.15,.125)$ ；乘 M/q 及ReLU门控后，仿射梯度为 $(.504,0)$ 、 $(0,.25)$ 。共享参数的数据梯度就是对所有相关样本路径求和。

W_{12} 的样本1贡献 $1 \times 0 = 0$ ；样本2贡献 $(-1) \times .25 = -.25$ ；惩罚贡献 $.1 \times (-.2) = -.02$ ；合计 $-.27$ 。 u_1 的样本1贡献 $.42 \times 2.4 = 1.008$ ，样本2贡献 $-.25 \times 0 = 0$ ，惩罚 $.1 \times .6 = .06$ ，合计 1.068 。

按 $(W_{11}, W_{12}, W_{21}, W_{22}, b_1, b_2, u_1, u_2, c)$ 顺序，总梯度为：

$$(.554, -.270, 1.038, .290, .504, .250, 1.068, -.450, .170).$$

学习率.05同时更新后为：

$$(.4723, -.1865, .2481, .3855, .0748, .1875, .5466, -.4775, .0915).$$

输入梯度两行是 $(.252,.1512)$ 、 $(-.05,.1)$ ，不作为模型参数更新。使用新参数和同一掩码，输出为 $(1.23203556,-.6338225)$ ， J 约.1675555102。若对其中一个共享参数少加一条样本路径，或反向重新抽掩码，便不再对应这个标量目标。

3 全零掩码时的剩余路径

掩码全0使两个隐藏输出都为0，因此 $P_1=P_2=c=.1$ 。残差为 $-.6$ 与 $.3$ ，平均后的输出梯度为 $-.3$ 与 $.15$ 。数据损失为 $(.6^2+.3^2)/4=.1125$ 。

所有 W 、 b 、 u 的数据路径都为0；但输出偏置 c 仍直接连到 P ，所以其数据梯度为 $-.3+.15=-.15$ 。 $\lambda=.1$ 时 W 与 u 还有 $\lambda\theta$ 的惩罚路径， b 无惩罚且数据梯度为0。总梯度为：

$$(.05, -.02, .03, .04, 0, 0, .06, -.05, -.15).$$

$\eta=.05$ 后，参数为 $(.4975, -.199, .2985, .398, .1, .2, .597, -.4975, .1075)$ 。若 λ 也为0，则只有 c 移动到 $.1075$ ，其余不动。全零掩码不等于整个模型所有参数都没有梯度，更不等于优化器中的所有历史状态都必定不再作用；本题用的是无历史状态的普通SGD。

4 从四张掩码到精确损失期望

第一条样本 $h=(1.2, .8)$ ， $u=(.6, -.5)$ ， $c=.1$ 。 $q=.5$ 时掩码00、01、10、11对应输出 $.1$ 、 $-.7$ 、 1.54 、 $.74$ 。均值 $(.1-.7+1.54+.74)/4=.42$ 。

四个偏差分别 $-.32$ 、 -1.12 、 1.12 、 $.32$ ，方差为 $(.1024+1.2544+1.2544+.1024)/4=.6784$ 。用独立分量公式也得到 $(.6 \times 1.2)^2 + (-.5 \times .8)^2 = .6784$ 。

第二条样本 $h=(0, .8)$ ，输出只有 $.1$ 与 $-.7$ ，各占一半；均值 $-.3$ ，方差 $.16$ 。两个样本的平均半平方损失比关闭dropout多出 $(.6784+.16)/4=.2096$ ，所以从 $.0221$ 变为 $.2317$ 。惩罚项与掩码无关，若比较总目标还需统一加 $.0575$ 。

这条等式依赖dropout后输出是仿射、损失是平方、各坐标掩码独立；如果后面还有非线性，不能原封不动沿用。

5 一个标量非线性反例

令 $h=1$ 、 $q=.5$ ，inverted dropout输出为0或2，各占一半。取后续函数 $f(t)=\text{ReLU}(t-1)$ 。于是 $f(\text{dropout } h)$ 为0或1，期望为 $.5$ ； $f(h)=\text{ReLU}(0)=0$ 。所以即使 $E[\text{dropout } h]=1=h$ ，也有 $E[f(\text{dropout } h)]=.5 \neq 0=f(h)$ 。

这里ReLU拐点在1，而不是只对非负 h 直接做ReLU。若随便写 $f(t)=\text{ReLU}(t)$ 、 $h=1$ ，0与2都在同一线性段，反而会得到相等，不能成为所需反例。非线性函数也可以在特定输入支持上恰好可交换；要展示不保证，必须选实际不相等的例子。

6 为什么不能反向重新抽掩码

固定 $h=1$ 、 $q=.5$ 、 $y=1$ ，前向掩码 $M=1$ ，输出 $P=2h$ ，损失 $\ell=(P-y)^2/2=.5$ 。当前图的局部导数 $\partial P/\partial h=2$ ，残差为1，所以 $d\ell/dh=2$ 。

若反向重新抽到 $M'=0$ 并用 $M'/q=0$ ，则报告梯度0，已经不是前向那条函数的导数。用固定前向 M 做 $h \pm \varepsilon$ 的中心差分，结果趋近2，而不是0。若差分两端也各自重新抽掩码，随机函数变化会淹没有限差分，检查本身就失效。

在实际训练里，不必人为保存每个普通Dropout掩码到CSV，但autograd必须沿用前向的图与门控。本课主训练显式采样掩码，独立NumPy重建用相同随机流，便于核对。

7 重建patience计数

序列从第1轮开始，min_delta=0，只有严格更低才改善，patience=2。

轮数	验证值	最佳值及轮数	连续未改善
1	.60	.60, 第1轮	0
2	.50	.50, 第2轮	0
3	.51	.50, 第2轮	1
4	.49	.49, 第4轮	0
5	.50	.49, 第4轮	1
6	.51	.49, 第4轮	2, 停止

应恢复第4轮，而不是第6轮。停止之后尚未观察到的第7轮不能影响已经作出的决定；如果看到完整轨迹再改patience，就属于额外搜索。若规则把改善定义为至少下降 δ ，还要明确“严格大于 δ ”还是“大于等于 δ ”，并列如何处理，不能只写一个patience数字。

8 翻转输入时同步翻转标签

本生成机制为 $Y = \text{clean}(X)$ 异或 B ， B 为独立Bernoulli(.15)， $\text{clean}(X) = 1\{x_1 > 0\}$ 。对 $x_1 \neq 0$ ，翻转 x_1 使 clean 变为 $1 - \text{clean}$ ；同时令 $Y' = 1 - Y$ ，则 $Y' = \text{clean}(X')$ 异或 B ，保留同一噪声机制。均匀输入也在镜像下保持分布，因此这个联合变换保留当前总体。

反例处理只翻输入不翻标签，才把标签机制弄反。合法增强是否需要改标签，取决于任务：目标分类中的左右翻转可能不改类名；文字、手性结构、空间坐标或医学侧别可能必须改标签，或根本不允许这种变换。不能从当前人工任务推断所有图像左右翻转的合法性。

同一原标签的增强副本仍彼此相关。即便联合分布的边缘形式正确，也不能将它们当作独立新观测来缩小置信区间。

9 四类平滑目标与logit梯度

$K=4$ 、 $\alpha=.2$ ，均匀部分每类.05。正确类为第2类，原one-hot是(0,1,0,0)，因此平滑目标 $q=(.05,.85,.05,.05)$ 。各项和为1。

给定 $p=(.1,.6,.2,.1)$ ，梯度 $p-q=(.05,-.25,.15,.05)$ ，和为0。这个和为0与softmax对所有logit同时加同一个常数的不变性一致。梯度下降会提高正确类logit，降低其他logit，但每个共享网络参数的变化还需要继续乘链式导数，不能把logit梯度直接当参数梯度。

如果把正确类写成.8、其余每类.2/3，是另一个“只分给错误类别”的约定，不是本题向所有类别均匀混合的定义。

10 保留指标冲突

早停相对固定预算基线，三个种子的测试错误率分别为：seed370，.1796875→.158854167；seed371，.184895833→.177083333；seed372，.174479167→.190104167。最后一个变差，所以不能说逐种子全部改善。

标签平滑相对基线，Brier分别为：seed370，.149870929→.150696713；seed371，.154287970→.154002353；seed372，.144477653→.143931709。第一个变差。三个均值几乎相同，差约.000001925；没有计算具有预先假设的显著性检验，也没有新的独立数据集重复。不能把微小均值差包装成校准胜利。

CE、错误率、Brier关注不同性质，排序冲突并不自动表示程序错误。应先固定主要指标与任务代价，再解释辅助指标，不能看到结果以后改换主指标。

11 先分组拆分 再只增强训练

同一原始样本的裁剪、翻转和颜色扰动共享内容。先增强再随机拆分，很可能使同一主体的近似副本跨集合，模型在测试时遇到训练信息的近亲。给副本不同ID不能消除依赖。

应先选择与部署独立性对应的单位，如原图、视频、病人、实验批次、设备或未来时间段，按该单位建立训练验证测试，再只对允许的训练源做增强。若确需测试时增强，先冻结推理规则并为其单独计费 and 记录，仍不能把测试标签用于选择变换。

在本实验中，每条生成记录对应独立原观察。即便如此，同一训练行在160轮中反复呈现、再增强，也只是48个原观察的反复使用。

12 后续dropout概率实验的可审计设计

一种合格设计可以是：固定主实验数据生成规律和697参数结构，预先选 $p \in \{0,.1,.3,.5\}$ ，其余处理关闭。每个候选使用相同算法种子和相同160轮上限，学习率先固定.01；明确这只比较该学习率下的概率，而不是各方法充分调参后的最佳性能。

每个候选3个种子， $4 \times 3 \times 480 = 5760$ 次更新、92160次训练呈现。分别隔离初始化、顺序和mask随机流；相同均匀随机数阈值化可作为配对方式，但不同p还改变inverted缩放，不能称为同一个梯度噪声强度。

只用验证集平均硬CE选p，完全同分按预定顺序选较小p，不通过测试决定。公开12个候选运行及全部成本。当前讲义测试已被反复查看，应另生成并封存独立测试，或在真实任务上设置相应外层独立评价。若把本讲已有的.3结果纳入新的选择历史，也应披露。

最后仍不能据此证明所有数据量、架构、学习率、位置 and 任务下该p最佳。若下一步要和权重衰减组合，先定义二因素设计以及交互效应的比较方式，而不是只在赢家上叠一个方法后把变化全归给它。