

037 正则化与数据增强

这一讲回答一个具体问题：怎样限制不可靠的拟合，又避免把真正的信号一起压掉？正则化给学习过程增加偏好；增强对“哪些变化不该改变答案”作出假设。两者都不是只要打开就能提高成绩的开关。我们将把数学对象、逐样本计算、模型状态和实验比较连成一条链。

先修020中的经验风险与验证边界，034中的L2和AdamW区别，以及036中的train、eval和no_grad。本讲重新给出所有手算数据与参数，无需跨讲导入程序。先用一个九参数回归网络精确核对dropout，再用独立的697参数二分类网络做有限消融。二者承担不同证据职责，手算的平方损失数值不能直接与分类交叉熵比较。

1 先写出你希望模型保留什么

设训练集为 $D=\{(x_i, y_i)\}$ ，参数为 θ ，原任务损失为 ℓ 。经验风险是 n 条训练记录的平均，真正关心的总体风险是新的目标分布上的期望。020已经说明，在训练集上选择模型后再报告训练成绩，会利用这份数据的偶然性。这里不重新把“训练损失低”当成有效性的判据。

正则化可以改变目标，例如给经验风险加参数惩罚；也可以改变算法，例如从优化轨迹中较早取一个参数快照；还可以向计算加入随机性。数据增强改变训练时呈现的输入或输入标签对，标签平滑改变目标分布。它们可能提高偏差、降低某些不稳定性，也可能丢失与任务有关的信息。

因此需要同时问两件事：施加了什么偏好；有什么独立证据表明这种偏好适合当前任务。相同训练测试差距可能对应很不同的模型。一个始终输出0.5的分类器可以很少过拟合，也可能根本没学会可用的规律。

本讲不把五种方法一次全加。主实验为固定预算基线、早停、dropout、解耦衰减、合法增强、故意错误的增强、标签平滑，共七个预先指定的处理。除该处理外，数据、结构、优化器基础配置和配对随机种子相同。组合效果及相互作用需要另一个实验设计，当前没有测试。

2 权重惩罚怎样进入目标与梯度

2.1 平均损失和参数选择必须明确

用一个对角选择矩阵 S 记录哪些参数受到惩罚：选中的坐标 $S_{ij}=1$ ，其余为0。 $\lambda \geq 0$ 是强度，采用带1/2的约定：

$$J_D(\theta) = \frac{1}{n} \sum_{i=1}^n \ell(f_{\theta}(x_i), y_i) + \frac{\lambda}{2} \theta^{\top} S \theta.$$

参数有 d 个数， S 是 $d \times d$ 矩阵， J 是标量。对任一坐标 θ_j ，平方项求导是 $2\theta_j$ ，恰好与1/2抵消； S 为对角0/1时得到：

$$\nabla_{\theta} J_D = \nabla_{\theta} \hat{R}_D + \lambda S\theta.$$

这条惩罚路径与数据路径并行。某参数在本批数据路径上梯度为0，仍可能被惩罚移动。把 $\lambda \|\theta\|^2$ 写成目标时，梯度则是 $2\lambda\theta$ ，不能在公式与代码之间丢掉2。

若将平均损失改成样本求和而 λ 保持不变，数据梯度放大 n 倍，惩罚相对变弱。要保持同一个最优点，可把整个原目标乘 n ，因此求和版本的惩罚系数也需乘 n 。即使目标整体倍乘后最优点不变，优化轨迹仍受学习率、epsilon等影响；034已经解释自适应优化中的尺度边界。

2.2 一个可以直接求解的几何例子

单独看两个参数 w_1 、 w_2 ，令数据目标为 $L=.5[(w_1-2)^2+.2(w_2+1)^2]$ ，惩罚为 $\lambda(w_1^2+w_2^2)/2$ 。令两个偏导为0，得到 $(w_1-2)+\lambda w_1=0$ 与 $.2(w_2+1)+\lambda w_2=0$ ，因此：

$$w_1^* = \frac{2}{1+\lambda}, \quad w_2^* = \frac{-.2}{.2+\lambda}.$$

两个方向的训练目标曲率不同，所以加入同一个惩罚后，相对收缩幅度也不同。 λ 从0增大，会向原点偏移，却不必沿数据最优点到原点的直线移动。图1的曲线由这两个明确公式产生，不是神经网络实测结果。




图1 蓝色实线为数据目标等高线，橙色虚线为参数平方范数等高线。绿色点是四个 λ 下精确求得的最优解。右图显示范数减小与数据损失增加可以同时发生。这个几何例子解释偏好，不提供任何测试集上的保证。

“权重小”还依赖输入单位与参数化。把一个输入从米改为厘米，同一个预测函数可用缩小100倍的对应权重表示；不处理单位就比较范数会失真。ReLU网络也可以将一层权重乘正数、下一层除以同数而保持部分函数不变，却改变惩罚。BN前权重缩放又受到036中归一化的影响。因此参数惩罚不是一个完全不依赖表示方式的“函数复杂度真值”。

2.3 L2与衰减只在明确条件下相同

无动量、无自适应缩放的普通SGD给出：

$$\theta^+ = \theta - \eta(g + \lambda S\theta) = (I - \eta\lambda S)\theta - \eta g.$$

g 是纯数据梯度， η 是学习率。这时加入L2和按上述因子缩小旧参数等价。若 g 先经过逐坐标矩阵 D 缩放，耦合L2会得到 $-\eta\lambda DS\theta$ ，解耦衰减则是 $-\eta\lambda S\theta$ ，通常不同。Adam还会把耦合项积累进一阶、二阶状态。034的边界在本讲继续有效；不能把AdamW的weight_decay说成当前交叉熵里简单多了一个L2项。[AdamW原论文](#)

主实验统一使用AdamW，仅在decay处理中将三层权重矩阵的衰减系数设为.1；偏置不衰减。手算为看清并行路径，使用普通SGD和显式L2。两种设置在各自章节标出，不把手算的等价关系偷换到主实验。

3 Dropout先是一个明确的随机运算

3.1 保留概率和丢弃概率不要混用

固定当前参数、当前输入以及dropout之前的隐藏向量 $h \in \mathbb{R}^k$ 。每个 M_j 独立取0或1， $P(M_j=1)=q$ ， $0 < q \leq 1$ 。 q 是保留概率， $p=1-q$ 是丢弃概率。本讲采用inverted dropout：

$$\tilde{h}_j = \frac{M_j}{q} h_j.$$

$M_j=0$ 时输出0； $M_j=1$ 时输出 h_j/q 。训练时把保留值放大，评价时直接用 h 。PyTorch的 p 参数表示丢弃概率，所以文档中的 $1/(1-p)$ 与这里的 $1/q$ 是同一个数。[PyTorch2.7 Dropout](#)

期望必须说明对谁取。以下 E_M 是在固定 h 后，只对本次新采样掩码取平均，不是在对训练数据或已训练参数取平均：

$$E_M[\tilde{h}_j | h] = q \frac{h_j}{q} + (1 - q)0 = h_j.$$

二阶原点矩为 $E[\tilde{h}_j^2 | h] = h_j^2/q$ 。减掉均值平方得：

$$\text{Var}_M(\tilde{h}_j | h) = \frac{1 - q}{q} h_j^2.$$

所以保持均值不等于保持数值、不等于保持方差。 q 越小，相同 h 下方差越大。 $q=1$ 时没有随机变化； $q=0$ 时该除法无定义。本课程函数拒绝 $q=0$ ，不能将其悄悄作为普通点带进推导。




图2 对固定 $h=(1.2,.8)$ ，两个掩码共四种等概率结果。左图显示保留值被乘2。右图是接一个仿射层后的输出，四值平均为.42。某一次输出可以远离.42，期望保持不是每一次保持。

3.2 反向传播条件于已经抽到的掩码

在本次计算图中， M 是已知的0/1常量， q 是预设超参数。局部导数为 $\partial \tilde{h}_j / \partial h_j = M_j / q$ ，不同坐标之间导数为0。因此若上游梯度是 $\bar{h}$ ，则 $\bar{h} = \bar{h} \odot M / q$ 。

“被丢弃的路径本次没有数据梯度”并不意味着该参数永久不学习。同一个共享参数还可能服务其他样本或其他保留路径；显式惩罚也可以独立更新它。反向时必须沿用这次前向的同一个掩码，不能重新抽一张再相乘。

对于固定训练集，dropout所拟合的数据目标是 $E_M[\hat{R}_D(\theta; M)]$ 。掩码分布与 θ 无关且枚举有限时，可以逐项求导，得到 $E_M[\nabla \hat{R}_D(\theta; M)] = \nabla E_M[\hat{R}_D(\theta; M)]$ 。它并不是“关闭dropout的目标”的无偏梯度；若后者不同，两个梯度平均也会不同。更一般无限随机空间中的交换还需要相应可积性条件。本讲直接枚举有限掩码，不省略这些边界。

4 九个参数走完一次完整计算链

4.1 数据 网络 掩码与目标

沿用034的小网络数据和初始参数，新增本节明确给定的dropout及惩罚路径：

$$X = \begin{bmatrix} 1 & 2 \\ -1 & 1 \end{bmatrix}, \quad y = \begin{bmatrix} .7 \\ -.2 \end{bmatrix}, \quad W = \begin{bmatrix} .5 & -.2 \\ .3 & .4 \end{bmatrix}.$$

$$b = (.1, .2), \quad u = (.6, -.5)^\top, \quad c = .1, \quad M = \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix}, \quad q = .5.$$

X 、 W 、 Z 、 H 、 M 均为 2×2 ，样本放在行； b 沿行广播， u 为 2×1 ， P 和 y 有两行一列。本节参数顺序固定为 $(W_{11}, W_{12}, W_{21}, W_{22}, b_1, b_2, u_1, u_2, c)$ 。令 $Z = XW + b$ ， $H = \text{ReLU}(Z)$ ， $\tilde{H} = H \odot M / q$ ， $P = \tilde{H}u + c$ 。

采用两条样本半平方误差的平均，再加仅 W 和 u 的惩罚：

$$L = \frac{1}{2} \sum_{i=1}^2 \frac{(P_i - y_i)^2}{2}, \quad \Omega = \frac{.1}{2} (\|W\|_F^2 + \|u\|_2^2), \quad J = L + \Omega.$$

矩阵Frobenius平方范数就是四个元素平方之和。外面的1/2来自样本平均，里面的1/2来自半平方，不能混为一个来源。偏置b和c不惩罚。 $\lambda=.1$ 、学习率 $\eta=.05$ 是本手算的教学设置，不是推荐默认值。

4.2 四个乘加与逐样本损失

$Z_{11}=1(.5)+2(.3)+.1=1.2$; $Z_{12}=1(-.2)+2(.4)+.2=.8$; $Z_{21}=(-1)(.5)+1(.3)+.1=-.1$; $Z_{22}=(-1)(-.2)+1(.4)+.2=.8$ 。因此：

$$Z = \begin{bmatrix} 1.2 & .8 \\ -.1 & .8 \end{bmatrix}, \quad H = \begin{bmatrix} 1.2 & .8 \\ 0 & .8 \end{bmatrix}, \quad \tilde{H} = \begin{bmatrix} 2.4 & 0 \\ 0 & 1.6 \end{bmatrix}.$$

样本1的第二个单元被dropout关闭；样本2的第一个单元虽然掩码保留，却已被ReLU关闭。两种门控作用于不同位置，不应该只看最后都是0就混淆原因。

$P_1=2.4(.6)+0(-.5)+.1=1.54$; $P_2=0(.6)+1.6(-.5)+.1=-.7$ 。残差分别为.84与-.5，半平方误差分别为.3528与.125。 $L=(.3528+.125)/2=.2389$ 。

W的平方和为.54，u的平方和为.61，所以 $\Omega=.1(.54+.61)/2=.0575$ ，标量总目标 $J=.2964$ 。记录L与 Ω 两项，才能知道数值改变来自拟合还是惩罚；不能只贴一个不注明组成的loss。

4.3 每条局部导数和中间梯度

对每条样本损失 ℓ_i ， $\partial J / \partial \ell_i = 1/2$ ， $\partial \ell_i / \partial P_i = P_i - y_i$ ，乘起来得到 $\bar{P} = (.42, -.25)^T$ 。输出对隐藏量的局部导数是 u_j ，对 u_j 的局部导数是 $\tilde{H}_{ij}$ ，对c是1：

$$\tilde{\bar{H}} = \bar{P} u^T = \begin{bmatrix} .252 & -.210 \\ -.150 & .125 \end{bmatrix}.$$

再乘本次M/q，得到 $\bar{H}$ ；再乘ReLU在当前Z的门控，得到 $\bar{Z}$ ：

$$\bar{H} = \begin{bmatrix} .504 & 0 \\ -.300 & .250 \end{bmatrix}, \quad 1[Z > 0] = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}, \quad \bar{Z} = \begin{bmatrix} .504 & 0 \\ 0 & .250 \end{bmatrix}.$$

本例没有 $Z=0$ ，故不涉及该不可微点的取值约定。仿射层有 $\partial Z_{ij} / \partial W_{kj} = X_{ik}$ ， $\partial Z_{ij} / \partial b_j = 1$ 。每个共享参数需累加两条样本路径，然后再加入独立的 λS_0 路径。下表已经包含样本平均因子，不应再整体除以2。

参数	样本1数据贡献	样本2数据贡献	惩罚贡献	总梯度
W11	0.504	0	0.05	0.554
W12	-0	-0.25	-0.02	-0.27
W21	1.008	-0	0.03	1.038
W22	-0	0.25	0.04	0.29
b1	0.504	-0	0	0.504
b2	-0	0.25	0	0.25

参数	样本1数据贡献	样本2数据贡献	惩罚贡献	总梯度
u1	1.008	-0	0.06	1.068
u2	0	-0.4	-0.05	-0.45
c	0.42	-0.25	0	0.17

例如W12的两条数据路径为 $1 \times 0 + (-1) \times .25 = -.25$ ，加惩罚 $.1(-.2) = -.02$ ，得到 $-.27$ 。u1的数据路径为 $.42 \times 2.4 + (-.25) \times 0 = 1.008$ ，再加.06得到1.068。b2的数据路径为 $0 + .25 = .25$ ，因不被惩罚，总梯度仍是.25。c收到 $.42 - .25 = .17$ 。

若继续向输入反传， $\bar{X} = \bar{Z}W^T$ 。样本1为 $(.504 \times .5 + 0 \times (-.2), .504 \times .3 + 0 \times .4) = (.252, .1512)$ ；样本2为 $(0 \times .5 + .25 \times (-.2), 0 \times .3 + .25 \times .4) = (-.05, .1)$ 。输入不更新，惩罚在这里也没有到输入的直接路径。




图3 左图连接数据前向、门控、标量损失、梯度和同时更新；右图把九个参数的数据与惩罚贡献分开画出。偏置的橙色柱为0来自我们明确排除了它们，而不是所有正则化都自动忽略偏置。

4.4 九个参数必须同时更新

用同一旧快照计算的总梯度，执行 $\theta_1 = \theta_0 - .05 \nabla J(\theta_0; M)$ 。不能先更新u，再用新的u计算本来应属于旧图的 $\bar{H}$ 。更新如下：

参数	旧值	变化量	新值
W11	0.5	-0.0277	0.4723
W12	-0.2	0.0135	-0.1865
W21	0.3	-0.0519	0.2481
W22	0.4	-0.0145	0.3855
b1	0.1	-0.0252	0.0748
b2	0.2	-0.0125	0.1875

参数	旧值	变化量	新值
u1	0.6	-0.0534	0.5466
u2	-0.5	0.0225	-0.4775
c	0.1	-0.0085	0.0915

4.5 下一次前向先保留同一掩码作诊断

新 $Z_{11}=0.4723+2(0.2481)+0.0748=1.0433$; $Z_{12}=-0.1865+2(0.3855)+0.1875=0.772$;

$Z_{21}=-0.4723+0.2481+0.0748=-0.1494$; $Z_{22}=0.1865+0.3855+0.1875=0.7595$ 。ReLU门控本次恰好未改变，不代表以后永远固定。

保留原 M 和 $q=0.5$ ， $\tilde{H}$ 的两行是 $(2.0866, 0)$ 与 $(0, 1.519)$ 。新 $P_1=2.0866(0.5466)+0.0915=1.23203556$ ；新 $P_2=1.519(-0.4775)+0.0915=-0.6338225$ 。

样本	新Z	新P	残差	半平方误差
1	(1.0433, 0.772)	1.23203556	0.53203556	0.141530919
2	(-0.1494, 0.7595)	-0.6338225	-0.4338225	0.0941009808

新数据平均为0.1178159497，惩罚为0.0497395605， $J=0.1675555102$ 。一次固定掩码的目标下降说明这个有限实例的这一步确实有效，不证明未来的随机训练损失每步下降。

为防止“会做一次，却不会接下一轮”，将新参数处的反向也展开。 $\bar{P}=(0.26601778, -0.21691125)$ ，输出对 $\tilde{H}$ 的导数改为新 $u=(0.5466, -0.4775)$ ，dropout导数仍是原 M/q 。新的 $\tilde{H}$ 两行分别为 $(0.1454053185, -0.1270234900)$ 、 $(-0.1185636893, 0.1035751219)$ ；乘两道门控后， $\bar{Z}$ 两行变 $(0.2908106371, 0)$ 、 $(0, 0.2071502438)$ 。

第二轮全部参数梯度如下，仍由两条样本数据路径加一条惩罚路径构成；这次只报告梯度，不继续更新，避免误以为实际训练会固定掩码不换。

参数	样本1贡献	样本2贡献	惩罚贡献	总梯度
W11	0.290810637	0	0.04723	0.338040637
W12	-0	-0.207150244	-0.01865	-0.225800244
W21	0.581621274	-0	0.02481	0.606431274
W22	-0	0.207150244	0.03855	0.245700244
b1	0.290810637	-0	0	0.290810637
b2	-0	0.207150244	0	0.207150244
u1	0.5550727	-0	0.05466	0.6097327

参数	样本1贡献	样本2贡献	惩罚贡献	总梯度
u2	0	-0.329488189	-0.04775	-0.377238189
c	0.26601778	-0.21691125	0	0.04910653

第二轮输入梯度为(.1373498639,.0721501191)和(-.0386335205,.0798564190)，这里用的也是新W。所有数值在calculations.json中保留足够精度；表格舍入不参与程序的下一步。

如果在 θ_1 处换成新掩码 $M'=[[1,1],[0,1]]$ ，输入仿射值没有变化，但P变为(.49477556,-.6338225)，数据平均.0575797581， $J=.1073193186$ 。若直接关闭dropout，P则为(.29313778,-.27116125)，数据平均.0426501974。这三个值评价的是同一参数上的三个不同函数，不能把“换掩码后的下降”全部归因于刚才的参数更新。

5 保持隐藏均值为什么不保持最终预测

5.1 十六张掩码可以完整枚举

两条样本各有两个独立掩码位，总共 $2^4=16$ 种，每种概率1/16。固定 θ_0 、X和y，逐个重新前向，可以精确算出期望，不需要用大量随机抽样近似。单看样本1，两个掩码为00、01、10、11时，P依次为.1、-.7、1.54、.74，平均.42；样本2的输出为.1、-.7、.1、-.7，平均-.3。

这两个均值正好等于关闭dropout的P，因为dropout后只有仿射层，期望可以穿过加法与常数乘法。但两样本平均半平方的期望是.2317，关闭dropout的半平方平均只有.0221。

一般对固定h、固定输出权重u、独立掩码， $P=u^T\tilde{h}+c$ 。独立性使不同坐标协方差为0，因此：

$$\text{Var}_M(P) = \frac{1-q}{q} \sum_j u_j^2 h_j^2.$$

把 $P-y$ 写成 $[P-E(P)]+[E(P)-y]$ ，平方并取期望，中心化交叉项为0：

$$E_M \left[\frac{(P-y)^2}{2} \right] = \frac{(u^T h + c - y)^2}{2} + \frac{1-q}{2q} \sum_j u_j^2 h_j^2.$$

本例样本1的P方差为 $(.6 \times 1.2)^2 + (-.5 \times .8)^2 = .6784$ ；样本2为 $0^2 + (-.5 \times .8)^2 = .16$ 。两个半方差取平均，附加值 $(.6784 + .16)/4 = .2096$ ，所以 $.0221 + .2096 = .2317$ 。

这说明在这个特定线性输出、平方损失和独立掩码的条件下，期望目标等价于一个带特征尺度的附加项。它不是任意深层网络都等价于 $\lambda \| \theta \|^2$ ；h还可能依赖可训练上游参数，附加项也随之改变。若掩码相关，方差中还会有交叉协方差项。[Dropout原论文第4至5节和第9节](#)提供随机子网络与边缘化讨论，当前数字和推导为独立实例。

5.2 非线性破坏可交换性

在这些固定P后面额外接sigmoid，仅用来展示非线性，不声称前面的回归网络已变成训练好的分类器。样本1有 $\text{sigmoid}(E[P])=.60348325$ ，而 $E[\text{sigmoid}(P)]=.58931300$ ；样本2分别为.42555748与.42839571。两种方向都可以出现，不能把某一差异方向推广到整个sigmoid定义域。




图4 左图比较精确枚举的平方损失与关闭dropout的平方损失。右图比较先平均再sigmoid与先sigmoid再平均，纵轴为突出差异截取了.35至.66。数值全部来自16张掩码，未把Monte Carlo误差当成机制。

因此一般有 $E[f(\tilde{h})] \neq f(h)$ ， $E[\ell(f(\tilde{h}), y)]$ 也一般不等于 $\ell(f(h), y)$ 。较早dropout后的非线性层还会改变更深处隐藏分布。推理时关闭dropout是一种确定性计算约定，不是对所有随机子网络预测的精确平均保证。

6 模式与随机状态是模型的一部分

6.1 train与eval控制什么

对标准PyTorch Dropout，train会采样并缩放，eval为恒等映射；它没有BN那样的运行均值、运行方差buffer。no_grad控制是否记录新的求导运算，不关闭dropout。图5实际执行同一个全1张量的四种组合，训练态两次前向可得到不同结果。

同一全1输入：模式控制 dropout；no_grad 控制运算图




图5 图中每格是一次真实输出，0代表丢弃、2代表保留后放大、1代表评价态原样通过。train加no_grad仍然采样。eval下若仍启用梯度，输入梯度为1；模式与梯度记录不是同一个开关。

一个细节值得保留：eval的Dropout可能直接返回原输入张量，因此即使在no_grad环境中，返回张量的requires_grad属性也可能保留True。它不表示no_grad失效，而是恒等返回没有新建求导运算。不要只靠一个requires_grad标志推断整个模型是否记录了新的图。实验用真实nn.Dropout核对这一边界。

主训练网络不含BN，目的是不让036中的运行统计机制混入当前消融。若在含BN的网络上把整个模型设成train以做多次随机推理，会同时影响BN，不再只是dropout对照。若研究确需Monte Carlo dropout，应明确哪些层训练态、哪些层评价态、抽样次数和输出如何聚合；不应仅凭随机预测的离散程度就承诺概率校准或可靠不确定性。

6.2 种子不只有一个

复现实验至少要区分数据生成、参数初始化、样本重排、dropout掩码和增强变换。本讲固定数据不变，用seed370、371、372分别控制每次运行的初始化与后三类随机过程，并为四类过程建立独立随机流。这样启用增强不会因为多抽了几个随机数而偷偷改变样本顺序，启用dropout也不改变初值。

精确恢复随机训练还需保存参数、优化器状态、模式、随机流状态、当前数据位置；仅重设同一个初始seed并不会从中断位置继续。本讲没有做磁盘断点恢复或跨平台位级复现；记录完整协议并在当前CPU环境重跑比较，是本次实际核验范围。

7 早停选择的是一段轨迹中的快照

7.1 不需要让训练损失回升才停止

训练损失持续下降、验证损失不再改善时，继续优化可能更多适应训练中的偶然细节。早停用验证数据在参数轨迹 θ_1 、 θ_2 、...中选快照，它本身也是模型选择。验证成绩参与了选择，不能又当成未经选择的最终成绩。

本实验上限160轮，每轮结束在eval和no_grad下计算原始硬标签验证交叉熵。只允许第1轮及以后成为候选，epoch0仅诊断。新值严格小于历史最好值就复制完整参数并将等待计数清零；否则等待数加1。连续20轮未改善就停止，恢复此前最佳快照。min_delta=0，完全同分保留更早快照。

“停止轮”和“恢复轮”不同。若最好点在17轮，随后20轮都未改善，停止发生在37轮，但最终模型是17轮。保存指向参数的可变引用会让所谓“最佳快照”随后一起变化；代码使用detach().clone()逐项复制state_dict。这里没有BN，但同一保存习惯也能保留普通buffer。




图6 三个预定种子全部展示。实线来自完整基线轨迹，早停直到停止时与配对基线逐位一致；绿线是恢复点，紫色虚线是实际停止点。基线后来出现的更低点不属于已经停止的规则可利用的信息，不能倒回去改写决定。

三次分别在37、24、25轮停止，恢复17、4、5轮。较晚的验证波动仍可能产生更好或更差的点，这正是patience需要事先指定的原因。看完全部轨迹再挑一条最漂亮的“早停规则”，相当于扩大了未报告的搜索。

7.2 为什么较早快照可能有类似收缩的作用

用一个独立的一维例子理解，不把它当成深网定理。令 $L(\theta) = .5(a\theta - b)^2$ ， $a \neq 0$ ， $\theta_0 = 0$ ，普通梯度下降满足 $\theta_{t+1} = (1 - \eta a^2)\theta_t + \eta ab$ 。若 $0 < \eta a^2 < 1$ ，递推展开：

$$\theta_t = [1 - (1 - \eta a^2)^t] \frac{b}{a}.$$

有限t让 θ_t 在零和无惩罚最优 b/a 之间。加 $\lambda\theta^2/2$ 后的精确最优是 $[a^2/(a^2 + \lambda)]b/a$ 。两者都有收缩因子，但想匹配所需 λ 取决于 a 、 η 和 t ；多个不同曲率方向通常无法共享同一个匹配 λ 。非线性网络、非零初始化、动量与自适应优化更不能仅凭这个标量例子宣称“早停就是L2”。

早停规则还依赖验证频率、度量、patience、min_delta、快照恢复、最大预算。经典的Prechelt早停研究讨论停止准则的效率与效果权衡。本讲不借用其具体基准收益作为当前实验的结果。

8 增强所声称的不变性必须属于这个任务

8.1 变换图像不等于自动获得正确标签

对随机变换T，最常见的标签不变增强拟合：

$$\hat{R}_{aug}(\theta) = \frac{1}{n} \sum_i E_T[\ell(f_\theta(Tx_i), y_i)].$$

这里隐含“变换后仍该使用 y_i ”的判断。理想情况下， (TX, Y) 与 (X, Y) 具有相同联合分布，增强没有改变目标总体。在更弱情形，即使同一个物体的语义标签可保留，输入频率、取景范围或难度分布也可能变化；最终要检查目标人群上的效果。Chen等的数据增强理论明确区分精确和近似不变性，错误假设可能引入偏差。

对分割、检测、关键点和坐标回归，变换输入时往往需要相应变换标签，例如翻转图像也要翻转掩码或框坐标。这是等变关系，不是“标签文件原封不动”。文本替换也可能改变否定、数值、时间或实体关系；科研成像的颜色、方向和绝对尺度有时就是待测信号。没有一个变换能脱离任务被永远叫作合法增强。

8.2 本讲的两镜能精确审计

主实验输入 $X = (x_1, x_2)$ 在 $[-1, 1]^2$ 均匀生成，干净多数类为 $1\{x_1 > 0\}$ ；再以.15概率独立翻转观测标签。于是 $\eta(x) = P(Y=1|x)$ 在 $x_1 > 0$ 时为.85，否则为.15。 x_2 不携带标签信息。

合法变换 $T_v(x_1, x_2) = (x_1, -x_2)$ 。均匀输入分布不变， x_1 不变，条件标签机制也不变。因此把同一个观测标签带到镜像位置符合这个合成总体的联合分布不变性。某个原标签本来可能是噪声；镜像不会把它变成新的独立标签，也不会修复它。

故意错误的变换 $T_{\beta}(x_1, x_2) = (-x_1, x_2)$ ，仍保留原标签。除 $x_1=0$ 这个概率为0的边界外，干净多数类必定翻转。若想把它作为合法的联合变换，在当前合成任务下应同时将二分类标签改为 $1-y$ ；本实验故意不改，以检验违反语义假设的后果。




图7 实心点为原位置，空心点为变换位置，空心边框仍使用原标签方向的颜色。翻转 x_2 留在同一侧；翻转 x_1 跨过真实边界。增强是否合法来自生成任务的定义，不是箭头是否好看。

两种处理都对每次呈现的训练样本以.5概率做镜像，否则保留原输入。使用同一增强随机流，三种子下被选中次数分别为3865、3806、3781，总呈现数每次7680。合法增强的干净多数类改变次数均为0；错误增强的改变次数等于选中次数。这个审计字段指“干净规则是否改变”，不是观测标签是否原本带噪。

错误镜像与恒等变换各半时，若总体完全对称，变换后同一位置的原标签条件概率会被平均成 $(.85+.15)/2=.5$ ，信号会被冲淡。有限训练还可能在 x_2 等方向拟合噪声，不必真的输出恒定.5。本实验的预测图将显示实际结果，而不拿这个总体推导冒充训练已收敛的事实。

8.3 拆分先于增强

先按原始样本、病人、实体或时间单位划分训练验证测试，再只增强训练数据。把一个原样本及其近似副本随机分到不同集合，会让评价看到训练对象的近亲。增强生成一万张副本，不会把48条原始记录变成一万个独立观测。

验证和测试采用既定的确定性评价输入。如果需要测试时增强，必须预先定义变换集合、预测聚合方法和额外计算预算；它改变了推理算法，应单独报告。本实验不使用测试时增强，也不用测试分数选增强强度。

9 标签平滑改变了希望模型输出的分布

9.1 从多类交叉熵推导

对 K 类，原one-hot标签是 $y_k = 1\{k=c\}$ 。均匀标签平滑定义 $q_k = (1-\alpha)y_k + \alpha/K$ ， $0 \leq \alpha \leq 1$ 。记softmax概率 $p_k = \exp(z_k) / \sum_j \exp(z_j)$ ，平滑交叉熵为：

$$\ell_{LS} = - \sum_{k=1}^K q_k \log p_k = (1 - \alpha)(-\log p_c) + \alpha \left(-\frac{1}{K} \sum_k \log p_k \right).$$

因为 $\sum_k q_k = 1$ ，代入 $\log p_k = z_k - \log \sum_j \exp(z_j)$ ，可得 $\ell = -\sum_k q_k z_k + \log \sum_j \exp(z_j)$ 。对 z_j 求导：第一项为 $-q_j$ ，第二项为 p_j ，因此 $\partial \ell / \partial z_j = p_j - q_j$ 。原始Inception论文第7节与PyTorch2.7交叉熵文档使用向均匀分布混合的约定。

二分类只用一个logit z 时，目标正类概率为 $q = (1 - \alpha)y + \alpha/2$ 。 $\alpha = .1$ 且 $y = 1$ 给 $q = .95$ ，不是.9；因为“分给所有类别”的.1中有.05又分回正确类。另一些约定只把 α 分给错误类别，数值不同，必须写清。

二分类交叉熵可写 $\ell = \log(1 + \exp z) - qz$ ，其梯度为 $\text{sigmoid}(z) - q$ 。对单个不受约束的logit， $q = .95$ 时最优 $z = \log(.95/.05) = \log 19 \approx 2.944$ ，而硬标签 $y = 1$ 的损失随 $z \rightarrow \infty$ 持续趋近0。真实网络参数共享，不能把这个单点解当成每条样本都能独立达到的值。




图8 同一 $y=1$ 样本，蓝线为硬标签目标，橙线为 $\alpha=.1$ 平滑目标。右图橙色梯度在 $\log 19$ 处穿过0，过度自信时梯度转正；硬标签梯度始终非负。图展示目标改变，不表示训练曲线一定更低。

9.2 比较时回到同一原任务指标

一个模型报告平滑CE，另一个报告硬标签CE，这两个loss数值不能直接排名。主实验训练时只有label_smooth处理使用软目标，所有运行的训练诊断、验证选择、测试报告都计算原始硬标签交叉熵；另外记录阈值.5分类错误率与Brier平均平方误差。

Brier分数在二分类是 $n^{-1} \sum (p_i - y_i)^2$ ，越小越好，但它不单独隔离校准。校准关注“预测为某概率的样本，事件频率是否与之相符”，还需要有定义的分箱或其他估计与足够数据。不能把一个较低Brier值直接说成已证明完美校准。

文献When Does Label Smoothing Help报告过校准改善，也讨论知识蒸馏中的限制；它不是所有任务必改善的定理。甚至在无限数据、可表达真实概率的模型中，若原 η 已准确，平滑目标的最优值变成 $(1 - \alpha)\eta + \alpha/2$ ，通常偏离原 η 。

10 一组保留全部结果的CPU消融

10.1 任务 数据和预算

数据生成seed3700，固定保存48条训练、96条验证、384条测试，共528条。三份输入分别校验SHA-256，行ID无交集。干净标签只用于增强语义审计，拟合始终使用带噪观测标签。训练、验证、测试实际翻转数分别9、12、59，正类数为21、40、191；这些有限样本比例不必等于总体的.15噪声率与.5正类率。

网络为2→24 tanh→dropout位置→24 tanh→1 logit，参数数目72+600+25=697，不含BN。所有处理均用AdamW，学习率.01，betas=(.9,.99)，epsilon=1e-8，单线程CPU、float64，foreach=False、fused=False。基线weight_decay显式设0；不依赖AdamW可能带有的默认衰减。

每轮48条训练记录打乱后分为3批，每批16条。固定上限160轮，即480次更新、7680次训练样本呈现。dropout只放在第一层tanh之后，丢弃概率.3；decay只衰减三层权重矩阵，系数.1；两种增强概率均.5；标签平滑 $\alpha=.1$ ；早停patience20。各处理只有这一组预先指定设置，没有强度网格搜索，也没有声称它们得到同样充分的最优调参。

三种子共同改变初始化、重排和相关随机流，但数据始终同一份。它们是算法随机性的三次配对运行，不是三次独立抽样的人群。每次处理共享相同初始化及重排流；早停与基线在停止前的全部记录逐位一致。

10.2 公平应具体到哪一种预算

六个非早停处理各做 $3 \times 480 = 1440$ 次更新；早停只做 $111 + 72 + 75 = 258$ 次，总计8898次更新、142368次训练样本呈现。相同上限是允许的计算预算相同，实际消耗并不相同。额外验证前向、测试前向、绘图网格推理和作者核验不计入optimizer更新，但同样要耗时，不能宣称墙钟或算术量完全公平。

早停在各轮验证后选择快照，其他处理固定使用最后一轮。虽然每轮都记录验证曲线用于诊断，这些曲线没有被拿来为其他处理偷偷选最低点。全部21个模型及其快照先冻结，再统一用测试数据作评价，不依据测试排名继续改变配置。

下表为三个预定种子的算术平均。完整21行、2987行逐轮记录和8064条逐样本测试预测都交付，均值不替代原始结果。

处理	训练硬CE	验证硬CE	测试硬CE	测试错误率
固定预算基线	0.449597	0.437586	0.498581	0.179688
早停	0.491914	0.415885	0.462430	0.175347
dropout	0.466784	0.424631	0.472187	0.170139
权重衰减	0.471110	0.435558	0.475011	0.171875
合法增强	0.484628	0.419053	0.454029	0.162326
错误增强	0.609122	0.703486	0.735984	0.439236

处理	训练硬CE	验证硬CE	测试硬CE	测试错误率
标签平滑	0.455414	0.437974	0.483804	0.176215




图9 左图保留三个种子的测试CE，短横线仅为算术平均，不是置信区间。右图是每次实际更新次数。错误增强明显损害当前任务，其余较小差异不构成统计显著性结论。

这份有限结果中，合法增强的平均测试CE最低；但结论必须保持完整：任务真值明确设计为 x_2 不相关，恰好给这项增强提供了正确先验；其他方法的强度未搜索，数据集没有重新抽样，也没有真实领域验证。它不是“增强普遍优于dropout”的证据。

早停的平均测试CE比固定预算基线低，但seed372的分类错误率从.174479升到.190104，即CE改善不保证阈值错误率也改善。权重衰减seed370、371的验证CE比各自基线略高；小范围的算法变化可能对不同指标及不同随机轨迹产生不同方向。

10.3 看预测面 才知道偏好是否合理

以下三个图组固定展示预先指定的seed370，不因测试表现选择种子。颜色范围都为0到1，黑线是预测概率.5边界，白边小点为训练观测标签；黑色空心大圈标记原始标签被生成噪声翻转的位置。圈不是算法已经识别出的错误，只有因为合成真值已知才能画出。




图10 固定预算基线、dropout与合法增强的预测面。真正的多数类边界是 $x_1=0$ 的竖线；沿 x_2 方向的额外变化在本任务中没有总体信号依据。合法增强鼓励对镜像位置给出一致行为，但有限训练不保证严格不变。




图11 早停、权重衰减和标签平滑的同尺度预测面。早停图使用恢复后的第17轮；另外两图使用第160轮。颜色较温和不能单独证明分类更准或概率更可靠，必须对照固定测试指标。




图12 错误增强的预测面仍可能出现弯曲边界和局部高低，有限网络并未被强制成为常数。原本x1方向的监督被冲淡，模型还可能拟合训练偶然结构。图不能用于宣称所有镜像增强都错误，错误来自本次变换没有同步改变所需标签。

10.4 不把标签平滑包装成校准保证

基线三个种子的测试Brier分别为.149870929、.154287970、.144477653；标签平滑分别为.150696713、.154002353、.143931709。seed370变差，另两个略好；平均从.149545517到.149543592，仅约.000001925的差异，不能据此讲成有意义的校准提升。




图13 左图是理想化总体推导：原 η 正确时， $\alpha=.1$ 平滑的最优概率一般偏向.5。右图为本次三个种子的测试Brier配对值，连线只表示同一个种子。一个变差、两个略好，不能忽略变差者，也不能用接近的均值证明等效。

11 从这个小实验走向科研记录

本讲的“实现正确”证据包含精确分数手算、32个参数与掩码组合下全部九参数的中心差分法和autograd、697参数网络的独立NumPy反向，以及21次训练全部8898步的独立NumPy重建。它们检查公式、随机流与更新实现。相同环境的脚本和Notebook重跑再比较六个输出文件的摘要，检查运行顺序与冻结数据。

这些核验不证明任务假设合理，也不证明现实泛化。若要扩展成科研比较，应在看新的测试结果以前决定：目标总体与采样单位、允许的不变性、所有候选强度、调参预算、随机重复来源、主要指标、统计不确定性方法以及最终独立测试。反复根据同一测试反馈换方案，会消耗它原有的独立评价角色。

至少记录：原始样本数与增强呈现数；每种变换的参数范围、概率和标签规则；损失的归约与是否平滑；受惩罚参数集合；dropout位置、保留概率与推理策略；优化器和模式；早停度量、频率、patience、快照恢复点；实际更新次数及失败运行。本实验没有丢弃失败或较差种子，也没有从不同指标中临时挑一个支持偏好的结论。

12 练习与检查问题

1. 对图1的二参数目标重新求偏导，计算 $\lambda=.1$ 的最优解，并解释为何两个坐标的相对收缩不同。
2. 遮住手算表格，重算两条样本前向、两项损失、W12和u1的三条梯度贡献，再核对全部九参数。
3. 将手算掩码改成全0，哪些参数还可能移动？若 λ 也为0又怎样？
4. 对固定 $h=(1.2,.8)$ ，枚举四种掩码求输出方差，再解释为什么半平方损失多出.2096。
5. 用一个标量ReLU反例证明 $E[f(\text{dropout } h)]$ 不总等于 $f(h)$ ，避免只重复“非线性”三个字。
6. 解释为什么前向抽一张掩码、反向再抽一张掩码不是当前目标的链式法则。设计最小数值检查。
7. 用验证序列(.6,.5,.51,.49,.50,.51)，patience=2、min_delta=0重建最佳点、等待数、停止点；恢复哪一轮？
8. 本合成问题若翻转x1并同时令y变成1-y，联合标签机制是否保留？现实图像任务能直接照搬吗？

9. $K=4$ 、 $\alpha=.2$ 、正确类为第2类时写出平滑目标，给 $p=(.1,.6,.2,.1)$ 求全部logit梯度。
10. 读21行结果，指出早停是否对每个种子的分类错误率都改善，以及标签平滑是否对每个Brier都改善。不要只报告均值。
11. 如果将增强的所有副本随机拆入训练与测试，会在哪里破坏独立评价？应当先按什么单位拆分？
12. 设计一个只改变dropout概率的后续实验，写出候选、预算、随机流、验证选择和新测试边界，并说明它还不能回答什么。

下一讲进入《容量过参数化与理论边界》。带走的不是“正则化越多越好”，而是把每个偏好写成可检查的假设，把每项结论限制在真正完成的计算和评价范围内。