

038 容量与理论边界练习详解

以下答案对应正文和实验指南。先独立写出中间量，再对照结果；数值一致但推理条件不同，仍可能得出错误结论。全文的训练手算目标为MSE的一半，容量风险为普通MSE。

1 为什么过参数化不等于可以拟合任意标签

对 $Xw=y$ ，解存在当且仅当 y 在 X 的列空间。 $p \geq n$ 只保证列数够多，不保证列空间等于全部 n 维空间。反例 $X = \begin{bmatrix} 1 & 1 \\ 2 & 2 \end{bmatrix}$ 、 $y = (1, 0)$ ：第一行要求 $w_1 + w_2 = 1$ ，第二行要求 $2w_1 + 2w_2 = 0$ ，矛盾。若 X 满秩 n ，则任意 y 都能拟合；若 $p > n$ ，还会有至少 $p - n$ 维零空间，解一般不唯一。神经网络的非线性表达与优化另需分析。

2 两次线性更新的完整答案

第0次前向：两行乘积全0；预测(0,0)，残差(-1,-2)，单样本半平方损失(0.5,2)，平均 $L=1.25$ 。局部路径为平均系数 $1/2$ 、半平方导数 r 、残差导数 l 、预测导数 x 。样本贡献为(-0.5,0,-0.5)和(0,-1,-1)；梯度(-0.5,-1,-1.5)，乘 $-\eta=-0.5$ 得到改变量(0.25,0.5,0.75)。

第1次参数(0.25,0.5,0.75)。两行乘积分别(0.25,0,0.75)、(0,0.5,0.75)；预测(1,1.25)，残差(0,-0.75)，单样本半平方损失(0,0.28125)， $L=0.140625$ 。上游 $dL/d\text{prediction}=(0,-0.375)$ ；贡献(0,0,0)和(0,-0.375,-0.375)，梯度(0,-0.375,-0.375)。改变量(0,0.1875,0.1875)，参数变为(0.25,0.6875,0.9375)。

第2次前向乘积(0.25,0,0.9375)、(0,0.6875,0.9375)，预测(1.1875,1.625)，残差(0.1875,-0.375)。单样本半平方损失为0.017578125和0.0703125，平均 $45/1024=0.0439453125$ 。样本1变差是共享 w_3 改变的结果，总损失仍下降。

3 全部插值解与范数

令 $w_3=1+t$ ，得到 $w=(-t, 1-t, 1+t)$ 。每个 t 都满足训练方程。平方范数为 $2+3t^2$ ，所以最小范数解在 $t=0$ 。新点(1,1,0)预测 $1-2t$ ， $t=-1, 0, 1$ 对应3、1、-1。若真系数为(0,1,1)，各向同性新输入使风险等于 $3t^2$ ；换一个目标分布或真系数，该评价需重算。

不要从“最小范数”跳到“最好的模型”。它是指定约束和欧氏度量下的唯一最小范数解，不是无条件最小总体风险解。

4 GD的零空间与稳定范围

因为任意梯度都在 X 的行空间，更新与零空间正交，初始化的零空间分量保持。零初始化的迭代只在行空间运动，收敛时到伪逆解。这里 XX^T 的特征值3和1，Hessian非零特征值3/2和1/2，故 $\eta \in (0, 4/3)$ 可保证两个方向收敛。 $\eta = 4/3$ 时最大谱方向乘数为-1，一般振荡不收敛，端点不能包含。

非零初始化的极限为 $X^+y + (I - X^+X)w_0$ 。80步数值轨迹接近该极限，但恒等式的证明来自每一步的正交性，不是“跑了80步没变所以一定不变”。

5 缩放后的隐式目标

$w = Su$, $S = \text{diag}(1, 1, 2)$ 。最小 u 范数等于最小 $w_1^2 + w_2^2 + w_3^2/4$ 。代入训练约束 $w_1 = 1 - v$ 、 $w_2 = 2 - v$ 、 $w_3 = v$ ，求导 $-6 + (9/2)v = 0$ ，得 $v = 4/3$ 。于是 $w = (-1/3, 2/3, 4/3)$ ，训练预测(1,2)，新点预测1/3。函数类和训练平方损失都没有变，但参数度量和梯度路径变了。

6 复制隐藏节点的完整导数

同一 X, y 上，窄模型 $W = (0.5, 1, 0)$ 、 $b = 0.5$ 、 $a = 1$ 、 $c = 0$ 。宽模型复制 W, b ， a 分别1/2。初始两行 $z = 1$ 、1.5；宽模型每行重复两次。ReLU门全部1，预测都是(1, 1.5)， $r = (0, -0.5)$ ，单样本半平方损失(0, 0.125)，平均0.0625。

$dL/d\text{prediction} = (0, -0.25)$ 。样本1所有梯度贡献0。样本2中窄模型 $dL/dz = -0.25$ ；宽每节点为-0.125。乘上 $x_2 = (0, 1, 1)$ ，窄 W 梯度(0, -0.25, -0.25)，宽每行(0, -0.125, -0.125)； b 梯度等于各自 dL/dz 。输出权重梯度均为 $-0.25 \times 1.5 = -0.375$ ；共享 c 梯度-0.25，只算一次。

乘学习率0.2同步更新。窄 $(W, b, a, c) = ((0.5, 1.05, 0.05), 0.55, 1.075, 0.05)$ 。宽每个节点 $(W, b, a) = ((0.5, 1.025, 0.025), 0.525, 0.575)$ ，共享 $c = 0.05$ 。下一前向窄 $z = (1.1, 1.65)$ 、预测(1.2325, 1.82375)、损失0.021280078125。宽每个 $z = (1.05, 1.575)$ ，输出相加后预测(1.2575, 1.86125)、损失0.021389453125。相同初始函数、相同步长，不保证同一参数化梯度运动。

7 早停与Ridge为什么不完全等价

线性GD在每个非零奇异方向有递推 $a_{t+1} = qa_t + (\eta s/n)u^T y$ ， $q = 1 - \eta s^2/n$ 。从零出发等比求和得到 $(1 - q^t)(u^T y)/s$ 。Ridge对应 $s(u^T y)/(s^2 + n\lambda)$ 。若强行对单个 s 匹配，解得

$$\lambda_s = \frac{s^2}{n} \frac{q^t}{1 - q^t}.$$

通常它随 s 变化，不能给全部方向同一个 λ 。若 q 为负且 t 为奇数，上式甚至给负 λ ，已不在非负Ridge惩罚内。本讲谱展示选非负 q 范围，避免把振荡混进直观，但稳定性推导没有删去该可能。

对 $X = \text{diag}(2, 0.2)$ 、 $n = 2$ 、 $\eta = 0.4$ ， q 为0.2和0.992。第1步系数为(0.4, 0.04)，预测(0.8, 0.008)， $L = (0.2^2 + 0.992^2)/4 = 0.256016$ ；第2步系数(0.48, 0.07968)，预测(0.96, 0.015936)。第二方向慢，不意味着程序漏更新，而是曲率小。

8 精确风险公式与遗漏信号

把 w 补零到96维得到 $e=w_{\text{padded}}-\beta$ 。因为新输入协方差 I ， $E[(x^T e)^2]=e^T I e=\|e\|^2$ 。也可逐项展开，交叉项均值0，对角项均值 e_j^2 。 $p=1$ 时遗漏 $\beta_2=-1$ 、 $\beta_3=0.5$ ，故有不可表达部分 $1+0.25=1.25$ ； $p=2$ 时为0.25； $p\geq 3$ 时为0。

带独立新标签噪声时平方展开多出 σ^2 ，交叉项为0。若未来输入协方差 Σ ，正确式为 $e^T \Sigma e$ ，不再是简单欧氏距离。若新噪声与 x 相关或有非零均值，也不能直接加 σ^2 了事。

9 如何描述实际双下降

$\sigma=0.8$ 、无惩罚时， $p=3、24、48、96$ 的干净风险中位数分别0.110237、48.458726、1.789907、1.913704。插值附近有尖峰，之后下降，但从48到96又上升。 $p=24$ 均值107.207575，最大464.558407，与中位数差异大，必须保留全seed。

$\sigma=0$ 时， $3\leq p\leq 24$ 的风险约 10^{-29} 至 10^{-31} ，没有噪声尖峰； $p>24$ 之后可能因行空间投影损失真信号而增大。结论必须包括这个反例。增加参数既能改变噪声拟合，也能改变信号投影，不是单一单调机制。

10 三类期望的区别

一次训练数据 D 固定后的 clean_risk 只对新输入平均。 $\text{conditional_noise_mean_risk}$ 固定完整训练设计、再平均训练噪声；它是信号误差加 $\sigma^2 \text{tr}(AA^T)$ 。若再对随机设计平均，得到第三个层次，某些理论讨论的是这一层或其高维极限。

一次噪声分解含 $2b^T v$ ，噪声平均后该项为0；遗漏信号或Ridge下单次交叉项一般不能直接删。400次重复保持同一个设计，不能称为400个独立数据设计；标准误只描述该Monte Carlo平均。4096个新输入只检查一个固定拟合的风险计算，不能替代整个模型族的独立外部验证。

11 一个看似很大的泛化界

若有限固定候选 $M=10^6$ 、 $n=5$ 、 $\delta=0.05$ ，则 $\epsilon=\sqrt{\log(4\times 10^7)/10}$ 约1.323。对 $[0,1]$ 损失，风险差不超过1本来就成立，这个上界没有给更强信息，不能据此判断模型必差。保持 M 与 δ 不变、 n 增大， ϵ 按 $1/\sqrt{n}$ 下降。

本讲Gaussian平方损失无界且参数连续，所以这个有限有界类界不能直接套实验。候选集合若是训练后构造，更不能先选中一个再把 M 当1。要使用更复杂工具，需声明新的复杂度与依赖条件。

12 理论与证据边界的合格表述

通用逼近：指定连续sigmoid版本说，在单位立方体对每个连续目标、每个正精度，存在足够宽的一层隐藏网络；不保证训练找到它。

GD选择：线性平方目标、普通GD、零初始化、稳定固定步长、收敛到极限时得到最小欧氏范数最小二乘解。改变参数坐标或算法后需重证。

统一界：独立同分布样本、预先固定有限类、有界损失下，高概率同时控制候选的经验/总体风险差；不是某个现实模型的分数的预报。

比例渐近： n 、 p 一起趋于无穷，比例不等于1并满足相应分布/矩/谱假设；不等于 $n=24$ 实验的精确有限样本预测。

后续计划示例：只把总体协方差改为预先指定的对角 Σ ，保持种子、噪声与求解器，重新用 $e^T \Sigma e$ 评价，比较谱和风险。其余条件不变仍不保证某个曲线形状，观察结果后如实报告。