

038 容量过参数化与理论边界

本讲解决一个常见研究困惑：为什么增加参数，有时降低未见数据上的误差，有时反而使误差升高？上一讲讨论衰减、早停和增强如何改变学习过程；本讲把“网络有多大”“算法最后选了什么函数”“目标分布上的风险多大”分开。答案必须同时描述数据、模型、优化规则和评价对象，不能只报参数数量。

先修013的秩、奇异值与零空间，020的经验风险和总体风险，以及037的正则化。我们从同一组两样本做两次完整线性训练更新，再把它放进一个隐藏层网络，核对复制神经元前后的所有梯度。随后用1944个可重跑的合成拟合观察插值附近的风险，并保留不符合“大模型总更好”的结果。这里没有深层网络性能排名，也没有真实部署效果的证据。

读完应能：区分参数数目、训练设计矩阵的秩和函数类；证明指定线性GD的最小范数选择；解释小奇异值怎样放大噪声；准确描述双下降实验；为存在性定理、泛化上界和渐近结论写出各自的适用条件。

1 四个问题不要用一个数字回答

设输入为 x ，参数为 $\theta \in \mathbb{R}^P$ ，模型为 $f_\theta(x)$ 。参数数目 P 是存储坐标的数量。函数类 $\mathcal{F} = \{f_\theta : \theta \in \Theta\}$ 是这些坐标能够表示的函数集合。不同参数可能给出相同函数，参数的约束也会改变集合。给定训练数据 D ，算法 A 输出 $\hat{\theta} = A(D)$ ；总体风险还要对规定的新样本分布求期望。



图1 参数到风险之间有多层关系。箭头是需要补充条件的映射，不是参数越多风险越小的逻辑蕴含。

例如，把线性预测写成 $f_{a,b}(x) = (a + b)x$ ，有两个参数，却只依赖一个有效系数 $a + b$ 。任意实数 a, b 所表达的函数类与 $f_w(x) = wx$ 相同。再如，在某份数据上两个特征列完全相同，训练预测只识别它们的系数之和，但在未来输入中这两列可能不再相同。前一种是整个函数参数化的冗余，后一种是这份训练数据的信息不足，不能混为一谈。

插值在本讲的平方损失模型中指每个训练预测都等于标签，训练MSE为零。**过参数化**必须相对某个约束说明；对一般位置的线性回归， $p > n$ 意味着未知系数多于标量方程。即使 $p \geq n$ ，若设计矩阵不满行秩，任意标签也未必能被插值。对分类网络，训练分类错误为零并不意味着交叉熵为零，也不能机械地把阈值写成“参数数目等于样本数”。

本讲线性实验的 p 是使用的输入特征数量，所有这些线性系数均被拟合，没有额外截距。它与后来深网的隐藏宽度不同；符号相同或曲线相似，不代表机制完全相同。

2 同一两样本上的第一次完整更新

全部手算采用无单位的合成数值、列参数约定。两个样本各有三个原始特征，第三列碰巧在这两行都为1，但不是模型强制添加的截距，新的输入第三坐标可以不是1。

$$X = \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \end{bmatrix} \in \mathbb{R}^{2 \times 3}, \quad y = \begin{bmatrix} 1 \\ 2 \end{bmatrix}, \quad w^{(0)} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}.$$

前向为 $\hat{y}_i = \sum_{j=1}^3 x_{ij}w_j$ 。定义残差 $r_i = \hat{y}_i - y_i$ ，单样本损失 $\ell_i = r_i^2/2$ ，优化目标 $L = (\ell_1 + \ell_2)/2 = \sum_i r_i^2/4$ 。这个目标是MSE的一半；后面的容量图为MSE风险，不再带1/2。

样本	三个乘积 $x_{ij}w_j$	预测	标签	残差	单样本 ℓ_i	对 L 的贡献 $\ell_i/2$
1	0, 0, 0	0	1	-1	0.5	0.25
2	0, 0, 0	0	2	-2	2	1

所以 $L^{(0)} = 1.25$ 。逐节点反向，而不是直接背矩阵公式： $\partial L / \partial \ell_i = 1/2$ ， $\partial \ell_i / \partial r_i = r_i$ ， $\partial r_i / \partial \hat{y}_i = 1$ ， $\partial \hat{y}_i / \partial w_j = x_{ij}$ 。因此样本 i 沿自己的路径传给参数 j 的是 $r_i x_{ij}/2$ 。

参数	样本1路径贡献	样本2路径贡献	累积梯度	$\eta = 0.5$ 时改变量	更新后
w_1	$(-1)/2 \times 1 = -0.5$	$(-2)/2 \times 0 = 0$	-0.5	0.25	0.25
w_2	$(-1)/2 \times 0 = 0$	$(-2)/2 \times 1 = -1$	-1	0.5	0.5
w_3	$(-1)/2 \times 1 = -0.5$	$(-2)/2 \times 1 = -1$	-1.5	0.75	0.75

三个梯度都基于旧参数计算，再同时更新。矩阵式 $g = X^T r/2$ 只是这六条路径的压缩。特别是 w_3 同时影响两个样本，必须把两条贡献相加。新参数为(0.25, 0.5, 0.75)；新预测逐项算为 $0.25 + 0 + 0.75 = 1$ 及 $0 + 0.5 + 0.75 = 1.25$ 。

3 第二次更新和第三次前向

第一次更新后的残差是(0, -0.75)，两个单样本半平方损失为(0, 0.28125)，平均目标 $L^{(1)} = 0.140625$ 。这次 $\partial L / \partial \hat{y} = (0, -0.375)$ ；局部导数 $\partial \hat{y}_i / \partial w_j$ 仍是原来的 X 。

参数	样本1贡献	样本2贡献	梯度	旧参数	同时更新后
w_1	0	$-0.375 \times 0 = 0$	0	0.25	0.25
w_2	0	$-0.375 \times 1 = -0.375$	-0.375	0.5	0.6875
w_3	0	$-0.375 \times 1 = -0.375$	-0.375	0.75	0.9375

第三次前向的三个乘积分别为 $(0.25, 0, 0.9375)$ 和 $(0, 0.6875, 0.9375)$ 。预测 $(1.1875, 1.625)$ ，残差 $(0.1875, -0.375)$ ，单样本损失为 $(0.017578125, 0.0703125)$ ，平均 $L^{(2)} = 0.0439453125 = 45/1024$ 。第一个样本在第二次更新前已经完全拟合，更新后却又产生误差：共享参数 w_3 为降低总目标而变化，单个样本不一定每步都改善。




图2 两轮反向传播均先保留逐样本贡献，再按参数列求和。负零仅为浮点符号，与零相同。

experiment.py的linear_step返回乘积、预测、残差、局部导数、贡献、累积梯度、改变量和下一前向。hand-trace.json不是只保存终点。独立测试使用Fraction的有理数运算重建两轮，而PyTorch autograd另核对第一轮；两者不会依靠同一个手写梯度公式通过检查。

4 拟合全部训练数据仍不决定未来预测

训练方程仅为 $w_1 + w_3 = 1$ 、 $w_2 + w_3 = 2$ 。先令 $w_3 = 1 + t$ ，代回得到全部解：

$$w(t) = \begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix} + t \begin{bmatrix} -1 \\ -1 \\ 1 \end{bmatrix}.$$

记 $z = (-1, -1, 1)^T$ 。因为 $Xz = (0, 0)^T$ ， z 属于 X 的零空间：沿它移动不会改变任何训练预测。三维参数中只有两个独立训练约束，秩为2，零空间维数为1。任意 t 的训练误差都等于零。

参数平方范数逐项展开为 $t^2 + (1 - t)^2 + (1 + t)^2 = 2 + 3t^2$ ，唯一最小值在 $t = 0$ ，得到 $w_* = (0, 1, 1)$ 。这是满足训练数据的最小欧氏范数解，却不证明真实系数为此值。

拿一个新输入 $x_* = (1, 1, 0)$ ，预测为 $w_1 + w_2 = 1 - 2t$ 。 $t = 0, 1, -1$ 分别预测 1、-1、3，而训练预测完全相同。若额外假设真实系数恰为 w_* ，新输入各坐标独立且均值 0、方差 1，则与真函数的总体平方误差为 $\|w(t) - w_*\|^2 = 3t^2$ ；这个结论利用了新分布和真实系数的假设，不能从两条训练记录推出。




图3 左图是全部插值解的范数和训练误差，右图是三个不同零空间初始化的真实80步GD。训练约束相同，但新点预测极限不同。

研究中的“隐式偏置”指算法即使不在目标中显式加入惩罚，也倾向或受限于某些解。它不是统计学的“偏差”一词在所有场合下的同义词。下面只证明一个可精确定义的线性例子。

5 为什么零初始化的线性GD选择最小范数解

对于 $L(w) = \|Xw - y\|^2 / (2n)$ ，梯度 $X^T(Xw - y)/n$ 一定属于 X^T 的列空间，也就是 X 的行空间。取任意零空间向量 z ， $z^T X^T = (Xz)^T = 0$ ，所以每次更新满足

$$z^T w^{(t+1)} = z^T w^{(t)} - \frac{\eta}{n} z^T X^T (Xw^{(t)} - y) = z^T w^{(t)}.$$

零空间分量始终保持初始化的值。零初始化没有零空间分量，因此所有迭代都在行空间内。行空间与零空间正交；任意最小二乘解都可写成 $X^+y + z_0$ ，且 $X^+y \perp z_0$ ，故其范数平方为 $\|X^+y\|^2 + \|z_0\|^2$ 。其中 X^+ 为 Moore-Penrose 伪逆，定义见下一节。只有 $z_0 = 0$ 达到最小范数。

还有一个不能跳过的条件：迭代必须收敛。若非零奇异值为 $s_1 \geq \dots \geq s_r > 0$ ，Hessian 的非零特征值是 s_j^2/n 。相应误差坐标每步乘 $1 - \eta s_j^2/n$ 。要让绝对值小于 1，取

$$0 < \eta < \frac{2n}{s_1^2}.$$

本例 $XX^T = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$ 的特征值是 3 和 1，故 $s_1^2 = 3$ ，稳定范围 $0 < \eta < 4/3$ ； $\eta = 0.5$ 符合要求。非零谱方向收敛，零空间分量保持，最终

$$w_\infty = X^+y + (I - X^+X)w^{(0)}.$$

这要求训练标签可精确拟合，但在不相容系统中终点只是最小二乘解。我们的两样本系统满行秩，因而确实插值。若初始化含 tz ，终点就含同样的 tz ，不再是最小范数解。若换成Adam、动量、非线性网络、不同坐标度量或不稳定步长，上述逐行证明不能原样套用。

6 坐标缩放也会改变隐式偏置

保持函数写作 $f = x^T w$ ，用 $w = Su$ 重新参数化，其中 $S = \text{diag}(1, 1, 2)$ 。在 u 上零初始化GD倾向最小化 $\|u\|^2 = \|S^{-1}w\|^2 = w_1^2 + w_2^2 + w_3^2/4$ ，不是原来的 $\|w\|^2$ 。

同样的训练约束下，令 $w_3 = v$ ，目标为 $(1-v)^2 + (2-v)^2 + v^2/4$ 。求导：

$-2(1-v) - 2(2-v) + v/2 = -6 + (9/2)v$ 。驻点 $v = 4/3$ ，于是 $w = (-1/3, 2/3, 4/3)$ ；训练预测仍为 $(1, 2)$ ，新点 $(1, 1, 0)$ 的预测却为 $1/3$ 。

“最小范数”若不声明参数坐标、尺度或度量，是不完整的说法。给原始特征缩放而没有同步改正则化，或者把一层分成两层，都可能改变训练偏好；这并不与二者能表示同一函数相矛盾。

7 奇异值把拟合与噪声放大连接起来

设紧致SVD为 $X = U_r \text{diag}(s_1, \dots, s_r) V_r^T$ 。 U_r 是训练样本空间中的正交方向， V_r 是参数行空间中的正交方向。把标签投影到 u_j 上后，满足该方向训练约束需要除以 s_j ：

$$\hat{w} = X^+ y = \sum_{j=1}^r v_j \frac{u_j^T y}{s_j}.$$

如果标签中噪声在 u_j 方向有分量 $u_j^T \epsilon$ ，它对系数的影响为 $v_j(u_j^T \epsilon)/s_j$ 。 s_j 很小时，即便噪声不大，系数也可能很大。取 $X = \text{diag}(2, 0.2)$ 、 $y = (1, 1)$ ，完整解是 $(0.5, 5)$ 。第二个方向需要的系数是第一个的十倍。

现在不把 $1/s_j$ 当作唯一选择。零初始化、稳定步长GD在第 j 个坐标的递推为

$a_{t+1} = (1 - \eta s_j^2/n) a_t + (\eta s_j/n) u_j^T y$ 。从 $a_0 = 0$ 对等比数列求和：

$$a_t = \frac{1 - (1 - \eta s_j^2/n)^t}{s_j} u_j^T y.$$

有限 t 时，小 s_j 的方向尚未充分拟合。这解释了此线性情形中早停的谱滤波作用。若进一步

$0 < \eta \leq n/s_1^2$ ，每个乘数非负，滤波因子随 t 单调接近 $1/s_j$ ；只有较宽的稳定条件时可能振荡，不能统称单调。

对显式Ridge目标 $\|Xw - y\|^2/(2n) + (\lambda/2)\|w\|^2$ 求导并置零，得到 $(X^T X + n\lambda I)w = X^T y$ ，其谱因子为 $s_j/(s_j^2 + n\lambda)$ 。 n 来自损失平均，不能遗漏。有限步GD和Ridge都能压制小奇异值，但滤波函数不同，不存在对所有谱方向统一精确对应的“一个训练轮数等于一个 λ ”。




图4 左图使用 $\eta/n=0.1$ 作连续谱示意，右图为 $n=2$ 的Ridge因子。数值实验另对固定两维矩阵核验0、1、2、10、100、1000步，图左的连续曲线不是这六个离散状态的折线。

least_squares使用NumPy SVD而非显式求逆 $X^T X$ ；后者会平方条件数。rcond=1e-12决定小于最大奇异值该比例的方向被视为数值零。数学上的非零秩与有限精度的数值秩不同。当前1944个拟合的无惩罚方向均未触发额外截断，实际秩为 $\min(n, p)$ ；另有秩亏与极小奇异值测试专门检验截断行为。Ridge分支使用全部奇异值的稳定滤波，报告的rank仍描述同一阈值下的设计矩阵。

8 同一数据上的神经元复制完整链

回到第2节同一 X, y ，现在用三输入、一隐藏ReLU、一个线性输出的网络： $z_i = Wx_i + b$ ， $h_i = \max(z_i, 0)$ ， $\hat{y}_i = ah_i + c$ 。先设 $W = (0.5, 1, 0)$ 、 $b = 0.5$ 、 $a = 1$ 、 $c = 0$ ，共6个可训练参数。两行的 $z = h = (1, 1.5)$ ，预测 $(1, 1.5)$ ，残差 $(0, -0.5)$ ，平均半平方损失0.0625。

再复制这个隐藏节点两次，保持每个 W, b 相同，但将输出权重各设为1/2。此时11个参数，且对所有输入， $\frac{1}{2}\text{ReLU}(Wx + b) + \frac{1}{2}\text{ReLU}(Wx + b)$ 都等于原函数；这不只是两条训练记录上的相等。这里仅展示宽模型参数集合内的一组复制参数，不是说整个宽函数类与窄类一样大。

对于任意隐藏宽度 m ，逐节点导数是 $g_i = r_i/2$ 、 $\partial \hat{y}_i / \partial h_{ij} = a_j$ 、 $\partial h_{ij} / \partial z_{ij} = 1$ （本例全部 $z > 0$ ），因此 $d_{ij} = g_i a_j$ 。每个样本对参数的贡献依次为 $d_{ij} x_{ik}$ 、 d_{ij} 、 $g_i h_{ij}$ 、 g_i ，对应 W_{jk}, b_j, a_j, c 。

样本1的 $g_1 = 0$ ，对两种网络每个参数的贡献均为0。样本2的 $g_2 = -0.25$ ：窄模型 $d_{21} = -0.25$ ；宽模型每个 $d_{2j} = -0.125$ 。下面的梯度也就是样本2的贡献，已经把样本1的零贡献累加进去。

参数	窄模型旧值	窄梯度	窄更新后	宽模型每个节点旧值	宽每节点梯度	宽每节点更新后
W_{j1}	0.5	0	0.5	0.5	0	0.5
W_{j2}	1	-0.25	1.05	1	-0.125	1.025
W_{j3}	0	-0.25	0.05	0	-0.125	0.025
b_j	0.5	-0.25	0.55	0.5	-0.125	0.525
a_j	1	-0.375	1.075	0.5	-0.375	0.575

参数	窄模型旧值	窄梯度	窄更新后	宽模型每个节点旧值	宽每节点梯度	宽每节点更新后
共享输出 c	0	-0.25	0.05	0	-0.25	0.05

学习率均为0.2，全体参数同时更新。宽表前五行各有两个独立参数，共10个； c 仅一个，不能复制其更新。下一前向：窄模型 $z = (1.1, 1.65)$ ，预测 $1.075z + 0.05 = (1.2325, 1.82375)$ ，损失0.021280078125。宽模型每个节点 $z = (1.05, 1.575)$ ，两个输出相加得 $1.15z + 0.05 = (1.2575, 1.86125)$ ，损失0.021389453125。




图5 初始函数完全相同，普通参数梯度下降的一步却不同。两组全部34个逐样本参数贡献和17个累积梯度均由autograd另行核验。

原因不是“宽模型突然不能表示原函数”，而是参数坐标的欧氏梯度不具任意重参数化不变性。这个单步例子不能推出宽模型长期更差，也不能证明深网一般选择最小欧氏范数。它说明一个研究对照若只匹配初始预测，未必匹配优化动力学。

9 容量实验先规定究竟改什么

我们构造总体 $x \sim N(0, I_{96})$ ，真实系数 $\beta = (1, -1, 0.5, 0, \dots, 0)$ ，干净目标 $f_*(x) = x^T \beta$ ，训练标签 $y = f_*(x) + \sigma \epsilon$ ， $\epsilon \sim N(0, 1)$ 独立于 x 。每个seed生成24行96列训练输入与24个噪声，再对全部配置重用。seed固定为3800至3811，合计12组独立生成的设计和噪声。不是12次优化初始化，也不是12个测试子集。

宽度为1、2、3、4、8、12、16、20、22、23、24、25、26、28、32、48、72、96。每个模型只取训练输入前 p 列，因此宽度间嵌套，前3维已含全部真信号，后来加的特征只有零真系数。固定噪声强度0、0.2、0.8；固定Ridge系数0、0.01、0.1，没有用风险挑选入。每个seed内噪声方向相同，只改变强度，构成成对控制。

12个配对seed

每个固定 $X(24 \times 96)$
和同一噪声 ε

18个嵌套宽度

只取前 p 列
 $p=1$ 到96

3个噪声强度

$\sigma=0, 0.2, 0.8$
 $y=X\beta+\sigma\varepsilon$

3个固定惩罚

$\lambda=0, 0.01, 0.1$
共1944个拟合

同一seed内成对；训练噪声和设计一同随seed改变。没有算法随机初始化。

图6 完整实验为 $12 \times 18 \times 3 \times 3 = 1944$ 次拟合。所有参数和预测都留在公开输出，不删高风险运行。

无惩罚时使用SVD最小范数最小二乘，不是只跑几个epoch的网络；因此容量曲线没有混入“更宽模型还没训练完”。Ridge是另一个明确改变目标的控制组。模型参数量只计 p 个线性系数，SVD临时数组和知道真 β 的评价程序都不是模型参数。

训练MSE为 $\|X_p \hat{w} - y\|^2 / n$ 。真正关注的是固定训练结果后，对一个新输入的**干净目标风险**：

$$R_{D,p} = \mathbb{E}_{x_{\text{new}}} [(x_{\text{new},1:p}^T \hat{w} - x_{\text{new},1:p}^T \beta)^2 \mid D].$$

把 $\hat{w}$ 补零到96维，记差 $e = \hat{w}_{\text{padded}} - \beta$ 。展开平方为 $\sum_j e_j^2 x_j^2 + 2 \sum_{j < k} e_j e_k x_j x_k$ ，独立零均值使交叉项期望为0，方差1使对角项期望为 e_j^2 。故

$$R_{D,p} = \|\hat{w} - \beta_{1:p}\|^2 + \|\beta_{p+1:96}\|^2.$$

第二项是遗漏特征的不可表达误差， $p=1$ 为1.25、 $p=2$ 为0.25、 $p \geq 3$ 为0。若评价带独立新噪声的标签，其风险再加 σ^2 。这是模型生成分布已知时的精确期望计算，不是有限测试集分数，也不是从真实数据估计未知 β 的方法。所有图都明确使用哪一种风险。

10 实际结果同时保留第二次下降和再次上升

细线是全部12次；仅显示时把小于 $1e-12$ 的舍入误差放在 $1e-12$




图7 无惩罚的三种训练噪声。粗线为12次中位数，细线保留每次运行；零噪声面板显示其机制不同。对数显示下限仅用于画图，原始输出不截断。

p	$\sigma=0$ 的风险中位数	$\sigma=0.2$ 的风险中位数	$\sigma=0.8$ 的风险中位数
1	1.27917	1.28187	1.33586
3	约 5.2×10^{-31}	0.006890	0.110237
12	约 2.8×10^{-30}	0.047122	0.753946
24	约 3.2×10^{-29}	3.028670	48.458726
32	0.459401	0.586613	2.753981
48	1.026888	1.072975	1.789907
96	1.675111	1.691181	1.913704

带噪声时，先从缺少真实特征的 $p = 1$ 下降到 $p = 3$ ，之后增加无关特征会更强地拟合噪声，插值附近风险很高，再向过参数区增加 p 出现下降。这是本实验支持的容量双下降现象。它不推翻误差分解，只是不能把整个算法族的风险强行画成单个U形。

但第二次下降不是无限单调下降： $\sigma = 0.8$ 从 $p = 48$ 到96的中位数又上升； $\sigma = 0.2$ 在 $p = 32$ 以后也明显上升。过参数区的最小范数投影可能丢失真信号，噪声放大减小与信号丢失增加在竞争。这里最宽模型也没有超过知道信号恰在前3维的 $p = 3$ 配置。实验把信号顺序特意公开，不能据此宣称实际任务能免费知道最优宽度。

零噪声时， $3 \leq p \leq 24$ 能恢复真系数到浮点精度，并无带噪声的尖峰。超过24后，最小范数解一般只是 β 在随机行空间中的投影，造成信号误差。图中的约 10^{-29} 是数值舍入，不是新的统计误差机制。

$\sigma = 0.8, p = 24$ 的12次风险中位数48.4587、均值107.2076、最小7.9344、最大464.5584。不能隐藏高风险样本，只报告最好seed；也不能把12次中位数当理论上的期望。小奇异值导致分布长尾，阈值附近均值尤其不稳定。这里没有据12个seed计算总体显著性结论。




图8 固定噪声0.8时， $\lambda=0.01$ 与0.1改变插值尖峰和训练误差。惩罚有偏但可降低方差，不能从这两个固定设置宣称已找到最优正则化。

11 一次噪声和对噪声求平均也不同

固定设计 X ，把标签写为 $y = y_{\text{clean}} + \sigma\epsilon$ 。对于SVD/Ridge这种线性估计器，

$\hat{w} = Ay = Ay_{\text{clean}} + \sigma A\epsilon$ 。令信号误差向量 $b = Ay_{\text{clean}} - \beta_{1:p}$ ，噪声响应 $v = \sigma A\epsilon$ ，则一次实际拟合的风险为

$$R_{D,p} = \|b\|^2 + \|\beta_{p+1:96}\|^2 + \|v\|^2 + 2b^T v.$$

代码分别记录signal_error、realized_noise_norm2和cross_term，三项相加等于clean_risk。对无惩罚且 $p \geq 3$ 的满秩情形，行空间/零空间正交会交叉项为零；但遗漏信号或Ridge场景不能不加说明地删去一次实现中的交叉项。

若现在再对独立、均值0、协方差 I 的训练噪声求期望，则 $\mathbb{E}[v] = 0$ ，交叉项的期望为0。按坐标展开可得 $\mathbb{E}\|A\epsilon\|^2 = \sum_{jk} A_{jk}^2 = \text{tr}(AA^T)$ 。因此固定完整训练设计、仅平均训练噪声的风险为

$$\mathbb{E}_{\epsilon}[R_{D,p} | X_{96}] = \|b\|^2 + \|\beta_{p+1:96}\|^2 + \sigma^2 \text{tr}(AA^T).$$

这里固定的是完整96列训练输入，包含被模型遗漏的真信号坐标；否则条件分布还会包含那些被遗漏坐标的随机性。无惩罚时 $\text{tr}(AA^T) = \sum_j 1/s_j^2$ ；Ridge时为 $\sum_j [s_j/(s_j^2 + n\lambda)]^2$ 。




图9 左图保留全部216个无惩罚 $\sigma=0.8$ 拟合，颜色为 p 。右图把一次噪声响应与噪声平均放大相比较；不可把两者当同一数值。

额外诊断固定 $n = 24, p = 32$ 的一个设计，重复400个训练噪声：精确条件均值2.63538，Monte Carlo均值2.57610，均值标准误0.06737。误差落在约一个标准误内，但不能把一次接近说成概率定理的证明。再固定一个拟合，用独立4096个新输入检查风险公式：有限样本MSE为2.45679，精确风险2.45336，Monte Carlo标准误0.05463。此检查只核验合成评价代码，不用于选择宽度或惩罚。




图10 三种期望的随机对象不同。右图从上到下依次固定更多对象，不能拿条件于训练数据的数值直接冒充对所有训练集的平均。

12 渐近公式是带条件的参照

Hastie等的原始论文研究最小范数线性回归及扩展特征模型。在最简单的正确指定各向同性情形，设噪声方差为 σ^2 、真系数平方范数趋于 r^2 ，且 n, p 同时趋于无穷、 $p/n \rightarrow \gamma \neq 1$ ，例如取独立同分布、均值0、方差1且具有某个大于4阶有限矩的特征坐标，噪声独立、零均值且方差有限，真系数为确定性向量，则该情形的极限风险包含： $\gamma < 1$ 时的噪声项 $\sigma^2\gamma/(1-\gamma)$ ； $\gamma > 1$ 时的信号项 $r^2(1-1/\gamma)$ 加噪声项 $\sigma^2/(\gamma-1)$ 。这里风险不含新标签的不可约噪声。

这些表达提示：接近比例1会放大噪声，而过参数区的信号项随比例增加。它们不承诺我们的 $n = 24$ 、12次抽样均值就等于这些数；也不覆盖 $p < 3$ 的遗漏信号配置。把 $\gamma = 1$ 直接代进去会得到未定义的分母，不能把它当“实际运行必定无穷大”。实际有限矩阵大多可逆，风险有限但可能非常大。定理中的极限顺序、风险是否平均训练噪声、谱条件，都必须查原文。

不能仅把神经网络线性化然后宣布这些公式适用：训练中的特征若在改变，其相关性、谱、参数路径和有效维数均可能不同。T3将讨论宽网络核视角与特征学习；本讲只建立如何读条件的习惯。

13 通用逼近告诉我们存在什么

Cybenko的经典结果之一针对单位立方体上的连续目标函数，以及连续sigmoid激活：给定任何正误差容限，存在足够多隐藏节点及相应权重，使一层隐藏网络在该紧域上一致逼近目标。量词的关键顺序是“给定目标和精度，存在某个有限宽度与参数”，宽度可以依赖目标和精度。

它不说当前给定宽度已经足够，不提供梯度下降一定找到这些参数的保证，也不直接给样本复杂度、训练时间或域外泛化。若目标不连续，直接套连续目标的一致逼近结论也不正确；若使用ReLU，需要查对应的另一版本定理，不能把“连续sigmoid”的原条件改掉而仍引用同一结论。本讲不证明该函数分析定理，只准确限定这一个版本的含义。

回到自己的实验，至少分别询问：函数类能否表示目标？算法能否从给定初始化找到低训练损失？有限数据能否识别有用解？目标分布是否与训练假设一致？一个存在性结果只回答第一个问题的一部分。

14 亲手推一个有条件的统一泛化界

为了不把抽象“泛化界”当万能预测器，先考虑一个严格简化的例子。预先固定有限函数类 $\mathcal{F} = \{f_1, \dots, f_M\}$, n, M 为正整数, $0 < \delta < 1$ 。样本独立同分布, 损失在 $[0, 1]$ 。对固定 f , Hoeffding 不等式给出 $\Pr(|R(f) - \hat{R}_n(f)| > \epsilon) \leq 2e^{-2n\epsilon^2}$ 。这里把该独立有界变量不等式作为概率工具; 下面的联合步骤可以直接推完。

令事件 E_j 表示第 j 个函数违反误差限。任意一次违反就是并集 $\cup_j E_j$ 。概率的并集上界不要求这些事件相互独立: $\Pr(\cup_j E_j) \leq \sum_j \Pr(E_j) \leq 2Me^{-2n\epsilon^2}$ 。希望此失败概率不超过 δ , 取对数并整理:

$$2Me^{-2n\epsilon^2} \leq \delta \implies \epsilon \geq \sqrt{\frac{\log(2M/\delta)}{2n}}.$$

于是概率至少 $1 - \delta$ 时, 每个候选都同时满足 $R(f) \leq \hat{R}_n(f) + \epsilon$ 。因为事件同时覆盖全部预先固定的候选, 之后用这些训练数据在该集合内选一个 f 仍可使用这个事件; 不能把训练后选出的模型伪装成事前固定一个候选, 从而擅自设 $M = 1$ 。




图11 候选数增大使这个特定上界变宽, 样本数增大使之变窄。超过1的风险差上界没有优于损失有界本身的信息。

这不是我们的Gaussian平方损失实验的可直接应用上界: 平方损失未限定在 $[0, 1]$, 连续参数函数类也不是这里的有限 M 。若要推广, 必须付出额外工作, 如尾部条件、覆盖数、VC维或数据相关复杂度, 不能简单把参数数目 p 填进 M 。神经网络VC维的原始研究本身区分权重数、层数和激活类型, 也不是“VC维恰等于参数数目”。

上界大并不证明模型差; 它可能只说明这个分析工具不够紧。上界是高概率最坏情形限制, 也不是某次实验应达到的分数。若用测试集选择候选、数据依赖增强或相关样本, 须重新检查前提。T2会继续讨论复杂度和数据依赖问题。

15 把理论边界写进研究报告

存在性	算法选择	概率界	比例渐近
紧集连续目标 连续sigmoid 可用任意足够宽度	线性平方损失 零初始化GD 稳定步长与收敛	固定有限函数类 独立同分布样本 损失有界	n和p一起趋于无穷 比例 $\gamma \neq 1$ 谱及噪声条件
不提供训练方法	不覆盖任意深网	不是现实分数预测	不是n=24精确等式

图12 四类理论回答不同问题。条件是结论的一部分，不应只摘取最吸引人的一句话。

一个合格的报告可写：在已知各向同性Gaussian总体、24个训练样本、前3维非零真实系数、固定SVD求解规则下，12组配对设计/噪声的容量扫描在带噪声时呈现插值附近尖峰和之后的下降；无噪声曲线不同，且更大p不保证一直改善。给出全部拟合、风险定义和谱记录，允许读者重跑。

不要写“实验证明深度学习大模型泛化更好”。这里甚至没有训练一个多层特征学习模型。也不要写“用理论解释了所有峰值”：我们给出了可精确核验的线性谱分解，但每次的峰高度还依赖具体噪声方向和设计。

接下来有三种有用扩展，必须先冻结计划再看结果：把信号从前3维移到稠密方向以检验特征顺序；令输入协方差非单位阵，并把风险从欧氏平方范数改为 $e^T \Sigma e$ ；用固定预算训练非线性网络，明确优化未收敛与表示学习造成的新差异。不要同时修改全部因素后仍把差异归因于参数量。

16 函数库到底替我们做了什么

- `numpy.random.default_rng`建立显式随机生成器。生成器只在原始fixture制作或额外诊断中使用；主1944拟合读取带哈希的固定数据。
- `numpy.linalg.svd`输出正交方向与奇异值，`full_matrices=False`只保留必要尺寸。它不决定我们的风险定义，也不会自动解释信号与噪声。
- `numpy.linalg.lstsq`在独立测试中使用不同求解入口；Ridge先拼接 $\sqrt{n\lambda}I$ 与零标签，再做增广最小二乘，以核对主SVD滤波实现。
- `torch.tensor`和`autograd.grad`在微型网络中核对每个样本的全部参数导数。ReLU本例远离零点，不借助不明确的边界导数蒙混过关。
- `csv`与`json`保存完整可检查记录；`hashlib`检查数据与图所读数值没有被悄悄修改。散列相等说明字节相同，不等于科学结论正确。
- `unittest`运行18组不同职责的测试；正常和-O模式均执行，关键输入守卫使用异常，不依赖会被-O去掉的`assert`。

实验文件只依赖本讲目录和声明的库，不导入前一讲隐藏状态。所有输出先算完并序列化，再逐文件原子替换；这避免普通计算失败留下新旧混合结果，但不等于整个输出目录具备断电事务能力。最终Notebook重新计算数值，展示的3张机制图来自自己核验的静态PNG；图脚本另行重建全部12张。

17 练习入口和来源

先完成独立实验指南中的手算、零空间、复制节点、容量/噪声与风险期望检查，再看answers.pdf的12题详解。至少写出两条本实验支持的结论和两条不能支持的结论。遇到不符合直觉的数据，先检查定义、数值秩和条件，再决定是否修改假说，不删除它。

本讲参考原始论文：Belkin等的双下降实验；Hastie等的最小范数插值分析；Cybenko的连续sigmoid逼近结果；Bartlett等关于分段线性网络VC维的结果。具体书目信息、实际阅读范围和NumPy/PyTorch官方接口见sources.md。推导、两样本例子、数据、全部图和实验叙事均为本讲独立制作，未复制论文图。