

039 练习与逐步详解

这些题检查你能否从分母、分布和条件出发解释结果，而不是记住“失衡就加权”或“概率不准就调温度”。所有数值沿用本讲约定；你可以先遮住解答，在纸上写出中间步骤。

题1 两个mean为何相差一倍

对 $s=(.42, -.3)$ 、 $y=(1, 0)$ 、 $a=(3, 1)$ ，分别用样本数和权重和归约。求两个损失及其梯度关系。如果增加同一个 $\lambda \|\theta\|^2/2$ 惩罚，还能说最优点相同吗？

解：稳定逐样本BCE为 $\ell_1=.5050369938177537$ 、 $\ell_2=.5543552444685271$ ，加权之和为 $3\ell_1+\ell_2=2.069466225921788$ 。除以2得到1.034733112960894；除以4得到.517366556480447。

在同一 θ 处，前者的数据梯度为后者2倍。没有其他目标项时，它们的最优点相同；固定学习率时轨迹不同。加上相同 λ 惩罚后，第一个目标是 $2J+\Omega$ ，第二个是 $J+\Omega$ ，不能整体倍乘互相得到，故最优点一般不同。若把第二个的全部目标一起乘2，包括惩罚项，则保留相同最优点。

PyTorch BCEWithLogitsLoss的pos_weight=3、mean对应第一种；二logit的CrossEntropyLoss按类别索引加class_weights=(1,3)、mean对应第二种。比较API时还须排除ignore_index、软标签和多标签轴等额外差异。

题2 推导加权最优概率 并反解

固定原始正例概率 $\eta=.2$ ， $a_0=1$ 、 $a_1=4$ 。写出条件风险，求最优 q ，并从 q 反解 η 。 $q=.5$ 是否意味着部署真实正例率为.5？

解：风险 $r(q)=-.8\ln q-.8\ln(1-q)$ 。导数为 $-.8/q+.8/(1-q)$ ，为0时 $q=1-q$ ，故 $q=.5$ 。二阶导数为 $.8/q^2+.8/(1-q)^2>0$ ，确认为唯一内点最小值。

一般情况 $a_0(1-\eta)q=a_1\eta(1-q)$ ，解出 $q=a_1\eta/[a_1\eta+a_0(1-\eta)]$ 。反解为 $\eta=a_0q/[a_1(1-q)+a_0q]$ 。代入 $q=.5$ 得到 $\eta=.5/(2+.5)=.2$ 。

所以 $q=.5$ 是加权风险下的最优概率形式，并非原始事件概率。理论成立还需要在该 x 可以自由选择 q 或模型正确表达、优化达到相应总体最优。有限模型上的解析修正仍须评价，不能自动视为真值。

题3 权重与代价能否重复使用

漏报代价4、误报代价1。比较三条规则：原始概率 η 用阈值.2；权重 $a_1/a_0=4$ 的理想 q 用阈值.5；同一个 q 用阈值.2。第三条对应原始概率多少阈值？

解：前两条等价，因为 $q^*\geq .5$ 当且仅当 $4\eta\geq 1-\eta$ ，即 $\eta\geq .2$ 。第三条要求 $4\eta/(1+3\eta)\geq .2$ ，乘正分母有 $4\eta\geq .2+.6\eta$ ，因此 $\eta\geq .2/3.4=1/17\approx .0588235294$ 。

第三条比原本代价目标更容易告警。它并非“更彻底地考虑代价”而自动正确；它改变了实际决策偏好。若 a 是频率平衡权重而非代价权重，则更要单独追踪两种理由。得到原分布概率后再依据任务代价决策，通常更便于解释与调整，但概率估计误差仍然存在。

题4 精确枚举 重采样并不创造新数据

损失为 $(.1, .6, 1.3)$ ，权重为 $(1, 2, 3)$ 。求归一化加权风险与 $q_i \propto a_i$ 下两次独立有放回抽样的批次平均期望。再解释抽到两条相同记录时应如何计数。

解：加权 $\sum = .1 + 1.2 + 3.9 = 5.2$ ，权重和6，风险为 $13/15 \approx .8666666667$ 。抽样概率 $(1/6, 1/3, 1/2)$ 。一次期望为 $.1/6 + .6/3 + 1.3/2 = .8666666667$ 。

两次索引 I, J 独立，批均值 $(\ell_I + \ell_J)/2$ 的期望由线性性得到同值。也可枚举九种有序对，每对概率 $q_i q_j$ ，求 $\sum_i \sum_j q_i q_j (\ell_i + \ell_j)/2$ 。由于 $\sum q = 1$ ，两项各给一半原期望。

若 $I=J=3$ ，则两次呈现都是第三条，批均值仍为1.3，样本呈现数是2，独特记录数是1。重复抽样可改变优化梯度的随机性，却不能增加独立观测的信息量。采样方差与新收集独立数据的方差不是同一个问题。

题5 批内权重和为什么可能有偏

继续题4，从原三条记录均匀有放回取 B 条。比较固定总体归一化与除以本批权重和。用 $B=1$ 给反例，再说明 B 很大能否证明有限 B 恰好无偏。

解：令总体平均权重 $\bar{a} = (1+2+3)/3 = 2$ 。固定归一化估计量为 $(1/B) \sum a_i \ell_i / \bar{a}$ ，期望等于 $(\sum a_i \ell_i / 3) / 2 = .8666666667$ 。

$B=1$ 时，自归一化 $a_I \ell_I / a_I = \ell_I$ ，期望为 $(.1 + .6 + 1.3)/3 = 2/3$ ，与目标 $13/15$ 不同。这已经否定“每批除权重和必然无偏”。 B 增大时，在适当大数条件下该比值可趋近目标，但一致性不等于每个有限 B 无偏。

如果先按 $q \propto a$ 抽样又乘 a ，期望与 $\sum a^2 \ell$ 成比例。若希望恢复普通经验风险，使用 $1/(n q_i)$ 的重要性权重，并要求目标有质量处 $q_i > 0$ 。支持集缺失不是调一个有限权重就能恢复的。

题6 不跳步算 W_{12} 和 u_2 的梯度

给定正文小网络，独立计算 W_{12} 、 u_2 、 c 的总梯度和新值。解释为何样本2通过 W_{12} 的路径是正数。再验证样本2损失为何变大。

解：前向 $s = (.42, -.3)$ ，概率 $p = (.6034832498647262, .4255574831883410)$ 。乘权重与归约后， $r = \partial J / \partial s = (-.2973875626014553, .1063893707970852)$ 。

隐藏单元2的输出权重是 $u_2 = -.5$ ，两个 Z_{i2} 都为 $.8 > 0$ ，因此 Z_{i2} 梯度为 $(-.5)r_i$ ，即 $(.1486937813007277, -.0531946853985426)$ 。 W_{12} 连接输入第一维到隐藏单元2，两个输入值为1、-1，贡献为 $.1486937813007277$ 与 $-.0531946853985426$ ，相加得 $.2018884666992703$ 。第二条路径的两个负数相乘成正数。

u_2 的局部导数为 $H_{i2} = .8$ ，总梯度 $= .8(r_1 + r_2) = -.1527985534434961$ 。 c 的局部导数均为1，总梯度 $r_1 + r_2 = -.1909981918043701$ 。学习率.1后， $W_{12}^+ = -.2201888466699271$ ， $u_2^+ = -.4847201446556504$ ， $c^+ = .1190998191804370$ 。

但重算样本2不能只使用这三个新参数，还需使用全部同步新值。其新 $H_{22} = .7862196493594173$ ，新 $s_2 = H_{22}u_2^+ + c^+ = -.2619966829881745$ 。 $y_2 = 0$ ，所以新损失 $\text{softplus}(s_2) = .5707046931045364$ ，大于原 $.5543552444685271$ 。总加权风险仍从 $.5173665564804470$ 降为 $.4707145894728684$ ，原因是权重3的样本1改善更多。

题7 为什么不能原地边更新边反传

假设先更新 u ，再计算隐藏层梯度，随后更新 W 和 b 。此时结果是否仍对应 $\theta^+ = \theta - .1 \nabla J(\theta)$ ？给出一个本例的具体变化。

解：不是。旧图的隐藏梯度必须用旧 $u = (.6, -.5)$ 。若先把 u 改成 $(.6356865075, -.4847201447)$ ，却保留旧 $r_1 = -.2973875626$ ，那么隐藏单元1梯度会变为 $r_1 \times .6356865075$ ，而正确旧梯度是 $r_1 \times .6 = -.1784325376$ ，两者不相等。

这种混合没有使用一个统一参数快照。它既不是正文的SGD，也不是完整地在新参数处重新前向再求梯度。可以设计坐标更新算法，但必须重新定义算法和相应计算，不应在SGD代码中无意混入它。

正确做法是先保存所有参数的旧梯度，再在不构图的更新段统一减去学习率乘梯度。主实验代码对所有参数先backward，之后进入no_grad循环同步使用已经完成的梯度，循环顺序不再影响旧梯度值。

题8 从完整代价矩阵重新推导阈值

设行动 a 、真实标签 y 的代价为 $C(a, y)$ ，不预设正确预测代价为0。推导行动1的条件，并指出何时可以写成一个常见方向的概率阈值。

解：两个行动的条件风险分别为 $R_1 = C(1, 0)(1-p) + C(1, 1)p$ ， $R_0 = C(0, 0)(1-p) + C(0, 1)p$ 。定义 $A = C(1, 0) - C(0, 0)$ ， $B = C(0, 1) - C(1, 1)$ 。选择行动1需要 $A(1-p) \leq Bp$ ，即 $A \leq (A+B)p$ 。

若 $A > 0$ 、 $B > 0$ ，表示在每种真实标签下做正确行动都优于做错误行动，则 $A+B > 0$ ，得到 $p \geq A/(A+B)$ ，阈值在 $(0, 1)$ 。取正确行动代价0就回到 $C_{FP}/(C_{FP} + C_{FN})$ 。

若 $A+B < 0$ ，除法不等号方向反转；若为0则不能除，需直接比较 A 与0。某行动可能处处占优。因此必须检查代价结构，不能在任意矩阵上无条件套入一个 $[0, 1]$ 阈值。

题9 温度的凸性与边界

固定验证logits s_i 和标签 y_i ，推导 $\beta=1/T$ 上的一阶、二阶导数。所有logits为0时怎样处理？如果每条记录都被正确方向分类且无错误，最优温度是否一定有限？

解：一条损失为 $\text{softplus}(\beta s) - y\beta s$ 。链式法则给导数 $[\sigma(\beta s) - y]s$ ；再求导得 $\sigma(\beta s)[1 - \sigma(\beta s)]s^2$ 。对样本平均得到正文公式，二阶非负。只要有非零 s ，有限 β 下严格凸；所有 $s=0$ 时预测恒.5，损失恒 $\ln 2$ ，没有唯一温度，返回 $\beta=1$ 并标记flat是明确约定。

若所有样本的方向都严格正确，即 $y=1$ 时 $s>0$ 、 $y=0$ 时 $s<0$ ，每条损失随 β 增大下降， $\beta \rightarrow \infty$ 时趋于0。这时无约束最优可能只存在于极限 $T \rightarrow 0$ ，而没有有限最小点。本实验限定 $\beta \in [.05, 20]$ ，该例返回 `upper_bound`。错误方向例子可能偏好 β 趋近0，受限实现返回 `lower_bound`。

对 T 或 $\log T$ 重新求导会引入变量变换因子，不能只因 β 凸就说任意参数化凸。测试使用独立黄金分割最小化校验最终NLL，与生产实现的导数二分形成不同数值路线。

题10 校准不改变哪些排名

对二分类或多分类，温度缩放保持哪些预测与排序？固定概率阈值.2是否也不受影响？温度能否把 $\text{logit}=0$ 对应的真实概率.2变成正确输出？

解：正温度保持每条样本logit的符号，二分类.5阈值预测保持；多分类共享正温度保持同一样本内类别logit顺序、并列关系和argmax。二分类跨样本logit大小关系也保持，sigmoid单调，因此精确算术下概率排序和ROC-AUC保持。

但多分类最大softmax概率涉及一整组logits，不能据此保证不同样本的最大置信度排名。固定.2阈值的规则等价于 $s \geq T \cdot \text{logit}(.2)$ ，阈值对应的logit位置依赖 T ，所以决策可能改变。温度缩放的“准确率不变”必须连同默认argmax或.5规则一起说。

任意 $T>0$ 都有 $\sigma(0/T)=.5$ ，无法得到.2。类先验导致的加性偏移需要不同处理，或更灵活且独立验证的校准模型。先验修正公式也有类别条件不变等前提，不是用它替换温度便保证所有任务成功。

题11 ECE为0的四条记录是否证明校准

对 $p=(.1,.1,.9,.9)$ 、 $y=(0,1,0,1)$ ，求一个箱和两个等宽箱的ECE，再求Brier和NLL。解释为什么阈值变化不会改变这些概率指标。

解：一个箱中 $\bar{p}=.5$ 、 $\bar{y}=.5$ ，ECE=0。两个箱各有2条，平均概率分别.1和.9，实际正例率都是.5，所以 $\text{ECE}=.5|-.5|+.5|.9-.5|=.4$ 。

$\text{Brier}=(.01+.81+.81+.01)/4=.41$ 。NLL= $[-\ln(.9)-\ln(.1)-\ln(.1)-\ln(.9)]/4 \approx 1.2039728043$ 。ECE的一个粗箱隐藏了两端相反误差；NLL/Brier仍给出不好的概率评分，但它们不是只测校准的纯统计量。

三者都由 (p,y) 确定，不使用阈值。只改变阈值、保持概率和标签，结果严格不变。可靠性图的箱是否空、每箱多少条、箱边界如何定义，都需要一并报告；多报几种分箱敏感性优于挑一个最小值。

题12 把当前结果写成可以反驳的研究结论

本实验中，加权原始输出比等权有更低代价，却有更差NLL；修正后相近；验证所选阈值都等于.2。请写一个恰当结论，并设计一个下一步实验，避免把三个种子当三份独立数据。

解：合适表述是：“在固定240/400/1000合成拆分、25参数tanh网络、三组配对初始化和相同呈现预算下，类别加权与平衡重采样的原始.5决策降低了给定1：4误报/漏报代价，同时原分布测试NLL更高。已知训练权重的logit修正及独立验证温度使其概率指标接近等权；本次经验阈值恰为理论候选.2。结果不证明任何方法在真实任务或其他数据集上普遍优越。”

下一步可固定全部协议，生成多份独立训练、验证、测试数据，在每份数据内继续配对三个算法种子，先在每个数据重复内计算方法差，再以数据重复为统计单位评价差异和不确定性。选择多少重复应依据计算预算、所需精度和方差预估，不靠看到结果后随意停止。

另一条明确问题是检验先验修正的边界：一组实验只改变 $P(Y)$ ，保留 $P(X|Y)$ ；另一组同时改变类别条件分布。两组都要有新的验证与测试，预先固定修正公式与先验信息来源。若第二组失败，不能把它隐藏后只报告符合假设的一组。

完整提交应附协议、真实更新预算、代码版本、逐样本输出、分组支持数、失败条件以及哪些验证未做。一次脚本成功只证明在那个环境中执行完成，既不是独立科学验收，也不是现实部署许可。