

039 独立实验指南

1 你将验证什么

这个实验包可独立运行，无需导入其他讲的代码。它比较原分布等权、类别加权、平衡有放回重采样三种训练方式，同时将“输出概率怎样解释”和“何时采取行动”分开。先用九参数小网络核对一次完整反向传播，再训练九个25参数网络，最后验证温度、阈值和分组指标。

需要理解Python函数、数组形状、sigmoid与BCE、SGD、训练验证测试分工。尚未掌握时可读019、021、037；本包仍完整给出数据、参数和公式。所有输入为原创公开合成CSV，不下载数据集、模型权重或第三方样本，不涉及真实设备或个人信息。

2 文件和第一次运行

- lecture.pdf: 完整理论、手算、机制图与有限实验解读。
- lab.pdf: 本指南；answers.pdf: 12道练习及逐步解释。
- experiment.py: 稳定数值函数、完整训练、验证拟合和测试评价。
- test_experiment.py: 独立Decimal与NumPy参考、全部预测指标重算、边界输入保护。
- experiment.ipynb: 已经真实顺序执行的Notebook，首格在导入前核验摘要。
- data/train.csv、validation.csv、test.csv: 权威冻结输入，必要的生成机制见data/README.md。
- outputs: 七份默认协议结果；figures: 14张原创教学图；make_figures.py用于重建。
- environment.yml、README.md、sources.md、source-checks.json、verification.json: 环境、入口、来源与作者核验记录。

本次实际CPU运行环境是Python3.12.14、NumPy2.3.5、torch2.7.1+cpu、Matplotlib3.10.8。训练单线程、float64，未执行GPU实验。environment.yml是可安装配置，未声称本次重新完成一个全新Anaconda求解。依赖渠道与操作系统不同可能影响精确版本和浮点字节；先查看自己的python与包版本。

在本单元目录运行：

```
python test_experiment.py
python experiment.py
python make_figures.py
```

脚本按自身位置找默认data与outputs，因此也可从其他工作目录使用绝对路径调用。为了保留原始参考结果，学习时建议改写新输出目录：

```
python experiment.py --output my_run
python experiment.py --epochs 20 --output quick_smoke
```

20轮只用于冒烟检查，不是正文中的240轮证据。make_figures.py默认只接受七份参考结果的确切摘要，会拒绝短协议结果，避免它们悄悄覆盖正文图。如果你改变协议，应另外编写探索图、保留新目录和版本说明，而不是删除摘要检查后继续称为同一结果。

3 实验A：用纸笔复现完整梯度

打开outputs/calculations.json。first包含第一次前向、全部中间导数、两条样本对九个参数的贡献及同步更新；next把更新后的参数作为新起点，保存下一次前向和反向。记录中所有数值保留双精度，正文只在展示时四舍五入。

小网络为 $Z=XW+b$ 、 $H=\text{ReLU}(Z)$ 、 $s=Hu+c$ ， X 两行为(1,2)、(-1,1)，标签为(1,0)，权重为(3,1)，分母 $D=4$ 。 W 两行为(.5,-.2)、(.3,.4)， $b=(.1,.2)$ ， $u=(.6,-.5)$ ， $c=.1$ 。

按以下顺序，不要先看总梯度再倒推中间数：

1. 算四个 Z 和四个 H ，得到 $s=(.42,-.3)$ 。
2. 用稳定BCE得(.5050369938,.5543552445)，加权风险.5173665565。
3. 算 $a_i(p_i-y_i)/4$ ，得到(-.2973875626,.1063893708)。
4. 乘 u 得到隐藏梯度，乘ReLU门控得到 Z 梯度。
5. 每条样本分别贡献给 W 、 b 、 u 、 c ，按参数累加。
6. 一次性执行 $\theta^+=\theta-.1g$ ，重新前向得(.6002918220,-.2619966830)。
7. 新加权风险.4707145895，但样本2损失增加。解释为何这并不矛盾。

独立测试使用55位Decimal的逐标量循环，不调用生产前向；另用PyTorch autograd以及两个参数点的18个中心差分坐标核验。float64与Decimal最后几位不同是正常舍入误差，测试采用明确容差，不靠字符串完全一致判定数学正确。

4 实验B：先核对归约与抽样

对logits(.42,-.3)、标签(1,0)、权重(3,1)，分别调用weighted_risk的count和weights模式。预期前者为后者2倍。再对照PyTorch的BCE正类权重与两logit交叉熵class_weight的mean，理解其分母为什么不同。

接着用三条固定损失(.1,.6,1.3)和权重(1,2,3)。按 $q=(1/6,2/6,3/6)$ 抽取一条记录的期望损失为.8666666667。将两次独立抽样的九种有序结果全部枚举，可以精确计算期望，不需要靠大量随机抽样近似证明。

测试还枚举从原分布均匀取两条的情况，比较固定总体分母与批内随机分母。后者结果一般不同。请再改成批大小1观察： $\Sigma a\ell/\Sigma a$ 变回 ℓ ，权重作用消失。这是“每批除权重和”与目标无偏性不能混用的最短反例。

注意期望相同不意味着每次抽到的批次相同，更不意味着整个训练轨迹相同。绘图03_denominators_sampling.png展示的是固定损失的代数例子，不是训练结果。

5 实验C：训练协议与数据隔离

训练集240条，其中74条正例。 $\pi=74/240$ ，正类权重 $a_1=.5/\pi\approx 1.621621622$ ，负类权重 $a_0=.5/(1-\pi)\approx .7228915663$ 。总体训练权重和在精确算术下等于240，因此weighted用除以240的mean与归一化加权目标一致。

模型 $2\rightarrow 6\rightarrow 1$ 有25参数，隐藏用tanh。初始化种子11、23、37在三方法间配对；重采样随机流由seed+39000独立建立。每次240轮，每轮一次SGD更新，学习率.08。无动量、权重衰减、dropout、增强或早停；不引入额外处理干扰归因。

uniform和weighted每轮读全部240条；resampled每轮有放回抽240条，概率与 a_i 成比例，不再乘类别权重。检查training-history.csv中的sampled_positive列：前两方法每轮都是74；重采样正例数围绕120变化，但不被强制等于120。

验证文件的前200条role=calibration用于拟合温度，后200条role=decision用于选择阈值。这是生成时固定的角色，不根据结果更换。测试标签只在全部九次训练、所有温度与阈值完成后解析；代码在此之前已构造frozen-plan对象。frozen-plan最终与其他结果一起落盘，并非写入不可修改的安全封存服务。

总预算2160更新、518400样本呈现。重复呈现不等于新样本；三个算法种子也不是三个独立数据集重复。不要把同一1000条测试记录重复三次当作 $n=3000$ 估计人群不确定性。

6 实验D：先验修正与验证温度

对uniform不修正；对weighted/resampled减去 $d=\ln[(1-\pi)/\pi]$ ， π 只来自训练标签。之后将修正logits与calibration角色的200条标签交给fit_temperature。另保存一组不做先验修正的温度，作为专门的失败对照。

函数在 $\beta=1/T\in[.05,20]$ 上求解验证平均BCE。检查返回的beta、temperature、status、gradient、nll_before、nll_after和n。内点通常gradient接近0；若status为边界，不能要求梯度等于0；全零logits为flat， β 固定1。

正文默认九个先验修正后温度约为1.0512至1.1689；全都为内点。数值来自当前固定数据，不能抄成别的任务默认温度。必须冻结网络后再拟合，不能让这个函数同时更新网络参数，也不能用测试数据替换验证对。

验证NLL改善不保证测试NLL改善；Brier/ECE不是拟合目标。具体观察加权raw_temperature：测试NLL均值略降，ECE均值反而上升。解释单参数乘法为何无法消除加性logit先验偏移。

7 实验E：阈值只改变行动

在decision角色的200条验证记录上，使用已经确定的校准概率，比较21个候选阈值0,.05,⋯,1。对每个阈值计算 $(FP+4FN)/n$ ，并列选较大阈值； p =阈值时告警。当前默认九次选择都为.2。

理论代价阈值也为 $1/(1+4)=.2$ ，所以两个视图在本次数据上相同。这是一次观察，不能证明经验选择必然等于理论值。阈值1在极端浮点饱和到 $p=1$ 时仍可能告警，不能把它普遍理解为“全部不告警”；本实验预测没有这个饱和问题。

比较prior_temperature与cost_validation：每条probability/logit完全相同，只有threshold和predicted可能不同。NLL、Brier、ECE应逐位相同；准确率、precision、recall和代价可改变。程序仍把两个视图都保存，便于明确检验这条不变量。

8 输出字段与自己的复算

文件	记录粒度	本次行数或内容	关键含义
calculations.json	两个参数点	first与next	所有前向、中间导数、路径、总梯度和更新
frozen-plan.json	训练/后处理规则	9个run	参数、先验位移、两个温度、阈值、预算
training-history.csv	每次更新	2160行	更新前实际训练目标、抽到的正例次数
metrics.csv	方法×种子×视图×组	162行	n、正例、混淆计数、代价、NLL/Brier/ECE
predictions.csv	方法×种子×视图×记录	54000行	id、group、y、logit、probability、threshold、predicted
reliability.csv	每个指标组合×箱	1620行	边界、n、平均p、正例率，空箱留空
validation-cost-curves.csv	方法×种子×阈值	189行	决策验证集的阈值和平均代价

ECE默认10等宽箱，并附ece5和ece20。这里分箱的是正类概率，不是预测类别的置信度。Brier只对正类概率求平方，未对两类向量求和。precision没有正预测时留空；recall没有真实正例时留空，不把未定义伪装成0。

至少手动复算一行：选uniform、seed=11、view=raw、group=all，筛出1000条预测，按predicted和y累计四格。再计算平均稳定BCE、 $(p-y)^2$ 、按概率分箱的加权绝对差。test_experiment.py已对全部162行做独立标量重算；你应能解释其每个分母。

9 Notebook与图的运行边界

Notebook首个代码格在导入experiment之前核对三个代码文件、三份数据、七份参考输出和14张图的SHA-256。可从039单元目录或含units/039的仓库根运行；其他位置可先设置UNIT039_DIR为下载后单元的绝对路径。目录定位失败时明确报错，不猜一个远端文件。

后续单元格包含手算输出、归约、测试组、全部九次训练的临时目录重跑、七份结果摘要对齐、验证参数和分组指标、内嵌原始图。重跑输出写临时目录，保留交付的参考文件。改变实现、输入或参考结果后首格应拒绝执行；正确做法是记录自己的修改版本，再按新协议验证。

本次Notebook使用新Python进程内的新InProcessKernel，清空旧输出后按顺序执行，保存真实输出。未测试Jupyter浏览器界面或外进程socket传输，也未声称在用户本机执行过。图重建需要中文字体；缺少CJK字体时先安装合适字体，现成PDF已包含可阅读字体。

10 失败检查与安全复现

1. 运行python -O test_experiment.py。优化模式不应移除输入保护，因为保护使用显式异常。
2. 从无关工作目录运行绝对路径脚本。默认数据定位应仍正确，显式相对--output按启动目录解释。
3. 把CSV复制到新目录后改动一个字节，用--data-dir指向它。应该在写输出前报告完整性不匹配。
4. 把results复制到新目录后损坏一个输出，用make_figures.py --results指向它。现有图或哨兵文件应保持原样。
5. 给epochs=0、错位标签、空数组、NaN、错误分母模式。应看到ValueError，不产生貌似成功的结果。
6. 对照README记录版本；执行完成只是第一步，还需检查数值、协议和图的含义。

输出单文件先写临时文件再原子替换；多个文件不是一个断电事务。异常中止可能留下混合版本，因此重新验证七份摘要，不要把“原子写单文件”描述为完整事务保障。所有临时数据仅属于本次教学 workflow，不放进发布清单。

11 需要提交的研究记录

写一页自己的实验记录，包括问题、P/Q/R分别是什么、三种方法实际分母、数据角色、配对预算、哪些指标改变及为什么。附上对一个分组和一个稀疏箱的支持数解释，再指出至少两个不能由当前结果推出的结论。

有余力时，使用新数据生成种子研究数据变化，或只改变已知真实先验并检验修正。每次只改一个关键机制，保留原始结果作对照。引入真实数据前必须重新定义任务代价与数据来源，不能把本讲合成标签和任意成本比移植成领域结论。

数值接口的明确边界

输入先检查类型与有限性，转换为float64后再检查一次。weighted_risk按权重和归约时先共同缩放权重，两个 $1e308$ 权重的零logit风险仍应为 $\ln 2$ ；按样本数归约若结果超出float64有限范围则拒绝。完整局部概率导数账本hand_trace要求参数绝对值不超过 $1e6$ 、logit绝对值不超过30，超出明确报错；这不缩小稳定BCE已测试的正负1000范围。测试新增极端权重、扩展精度转换溢出和局部导数饱和回归，普通和-O模式均需通过。

温度梯度的正类项用 $-\text{sigmoid}(-\beta s)$ ，不先把 $\text{sigmoid}(\beta s)$ 舍入成1再减1。单一正确极端logit正1000/标签1和负1000/标签0都应取 β 上界20；反向错误标签取下界0.05。全正确/全错误方向按单调性处理；混合方向梯度数值全零时标numerically_flat并保留 $\beta=1$ ，不声称已经识别精确最优边界。