

039 损失设计失衡与校准

实际任务的代价与模型训练目标不一致时怎样处理？一个告警系统可能有很高的准确率，却漏掉大部分真正需要处理的情况；另一系统能找出更多正例，却把“告警倾向”误当成事件发生概率。训练损失、概率陈述与行动规则各自有意义，前提是没有把它们说成同一个对象。

本讲先修019的交叉熵、021的混淆矩阵与验证边界、037的训练目标和正则化。我们将自己推导加权风险的最优输出、采样等价关系、代价阈值与温度缩放；再逐条核对一个九参数网络的完整更新，最后运行一个25参数网络的九次配对实验。所有数据和机制图为原创合成教学材料，不代表任何真实行业的效果。

1 三个对象必须分开命名

P表示希望解释的原始总体分布，本实验也是部署分布。训练集只是从P得到的有限样本，不等于P本身。Q表示训练时实际抽取记录的分布；平衡抽样可能使Q与P不同。R表示我们用来优化的风险，即在哪个分布下、对哪种损失取期望。另用 δ 表示把模型输出变成行动的决策规则。

例如原始数据正例率为10%，我们将每次训练批次的正例比例提高到约50%。模型现在经常遇到正例，但这个操作没有改变部署环境中事件真正发生的频率。若又对正例损失乘9，便在采样改变之外再次改变目标，并非只做了一次“平衡”。




图1 三个对象与部署链。采样控制谁被呈现；权重和分母控制呈现后的评分；部署需要解释输出对应的分布，再用验证数据和真实代价确定使用方式。本讲默认P在训练、验证与测试之间不发生真实漂移，只有训练抽样被人为改变。

失衡本身不是必须消除的错误。罕见事件真实地罕见时，原分布的交叉熵正是按真实频率评价概率。需要额外处理的原因可能是少数类信息不足、有限预算下难以学习、误判代价不对称，或数据收集造成了选择偏差。不同原因对应不同干预，不能由“正例少”直接推得“权重一定取倒数频率”。

2 二分类交叉熵怎样稳定地计算

令一个样本输入为 x ，真实标签 $y \in \{0, 1\}$ 。网络输出实数 $\text{logit } s$ ，概率形式为 $p = \sigma(s) = 1/(1 + \exp(-s))$ 。 s 不是概率；它可以为负，也不必小于1。与 s 对应的odds为 $p/(1-p) = \exp(s)$ ，因此 $s = \ln[p/(1-p)]$ ，称为对数优势。

二分类交叉熵为：

$$\ell(s, y) = -y \ln p - (1 - y) \ln(1 - p) = \log(1 + e^s) - ys.$$

直接先算 p 、再取 $\log$ ，在 s 很大时可能得到 p 舍入为1，随后 $\log(1-p)$ 变成负无穷。稳定形式为：

$$\ell(s, y) = \max(s, 0) - ys + \log(1 + e^{-|s|}).$$

对本讲的硬标签，还可以分支写成 $y=1$ 时 $\text{softplus}(-s)$ 、 $y=0$ 时 $\text{softplus}(s)$ 。代码用 $\text{logaddexp}(0, \pm s)$ ，主训练用PyTorch的`binary_cross_entropy_with_logits`。二者都接收logits，不应先做sigmoid再传入。PyTorch 2.7 BCEWithLogitsLoss

局部求导可以从概率形式出发： $\partial \ell / \partial p = -y/p + (1-y)/(1-p)$ ， $\partial p / \partial s = p(1-p)$ 。相乘并约去分母得到 $\partial \ell / \partial s = p - y$ 。这是数学等式；实现时使用稳定组合，避免先构造可能极大的 $\partial \ell / \partial p$ 。手算账本为了展示这两项局部导数，额外要求所有logit绝对值不超过30、参数绝对值不超过 10^6 ；超出时明确拒绝，不把无穷局部导数写成有效JSON。稳定BCE本身仍可处理下文的 ± 1000 。

稳定不等于任意非法输入都能接受。本课程拒绝NaN、无穷、空批次、非0/1标签、错位形状，并对接收标签的公开logit接口要求 $|s| \leq 10^6$ 以限制教学范围。 ± 1000 的正确和错误预测分别得到约0和1000的有限损失。边界拒绝是显式异常，不依赖可被Python优化模式移除的assert。输入转换为float64之后还要重新检查有限性；较宽浮点类型中有限的值，也可能在转换时溢出。

3 加权损失改变的究竟是什么

3.1 先写分母 再谈权重大小

给样本 i 正权重 $a_i > 0$ 。两种常见归约分别为：

$$J_{\text{count}} = \frac{1}{n} \sum_i a_i \ell_i, \quad J_{\text{weight}} = \frac{\sum_i a_i \ell_i}{\sum_i a_i}.$$

对于一个固定数据集和固定权重，它们相差正常数 $(\sum a_i)/n$ ，因而无正则化时具有相同最优点，但梯度尺度和给定学习率下的更新不同。如果还有固定强度的正则项，单独缩放数据项会改变正则的相对作用，最优点也可能改变。037的目标组成在这里仍要逐项解释。

一条样本对 s_i 的总梯度是 $a_i(p_i - y_i)/D$ ，其中 D 是已声明的分母。 D 若只由标签和固定权重组成，不是待学习变量。把这个梯度先算好后，再在别处额外除一次批大小，会悄悄改变目标。

权重归一化的代码先将全部正权重除以其最大值，再计算分子和分母，避免有限权重相加溢出；例如两个 10^{308} 权重不能直接先求和。按样本数归约若真实结果超出float64有限范围，则显式拒绝。

框架API的mean不必表示同一个分母。在PyTorch2.7中，BCEWithLogitsLoss的mean按元素数归约；pos_weight只乘正标签项。单标签CrossEntropyLoss在类别索引目标和class_weight设置下，其mean通常按有效目标权重和归约；概率目标另有规则。不能仅凭两个函数都写mean便声称等价。

CrossEntropyLoss官方定义

本讲手算使用 $D=3+1=4$ ；主实验使用除以训练样本数240，但把类别权重归一化到训练集平均恰为1。两个章节均明确约定，不把手算中的3:1与主实验的倒数频率权重混用。

3.2 从条件风险推出最优输出

固定 x ，记真实正例概率 $\eta=P(Y=1|X=x)$ 。假设 $0<\eta<1$ ，负类权重 $a_0>0$ 、正类权重 $a_1>0$ ，候选概率 $q\in(0,1)$ 。条件加权风险为：

$$r(q|x) = -a_1\eta\ln q - a_0(1-\eta)\ln(1-q).$$

对 q 求导，设为零： $-a_1\eta/q + a_0(1-\eta)/(1-q)=0$ 。两边乘正数 $q(1-q)$ 并移项，有 $a_0(1-\eta)q=a_1\eta(1-q)$ 。所以：

$$q^*(x) = \frac{a_1\eta(x)}{a_1\eta(x) + a_0[1-\eta(x)]}.$$

二阶导数为 $a_1\eta/q^2 + a_0(1-\eta)/(1-q)^2 > 0$ ，因此这是唯一最小点。 $\eta=0$ 或 1 时，最小值在对应概率端点取得，有限logit只能逐渐接近。除以一个与模型无关的正归一化常数不会改变这一结论。




图2 左图是理论最优输出映射， $a_1/a_0=4$ 时 $\eta=.2$ 变成 $q^*=.5$ 。右图固定 $\eta=.2$ ，画出不同权重的条件风险曲线。它们来自明确公式，说明加权输出的概率含义已经改变，不能当作训练网络一定达到的结果。

把上式改写为odds关系更清楚： $q/(1-q)=(a_1/a_0)\eta/(1-\eta)$ 。因此 $\text{logit } q^* = \text{logit } \eta + \ln(a_1/a_0)$ 。当正例受到更大权重时，最优加权输出向正类偏移；这可能有利于某些决策，也意味着原始分布的概率解释不再直接成立。

这里要求可以在每个 x 独立选择 q ，或者模型正确表达最优条件概率，并达到相应总体风险最优。在有限网络、有限数据、有限优化和正则化下，不能保证实际输出恰好等于 q^* 。解析关系是解释目标的基准，不是无条件修复模型的定理。

4 重采样与加权何时等价

在固定训练集上，普通经验分布给每条记录概率 $1/n$ 。令 $A=\sum a_i$ ，改成以 $q_i=a_i/A$ 有放回独立抽样，再对抽到的损失取普通平均。一次抽样 I 的期望为：

$$E_I[\ell_I] = \sum_i q_i \ell_i = \frac{\sum_i a_i \ell_i}{A}.$$

同理，对固定参数 θ ，如果抽样概率不依赖 θ ，则 $E[\nabla \ell_i] = \sum q_i \nabla \ell_i$ 。在有限训练集上只是交换有限和与导数。因此重采样的批次平均梯度，是归一化加权经验风险梯度的无偏估计。它不是普通原分布经验风险的无偏估计。




图3 三条记录的损失为(1,6,1.3)，权重为(1,2,3)。除以样本数得到1.7333，除以权重和及重采样期望均为.8667。右边两项等价依赖明确的抽样概率和普通批次平均；不能把左项同样的数值尺度默认为成立。

“期望梯度相同”不等于“训练轨迹相同”。重复抽到某些记录、暂时没抽到另一些记录会产生随机性；非线性参数更新之后的未来梯度不同。自适应优化器还会积累不同的状态。本实验用简单SGD，消除动量状态这一额外因素，仍能看到重采样与精确全批加权的有限差异。

4.1 批内自归一化是另一个随机估计量

若从原训练集均匀抽 B 条记录，使用 $(1/B)\sum a_i \ell_i$ ，期望是 J_{count} 。若再除以预先算好的平均权重 A/n ，则期望为 J_{weight} 。但每次都除以当前批的随机权重和，得到 $\sum_{\text{batch}} a_i \ell_i / \sum_{\text{batch}} a_i$ ，通常不能把期望写成两个期望的比值。批大小为1时，这个比值直接退化为该条未加权损失，尤其直观地暴露问题。

4.2 不要重复平衡

若已经按 $q_i \propto a_i$ 重采样，又对抽到的损失乘 a_i ，则期望与 $\sum a_i^2 \ell_i$ 成比例。想回到普通经验风险，可以在 $q_i > 0$ 的条件下使用重要性权重 $1/(nq_i)$ ，但权重过大可能造成高方差。若某些记录 $q_i = 0$ ，而它们在目标风险中有正质量，单靠采到的数据无法恢复被删掉的贡献。

实际工程还会用无放回抽样、每批严格指定类别数量或先重采样实体再取记录。它们的依赖结构与这里不同，不能照搬“独立有放回”的方差和预算。报告中需写抽样单位、是否放回、每轮抽多少条，而不只写“balanced sampler”。

5 九参数小网络的一次完整加权更新

5.1 固定所有输入与形状

采用两条二分类样本，样本放在矩阵行。 X 是 2×2 ， W 是 2×2 ， b 和 u 各长2， c 是标量：

$$X = \begin{bmatrix} 1 & 2 \\ -1 & 1 \end{bmatrix}, \quad y = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad W = \begin{bmatrix} .5 & -.2 \\ .3 & .4 \end{bmatrix}.$$

$$b = (.1, .2), \quad u = (.6, -.5)^\top, \quad c = .1, \quad a = (3, 1)^\top.$$

定义 $Z = XW + b$ ， $H = \text{ReLU}(Z)$ ， $s = Hu + c$ ， $p = \sigma(s)$ 。目标 $J = (3\ell_1 + \ell_2)/4$ ，不加正则、不用dropout。参数顺序固定为 $(W_{11}, W_{12}, W_{21}, W_{22}, b_1, b_2, u_1, u_2, c)$ 。学习率 $\eta_{\text{step}} = .1$ ，与条件正例概率 $\eta(x)$ 不是同一个量；下文更新直接写.1以免混淆。

5.2 每条样本的前向与标量目标

$Z_{11} = 1(.5) + 2(.3) + .1 = 1.2$ ， $Z_{12} = 1(-.2) + 2(.4) + .2 = .8$ ； $Z_{21} = (-1)(.5) + .3 + .1 = -.1$ ， $Z_{22} = (-1)(-.2) + .4 + .2 = .8$ 。ReLU仅把 Z_{21} 变成0，所以 H 两行为 $(1.2, .8)$ 和 $(0, .8)$ 。

$s_1 = 1.2(.6) + .8(-.5) + .1 = .42$ ； $s_2 = 0(.6) + .8(-.5) + .1 = -.3$ 。接着按稳定公式求损失：

样本	y	logit s	概率p	稳定BCE ℓ	加权后对J的贡献
1	1	.42	.6034832499	.5050369938	.3787777454
2	0	-.3	.4255574832	.5543552445	.1385888111

$J = .5173665565$ 。若错误地把同一加权和除以2，会得到1.0347331130，梯度也整体大2倍。这不是另一次实验“学得更差”，而是损失定义被改变。

5.3 每个局部导数及路径乘积

$\partial J / \partial \ell$ 分别为.75和.25。 $\partial \ell / \partial p$ 分别为-1.6570468198与1.7408182207； $\partial p / \partial s$ 分别为.2392912170与.2444583117。三项相乘，或直接计算 $a_i(p_i - y_i)/4$ ，都得到：

$$\bar{s} = (-.2973875626, .1063893708)^\top.$$

这里上横线表示J对该量的导数。输出仿射层的局部导数为 $\partial s_i / \partial H_{ij} = u_j$, $\partial s_i / \partial u_j = H_{ij}$, $\partial s_i / \partial c = 1$ 。因此：

$$\bar{H} = \bar{s}u^\top = \begin{bmatrix} -.1784325376 & .1486937813 \\ .0638336225 & -.0531946854 \end{bmatrix}.$$

ReLU在 $Z \neq 0$ 时的局部导数是 $1[Z > 0]$ ，本例门控为两行(1,1)、(0,1)。因此第二条样本第一条隐藏路径被截断：

$$\bar{Z} = \begin{bmatrix} -.1784325376 & .1486937813 \\ 0 & -.0531946854 \end{bmatrix}.$$

输入仿射层有 $\partial Z_{ij} / \partial W_{kj} = X_{ik}$ 、 $\partial Z_{ij} / \partial b_j = 1$ ，其他不连接的坐标局部导数为0。共享参数要累加所有样本贡献，不能只取最后一条记录：

参数	样本1路径贡献	样本2路径贡献	总梯度
W11	-.1784325376	0	-.1784325376
W12	.1486937813	.0531946854	.2018884667
W21	-.3568650751	0	-.3568650751
W22	.2973875626	-.0531946854	.2441928772
b1	-.1784325376	0	-.1784325376
b2	.1486937813	-.0531946854	.0954990959
u1	-.3568650751	0	-.3568650751
u2	-.2379100501	.0851114966	-.1527985534
c	-.2973875626	.1063893708	-.1909981918

例如W12收到 $1 \times .1486937813 + (-1) \times (-.0531946854)$ ，两个正贡献相加，而不是相减。u2收到 $.8 \times (-.2973875626) + .8 \times .1063893708$ 。损失梯度中已经含分母4，表格不能再除以样本数。

若把梯度继续传到输入， $\bar{X} = \bar{Z}W^\top$ 。两行分别为 $(-.1189550250, .0059477513)$ 、 $(.0106389371, -.0212778742)$ 。本任务输入是固定数据，不更新；列出它们是为了确认每条路径的方向和矩阵形状。




图4 左图是完整计算链，右图拆开九个参数的两条样本路径。样本2虽然第一个隐藏单元为0，仍然通过第二个隐藏单元影响多个参数；“一条路径没有梯度”不能简写成“这一样本不参与学习”。

5.4 全部参数使用同一旧快照同步更新

执行 $\theta^+ = \theta - 0.1 \nabla J(\theta)$ 。先计算完整旧梯度，再同时更新；若先改 u ，再用新 u 计算旧图中的 $\bar{H}$ ，便不再是此目标在 θ 处的 SGD。

参数	旧值	变化量	新值
W11	.5	+.0178432538	.5178432538
W12	-.2	-.0201888467	-.2201888467
W21	.3	+.0356865075	.3356865075
W22	.4	-.0244192877	.3755807123
b1	.1	+.0178432538	.1178432538
b2	.2	-.0095499096	.1904500904
u1	.6	+.0356865075	.6356865075
u2	-.5	+.0152798553	-.4847201447
c	.1	+.0190998192	.1190998192

5.5 下一次前向 不能只停在更新公式

用未四舍五入的新参数重新计算。

$Z^{+11} = .5178432538 + 2(.3356865075) + .1178432538 \approx 1.3070595225$;

$Z^{+12} = -.2201888467 + 2(.3755807123) + .1904500904 \approx .7214226683$ 。第二行同理为 $(-.0643134925, .7862196494)$ ，门控本次保持不变。

样本	新隐藏向量	新logit	新概率	新BCE
1	(1.3070595225,.7214226683)	.6002918220	.6457230677	.4373845549
2	(0,.7862196494)	-.2619966830	.4348729428	.5707046931

$J^+=.4707145895$ ，比原目标小。然而样本2损失由.5543552445增加到.5707046931。加权总目标下降，并不意味着每条样本都获益。这个局部冲突正是用一个标量目标权衡不同记录的实际含义。

下一次反向时 $\bar{s}^+=(-.2657076992,.1087182357)$ ，必须乘新 u ，而不是旧 u 。新总梯度依参数顺序为 $(-.1689067994, .1814917933, -.3378135987, .2048898299, -.1689067994, .0760959555, -.3472957785, -.1062111442, -.1569894635)$ 。程序保存了两次完整路径；独立Decimal标量实现、PyTorch自动微分与18个中心差分坐标均互相核对。本例在两点都远离ReLU零点，因此差分不跨不可微边界。

6 代价阈值从行动风险推出

设行动1为告警，行动0为不告警；正确行动代价为0，一次误报代价 $C_{FP}>0$ ，一次漏报代价 $C_{FN}>0$ 。若 p 已经表示该记录在部署分布的条件正例概率，则：

$$R(1 | x) = C_{FP}(1 - p), \quad R(0 | x) = C_{FN}p.$$

选择期望代价较小者。按本讲并列时告警的约定， $C_{FP}(1-p) \leq C_{FN}p$ 当且仅当：

$$p \geq \tau^* = \frac{C_{FP}}{C_{FP} + C_{FN}}.$$

主实验 $C_{FP}=1$ 、 $C_{FN}=4$ ，所以理论阈值为.2。这个数字不是从测试集选出。比起.5，它愿意容忍更多误报来减少漏报；这不等于模型的概率估计能力变好了。




图5 左图比较两种行动的条件期望代价，在 $p=.2$ 处相等。右图反解出代价比 $C_{FN}/C_{FP}=(1-\tau)/\tau$ 。代价若依赖 x 、还有容量约束或拒识选项，这个单一常数阈值不再覆盖整个问题。

6.1 条件与一般化

该推导假设概率适用于部署、代价已给定且与样本无关、每条行动互不约束、没有其他效用项。若一天最多检查十台设备，就要考虑跨样本的资源约束；若误报代价随设备变化，阈值也应随 x 变化。若正确行动也有代价，应比较完整代价矩阵的两项条件期望，而非把公式机械套入。

原分布概率准确已是很强假设。实际模型有偏差时，可以在独立验证集上比较预先列好的阈值候选。本实验先定21个候选 $0, .05, \dots, 1$ ，比较 $(FP+4FN)/n$ ，并列选较大阈值。它只是候选集中验证代价最低者，不是未知总体最优者。[Elkan](#)，[代价敏感学习基础](#)

6.2 权重与阈值不要把同一代价算两次

从 q 公式可得 $q \geq .5$ 当且仅当 $\eta \geq a_0/(a_0+a_1)$ 。若 $a_0=C_{FP}$ 、 $a_1=C_{FN}$ ，在理想条件下，加权输出用 $.5$ 阈值与原始概率使用代价阈值相同。但 q^* 仍不是 η ，若再对它使用 $C_{FP}/(C_{FP}+C_{FN})$ ，就会进一步偏向正类，相当于重复施加部分代价偏好。

主实验的类别权重来自频率，并非代价 $1:4$ 。它们承担平衡训练风险的职责；代价阈值在恢复概率解释及验证温度之后单独处理。报告应把“为什么选这些权重”和“为什么用这个行动阈值”各写一句。

7 先验修正：加法位移与温度乘法不同

若模型输出 q 确实是类别加权分布的条件概率，已知 a_0 、 a_1 ，且希望返回原分布，可反解：

$$\eta = \frac{a_0 q}{a_1(1-q) + a_0 q}, \quad \text{logit } \eta = \text{logit } q - \ln \frac{a_1}{a_0}.$$

logit空间做减法通常比先除概率更稳定。对于平衡类别权重 $a_1=.5/\pi$ 、 $a_0=.5/(1-\pi)$ ，需减去 $\ln[(1-\pi)/\pi]$ 。本实验只用训练标签估计 $\pi=74/240=.3083333333$ ；不读取测试正例率来修正预测。对uniform处理不减任何常数。

更一般地，若源分布 Q 与部署分布 P 满足类别条件不变 $P(X|Y)=Q(X|Y)$ ，只有先验不同，且各类别在源中有正概率，那么Bayes公式给出二分类修正：

$$\text{logit } p_P = \text{logit } p_Q + \ln \frac{\pi_P}{1-\pi_P} - \ln \frac{\pi_Q}{1-\pi_Q}.$$

多分类时按 $p_P(k|x) \propto p_Q(k|x)\pi_P(k)/\pi_Q(k)$ 重归一化。这依赖label shift条件及可用的先验估计；若 $P(X|Y)$ 也变了，公式一般不够。未知部署先验的估计是另一个研究问题，本讲没有实施BBSE，也不从测试标签偷取答案。[Lipton](#)等，[label shift定义](#)




图6 左图比较logit平移和缩放。先验修正移动截距；温度缩放改变相对于0的尺度。右图中所有正温度都把 $s=0$ 映射到.5，所以单一温度不能把一个本应为.2、但logit为0的预测修好。

有限网络未必学到真正的 q ，训练样本先验也有误差。因此本实验的先验修正是有理论依据的有限操作，要继续接受独立评价，不能因为公式正确就宣称校准已经完成。先平移后缩放得到 $(s-d)/T$ ，与先缩放再减 d 一般不同，代码和部署必须保留同一个顺序。

8 温度缩放：只用验证标签拟合一个数

固定已训练网络的所有参数，取未用于训练的验证logits。二分类温度缩放为 $p_T = \sigma(s/T)$ ， $T > 0$ ；多分类为 $\text{softmax}(z/T)$ ，所有类别共享同一个正标量。原论文以验证NLL确定 T ，不能用测试标签拟合。

Guo等，2017，第4.2节

8.1 在逆温度上看清优化

令 $\beta = 1/T > 0$ ，校准验证集含有 m 条，logits记为 s_i 。目标与两阶导数为：

$$L(\beta) = \frac{1}{m} \sum_i [\log(1 + e^{\beta s_i}) - y_i \beta s_i],$$

$$L'(\beta) = \frac{1}{m} \sum_i [\sigma(\beta s_i) - y_i] s_i,$$

$$L''(\beta) = \frac{1}{m} \sum_i \sigma(\beta s_i) [1 - \sigma(\beta s_i)] s_i^2 \geq 0.$$

因而这是 β 上的凸目标。若至少一个 $s_i \neq 0$ ，在有限 β 下二阶导数严格为正；若所有 $s_i = 0$ ，目标恒为 $\ln 2$ ，温度无法识别。该凸性不等于对 T 或 $\log T$ 都具有相同的全局凸性，选择变量时要说清楚。

代码把 β 限制在 $[.05, 20]$ ，即 $T \in [.05, 20]$ ，用于明确有限搜索范围。先检查两端导数，若最优在边界就记录边界状态；否则做90轮二分寻找 $L'(\beta) = 0$ 。全零logits时保留 $\beta = 1$ 并标flat。计算正类梯度使用 $-\sigma(-\beta s)$ ，避免 $\sigma(\beta s)$ 先舍入为1再减1。所有非零标签margin同为正确方向时，目标严格递减，直接取

上界；全为错误方向则取下界。混合方向若两端梯度在浮点数中都为0，则保留 $\beta=1$ 并标 numerically_flat，不将数值分辨率不足冒充已确定边界。选择范围包含 $\beta=1$ ，所以数值误差外，所拟合验证NLL不会比不缩放更差；这个结论只针对拟合数据和NLL。




图7 类别加权、seed=11的实际温度拟合。输入已先减去已知训练权重对应的logit位移。左图是200条校准验证数据上的NLL，右图是其导数，零点对应 $\beta \approx .8823$ ，即 $T \approx 1.13345$ 。横轴是逆温度，不是 T 。

8.2 什么保持 什么改变

对固定 s 和正 T ， $\text{sign}(s/T)=\text{sign}(s)$ ，所以二分类.5阈值预测保持不变；多分类共同正温度保持同一条样本的logit大小顺序和argmax。因此固定规则下准确率保持。二分类所有记录的分数的排序也保持，理想精确算术下基于排序的ROC-AUC保持；浮点极端饱和可能制造额外并列，应在logit上检查。

不能将这句话扩大为“多分类所有样本的置信度排名都不变”。不同记录的其他类别logits会影响softmax分母，最大概率跨记录的排序可能改变。也不能扩大为“任何阈值下的准确率都不变”：固定概率阈值.2对应 $s \geq T \logit(.2)$ ， T 改变时行动可能改变。

NLL、Brier和ECE通常会改变，未必都改善，未必在测试集改善，未必在每个分组改善。 $T > 1$ 使输出更接近中性概率， $T < 1$ 使其更尖锐，最优温度不必大于1。温度只有一个自由度，无法学习额外特征、恢复错误排序或修复所有局部偏差。

9 怎样评价概率而不偷换成准确率

校准的一种二分类定义为 $E[Y|p(X)=t]=t$ ，即被模型报为某个概率的人群，真正正例比例与该概率相同。连续分数时应理解为条件期望的几乎处处性质，有限数据不能逐个实数 t 直接验证。总体校准也不保证 $E[Y|p(X)=t, G=g]=t$ 在每个组内成立。

NLL是前面的平均负对数概率，Brier在本讲指单个正类概率的均方误差： $BS=(1/n)\sum(p_i - y_i)^2$ 。若把两类概率向量的平方误差相加，会得到两倍，本讲不采用那个约定。固定真实 η ，有 $E[(p - Y)^2 | x] = (p - \eta)^2 + \eta(1 - \eta)$ ，所以理想条件下最优 $p = \eta$ 。NLL与Brier都评价概率质量，但不是只衡量校准的纯指标，也受到任务不确定性和辨别信息的影响。

始终输出总体正例率的模型可以总体校准，却没有个体区分能力。相反，一个高度准确的分类器可以系统性过度自信。应同时报告准确率或任务相关决策指标，以及概率指标，不能用“校准更好”替代任务目标。

9.1 本讲的可靠性图与ECE定义

我们对正类概率 p 分箱，而非对 $\max(p, 1-p)$ 的top-label confidence分箱。 K 个等宽区间为 $[k/K, (k+1)/K)$ ，最后一个包含1。每个非空箱 B_k 记录 n_k 、平均预测 $\bar{p}_k$ 和实际正例率 $\bar{y}_k$ ：

$$\widehat{ECE}_K = \sum_{k: n_k > 0} \frac{n_k}{n} |\bar{p}_k - \bar{y}_k|.$$

可靠性图横轴 $\bar{p}_k$ 、纵轴 $\bar{y}_k$ ，理想位置是对角线。空箱没有经验正例率，不画成0；小箱要附样本数，不能只看曲线锯齿。阈值不参与本定义，所以仅调整行动阈值时NLL、Brier和ECE完全相同。

分箱会抵消箱内方向相反的误差。四条预测(.1,.1,.9,.9)，标签(0,1,0,1)，只有一个箱时平均预测和正例率都为.5，ECE=0；两个箱时各自实际正例率为.5，ECE=.4。第一个结果没有证明完美校准。




图8 分箱抵消的有限反例。左图显示两种预测概率都对应0和1两种观察；右图只有分箱数改变，模型与标签完全不变。ECE的数值必须连同分箱规则、样本数一起阅读。

有限样本中的ECE还含估计偏差，粗箱近似和小箱随机误差方向不同，不能说分箱越细越准确。我们预先报告5、10、20等宽箱敏感性，并不从中挑最好看的一个作为唯一成绩。Roelofs等，有限样本与分箱偏差 分组较小时更需谨慎，显著性或不确定区间需要另行设计。本实验不把三个算法种子当作三份独立测试人群。Vaicenavicius等，校准评价框架

10 可复现实验：先冻结选择 再读测试标签

10.1 数据与可观测边界

固定生成器PCG64、seed=3902026，依次产生train240、validation400、test1000条。组G以概率.25取1，基础两个输入为独立标准正态， x_1 额外加.35G。真实生成logit为 $1.1x_1 - .8x_2 + .65x_1x_2 - 1.6 + .8G$ ，标签为相应sigmoid概率的Bernoulli抽样。

模型只输入 x_1 、 x_2 ，不输入G；G仅用于审计分组。因此即使学习器最优地估计 $P(Y|X)$ ，也未必对 $P(Y|X, G)$ 完成组内校准。这是有意加入的模型信息边界，并不对应任何真实受保护属性或公平性结论。

集合	条数	正例	组0条数/正例	组1条数/正例	用途
训练	240	74	181/44	59/30	训练网络、估计类别权重
验证	400	112	305/67	95/45	前200拟温度，后200选阈值
测试	1000	294	731/190	269/104	全部选择冻结后的评价

拆分顺序与角色在数据生成时固定，没有根据最终表现重分。独立验证集内部再分两部分，使温度拟合和阈值选择不重复使用同一批标签。超参数、种子、预算、代价、阈值候选、分组和分箱数都预先规定；本实验没有搜索每种方法的最佳配置。

10.2 三种训练方式与同一预算

模型为 $2 \rightarrow 6 \rightarrow 1$ ：隐藏层 $\tanh(XW+b)$ ，输出实数 $s=hu+c$ ，共 $12+6+6+1=25$ 个参数。W由 $N(0, .45^2)$ 、u由 $N(0, .35^2)$ 初始化，偏置为0。种子11、23、37在三种方法间配对，共九次。每次240轮、每轮240次样本呈现、一次SGD更新，学习率.08，无动量、无正则化、无早停。

- uniform：固定240条训练记录的普通BCE平均，每轮全部使用。
- weighted：仍使用全部240条，按 $a_1=.5/\pi$ 、 $a_0=.5/(1-\pi)$ 乘BCE，再除以240； $\pi=74/240$ ，平均权重为1。
- resampled：每轮按 $q_i=a_i/\Sigma a$ 有放回抽240次，取未再加权的BCE平均；实际每轮正例数并不严格等于120。

总计2160次更新、518400次训练样本呈现。重采样多次出现同一记录计多次呈现，不等于获得新信息。训练记录数和模型结构一致并不意味着三种优化过程的噪声相同；这正是比较对象的一部分。

10.3 六种输出视图

每个已训练网络都保留以下预先规定的视图，绝不从测试结果选一种才报告：raw原始输出；raw_temperature直接对原始logit拟温度；prior先验修正；prior_temperature先修正再拟温度；cost_theory沿用校准概率、阈值.2；cost_validation沿用同一概率、阈值由决策验证集选择。

uniform的prior是恒等操作，因此部分视图数值相同，这是合理对照而非遗漏。额外保留raw_temperature，是为了直接检验“温度能否代替先验修正”。测试预测共 $9 \times 6 \times 1000 = 54000$ 行；每视图按全体、组0、组1计算，共162行指标；可靠性表保留1620个箱，包括空箱。

程序先在内存构造含所有模型参数、温度和阈值的frozen-plan对象，再解析测试标签。输入文件的字节摘要可提前核验，但不把摘要当标签选择信号。最后成功后写结果文件。这个顺序提供可审计证据，不是访问控制：人若看过测试后改协议，再运行也不算新独立测试。

11 实际结果：改善哪个对象 要逐项说

以下都是同一份1000条合成测试记录上的三个算法种子均值；没有统计显著性或真实任务推广的主张。

训练方式/视图	准确率	NLL	Brier	10箱ECE	平均代价
等权, 原始 .5	.724667	.527406	.177685	.046955	.782333
加权, 原始 .5	.691000	.601866	.207404	.164320	.555000
重采样, 原始 .5	.690333	.601942	.207469	.164430	.558667
等权, 温度 .5	.724667	.527254	.177408	.032539	.782333
加权, 修正+温度 .5	.722333	.528340	.178052	.034546	.768667
重采样, 修正+温度 .5	.721000	.528418	.178099	.034217	.772000
等权, 温度+阈值 .2	.585667	.527254	.177408	.032539	.530333
加权, 修正+温度+.2	.580000	.528340	.178052	.034546	.527000
重采样, 修正+温度+.2	.581000	.528418	.178099	.034217	.527000

全负规则在本测试集准确率为.706，平均代价 $4 \times .294 = 1.176$ ；全正规则准确率.294、平均代价.706。它们提醒我们：准确率最高的规则未必代价最低。代价单位是事先定义的教学相对单位，不能解释为节省了实际货币。




图9 三种子散点与短横均值。加权和重采样的原始输出在原分布测试NLL、Brier上较差；先验修正改善了其概率解释。温度变化保持对应.5分类准确率，但可以改变概率指标。所有点均保留，未挑最佳种子。

11.1 温度不是先验偏移的替代品

类别加权的raw_temperature平均NLL从.601866变为.597540，但10箱ECE从.164320变为.169401，反而增加；重采样也出现相近现象。温度是按验证NLL拟合，既没有针对测试ECE优化，也不能通过单一缩放消掉加性logit偏移。这个结果不支持“只要校准就让所有指标改善”。

先验修正后，三方法得到相近但不相同的概率指标。加权与重采样在这一有限设置中没有显著优于等权的证据；我们没有通过扩大超参数搜索来替某种方法找最有利条件。差异还可能来自优化轨迹、有限数据、模型未包含G和交互项拟合程度。




图10 seed=11的正类概率可靠性图，点面积随箱样本数增大。末端急降不是已证明的总体规律：等权原始输出的0.8至0.9概率箱只有4条且全为负，温度后同箱只有2条。空箱不绘点，完整计数见reliability.csv。

11.2 调阈值改变行动 不改变概率分数

九个决策验证选择都恰好得到.2，与理论候选相同，因此cost_theory与cost_validation的测试结果相同。这个相等是本次数据上的观察，不能推广成“任何有限验证集都会选理论阈值”。

等权温度模型把阈值从.5降到.2后，平均准确率从.724667降至.585667，但平均代价从.782333降至.530333，召回从.425170升至.868481。NLL、Brier、ECE完全不变，因为每条概率没有变。若论文把这一改动写成“模型概率准确性改善”，就错把决策改进归给了概率估计。




图11 左图只用决策验证集计算候选阈值代价，线仅连接候选点；右图报告冻结视图的测试代价。左边不是测试曲线，右边没有用测试结果回选阈值。有限曲线的最低点与总体最优不是同义词。

11.3 分组与空间边界揭示遗漏




图12 左图分别保留全体、组0、组1的10箱ECE散点，人数差异已标出；右图展示相同校准预测在5、10、20箱下的总体ECE均值。小组更少的正例和每箱记录会放大评价不确定性，不能只看最高一根点就判定方法优劣。

总体指标将不同组按人数混合。一个组中偏高、另一个组中偏低的预测可能相互抵消。G未作为模型输入，加上有限样本误差，使“一组温度适用于所有组”没有保证；但这也不自动授权拟合每组温度，后者需要新的验证预算与预先设计，且应考虑实际部署可否使用分组信息。




图13 seed=11的原始输出空间图，黑线为.2、白线为.5。加权和重采样改变了学习目标，原始分数不能不加解释地与等权输出当作同一概率。颜色仅是模型在二维网格上的输出，没有使用测试标签选边界。




图14 相同网络经过既定先验修正和验证温度后的空间图。黑线仍是.2、白线仍是.5；温度本身保留.5边界，先验平移可以移动它。图中输入G被排除，不能展示对完整(X,G)生成规则的全部差异。

12 把这一讲变成科研设计

先提出一个可证伪问题，例如“在相同记录预算下，平衡重采样是否降低少数类漏报，而其原始分数是否偏离部署概率”。然后把训练分布、损失、权重分母、网络预算、验证用途、代价与评价指标写进协议。比较时保留配对初始化，并区分算法随机性与数据重复。

若要扩展，第一步可增加独立数据生成种子，报告配对差异的不确定性；第二步可改变真实先验或引入 $P(X|Y)$ 漂移，检验先验修正失效的条件；第三步才考虑更灵活的校准映射。每次扩展都需要新的封存测试或明确的探索性标签，不能拿这一讲已反复阅读的测试集继续宣称独立发现。

阅读一篇失衡学习论文时，至少寻找六项信息：原始先验、实际采样规则、损失完整公式和分母、输出概率的参照分布、校准与阈值的拟合数据、带支持数的分组指标。缺任一项都可能让“更好”缺少可比较的含义。