

040 练习详解 训练诊断与调参实验

先独立完成题目，再用这里的推导核对。数值例子的作用是验证计算和实验边界，不是把一种曲线形状变成通用病因。

1 为什么两样本梯度是残差除以2

题目：七参数手算使用单例 $\ell_i = (\hat{y}_i - y_i)^2/2$ 和 $L = (\ell_1 + \ell_2)/2$ 。写出从 L 到 w_1 的路径，解释哪里出现平均因子。

解：对每个样本， $\partial L/\partial \ell_i = 1/2$ ， $\partial \ell_i/\partial \hat{y}_i = r_i$ 。因此 $u_i = \partial L/\partial \hat{y}_i = r_i/2$ 。路径到 w_1 还要依次乘 a_1 、ReLU门和 x_i ：

$$\frac{\partial L}{\partial w_1} = \sum_{i=1}^2 \frac{r_i}{2} a_1 \mathbf{1}[z_{i1} > 0] x_i.$$

在初值处，第一例 $(-0.15/2)(1)(1)(-1) = 0.075$ ，第二例 $(0.35/2)(1)(1)(1) = 0.175$ ，合计0.25。两个贡献已经各含1/2，相加后不能再求平均。若训练代码误用 $\sum \ell_i$ ，该例梯度会扩大2倍；同时把学习率缩小2倍可在这个纯SGD例里抵消，但不应靠另调参数掩盖损失约定错误。

输出偏置梯度为 $(r_1 + r_2)/2 = 0.1$ ；它不是两个残差平方的平均。平方产生正损失，却不意味着每个参数梯度都为正。

2 补全两轮所有共享参数路径

题目：列出两轮逐样本贡献，验证同步更新，并给出第三次前向。

解：第一轮七参数顺序为 $(w_1, w_2, b_1, b_2, a_1, a_2, c)$ 。第一例贡献 $(0.075, -0.0375, -0.075, 0.0375, -0.0375, -0.1125, -0.075)$ ；第二例贡献 $(0.175, -0.0875, 0.175, -0.0875, 0.2625, 0.0875, 0.175)$ 。相加得到 $(0.25, -0.125, 0.1, -0.05, 0.225, -0.025, 0.1)$ 。

用学习率0.2同时更新后，参数为 $(0.45, -0.475, 0.98, 1.01, 0.955, -0.495, 0.08)$ 。用它重新算两例预测 -0.148925 、 1.180825 ，残差为 -0.148925 、 0.180825 ，所以新的 u 为 -0.0744625 与 0.0904125 。

第二轮局部隐藏梯度分别为 $(-0.0711116875, 0.0368589375)$ 和 $(0.0863439375, -0.0447541875)$ 。全部贡献如下；它们再次各自包含平均因子。

参数	第一例贡献	第二例贡献	合计
w_1	0.0711116875	0.0863439375	0.157455625
w_2	-0.0368589375	-0.0447541875	-0.081613125
b_1	-0.0711116875	0.0863439375	0.01523225
b_2	0.0368589375	-0.0447541875	-0.00789525
a_1	-0.039465125	0.129289875	0.08982475
a_2	-0.1105768125	0.0483706875	-0.062206125
c	-0.0744625	0.0904125	0.01595

第二次更新得到

$$\theta_2 = (0.418508875, -0.458677375, 0.97695355, 1.01157905, 0.93703505, -0.482558775, 0.07681).$$

第三次前向的两例隐藏输入分别为

$$z^{(1)} = (0.558444675, 1.470256425),$$

$$z^{(2)} = (1.395462425, 0.552901675).$$

门均为1。预测为 -0.10939290542302063 与 1.117599648199548 ；损失约 0.006449121253386854 。

如果第二步仍用 g_0 ，相当于假设参数变化后所有中间量和局部导数都没变。本例的 a_2 梯度从 -0.025 变到 -0.062206125 ，已经直接否定这种假设。同步更新只规定“同一步使用同一旧参数”，不规定“所有步使用最初参数”。

3 推导主实验tanh网络的显式梯度

题目：令归一化输入为 s_i ， $h_{ij} = \tanh(w_j s_i + b_j)$ ， $\hat{y}_i = \sum_j a_j h_{ij} + c$ 。推导带权重惩罚的目标梯度。

解：记 $r_i = \hat{y}_i - y_i$ 和 $d_i = r_i/n$ 。tanh导数为 $1 - h_{ij}^2$ 。令

$$q_{ij} = d_i a_j (1 - h_{ij}^2).$$

沿路径相乘并对样本求和，得到

$$\begin{aligned} \frac{\partial J}{\partial w_j} &= \sum_i q_{ij} s_i + \lambda w_j, & \frac{\partial J}{\partial b_j} &= \sum_i q_{ij}, \\ \frac{\partial J}{\partial a_j} &= \sum_i d_i h_{ij} + \lambda a_j, & \frac{\partial J}{\partial c} &= \sum_i d_i. \end{aligned}$$

n 只进入 d_i ，偏置不加惩罚。实际更新用这四块梯度的同一个旧参数状态。独立NumPy重建采用这些公式，不调用PyTorch反向；作者侧重建51次训练、12206次更新、511130个更新坐标，最大参数差约 9.1×10^{-13} 。这种数值一致不是对任意网络或硬件的普遍误差界。

4 两条高损失曲线能否证明欠拟合

题目：训练和验证损失都高，为什么不能立即增加网络宽度？给出本讲两个不同原因。

解：slow种子4002几乎未沿梯度走足够远，固定初值增大步长可明显改变结果；strong_penalty是在优化 $L_{\text{data}} + \lambda P$ ，即使很好地降低这个目标，数据误差也可能较高。二者都可能产生高训练误差，却分别涉及优化进度与目标约束。

线性条件则能和训练最小二乘解比较。若已接近该函数类的解析最优，还存在明显误差，就有理由考察函数类限制；但噪声、任务定义和标签质量仍是替代解释。换宽网络之前，至少核对数据对应、损失归约、梯度正确性、实际参数变化和适当基线。

训练低、验证高也不等于已唯一识别过拟合。不同评价模式、输入分布或标签错位同样会产生间隙。只有控制这些差别后，正则化、容量和更多数据等干预才更有解释力。

5 为什么饱和反例和随机标签失败必须保留

题目：输入放大50倍后饱和更多，验证损失却更低；置乱8个训练标签又没有完全拟合。分别写出允许和不允许的结论。

解：允许说“在这份固定合成任务、固定预算和三个种子下，增加输入尺度同时增加饱和比例并改善了验证分数”。不允许说“饱和总有益”或“饱和导致改善已经被证明”。尺度改变可能使特征形状更适应当前函数；也可能主要改变优化路径。冻结隐藏特征只训输出层、或更换目标函数形状，是可以进一步区分解释的实验，但需要新的开发计划。

置乱8例在800步后损失约0.083834，说明在指定设置下没有达到近零训练误差。未拟合可以涉及样本间距、光滑特征、条件数和有限预算；梯度测试通过也不保证任务可快速拟合。不能因此直接宣称实现错误，也不能因为希望展示记忆能力而隐瞒失败。

请对照正文图5逐种子核对。这个反例使用同一训练、验证划分，但没有进入主候选集合；不能据此悄悄更换测试比较对象。

6 预算、配对与单因素归因

题目：主搜索有几次训练和几次更新？为什么获胜者相对参照不能全部归因于学习率？

解：3种学习率乘3种惩罚乘3个初始化，共27次训练；每次180步，共4860次更新。每步48训练例，所以计入接受更新的样本呈现数233280。这个计数不包含评价前向、失败候选和计时成本；整个教学运行还包括诊断和探针，总接受更新12206次。

主获胜者为 $\eta = 0.2, \lambda = 0$ ，参照为 $\eta = 0.05, \lambda = 0.001$ ，两项都变了。固定 $\lambda = 0.001$ 时，改变步长0.05到0.2的三个差分别为：

初始化种子	新验证损失减旧验证损失
4001	-0.002624509178052706
4002	-0.005188931376523959
4003	-0.002840789834969869

平均约-0.00355141012985。三条方向一致是有限的配对证据，不等于任意数据集都有效。其余11组相邻对照也全部保存，防止只展示符合预期的一组。改变学习率的影响可能依赖惩罚强度，所以单因素比较与网格交互检查互相补充。

7 用精确概率说明选择偏差

题目： K 个候选的单样本验证错误独立服从Bernoulli(1/2)，独立未来错误率也都为1/2。最小验证错误的期望是多少？

解：最小值只有0或1；它等于1当且仅当全部 K 个候选都犯错。由指定独立条件，其概率是 2^{-K} 。故 $E[\min \hat{R}_k] = 2^{-K}$ ，而未来错误期望仍为1/2。 $K = 1, 2, 4, 8$ 时，验证期望分别为0.5、0.25、0.0625、0.00390625。

越多候选带来越低验证赢家分数，完全可以发生在所有候选同样好的世界里。真实候选误差相关时公式不再照搬，但“选择了有利估计噪声”的风险仍需处理。独立测试用于评价固定选择；嵌套交叉验证则在每个外层训练折内部重新调参。先用全数据选参数，再重新拆分，不能让已经用过的信息恢复成未见。

8 为什么集成损失不等于单模型损失均值

题目：三个预测 p_1, p_2, p_3 的平均为 $\bar{p}$ 。证明平均平方误差与平均预测平方误差的关系。

解：写 $p_s - y = (p_s - \bar{p}) + (\bar{p} - y)$ ，平方后对 s 平均。因为 $\sum_s (p_s - \bar{p}) = 0$ ，交叉项消失：

$$\frac{1}{3} \sum_{s=1}^3 (p_s - y)^2 = (\bar{p} - y)^2 + \frac{1}{3} \sum_{s=1}^3 (p_s - \bar{p})^2.$$

右侧第二项非负，因此对于这些固定预测，集成平方误差不大于平均单模型平方误差。这个恒等式不说明集成一定胜过最好的单个模型，也不保证换数据后仍然相同。本讲选择用3种子验证损失均值，部署用均值预测；两者有明确区别，当前选择规则也不保证集成验证损失本身最小。

若项目目标是选择最佳集成，应预先规定以集成验证预测形成选择指标；不能看完测试分数后才改规则。

9 区间到底包含哪一种随机性

题目：测试配对平均差为-0.00252654，95%百分位bootstrap区间约[-0.00417487,-0.00100847]。能否说新数据集上重新训练也必定改善？

解：不能。抽样单位是512个独立测试ID，每次同一ID同时取两种模型预测，保持配对。区间条件于已经观测的训练数据、开发选择与这组已拟合模型；它没有重新抽训练数据、重新进行27次搜索，也不包含未来分布改变。

只有在目标问题明确为“固定这两个部署集成，在相同生成分布下新测试样本的平均损失差”时，这个条件性区间才对应所讨论的不确定性。百分位bootstrap本身也只是有限样本近似，不能把95%解释为当前参数有95%的频率学派概率落在已给定区间中。

此外，总体改进不表示每例都改善。应同时看逐例差与左右组结果。右组更嘈杂的已知机制说明高误差未必都是系统性偏差；反过来，知道噪声大也不能免除模型误差检查。

10 一份合格的结论应如何写

可写：“在固定一维合成分布、48例训练与180步全批次预算下，9配置的3种子验证均值选择了学习率0.2、无权重惩罚。与预先指定参照相比，最终3模型集成的512例测试half-MSE减少约0.00253。按独立测试ID配对的条件性bootstrap区间为负。单因素对照支持当前设置下增大学习率的有限效果，但最终配置还改变了惩罚；不作普遍因果归因。”

还必须保留限制：“输入饱和的诊断条件在验证上更好，但不在主搜索空间中，未据此改最终方案。随机标签探针没有完全拟合。区间不包含重训、重新选择或分布漂移；没有GPU、真实任务、所有平台或大型网络结论。”

这类结论之所以可继续研究，在于别人能够指出哪项替代解释尚未排除，并用保存的协议、参数、预测与失败记录重做下一次实验。