

040 训练诊断与调参实验


从一条下降曲线，走到一项能够被他人核实的实验决定。

1 本讲要解决的问题

前面的单元已把数据、反向传播、优化器、初始化、正则化和损失设计接起来。现在模型能运行了，但验证结果不好。你下一步应该增大网络、改学习率、换损失，还是先查样本？本讲不提供看图猜病的口诀，而是建立一条证据链：确认所比较的量，再提出多个解释，用尽量小的受控实验区分，最后在冻结的预算内选择方案。

先修022的配对比较、031的梯度核验、034的优化目标、037的正则化以及039的任务损失与评价区别。即使暂时不做复杂研究，也要能回答三件事：这个数字如何计算；哪个数据影响了选择；改变一项因素后，同一随机条件下发生了什么。

本讲主实验是一维合成回归。它便于把每个预测点、每次更新和每条失败曲线完整保留下来。使用回归并不表示分类诊断较不重要：若分类准确率不变而NLL改善，应先检查指标和阈值，而不能把它自动归为“模型没有学习”。039已经解释了这一点。



曲线形状提出问题；受控对照才缩小解释范围。

图1 先形成可区分的假设，再做有边界的实验。箭头表示工作顺序，不是曲线到病因的自动分类器。

2 先确认你画的究竟是哪一个量

设训练集有 n 个样本，模型输出 $f_{\theta}(x_i)$ ，标签是 y_i 。本讲的训练数据损失为

$$L_{\text{data}}(\theta) = \frac{1}{2n} \sum_{i=1}^n (f_{\theta}(x_i) - y_i)^2.$$

“half-MSE”就是均方误差的一半； $1/2$ 用于消掉平方求导时的系数2，不是减少了样本数。RMSE则是 $\sqrt{2L_{\text{data}}}$ 。如果训练日志用求和、验证用均值，或者一边用MSE另一边用half-MSE，两条曲线的位置就不能直接比较。

主实验只对输入权重 w 和输出权重 a 加惩罚，不惩罚偏置 b, c ：

$$J(\theta) = L_{\text{data}}(\theta) + \frac{\lambda}{2}(\|w\|_2^2 + \|a\|_2^2).$$

因此日志同时保存train_data_loss与train_objective。验证曲线只算验证样本的数据损失，不加参数惩罚。把 J_{train} 减去 L_{val} 叫作“泛化间隙”，会把不同目标混在一起。即使统一了损失，训练与验证仍来自不同样本；小样本噪声、不同难度和预处理差异都可能使验证损失低于训练损失。

本实验没有dropout和BN，因而排除了训练模式与推理模式对曲线的干扰。真实网络还要核对train/eval状态、随机增强是否开启，以及训练曲线是在更新前、更新后还是各小批次不同参数下累计。它们不是可忽略的记录细节。


3 先在七个参数上看清一次诊断对象

用两个样本 $(x_1, y_1) = (-1, 0)$ 、 $(x_2, y_2) = (1, 1)$ 。它们仅用于纸笔核验，不属于稍后的48例训练数据。网络有两个ReLU隐藏单元和一个线性输出：

$$z_{ij} = w_j x_i + b_j, \quad h_{ij} = \max(0, z_{ij}), \quad \hat{y}_i = a_1 h_{i1} + a_2 h_{i2} + c.$$

参数固定按 $\theta = (w_1, w_2, b_1, b_2, a_1, a_2, c)$ 排列，初值为 $(0.5, -0.5, 1, 1, 1, -0.5, 0.1)$ 。先算各样本残差 $r_i = \hat{y}_i - y_i$ 、单样本损失 $\ell_i = r_i^2/2$ ，再取 $L = (\ell_1 + \ell_2)/2$ 。本例不加惩罚，学习率 $\eta = 0.2$ 。

第1次更新用 θ_0 ；第2次重新前向并用 θ_1 求所有局部导数



反向： $r/2 \rightarrow$ 乘 $a \rightarrow$ 乘门 $\rightarrow$ 乘 x ；共享参数的两例贡献相加

图2 两个样本共享同一组参数。反向时平均因子已经进入 $r/2$ ；再除以2会产生错误。

样本	z_1, h_1	z_2, h_2	$\hat{y}$	r	$\ell = r^2/2$
$x = -1, y = 0$	0.5, 0.5	1.5, 1.5	-0.15	-0.15	0.01125
$x = 1, y = 1$	1.5, 1.5	0.5, 0.5	1.35	0.35	0.06125

例如第一例先得到 $z_1 = 0.5(-1) + 1 = 0.5$ 与 $z_2 = (-0.5)(-1) + 1 = 1.5$ ，再算 $\hat{y} = 1(0.5) - 0.5(1.5) + 0.1 = -0.15$ 。两例相加后， $L_0 = (0.01125 + 0.06125)/2 = 0.03625 = 29/800$ 。

这里所有 z 均大于0，所以ReLU局部导数均为1。不能因为本例门都开启，就在任何输入或后续训练中省略门；在 $z = 0$ 处还要区分数学不可导和框架所采用的约定。

4 局部导数怎样积累成全部参数梯度

先把链拆开。对第 i 例， $\partial L/\partial \hat{y}_i = r_i/2$ ； $\partial \hat{y}_i/\partial h_{ij} = a_j$ ； $\partial h_{ij}/\partial z_{ij} = \mathbf{1}[z_{ij} > 0]$ ； $\partial z_{ij}/\partial w_j = x_i$ ， $\partial z_{ij}/\partial b_j = 1$ 。输出层还有 $\partial \hat{y}_i/\partial a_j = h_{ij}$ 与 $\partial \hat{y}_i/\partial c = 1$ 。

记 $u_i = r_i/2$ ， $v_{ij} = u_i a_j \mathbf{1}[z_{ij} > 0]$ 。每例对七个共享参数的贡献依次为

$$(v_{i1}x_i, v_{i2}x_i, v_{i1}, v_{i2}, u_i h_{i1}, u_i h_{i2}, u_i).$$

第一例 $u_1 = -0.075$ ，传到两个隐藏输出的梯度是 $(-0.075, 0.0375)$ ，乘门后不变。第二例 $u_2 = 0.175$ ，对应 $(0.175, -0.0875)$ 。 w_1 收到第一例 $(-0.075)(-1) = 0.075$ 和第二例 $0.175(1) = 0.175$ ；同一参数的两条样本路径必须相加。

参数	第一例贡献	第二例贡献	总梯度 g_0	同时更新后的 θ_1
w_1	0.075	0.175	0.25	0.45
w_2	-0.0375	-0.0875	-0.125	-0.475
b_1	-0.075	0.175	0.1	0.98
b_2	0.0375	-0.0875	-0.05	1.01
a_1	-0.0375	0.2625	0.225	0.955
a_2	-0.1125	0.0875	-0.025	-0.495
c	-0.075	0.175	0.1	0.08

表中最后一列统一用 $\theta_1 = \theta_0 - 0.2g_0$ 。计算 w, b 梯度时仍使用旧 a ；不能先更新输出层，再把新 a 用于同一步反向。那会混合不同参数点的导数。

5 第二轮不能沿用第一轮梯度

用刚得到的七个新参数完整重做前向。第一例两个 z 为 $(0.53, 1.485)$ ，预测 $0.955(0.53) - 0.495(1.485) + 0.08 = -0.148925$ ；第二例两个 z 为 $(1.43, 0.535)$ ，预测 1.180825 。门仍全部开启。单例损失分别为 0.0110893278125 与 0.0163488403125 ，因此

$$L_1 = 0.0137190840625 = \frac{43901069}{3200000000}.$$

新的 u 为 $(-0.0744625, 0.0904125)$ 。第一例的隐藏局部上游梯度是 $(-0.0711116875, 0.0368589375)$ ；第二例是 $(0.0863439375, -0.0447541875)$ 。它们用了新输出权重 $(0.955, -0.495)$ ，而不是旧权重。

参数	第一例新贡献	第二例新贡献	总梯度 g_1	$\theta_2 = \theta_1 - 0.2g_1$
w_1	0.0711116875	0.0863439375	0.157455625	0.418508875
w_2	-0.0368589375	-0.0447541875	-0.081613125	-0.458677375
b_1	-0.0711116875	0.0863439375	0.01523225	0.97695355
b_2	0.0368589375	-0.0447541875	-0.00789525	1.01157905
a_1	-0.039465125	0.129289875	0.08982475	0.93703505
a_2	-0.1105768125	0.0483706875	-0.062206125	-0.482558775
c	-0.0744625	0.0904125	0.01595	0.07681

第二次同时更新后，再做第三次前向：第一例 $z = (0.558444675, 1.470256425)$ ，第二例 $z = (1.395462425, 0.552901675)$ ，所以各门仍为1。预测分别为 -0.10939290542302063 和 1.117599648199548 ，对应 $L_2 \approx 0.006449121253386854$ 。这一步是重新计算，不是拿一阶近似当真实损失。




图3 两次更新、三次前向。第二行梯度与第一行不同；损失下降只是该例这两步的实际事实。

程序以Fraction保存精确分数，另用逐样本autograd核对两轮共28个参数贡献。本讲还对随机平滑网络的340个参数坐标做显式NumPy梯度与中心差分检查。通过这些检查仅说明所测计算一致，不证明数据标签正确、调参公平或模型具有现实用途。

6 四类解释如何区分

“训练损失高、验证也高”至少有几种解释：函数类表达不了目标，训练尚未达到较好解，正则化限制很强，输入标签有问题，或者当前损失本来就在错误刻画任务。单看两个数无法识别是哪一种。

观察	尚不能排除的解释	优先做的可区分检查
损失几乎不动	步长小、梯度断开、已接近当前目标驻点	核对梯度与参数是否变化；同初值改变步长；看最小样本测试
损失迅速增大	步长过大、数值失稳、坏批次	先保存失败状态；检查有限值和目标归约；固定数据降低步长
训练低而验证高	过拟合、拆分差异、评估状态或标签错位	对齐评价方式；审计拆分；再检验正则化、容量或更多训练数据
训练和验证都较高	函数类不足、优化不足、噪声或错误目标	可解析/强基线；小数据拟合；单因素改变函数类或预算
某一组误差大	样本少、噪声高、覆盖不足、系统偏差	报告组大小和残差；查生成/采样机制；预先规定后续验证

诊断中的“优化失败”是相对某个目标与可达参照而言。例如线性模型若已接近解析最小二乘，却仍不如非线性模型，就有证据排除“只是没有把这条直线训练好”；仍不能从而证明该非线性模型就是正确物理机制。过强惩罚让数据损失高时，也不能自动说优化器失败：它可能认真优化了你给它的另一个目标。

7 真实诊断实验的固定对象

三个独立随机种子4040、4041、4042分别生成48例训练、128例验证和512例测试。每个 x 独立均匀来自 $[-3, 3]$ ，条件均值和标签为

$$f_*(x) = 0.8 \tanh(1.3x) + 0.25 \sin(3x), \quad Y = f_*(X) + \sigma(X)\varepsilon, \quad \varepsilon \sim N(0, 1),$$

其中 $x < 0$ 时 $\sigma = 0.1$ ，否则 $\sigma = 0.35$ 。因此右侧更嘈杂是明确的合成机制，不是模型事后发现的真实世界结论。训练归一化的均值和标准差仅用当前训练子集估计；验证和测试复用这两个数。默认主网络 $1 \rightarrow 8 \rightarrow 1$ 使用tanh，共 $8 + 8 + 8 + 1 = 25$ 个参数。

三个初始化种子4001、4002、4003在配置间配对。相同种子、相同宽度使用完全相同的初始参数，数据与全批次顺序也相同。每步对全部48例求梯度，没有小批次抽样噪声；种子差异只对应所记录的初始化差异，不能当作三份新数据集。

诊断参照固定 $\eta = 0.05, \lambda = 0.001$ 、180步。分别只把步长改为 10^{-5} 或10、函数类改为线性、训练标签置乱、标准化输入再乘50，或把惩罚改为1。每种条件均运行3种子。线性条件改变函数类和参数数目，是模型类对照；它与其他条件的每步计算量也不同。




图4 本图展示6类条件的18条诊断运行；另3条输入尺度对照见图5，全部21条保存于轨迹。3条过大步长运行只接受2次更新，不能伪造它们的第180步结果。标签置乱条件的训练损失针对被置乱标签。

极小步长下，种子4002和4003几乎未学到足够好的函数；但4001初始状态已偶然较好，180步验证损失约0.06577，接近参照0.06484。不能只挑4002的曲线来宣称“小步长必然表现差”。线性模型三个种子最终验证损失都约0.08406；强惩罚条件约0.288。

失稳条件的拟议第3次更新使目标超过预设 10^6 上限，被拒绝提交。文件保留当前参数、拟议参数、拟议目标与已接受步数。它们不是收敛者，也不是丢失文件。总训练51次中有3次此类停止，其余48次完成各自固定预算。

8 诊断指标也需要反例

常见经验是tanh饱和会压小某些局部导数。但“存在饱和单元”不推出“整个任务训练失败”。本实验把标准化输入乘50后，初始化饱和比例确实升高；三个种子的验证损失却约0.04712、0.04509、0.04498，都低于参照。




图5 饱和增加但验证更好。这一对照保留在教材里；它提醒我们不能用单一内部统计代替任务证据。

这不证明大尺度输入普遍有益。这里是一维有限任务，输出层仍可改变组合，近似门形的特征可能更贴近这份数据，隐藏权重也并非全部完全失去梯度。要区分这些解释，还需冻结特征、仅训输出层、改变目标形状等新的计划。主搜索空间未包含输入尺度，不能在看见这张图后把该诊断条件偷偷放入最终获胜者。

同样，梯度范数大不直接等于更新过大，因为更新还取决于学习率与优化器。可记录

$$\rho_t = \frac{\|\Delta\theta_t\|_2}{\|\theta_t\|_2 + \epsilon}, \quad \epsilon = 10^{-12}.$$

分母的 ϵ 只防止零除。本讲SGD的 $\Delta\theta = -\eta\nabla J$ ，所以该量能直接核查。但它对参数化和层尺度敏感，不存在本讲已经证明的通用“安全阈值”。有些层参数接近0会放大比值；全模型范数还可能遮住小层的异常。




图13 同一初始化在两种学习率下的梯度范数与拟议更新比。只画真实已保存的前3个状态；第3个状态之后的失稳候选不再提交。

9 小批次拟合和过拟合各自能说明什么

最小调试探针取训练集前8例，16个tanh单元， $\lambda = 0$ ， $\eta = 0.1$ ，固定800步。完整标签训练损失从初值下降到约0.002642；固定置乱标签下降到约0.083834，没有接近0。置乱改变的是 x 与训练标签的对应，不是把验证/测试标签也一起改掉。

随机标签未拟合，可能由样本位置、函数类、初始化、条件数、优化预算或实现问题共同造成。已通过梯度核验也只排除所测计算错误。不能把“随机标签没到零”直接当成程序有bug，更不能增删样本或偷偷增加预算，把期望中的成功图做出来。若需要继续诊断，应明确写出下一项受控干预。

另一个独立教学探针使用前16例、32单元、2500步、无惩罚。它用于观察训练历程，不与主搜索混为同预算方法排名。验证损失在216步最低约0.056171，最终约0.060679；最终训练损失约0.011308。继续拟合训练集并未继续改善这份验证集。




图6 左图保留过拟合过程，右图保留小批次探针的未完成拟合。左图选择最小验证步只是诊断，不是已通过独立测试的早停收益。

要评价一种早停策略，应在验证集选择停止规则和恢复的参数，再用独立评价评估整个策略。不能把验证最小值既当选择依据又当无偏成绩。若需要研究随新训练数据变化的性能，应重做训练与选择，而不是只在固定模型上重采样测试行。

10 将调参写成一个有限算法

主计划仅搜索 $\eta \in \{0.01, 0.05, 0.2\}$ 与 $\lambda \in \{0, 0.001, 0.01\}$ 的9个组合，每组合3个配对初始化，每次180次全批次更新。所有配置宽度都为8，其余协议相同。总计27次运行、4860次被接受的更新，训练更新样本呈现数为 $4860 \times 48 = 233280$ 。

这里“样本呈现数”只统计被接受更新所用的训练样本，不包含验证前向、拒绝的候选前向、日志计算或绘图。它不是总浮点运算数，也不是耗时。诊断21次运行、小批次2次和过拟合1次另列预算；不能把它们从总实验成本中抹去，也不能声称不同宽度等步数就等计算量。

选择规则是：取各配置第180步验证half-MSE的3种子算术平均，越小越好；任一种子未完成则该配置不可参选；同分按协议列出的先后顺序。这个规则选的是一个配置，不是最好种子。若全部配置失败，程序报错而不是挑最后一个幸存文件。

固定参照为 $\eta = 0.05, \lambda = 0.001$ 。最后选择 $\eta = 0.2, \lambda = 0$ ，验证均值从参照0.065901降至0.061972。这个差值来自同一验证集上的选择过程，不能直接作为未见总体改进的无偏估计。




图7 完整9格搜索与27个实际种子分数。横轴配置序号严格按protocol.json列出顺序；没有隐藏低分配置。

计划文件在每次运行前核验SHA，包含搜索集合、种子、预算、停止上限、选择规则和最终比较对象。它是冻结的可复现教学协议，不声称拥有外部时间戳的科研预注册。现实探索如果已经看过很多验证结果，应如实记录探索历史；把后来决定的规则写进JSON，不能追溯消除已发生的选择。

11 单因素比较与完整网格回答不同的问题

获胜者与参照同时改变了 η 和 λ ，所以最终差值不能全部归因于“增大学习率”。本讲自动列出网格中全部12组相邻取值的单因素比较：固定每个 λ 比较相邻学习率，固定每个 η 比较相邻惩罚。每对都按初始化种子相减，差值定义为“后者验证损失减前者”。

例如固定 $\lambda = 0.001$ ，把步长从0.05改为0.2，三个配对差分别约为

$-0.00262451, -0.00518893, -0.00284079$ ，平均约 -0.00355141 。这支持“在当前数据、180步预算及三个初值下，这项单因素改变使验证损失下降”。它不支持任意学习率越大越好，也不是对任意数据集的统计保证。




图8 全部12个相邻单因素对照。蓝点是3个配对种子，竖线是均值；正值反例与负值结果一起保留。

逐一改变因素有助于排除某些混杂，却不意味着因素没有交互。一个学习率在弱惩罚下有效，在强惩罚下可能不再有效。完整网格能观察这类依赖，代价是计算数随维度增加。若每轴 m 个值、 d 个维度，完整网格需要 m^d 组配置；配对种子再乘相应重复数。

正值超参数跨几个数量级时，可以令 $u \sim U[\log a, \log b]$ ，再取 $\eta = e^u$ ；在这个指定分布下，各等比区间得到相同概率。0不能取对数，因此无惩罚的 $\lambda = 0$ 须作为单独候选。若目标良好区域在搜索分布中的概率为 p ， B 次独立随机候选至少命中一次的概率是 $1 - (1 - p)^B$ 。这依赖候选独立且区域固定；不是随机搜索必胜的定理。

Bergstra与Bengio的一手研究说明，少数超参数主导表现时，随机搜索在重要方向上常能探索更多不同取值。本讲仍用二维小网格，因为它便于完整展示交互与每个相邻对照；没有用一个网格实验冒充验证了随机搜索优势。[S2]

12 验证集为什么也会被过拟合

最简单的精确反例不需要训练网络。假设 K 个候选本来都一样好：对独立未来样本，错误概率均为 $1/2$ 。每个候选只用一个验证样本计0或1错误，而且为了这个反例，假设各候选验证错误彼此独立。挑选验证错误最小者时，只有 K 个都错，最小错误才是1。因此

$$E[\min_k \hat{R}_k] = (1/2)^K,$$

而被挑中者在独立新样本上的错误概率仍是 $1/2$ 。 $K = 2$ 时，验证最小误差期望0.25，看起来优于0.5；其实没有任何候选变强。 $K = 8$ 时验证期望只有 $1/256$ 。这里候选错误独立是特设条件，真实模型往往相关，不能直接套这个数值公式。

另一项模拟令所有候选真分数都为1，验证测量和独立审计各加独立 $N(0, 0.1^2)$ 噪声。固定2000次重复，比较 $K = 1, 4, 16, 64$ 。候选越多，验证赢家越容易带着有利的测量噪声；独立审计均值仍在1附近。它是分数噪声机制实验，不是2000次神经网络训练。




图12 左图可穷举核对，右图来自固定随机模拟。两种例子共同说明选择与评价不能使用同一份噪声证据。

Cawley与Talbot研究了模型选择层面的过拟合及评价偏差。实际公平比较应把调参流程视为拟合算法的一部分；嵌套交叉验证的外层每次都要重新完成内层选择，而不是先用全数据调好参数，再把数据重新分成所谓“未见”测试折。[S1]

主实验采用一次独立测试集，但这也有使用条件：看完测试结果后不能继续按它挑设置；若现实工作确实这样做了，必须承认它已参与开发，并重新安排新的评价来源。给验证赢家加一个普通验证bootstrap区间，不会自动修复选择偏差。

13 冻结选择后的最终比较

部署对象预先规定为同一配置下3个种子模型的预测均值。注意，“先平均预测再算平方损失”与“先算3个模型损失再平均”一般不相等；本讲选择时用后者的验证分数，最终部署报告则针对前者，明确写出差别，不混用。当前选择规则不保证让集成验证损失最小；若要优化集成的验证表现，应在运行前另行规定用集成预测选择的规则。

在选择固定后，脚本才把测试标签交给final_evaluate。该函数只比较参照集成、选出集成，以及预先列出的训练均值常数和训练最小二乘直线。search的参数中没有test对象；执行记录显示先完成选择，再完成诊断，最后做固定测试比较。文件哈希校验可以提前读取测试文件字节，但不使用测试标签计算选择分数。

固定最终对象	测试half-MSE	测试RMSE
参照: $\eta = 0.05, \lambda = 0.001$ 的3模型均值	0.05093144	0.31915965
选出: $\eta = 0.2, \lambda = 0$ 的3模型均值	0.04840490	0.31114274
训练集拟合的最小二乘直线	0.06533719	0.36148910
训练标签均值常数	0.31226708	0.79027474




图9 512例测试样本及冻结模型预测。已知条件均值只来自合成生成公式，用于解释；没有用它重新训练或选择。

test.csv公开后，任何读者都能看见标签；代码顺序和协议可以证明默认脚本没有用它做选择，不能物理阻止后来的人反复调参。科研报告应区分可审查的流程约束与真正封存的数据治理。

14 分组误差和区间应支持什么结论

测试左组269例，右组243例。选出集成的half-MSE分别约0.024304与0.075085；参照分别约0.025269与0.079340。右组较大误差的一部分可由更大的条件噪声解释：若条件均值完全已知，左右组的理论不可约half-MSE分别为 $0.1^2/2 = 0.005$ 和 $0.35^2/2 = 0.06125$ 。模型实际误差还含估计和近似因素；有限样本的观测误差不会恰好等于期望。




图10 同时报组大小、损失与有符号残差。总体平均不能替代分组检查；分组差异也不能自动变成现实因果或公平性结论。

对每个测试ID i ，定义配对差

$$d_i = \frac{(\hat{y}_{i,\text{selected}} - y_i)^2 - (\hat{y}_{i,\text{baseline}} - y_i)^2}{2}.$$

每次有放回抽512个测试ID，用同一批ID同时取两种预测，计算平均差。固定种子4091重复2000次，用2.5%与97.5%分位数形成百分位bootstrap区间。平均差为 -0.00252654 ，区间约 $[-0.00417487, -0.00100847]$ 。




图11 配对差分布与逐样本差。这个区间条件于当前训练数据、选择过程和已经拟合的模型；不覆盖重新收集训练数据、重新调参或分布漂移的不确定性。

本生成器的测试行是独立抽样，因此以行作为重采样单位有明确依据。若多行来自同一人、同一设备或同一时间序列，应依022重新考虑独立单位，不能照搬按行bootstrap。3个初始化种子的变化也不是512个测试例的抽样变化，两种不确定性来源不能靠混在一张表里解决。

15 从日志写出下一次实验

一次好的诊断记录应包括原始现象、至少两个解释、区分它们的实验、固定项、改变项、预算、失败规则 and 结论边界。比如“步长很小的某些初值验证差”对应优化不足与坏初始表示两种解释；保持同一初值，比较全部相邻学习率对照，比换一个幸运种子更能区分它们。

本次没有证明饱和改善的机制，也没有证明随机标签探针的唯一失败原因；这些是清楚保留下来的开放问题。若接着研究输入尺度，应建立新的开发计划，不能再拿已经用过的512例测试来证明新结论。若要比训练成本，应真正测量统一环境下的耗时和资源，不能把更新计数直接改名为效率。

学习到这里，应能在041迁移学习中提出更严格的问题：冻结表示是否限制了可达函数；微调是否只是增加了预算；源任务是否提供了适合目标任务的特征。040提供的是形成证据的方式，而不是一个永远正确的调参顺序。

16 阅读核验与练习

先独立重算两轮七参数链，再运行实验。检查任意一个训练状态的参数、目标和下一步更新是否一致；查找3次失败的停止原因；核对全部12组单因素比较，找出一个正差值；解释为什么输入饱和的反例不能被删。最后用自己的话写出bootstrap区间覆盖和不覆盖的随机性。

单独实验指南给出运行、数据和文件字段；详解逐题展示推导与数值。所有曲线均由已保存的实际运行生成，没有用预设形状替代训练。主要来源为S1模型选择偏差、S2随机搜索、S3神经网络调试建议与S4官方SGD语义；具体查阅位置与适用边界见sources.md。