

041 迁移学习与适配练习详解

本解答沿着同一模型和同一批两条样本展开。你应先独立算一次，再用程序核对。计算正确与研究结论可信是两层要求；最后几题专门考察怎样限制结论。

1 完整梯度与单样本退化

$k = \log(3)/2$ ，输入为 $(1, 0), (0, 1)$ ，标签为 $1, -0.4$ ，参数为 $(k, -k, 0, 2, 0.1)$ 。前向得到 $z = (k, -k)$ 、 $h = (0.5, -0.5)$ 、预测 $(1.1, -0.9)$ 、残差 $(0.1, -0.5)$ 。逐样本半平方损失为 $(0.005, 0.125)$ ，平均损失 0.065。

损失归约导数均为 $1/2$ ；平方误差对预测导数分别为0.1和-0.5；预测对h导数均为2，对v导数为h，对b导数为1；tanh局部导数均为0.75；z对a导数为对应输入，对c导数为1。因此 $q = (0.05, -0.25)$ ， $d = (0.075, -0.375)$ 。

样本	对a1贡献	对a2贡献	对c贡献	对v贡献	对b贡献
1	0.075	0	0.075	0.025	0.05
2	0	-0.375	-0.375	0.125	-0.25
合计	0.075	-0.375	-0.300	0.150	-0.200

对输入的两行梯度为 $(0.075k, -0.075k)$ 和 $(-0.375k, 0.375k)$ 。输入不是参数，但也能作为可微变量。冻结参数不使这些数学导数消失。

只更新头且学习率0.2时， $v' = 1.97, b' = 0.14$ 。完整新前向仍有 $z = (k, -k), h = (0.5, -0.5)$ ，预测变成 $(1.125, -0.845)$ ，误差 $(0.125, -0.445)$ ，损失 $(0.0078125, 0.0990125)$ ，平均0.0534125。第一条损失从0.005上升，但第二条下降更多；总梯度针对平均损失，不保证逐样本改善。

全参数分组同步更新时，表示步长0.1、头步长0.2：

$$\theta' = (k - 0.0075, -k + 0.0375, 0.03), \quad \phi' = (1.97, 0.14).$$

随后两样本新前向为：

样本	z	h	预测	残差	半平方损失
1	0.571806144	0.516684484	1.157868434	0.157868434	0.012461221
2	-0.481806144	-0.447688925	-0.741947181	-0.341947181	0.058463937

新平均损失为0.035462579。

这些数值均来自重新前向。每条局部导数在新参数点也要重新算，不能沿用旧h或旧v。
calculations.json保存三套完整追踪：旧参数、分组更新后、冻结更新后。

2 偷换参数会改变更新规则

如果先把 v 更新成1.97，却仍使用旧误差 $e_1 = 0.1$ 和旧表示 $h_1 = 0.5$ ，样本1对a1的“混合梯度”变成

$$\frac{1}{2} \times 0.1 \times 1.97 \times 0.75 \times 1 = 0.073875.$$

它不同于旧点真实梯度0.075，也不是完整新点的梯度，因为新点的预测、误差和h也应改变。混用新旧值没有对应本讲目标函数在同一点的导数。即使最后损失碰巧降低，也不能称其实现了指定的同步SGD。

正规顺序是旧参数前向、旧参数反向、收集全部梯度、同时更新、下次从头前向。分组学习率只改变更新乘数，不改变反向中使用的参数时刻。

3 冻结中间层但训练前置适配器

设输入适配器为 $u = r_\psi(x)$ ，中间固定层为 $h = f_\theta(u)$ ，任务头为 $g_\phi(h)$ 。虽然不更新 θ ，仍需要

$$\nabla_\psi L = J_{r,\psi}^\top J_{f,u}^\top \nabla_h L.$$

固定 θ 不应删去中间雅可比 $J_{f,u}$ 。把表示参数设为requires_grad=False，保留正常前向图，便能传回适配器。对h执行detach或用no_grad包住f会切断这条路径；头仍可学习，但前置适配器得不到经f传来的梯度。

eval是另一个维度。它改变某些模块的训练态行为，不能代替冻结或求导控制。参数全部冻结的BatchNorm在train模式仍更新running_mean；eval才使用其推理规则。若我们确实希望目标域统计更新，则应把这一策略作为额外适配方法报告，并明确哪些目标数据可用于统计估计，不能偷偷使用测试批次。

还要清空旧grad并检查优化器状态。不能把“grad是None”和“grad是零”混为一谈：具体优化器对它们的跳过行为可能不同；本讲不依赖这种偶然差异来实现冻结。

4 条件方差分解的成立范围

设 $m(H) = \mathbb{E}[Y \mid H]$ 。展开

$$Y - q(H) = (Y - m(H)) + (m(H) - q(H)).$$

平方后第一项条件期望为 $\text{Var}(Y \mid H)$ ，第二项是仅依赖H的平方，交叉项条件期望为零。再对H求期望，得到正文分解。只需要相关二阶矩存在，不需要神经网络或正态分布。

给定H最优的平方误差预测器是 $m(H)$ 。若H只由 X_1 决定， X_2 独立于 X_1 ，目标依赖 X_2 与独立零均值噪声，那么H对目标没有额外预测信息，最优预测退化为均值。

这不能直接计算当前模型的精确测试MSE：有限源训练并未强制 a_2 严格为零；经验测试均值也有抽样误差；我们的冻结头还受仿射形式和岭惩罚限制。该分解说明不可恢复信息的机制，不是把理想极限数值硬贴到有限网络上。

5 域和任务可以分别变化

源输入两个坐标都是均匀分布 $[-2, 2]$ 。目标第一坐标变为 $[-1.5, 2]$ ，第二不变，所以源到目标输入边缘分布发生变化。相关目标维持同一条件标签规则，是该构造中的协变量移位。

正交目标在同一目标 x 上将标签从 $\tanh(1.2x_1)$ 改成 $\tanh(1.2x_2)$ ，因此相关与正交之间是任务规则变化。正交目标相对于源同时经历域变化和任务变化。即使源和目标输入分布完全相同，标签规则改变仍然是任务变化。

“负迁移”不是第三种分布变化的名称，而是方法相对对照退化的经验结论。必须指明评价风险、从零方法、初始化配对、目标标签量和预算。

6 岭探测的闭式最优和局限

目标为 $J(\beta) = \|\Phi\beta - y\|^2/(2n) + \lambda\beta^\top D\beta/2$ 。逐项求导：

$$\nabla_{\beta} J = \Phi^\top (\Phi\beta - y)/n + \lambda D\beta.$$

令梯度为零可得正文的正规方程。惩罚只约束特征斜率，不惩罚截距，避免仅因标签整体平移就产生不必要的均值收缩。这个约定不是唯一可能的正则化定义，但必须在实现和解释中一致。

若 λ 正，除截距外所有坐标都被惩罚，截距列为全一且 n 非零，则对任意非零向量 u ， $\|\Phi u\|^2/n + \lambda u^\top D u > 0$ ：有非零斜率时第二项正；仅有非零截距时第一项正。因此系统正定。这解释本例可解，不应推广为 λ 零时任何特征矩阵都可逆。

测试对所有108个岭候选用独立构造的特征矩阵检查正规方程残差；残差很小说明解对应指定目标。它不说明冻结表示足够好，也不说明RBF带宽已经最优。

7 标签预算和计算预算

16条训练标签的实验还用了128条验证标签，所以目标开发监督是144条标签；64条方案是192条。每任务512条测试标签属于评价成本，不作为拟合或选择监督。两目标共用输入但每种标签定义都必须明确。

单个神经方法、指定任务与 n 、指定种子，有3个候选各160步，总480次更新、480 n 次目标训练样本呈现。 n_{16} 时是7680次呈现， n_{64} 时是30720次。每一步额外评估128条验证数据，虽然没有反向传播，计算时间仍不为零。

源模型每个种子600步乘512条，为307200次源样本呈现；三个种子为921600。144个目标神经候选共有23040次更新、921600次目标训练样本呈现。每个序列还记录第0步，所以神经目标历史为144乘161，即23184行，源历史为3乘601，即1803行。

108个目标岭候选是直接线性求解，不应伪装成160步神经训练；LPFT还额外做36次固定惩罚初始化岭解。端到端预算没有匹配。若要公平比较部署可支付的总计算，还需测源成本如何摊销、多个目标复用次数、设备、峰值内存和实际计时边界。

8 如何解释有限协议下的负迁移

当前正交任务n64的均值MSE，从零0.00765，小步微调0.59977，而等步微调0.00680。三个小步微调种子都比其从零配对更差，这不是只挑出一条失败种子。它支持当前小步适配协议在这个任务和预算内负迁移。

不能由此推断所有预训练失败：等步微调是实际恢复反例。也不能把冻结与小步微调的失败完全归为一个原因：冻结限制表示函数族，小步微调允许修改但变化速度有限。LPFT头斜率可能变小，使表示梯度中的 v 因子变小；观察这一轨迹是机制线索，不是排除全部其他解释的因果证明。

下一项实验可固定相同训练/验证拆分及标签量，预先声明表示步长倍率和步数网格，同时运行从零和两种微调。若增加预算，要报告每个候选更新数和总搜索成本；不能把新长训练结果直接和旧短基线写成等预算优势。

当前测试结果已经被阅读，应另外生成新的开发和测试随机种子，并在新测试打开前冻结选择。若要估计数据抽样波动，必须重复完整数据生成、训练和选择过程；仅增加初始化种子不足以代表数据分布不确定性。RBF不随初始化变化，三份重复数值不能贡献三个独立样本。

9 延伸检查

若相关任务冻结表现很好，但解冻后变差，先检查是否学习率过大、数据太少、归一化状态改变、头与表示步长不匹配、标签定义错误或源表示本来已经足够。没有证据前不要把任何退化都命名为灾难性遗忘。

若要声称遗忘，需要合法的源保留评价集或明确旧能力测验，区分源训练误差、源泛化和目标表现。本实验没有独立源测试，所以不能据源训练损失变化就证明真实旧任务能力遗忘。

若要研究输入域变化本身，可保持同一条件标签规则，改变目标输入分布，并设置多个独立目标测试域。本讲的目标测试与目标训练同分布；这不是一个额外的目标分布外测试套件。