

042 练习详解

答案给出推导、数值检查点和结论边界。先独立尝试，再对照原始轨迹。

1 复制记录后哪种风险不变

A有两行、B有一行，逐行损失为 $(0, 0, 2)$ 。行风险为 $(0 + 0 + 2)/3 = 2/3$ 。实体风险先平均A得到0，B得到2，再平均两个实体，结果为1。

完整复制A的记录一次后，行损失为 $(0, 0, 0, 0, 2)$ ，行风险降为 $2/5$ 。实体风险仍为 $[0 + 2]/2 = 1$ 。因此复制同一个实体的全部记录没有改变实体风险，却改变了行风险；如果只复制实体内某一条、而该实体其他行损失不同，实体内部均值也会改变，不能随意推广“不变”。

一般地，行目标给实体 g 权重 m_g/N ，实体目标给它 $1/G$ 。当所有 $m_g = m$ 时， $N = Gm$ ，两种行权重都为 $1/(Gm)$ 。当 m_g 不同但各实体损失恰好相同，两个数值也可能相等，但那不说明两种抽样规则相同。

2 第一轮损失和局部上游

初始三例预测是 $(-0.25, 0.5, 1.25)$ ，标签 $(0, 1, 0)$ ，所以残差 $(-0.25, -0.5, 1.25)$ 。单行half-MSE为 $(0.03125, 0.125, 0.78125)$ ，权重 $(0.25, 0.25, 0.5)$ 后相加得0.4296875。

权重惩罚是 $0.1(0.5^2 + (-0.5)^2 + 1^2 + (-0.5)^2)/2 = 0.0875$ ，总目标0.5171875。对预测的上游 $u = qr$ 为 $(-0.0625, -0.125, 0.625)$ ，不是简单 $r/3$ 。

第一例到隐藏输出的上游为 $u(a_1, a_2) = (-0.0625, 0.03125)$ ，ReLU门都为1，所以到两个 z 也相同。再乘输入 -1 ，得到对 w 的贡献 $(0.0625, -0.03125)$ 。偏置贡献不乘 x 。

3 为什么要先加数据路径再加惩罚

三例数据贡献相加得

$$g_{\text{data}} = (0.6875, -0.34375, 0.4375, -0.21875, 0.78125, 0.09375, 0.4375).$$

惩罚梯度为 $(0.05, -0.05, 0, 0, 0.1, -0.05, 0)$ 。因此总梯度为 $(0.7375, -0.39375, 0.4375, -0.21875, 0.88125, 0.04375, 0.4375)$ 。

参数统一减去0.1倍总梯度，得到

$(0.42625, -0.460625, 0.95625, 1.021875, 0.911875, -0.504375, -0.04375)$ 。不能把正则项在三行各加一次再求和，那会变成三倍惩罚；也不能把 q 归一化后再除以3。

如果你确实定义的是求和风险而不是平均风险，应当相应说明惩罚系数和学习率的尺度，而不是假装两个目标仅仅写法不同。

4 第二轮全部梯度与新前向

第二轮预测为 $(-0.3081921875, 0.312822265625, 0.93383671875)$ ，数据损失约0.288912212204。
新上游为 $(-0.077048046875, -0.171794433594, 0.466918359375)$ 。

这一次输出权重为 $(0.911875, -0.504375)$ 。以 b_1 为例，到两隐藏单元的上游是 $(0.425771178955, -0.235501947510)$ ；输入为1，故对两个 w 贡献相同，对 a 贡献是 $u(1.3825, 0.56125) = (0.645514631836, 0.262057929199)$ 。

把三例贡献相加，再加新权重惩罚，得到下表。总梯度和参数都是显示近似，真正更新用精确Fraction账本。

参数	第二轮总梯度	第二次更新后参数
w_1	0.538654366699	0.372384563330
w_2	-0.320425556152	-0.428582444385
b_1	0.198857942078	0.936364205792
b_2	-0.109992021423	1.032874202142
a_1	0.531588239868	0.858716176013
a_2	-0.078155737122	-0.496559426288
c	0.218075878906	-0.065557587891

用这些新参数再次前向得到 $(-0.306959219910, 0.225630081020, 0.758219381949)$ ，总目标约0.295774145026。所有完整分数在hand_chain.json中；排版近似值不替代计算真值。

A2目标为1，预测反而从0.5继续下降，证明总目标下降不保证每行改进。它不是梯度错误，而是共享参数、权重及惩罚共同优化一个总标量的结果。

5 推导真实网络的参数数和梯度形状

二维输入、6个隐藏单元、一个输出：输入权重12，隐藏偏置6，输出权重6，输出偏置1，共25。批次输入为 $N \times 2$ ，隐藏矩阵 H 为 $N \times 6$ ，预测、残差和 u 均为长度 N 的向量。

对 $\tanh$ 有 $\partial h / \partial z = 1 - h^2$ ，因此 $D = (uv^\top) \odot (1 - H^2)$ 形状为 $N \times 6$ 。 $X^\top D$ 为 2×6 ，恰好匹配 W ； D 沿行相加为6，匹配 b ； $H^\top u$ 为6，匹配 v ； u 求和为标量，匹配 c 。

正则对 W, v 分别给出 $\lambda W, \lambda v$ ，偏置不加。把 $H^\top u$ 误写成 $u^\top H$ 虽然在一维数组语义下有时得到相似存储形状，也应先固定布局再实现；NumPy广播“能运行”不是公式正确的证据。

6 为什么预处理必须同一份

训练实体加权均值 $\mu = \sum_i q_i x_i$ 与标准差 s 只由训练数据拟合。两个MLP模式都使用它，所以对照中的明确变化是数据损失权重。

若按行条件用行加权尺度、按实体条件用实体加权尺度，两个模式同时改变了损失和输入参数化。即使最后有差异，也不能只归因于损失权重。若用全数据拟合尺度，又把测试分布信息提前注入流程。即使不读取测试标签，也不是原先声明的训练内预处理。

本讲测试会把验证标签翻转，检查短训练路径完全不变而验证分数改变。这说明验证标签不进入梯度更新；但模型选择本来就依赖验证分数，因此不能进一步声称验证标签对最终选中配置也无影响。

7 预算匹配的具体数字

每种目标有2个学习率 $\times$ 3个种子，共6次拟合，每次350次更新，所以每种目标2100次更新。每次更新读224行训练样本，得到 $2100 \times 224 = 470400$ 行次。两种目标合计12次拟合、4200次更新、940800行次。

每次运行保存初始状态和350次更新后的状态，共351个；12次总计4212个，乘25参数为105300个状态坐标。这里“坐标”指保存的参数数值数量，不是新增独立样本。

成本账本还包括四次三次多项式ridge、一次线性ridge和一次常数拟合。数据生成、验证前向、测试前向、有限差分 and 绘图也耗时；行样本呈现数不包含这些，不能冒称总运算量或墙钟时间。

8 平均模型损失为什么不同于集成损失

对同一个目标 y ，设三个模型预测 p_s ，均值 $\bar{p}$ 。展开平方得

$$\frac{1}{3} \sum_{s=1}^3 \frac{(p_s - y)^2}{2} = \frac{(\bar{p} - y)^2}{2} + \frac{1}{6} \sum_{s=1}^3 (p_s - \bar{p})^2.$$

交叉项为 $(\bar{p} - y) \sum_s (p_s - \bar{p}) = 0$ 。因此集成损失不大于平均单模型损失，但哪一个超参数最优仍可改变，因为预测分歧项也随超参数变化。

本协议用平均单模型验证损失选学习率，用平均预测报告固定集成；它没有声称选择规则直接最小化集成验证风险。若希望按集成选参，应在训练前写进新协议，不是在看见测试结果后改口径。

9 强基线的方程与结论

三次多项式有10列，截距列不惩罚。目标导数为 $\Phi^\top Q(\Phi\beta - y) + \lambda D^\top D\beta$ 。令其为0得到正规方程，但实现使用增广最小二乘而非显式逆矩阵；正规方程可以用于小问题的独立数值核对，不作为通用稳定求解建议。

验证选择 $\lambda = 0.01$ ，测试实体half-MSE约0.052475，小于实体MLP的0.090165及行MLP的0.140537。允许的结论是本次固定问题上这个强基线表现更好。它不证明所有多项式都优于网络，也不证明网络容量不足是唯一原因。

“从0.140537改善到0.090165，因此提出了优于传统方法的模型”是不成立的。改进参照模型和超越强基线是两个不同命题。

10 区间的重采样单位是什么

每个 d_g 先在实体内部平均两模型的损失差，再对160个实体平均。bootstrap每次抽160个实体索引，保留同一实体内部的全部重复行和两模型配对。结果约为点估计-0.0503723、95%百分位区间[-0.0784929,-0.0250965]。

如果同一实体被抽到两次，应贡献两次 d_g 。重新按原始ID去重会改变bootstrap分布。如果独立抽788行，就把相关重复测量拆散了；如果分别重采样两模型，就丢失配对带来的协方差信息。

这是固定训练和选择下对新实体抽样的条件性近似区间。要评价重训练和重新选参的整体算法，必须在新的外层重复训练、选择和评价中估计；仅重复初始化三个种子不能代替外层数据变化。

11 验证排序与区域退化怎样报告

验证中按行训练三种子平均分0.086825小于按实体训练的0.092875，但测试集成主分数排序相反。协议只在每种条件内部选学习率，并未让验证从两个方法中只选一个。所以保留并比较两个方法符合原协议。

可以提出小验证集、区域组成、种子波动和集成方式等解释，不能凭一张表就确定唯一原因。测试中左区域从0.044943变到0.050049，为退化；右区域从0.231468降到0.128323，整体仍改善。表述应同时包含总体收益、局部损失和强基线胜出。

若实际任务左区域错误代价更高，应在事前定义相应效用或约束，再制定新比较；不能看到结果以后换指标来保证某个方法获胜。

12 身份记忆反例与下一步研究

身份反例中，同一实体的前三行平均估计 b_g ，新一行减去该平均时 b_g 相消，只留下方差 $0.01 + 0.01/3$ ，再乘half-MSE的 $1/2$ 得到0.00666667。

全新实体的 b_g 不可见。用60个训练实体四行总均值作常数，常数估计方差为 $(1 + 0.01/4)/60$ ；新标签方差为1.01，两者独立，相加并除2得到0.51335417。两种实际损失0.006828与0.426475是有限样本观测，不要求恰等于期望。

一个合格的后续问题是：在固定总测量预算下，新增实体和增加重复次数对新实体风险有什么不同作用？需要预先指定实体数、重复次数、总预算及新的拆分；控制生成机制并保留所有结果。这是未来实验，不是本讲已经验证的结论。