

042 可靠神经网络阶段项目

把一个明确的问题，变成别人能重新计算、也能提出反驳的研究包。

1 从会训练走向会研究

前面各讲已经分别解释了风险、反向传播、优化、正则化和可信评价。这一讲不再增加一个听起来新颖的模型名字，而是把这些环节放进同一个问题：每个实体被测量的次数不同，直接对数据表的每一行平均，是否就是我们希望优化的目标？

这里的“实体”只是原创合成数据中的编号，可以帮助理解同一台设备、同一块材料或同一个模拟对象的重复测量；数据不代表任何真实个人或实际研究对象。部署问题先写清楚：遇到一个从未见过的新实体，在它的一次测量上预测连续目标。我们希望每个新实体对评价的贡献相同，而不是测量次数越多的实体越重要。

你将完成一个可审查的MLP研究包：七参数纸笔账本、25参数真实训练、全部候选和随机种子、一个三次多项式强基线、固定测试比较、实体配对区间及失败样本。先修040；讨论容量理论可以补038，采用预训练时才补041。本项目不依赖预训练、GPU或付费API。

本次结果值得同时记住两件事。相同神经训练预算下，按实体加权的MLP在这份测试集上优于按行加权的MLP；但两者都没有超过三次多项式ridge。前一个改进不能遮住后一个失败。我们的研究能力体现在能把二者解释清楚，而不是只保留有利于网络的一张图。

完整研究包的审计顺序




图1 从任务与抽样单位出发，逐项检查计算、选择、评价和结论。测试只在所有选择冻结后用于固定比较。

2 两种平均回答不同的问题

设共有 G 个实体，第 g 个实体有 m_g 次测量。第 j 次输入为 $x_{gj} \in \mathbb{R}^2$ ，目标为 $y_{gj} \in \mathbb{R}$ ，单行损失定义为 $\ell_{gj} = (f_\theta(x_{gj}) - y_{gj})^2/2$ 。数据表总行数是 $N = \sum_g m_g$ 。两种经验风险分别为

$$L_{\text{row}}(\theta) = \frac{1}{N} \sum_{g=1}^G \sum_{j=1}^{m_g} \ell_{gj},$$

$$L_{\text{entity}}(\theta) = \frac{1}{G} \sum_{g=1}^G \frac{1}{m_g} \sum_{j=1}^{m_g} \ell_{gj}.$$

前者先等概率抽一行。实体 g 被抽到的概率是 m_g/N 。后者先等概率抽一个实体，再在该实体内等概率抽一次测量。每行权重变成 $q_{gj} = 1/(Gm_g)$ ，所有权重仍然加起来等于1。它们不是同一个平均数的两种实现；当重复次数和输入区域有关时，改变权重会改变训练目标。

最小例子有实体A的两行和实体B的一行。如果逐行损失是 $(0, 0, 2)$ ，行平均为 $2/3$ ，实体平均是 $[0 + 2]/2 = 1$ 。把A的两行完整复制一遍，实体平均仍是1，行平均却降为 $2/5$ 。这个操作没有增加独立实体信息，不能解释成模型真的改进。

如果所有 m_g 相等，两种权重完全相同。如果部署是按测量流量计费、每条测量都同等重要，那么行风险可能正是适合的目标。按实体加权不是道德标签，也不是自动提高所有任务性能的技术。首先要知道现实问题怎样产生一次预测请求。




图2 左侧是三行纸笔例子的权重。右侧是实际数据中左区域的行比例与实体比例；同一张表在两种抽样规则下代表不同质量。

3 数据生成过程与信息边界

每个实体有中心 $u_g \sim \text{Uniform}([-2, 2]^2)$ 和共享偏移 $b_g \sim \mathcal{N}(0, 0.25^2)$ 。若中心第一坐标小于0，测量8次；否则测量2次。测量输入是 $x_{gj} = u_g + \epsilon_{gj}$ ，其中 $\epsilon_{gj} \sim \mathcal{N}(0, 0.05^2 I)$ 。目标为

$$y_{gj} = 0.7 \sin(1.5x_{gj,1}) + 0.35x_{gj,1}x_{gj,2} + 0.25x_{gj,2}^2 + b_g + \xi_{gj},$$

其中 $\xi_{gj} \sim \mathcal{N}(0, 0.08^2)$ ；不同实体及所声明的噪声来源独立。共享的 b_g 使同一实体的残差相关。相近输入也是由同一个中心生成的，所以“788行”不等于“788个独立实体”。分组标签由潜在中心定义，少量带噪测量可以越过 $x_1 = 0$ ，不能重新按观测符号改写原来的区域。

生成器分别用种子4200、4201、4202建立互不重叠的训练、验证和测试实体。行ID、实体ID、重复编号、两个输入、目标和区域全部公开。ID只用于拆分、加权和评价，绝不进入主模型特征；未观察到的中心和共享偏移也不输入模型。

拆分	独立实体数	测量行数	左区域实体数	左区域行比例
训练	40	224	24	85.71%
验证	32	190	21	88.42%
测试	160	788	78	79.19%

训练与验证左区域实体比例分别为60%和65.625%，测试为48.75%。这是固定小样本的一次抽样结果，并没有人为把验证组成改到和测试一致。协议、数据与生成种子在训练前固定；事后不能因区域结果不理想而重新抽一份更有利的数据。

完整性检查会读取所有文件的字节并比较哈希；这不等于用测试标签选择模型。程序只在选择完成后解析测试表。这个结构边界有用，但文件公开后读者仍可主动窥看标签，因此它是可重复教学实验，不是长期保密的盲测排行榜。




图3 所有点来自原创合成过程。空间上紧密的小簇是重复测量，不是多个独立证据；颜色仅表示目标值，超出色标端点的值使用端点色。

4 把加权目标放进同一个纸笔网络

用三行 $(x, y) = (-1, 0), (0, 1), (1, 0)$ ，前两行属于A，第三行属于B，所以 $q = (1/4, 1/4, 1/2)$ 。这只是用于手算的一维微型例子，不混入二维主实验。网络定义为


$$z_{ij} = w_j x_i + b_j, \quad h_{ij} = \max(0, z_{ij}), \quad \hat{y}_i = a_1 h_{i1} + a_2 h_{i2} + c.$$

参数顺序固定为 $\theta = (w_1, w_2, b_1, b_2, a_1, a_2, c)$ ，初值为 $(0.5, -0.5, 1, 1, 1, -0.5, 0)$ 。本段学习率 $\eta = 0.1$ ，正则系数 $\lambda = 0.1$ ，只惩罚权重，目标为

$$J(\theta) = \sum_{i=1}^3 q_i \frac{(\hat{y}_i - y_i)^2}{2} + \frac{\lambda}{2} (w_1^2 + w_2^2 + a_1^2 + a_2^2).$$

主实验稍后使用tanh与更小的正则系数；纸笔实例的作用是逐节点展示链式法则、加权和惩罚的接法，不把它冒充实际25参数网络的训练日志。

纸笔网络的局部计算路径



三例共享七个参数；正则项 $\lambda\theta$ 另加到权重坐标，不添加到偏置

图4 每个样本先得到自己的预测和加权损失；七个参数由三行共同使用。反向累加数据贡献以后，再加相应权重坐标的惩罚导数。

第一例 $z_1 = 0.5(-1) + 1 = 0.5$, $z_2 = (-0.5)(-1) + 1 = 1.5$ ；两个ReLU门都打开，所以 $h = z$ 。预测为 $1(0.5) - 0.5(1.5) = -0.25$ ，残差也是 -0.25 。另外两例用同一组旧参数计算如下。

行	$z_1 = h_1$	$z_2 = h_2$	预测	残差 r	$r^2/2$	加权损失 $qr^2/2$
A1	0.5	1.5	-0.25	-0.25	0.03125	0.0078125
A2	1	1	0.5	-0.5	0.125	0.03125
B1	1.5	0.5	1.25	1.25	0.78125	0.390625

相加得到 $L_0 = 0.4296875 = 55/128$ 。惩罚项是 $0.05(0.25 + 0.25 + 1 + 0.25) = 0.0875$ ，所以 $J_0 = 0.5171875 = 331/640$ 。偏置没有被惩罚；也不能在加权求和以后再除以3，否则会偷偷改变数据项和正则项的相对尺度。

5 局部导数与所有共享参数的累加

平方损失对预测的局部导数是 r_i 。权重乘法再给出上游 $u_i = q_i r_i$ ；输出到隐藏层的局部导数为 a_j ；ReLU到 z 的局部导数是 $\mathbf{1}[z_{ij} > 0]$ ； z 对 w_j 和 b_j 的局部导数分别为 x_i 和 1。记

$$v_{ij} = u_i a_j \mathbf{1}[z_{ij} > 0].$$

每行对七个参数的贡献依次是

$$(v_{i1}x_i, v_{i2}x_i, v_{i1}, v_{i2}, u_i h_{i1}, u_i h_{i2}, u_i).$$

本轮 $u = (-0.0625, -0.125, 0.625)$ ，两条隐藏支路的 v 分别为 $(-0.0625, 0.03125)$ 、 $(-0.125, 0.0625)$ 、 $(0.625, -0.3125)$ 。例如第一例对 w_1 的贡献是 $(-0.0625)(-1) = 0.0625$ ，第三例贡献是 $0.625(1) = 0.625$ 。它们流入同一参数，应当相加。

参数	A1贡献	A2贡献	B1贡献	数据梯度
w_1	0.0625	0	0.625	0.6875
w_2	-0.03125	0	-0.3125	-0.34375
b_1	-0.0625	-0.125	0.625	0.4375
b_2	0.03125	0.0625	-0.3125	-0.21875
a_1	-0.03125	-0.125	0.9375	0.78125
a_2	-0.09375	-0.125	0.3125	0.09375
c	-0.0625	-0.125	0.625	0.4375

惩罚导数在四个权重上为 $\lambda\theta_k$ ，在三个偏置上为0。将它加到上表最后一列后，统一执行 $\theta_1 = \theta_0 - 0.1\nabla J(\theta_0)$ 。

参数	惩罚梯度	总梯度	同步更新后的参数
w_1	0.05	0.7375	0.42625
w_2	-0.05	-0.39375	-0.460625
b_1	0	0.4375	0.95625
b_2	0	-0.21875	1.021875
a_1	0.1	0.88125	0.911875
a_2	-0.05	0.04375	-0.504375
c	0	0.4375	-0.04375

计算 w, b 的梯度时，仍然必须用旧的 a 。如果先更新 a 再反传到第一层，得到的就不是同一个参数点的梯度。全批量同步更新并不等于逐行更新三次。

6 第二轮完整重算及第三次前向

新参数重新代入三行，得到下表。所有 z 仍大于0，所以这次门导数依然为1；这只是本实例的事实，不是对所有ReLU的省略规则。

行	新 z_1	新 z_2	新预测	新残差	新 $u = qr$
A1	0.53	1.4825	-0.3081921875	-0.3081921875	-0.077048046875
A2	0.95625	1.021875	0.312822265625	-0.687177734375	-0.171794433594
B1	1.3825	0.56125	0.93383671875	0.93383671875	0.466918359375

例如A1预测为 $0.911875(0.53) - 0.504375(1.4825) - 0.04375$ 。三行加权损失依次为0.011872803055、0.059026654828、0.218012754321，总数据损失为0.288912212204；权重惩罚为0.073988730469，总目标为0.362900942672。

新隐藏上游分别为 $(-0.070258187744, 0.038861108643)$ 、 $(-0.156655049133, 0.086648817444)$ 、 $(0.425771178955, -0.235501947510)$ 。它们使用新输出权重，不沿用第一轮的值。乘 x 或乘 h 后，每一条参数路径都得到新贡献。

参数	A1新贡献	A2新贡献	B1新贡献	新数据梯度
w_1	0.070258188	0	0.425771179	0.496029367
w_2	-0.038861109	0	-0.235501948	-0.274363056
b_1	-0.070258188	-0.156655049	0.425771179	0.198857942
b_2	0.038861109	0.086648817	-0.235501948	-0.109992021
a_1	-0.040835465	-0.164278427	0.645514632	0.440400740
a_2	-0.114223729	-0.175552437	0.262057929	-0.027718237
c	-0.077048047	-0.171794434	0.466918359	0.218075879

参数	新惩罚梯度	新总梯度	第二次更新后的参数
w_1	0.042625	0.538654367	0.372384563330
w_2	-0.0460625	-0.320425556	-0.428582444385
b_1	0	0.198857942	0.936364205792
b_2	0	-0.109992021	1.032874202142
a_1	0.0911875	0.531588240	0.858716176013
a_2	-0.0504375	-0.078155737	-0.496559426288
c	0	0.218075879	-0.065557587891

表中为了排版而四舍五入；程序用Fraction保存精确分数，不能用表中短小数作为后续真值。再次前向的三个 z 向量约为 $(0.563979642462, 1.461456646527)$ 、 $(0.936364205792, 1.032874202142)$ 、 $(1.308748769122, 0.604291757758)$ 。预测依次为 -0.306959219910 、 0.225630081020 、 0.758219381949 ，数据损失约 0.230458249555 ，总目标约 0.295774145026 。




图5 每一列对应同一个共享参数。三条样本路径和一条正则路径相加，才是用于同步更新的总梯度；颜色采用相同的正负尺度，格内数字仅为显示近似。

A2的预测从0.5降到0.3128再到0.2256，与标签1反而更远，而总目标持续下降。这不是反向传播错误：加权总目标可能通过改善权重更大的B1而牺牲某些样本。一个总损失数值不能保证每个实体、每个区域或每次预测都改进。




图6 两轮更新后必须实际重做前向。总目标下降与单行误差改善是不同命题，本例保留了A2变差的事实。

7 从七参数账本到25参数实际网络

真实项目用 $X \in \mathbb{R}^{N \times 2}$ ，先在训练实体上拟合逐特征均值与总体标准差： $\mu_k = \sum_i q_i^{\text{entity}} x_{ik}$ ， $s_k^2 = \sum_i q_i^{\text{entity}} (x_{ik} - \mu_k)^2$ ，再令 $\tilde{X}_{ik} = (x_{ik} - \mu_k)/s_k$ 。验证和测试只应用这组尺度，不重新估计。两个MLP条件使用完全相同的实体加权尺度，因此主对照只改变训练损失权重。

网络为 $H = \tanh(\tilde{X}W + \mathbf{1}b^\top)$ ， $\hat{y} = Hv + c\mathbf{1}$ 。形状分别是 $W: 2 \times 6$ 、 $b: 6$ 、 $v: 6$ 、 $c: 1$ ，共 $12 + 6 + 6 + 1 = 25$ 个参数。 $\tanh$ 是平滑非线性，便于全坐标有限差分；它并不因平滑而自动消除饱和或非凸优化困难。

对任意一种已归一化权重 q , 令 $r = \hat{y} - y$, $u = q \odot r$, 则

$$D = (uv^\top) \odot (1 - H \odot H),$$

$$\nabla_W J = \tilde{X}^\top D + \lambda W, \quad \nabla_b J = \sum_i D_{i,:},$$

$$\nabla_v J = H^\top u + \lambda v, \quad \nabla_c J = \sum_i u_i.$$


主实验 $\lambda = 0.002$, 不惩罚 b, c 。这四式就是纸笔账本的批次形式：先产生各行上游, 再沿隐藏单元路径传播, 最后对共享参数累加。若 q 已经和为1, 就没有另一个 $1/N$ 。没有dropout、BatchNorm或小批次随机抽样, 以免给这次“只改权重”的对照加入额外因素。

程序用PyTorch求梯度, 测试另写NumPy公式并对200个随机参数坐标做中心差分。作者核验还用逐样本显式累加的实现重建全部4200次更新和105300个参数状态坐标; 它避免仅把同一训练函数再调用一次就称为独立核验。通过这些检查支持实现对应公式, 不证明该模型在真实任务上合适。

8 先冻结预算与选择规则

两种权重各有两个学习率候选0.03和0.1, 每个候选使用相同的三个初始化种子4211、4212、4213, 均做350次全批量同步更新。每个条件是6次拟合、2100次更新、470400行样本呈现; 两条件合计12次拟合与4200次更新。

样本呈现数只计参与梯度更新的训练行, 不含验证前向、记录、梯度核验和绘图。相同宽度、步数、行数并不等于已测得相同墙钟时间; 权重处理也有小开销。这里匹配的是明确列出的神经训练预算, 没有测量或宣称总计算优势。



强基线另报4次十系数三次多项式拟合; 不冒称与梯度下降等计算量

图7 两个MLP条件的候选、种子、参数数、更新数和行样本呈现预算对应。经典求解器的成本单独披露, 不能把一次最小二乘求解等同一次神经更新。

在每种权重条件内部，按三个种子的最终验证实体half-MSE平均值选择学习率，严格平局按协议中候选顺序。禁止看测试结果后改候选、换种子或改训练步数。不用早停；350步既不称作收敛，也不保证已找到该网络的最好参数。

最终部署用选中学习率的三个模型预测平均。注意“单模型损失的平均”不同于“平均预测的损失”。平方损失下，后一项不大于前一项，但本协议按前一项选配置，没有声称为集成预测直接找到了最优超参数。每个模型的预测和两种层级的结果都保留。




图8 这里只画被选择学习率的六条完整训练路径，每个面板三种子，各有训练和验证曲线。绘图统一使用实体风险，不能拿两个不同加权训练目标的绝对值比较优劣。

9 验证结果也可能和测试排序不同

训练权重	学习率	三种子平均验证实体half-MSE
按行	0.03	0.14729935
按行	0.1	0.08682504
按实体	0.03	0.13222828
按实体	0.1	0.09287519

两个条件都选0.1。在这份验证集上，按行训练的平均单模型损失还略低于按实体训练。这一点必须保留。我们预先指定比较两种条件，并在各自内部调学习率，没有验证后只留下分数更好的一个条件。如果实际部署协议是“在所有方法中选一个最优方法”，就需要按那个协议评价，不能事后改成同时保留两者。

验证实体只有32个，且区域组成与测试不同；有限样本、初始化变化和集成方式都可能影响排序。观察到排序改变本身不能证明唯一原因。要检验哪个因素有贡献，需要新的受控实验；当前测试集不能继续充当调试反馈。




图9 所有四个候选和十二个种子结果都在图中。折线表示固定候选的平均分，不表示两个学习率之间的连续性能定律。

10 强基线为什么是项目的一部分

常数预测器取训练实体加权目标均值。线性ridge使用常数、两个标准化输入，共3个系数，固定 $\lambda = 0.001$ 。它们能说明网络学到了多少非线性，但只有线性基线仍然可能过弱。

强基线使用两个标准化输入的总次数不超过3的所有单项式：1, $z_1, z_2, z_1^2, z_1 z_2, z_2^2, z_1^3, z_1^2 z_2, z_1 z_2^2, z_2^3$ ，共10个系数。训练目标为

$$\frac{1}{2} \|Q^{1/2}(\Phi\beta - y)\|_2^2 + \frac{\lambda}{2} \|D\beta\|_2^2,$$

其中 $Q = \text{diag}(q^{\text{entity}})$, $D = \text{diag}(0, 1, \dots, 1)$ 使截距不受惩罚。程序求增广系统 $[Q^{1/2}\Phi; \sqrt{\lambda}D]$ 与 $[Q^{1/2}y; 0]$ 的最小二乘解，不显式求逆。

候选 λ 为 0.0001、0.001、0.01、0.1，对应验证分数约 0.050787、0.050481、0.048259、0.049990，选择 0.01。四次多项式求解、一次线性求解和一次常数拟合都记录在成本账本中；这些求解没有与神经网络匹配墙钟时间，不能比较“同算力效率”。强基线的作用是检验我们是否只打败了一个太弱的对手。




图10 多项式强基线的四个候选全部保留。绿色是由验证集选出的0.01，不是由测试集回选的参数。

11 冻结后的测试结果与局部退化

固定模型后，才解析160个测试实体的788行测量。每个实体先在自己的重复测量内平均损失，再对实体平均。以下数字都不含正则惩罚。

模型	全部实体half-MSE	左区域	右区域
按行训练MLP集成	0.14053700	0.04494311	0.23146778
按实体训练MLP集成	0.09016470	0.05004941	0.12832314
三次多项式ridge	0.05247549	0.03102165	0.07288281
线性ridge	0.25624283	0.14179978	0.36510329
常数	0.33671058	0.22804165	0.44007858

主比较的差值是 $0.09016470 - 0.14053700 = -0.05037230$ ，负值表示实体加权条件在主指标上更好。但左区域从0.04494311上升到0.05004941，是退化；右区域下降幅度较大，带动整体改善。因此不能写成“按实体加权对所有区域都有益”。

两者的逐行测试平均又分别为0.08376296和0.06633989，与实体平均不同。报告时必须带上指标的抽样单位，不能把0.1405和0.0663横向拼起来，夸大改进。全部区域内重复次数相同，区域内部的行均值与实体均值相等；总体的区域权重不同，才产生总体差别。

三次多项式在这次固定比较中优于两种MLP。它与合成真值中低次多项式和有界区间上的平滑正弦结构较匹配，这是一种合理解释，但尚不是对优势来源的独立消融证明。既不能因此宣称神经网络无用，也不能把这一结果从研究报告中删除。




图11 测试主指标与两个区域同时呈现。改善原先的神经网络不意味着胜过强基线，也不意味着每个区域都改进。

12 按独立实体做配对区间


对测试实体 g 计算同一批行上的两种模型损失差

$$d_g = \frac{1}{m_g} \sum_j \left[\frac{(\hat{y}_{gj}^E - y_{gj})^2}{2} - \frac{(\hat{y}_{gj}^R - y_{gj})^2}{2} \right].$$

点估计是 $\bar{d} = \sum_g d_g / 160$ 。每次bootstrap有放回抽160个实体索引，同一实体的全部重复测量和两种预测共同保留；然后平均所抽 d_g 。重复2000次，取均值分布的2.5%和97.5%分位数，得到约 $[-0.07849288, -0.02509653]$ 。


这里先把每个实体压成 d_g 再重采样，与整实体复制全部重复行后重新按抽到的实体出现次数平均等价；不能按原始实体ID合并重复抽到的同一实体，那会丢失bootstrap抽样次数。也不能独立重采样两个模型，破坏配对，或把788行当788个独立实体。

这个百分位区间是近似的、条件性的：训练数据、预处理、选参和六个已训练网络保持不变，只刻画同一实体生成机制下的测试实体抽样波动。它没有覆盖重新采训练实体、重新初始化、重新选择、换生成机制等不确定性。三个初始化种子不是三个独立数据集，不能与160个实体合并成480个独立证据。



13 失败案例与错误拆分的独立反例

按实体MLP的实体损失从大到小排序，展示最差四个实体，同时提供完整160个实体损失。图13用于事后诊断和提出新假设，没有据此重训或回调超参数。测试标签一旦用来启发下一轮改动，就必须把下一轮视为新实验，并配置新的独立评价资料。



为把拆分问题和网络优化分开，我们另外构造80个身份的纯记忆例子： $y_{gj} = b_g + \epsilon_{gj}$,

$b_g \sim \mathcal{N}(0, 1)$, $\epsilon_{gj} \sim \mathcal{N}(0, 0.1^2)$ ，每个身份四行。若前三行用于记住该实体均值、第四行测试，预测器已经看过该实体信息。预测误差中 b_g 抵消，理论half-MSE为

$$\frac{1}{2} \left(0.1^2 + \frac{0.1^2}{3} \right) = 0.00666667.$$

若前60个实体全部用于训练，后20个实体完全未见，身份查表无处可查，使用训练目标总均值。该均值方差为 $(1 + 0.1^2/4)/60$ ，新观测方差为 $1 + 0.1^2$ ，因此理论期望为

$$\frac{1}{2} \left[1 + 0.1^2 + \frac{1 + 0.1^2/4}{60} \right] = 0.51335417.$$

固定种子的实际损失分别是0.00682796和0.42647490。随机样本不必等于理论期望。两个方案面对的测试实体集合与预测任务不同，因此这不是主MLP的配对性能比较，也不能直接把两数相减当作某个算法的改进量。它只精确说明：同一实体的新观测与从未见过的新实体，是不同的泛化问题。




图14 独立的身份记忆反例不参与主实验选参。共享偏移在已见实体预测中可被记住，在新实体中不可见；水平黑线是生成模型下的理论期望，不是经验置信区间。

14 怎样交出可以被复查的研究包

本讲的六个数值产物包括结果摘要、精确手算、固定测试评价、身份反例、逐步曲线以及全部训练参数轨迹。每次接受更新前后的状态都保存，4212个状态并非只截取最佳曲线。大轨迹采用确定性gzip无损封装，记录原始字节长度与SHA；压缩改变存储方式，不减少精度、不丢种子、不抽稀步骤。

所有输出先计算并序列化成功，然后逐文件原子替换。因此遇到输入损坏、非法路径或非有限值，程序可以在写入前失败；但这不是跨六个文件的崩溃事务，机器在替换途中断电仍可能留下不同代产物。哈希检查用于发现这种不一致。不要把“没有报错”或“数值看起来相近”作为唯一验收方式。

项目报告应说明任务、独立单位、预测时点、禁止特征、目标风险、训练与选择预算、主比较、区间条件、全部失败和下一步。结果段可以写：在本次固定合成重复测量任务和冻结协议下，实体加权MLP的测试实体half-MSE低于行加权MLP，主配对区间为负；左区域有所退化，且三次多项式ridge更好。不要写成新的普遍算法、因果机制证明或真实部署保证。

结论要对应证据的范围

实现证据

全梯度检查、4200 次更新独立重算

支持此实现符合既定公式

比较证据

同初始化与预算、冻结选择、整实体区间

支持固定合成数据上的条件性差异

仍未证明

换数据、重训练、跨域、总计算优势

需要新协议、新数据和额外实验

图15 实现正确、比较可信和现实有效性是不同层次。研究结论必须停在现有证据所能支持的位置。

15 审查者如何反驳这份结果

一份研究包应当允许别人找错。先检查实体名单是否重叠，再核对权重是否与声明的风险一致；任选一个训练状态，独立重算梯度和下一状态；逐个检查全部候选是否使用相同预算；最后从固定预测重新计算实体损失和区间。如果其中一步失败，先修复证据链，不要继续讨论“为什么有效”。

有些反驳需要新实验而非修程序。例如，更多训练实体是否会改变两MLP差距、统一重复次数是否会消除权重差异、更多训练步是否足以追上强基线，这些都不是当前4200次更新能回答的问题。把它们写成可证伪预测，冻结新的数据与预算，才是从复现练习走向研究的下一步。现有公开测试可以用于复查旧结果，不能再作为新结论的独立盲测。

来源链接与实际核查范围见sources.md；本讲推导、合成数据、图和叙事独立编写。