

044 练习解答与研究解释

解答用于检查推理链，不能替代你独立完成纸笔、执行脚本与查看全部运行。以下数值来自本包原始数据与已执行结果；不同软硬件浮点实现可能有小差异，不能承诺跨版本逐位一致。

1 任务A：完整前向

网络的参数顺序为(w,b,v,c,a,d)，两个空间位置共享w,b,v,c，两条样本也共享全部六参数。初值(0.5,0.25,0.4,-0.1,0.8,0.1)。A的第一个z为-0.25，ReLU输出0；另外三个位置均为正。

节点	A	B
输入x	(-1,1)	(1,2)
目标	0	1
$z=wx+b$	(-0.25,0.75)	(0.75,1.25)
$h=\text{ReLU}(z)$	(0,0.75)	(0.75,1.25)
$F=vh+c$	(-0.1,0.2)	(0.2,0.4)
$s=x+F$	(-1.1,1.2)	(1.2,2.4)
$m=\text{mean}(s)$	0.05	1.8
预测= $am+d$	0.14	1.54
误差	0.14	0.54
半平方误差	0.0098	0.1458
平均损失贡献	0.0049	0.0729

$L_0 = 0.0778$ 。这里先计算每条样本半平方误差，再对两条样本平均，所以不是0.1556，也不是0.0389。

2 所有局部导数与输入路径

损失对单条预测的上游为 $u = e/2$ ；预测对a、d、m的局部导数分别m、1、a；均值对每个s的局部导数1/2；加法对两输入的局部导数均为1；F对v、c、h的导数为h、1、v；ReLU导数为门；z对w、b、x的导数为x、1、w。

因此A的 $u=0.07$ ， $g_m=0.056$ ，每个位置 $q=0.028$ ；B的 $u=0.27$ ， $g_m=0.216$ ， $q=0.108$ 。乘 $v=0.4$ 并通过门，A的 $r=(0,0.0112)$ ，B的 $r=(0.0432,0.0432)$ 。

A输入直接梯度(0.028,0.028)，残差支路梯度(0,0.0056)，总和(0.028,0.0336)。B对应为(0.108,0.108)+(0.0216,0.0216)=(0.1296,0.1296)。即使A第一个内部门关闭，直接路径仍传递0.028。这个例子加法后没有ReLU；若加上末端门，A第一个s=-1.1会把该位置两支的上游都关掉，已是另一个网络。

3 六参数梯度与第一次同步更新

参数	A路径贡献	B路径贡献	总梯度	更新后
w	0.0112	0.1296	0.1408	0.48592
b	0.0112	0.0864	0.0976	0.24024
v	0.021	0.216	0.237	0.3763
c	0.056	0.216	0.272	-0.1272
a	0.0035	0.486	0.4895	0.75105
d	0.07	0.27	0.34	0.066

w的B贡献为 $0.0432 \times 1 + 0.0432 \times 2$ ；v的B贡献为 $0.108 \times 0.75 + 0.108 \times 1.25$ ；c被两个位置共享，所以B贡献为 2×0.108 。最后样本相加时不再除以2，因为u中已经包含平均权重。

同步意味着所有右侧梯度都在旧参数处求值。先改a再回传w会使用不一致的链式乘子；逐条样本立即更新也不是本题的全批更新。

4 新参数下完整前向与第二轮

节点	A	B
新z	(-0.24568,0.72616)	(0.72616,1.21208)
新h	(0,0.72616)	(0.72616,1.21208)
新F	(-0.1272,0.146054008)	(0.146054008,0.328905704)
新s	(-1.1272,1.146054008)	(1.146054008,2.328905704)
新m	0.009427004	1.737479856
新预测	0.0730801513542	1.3709342458488
新误差	0.0730801513542	0.3709342458488
新平均损失贡献	0.00133517713049	0.03439805368585

$L_1 = 0.03573323081634$ 。新的u分别0.0365400756771、0.1854671229244；新的g_m分别0.02744342383729、0.13929508267237；新的q分别0.01372171191864、0.06964754133619。乘新v=0.3763并过门，A的r=(0,0.00516348019499)，B的r=(0.02620836980481,0.02620836980481)。

参数	A第二轮贡献	B第二轮贡献	第二轮总梯度
w	0.005163480195	0.078625109414	0.083788589609
b	0.005163480195	0.052416739610	0.057580219805
v	0.009964158327	0.134993650519	0.144957808846
c	0.027443423837	0.139295082672	0.166738506510
a	0.000344463440	0.322245390031	0.322589853471
d	0.036540075677	0.185467122924	0.222007198602

A新输入梯度为(0.013721711919,0.016230750215)，B为(0.082382712392,0.082382712392)。这里残差路径乘的是新w=0.48592，不能复用0.5。

第二次更新后的六个参数分两行列出，以免长数字被换行拆开：

- (w,b,v) = (0.477541141039, 0.234481978020, 0.361804219115)
- (c,a,d) = (-0.143873850651, 0.718791014653, 0.043799280140)

第三次前向：

节点	A	B
z	(-0.243059163020,0.712023119059)	(0.712023119059,1.189564260098)
h	(0,0.712023119059)	(0.712023119059,1.189564260098)
F	(-0.143873850651,0.113739117932)	(0.113739117932,0.286515517561)
s	(-1.143873850651,1.113739117932)	(1.113739117932,2.286515517561)
m	-0.015067366359	1.700127317747
预测	0.032968992586	1.265835519902
平均损失贡献	0.000271738618	0.017667130910

总损失 $L_2 = 0.01793886952844$ 。显示表经过舍入；reference.py用Fraction计算，因此复算应使用完整精度。损失连续下降是这组输入、参数、步长的事实，不是残差结构的无条件定理。

5 任务B：形状与投影

第一层输出(N,16,7,7)，因为 $\text{floor}((13+2-3)/2)+1=7$ 。第二层仍为(N,16,7,7)。投影输出 $\text{floor}((13-1)/2)+1=7$ ，所以两支匹配。若投影stride1则仍为 13×13 ，加法应报错；广播不能把13匹配到7。

参数分别1152、2304、128，总3584；输出每通道 7×7 ，MAC总 $49 \times 3584=175616$ 。两条支路相加还要 $16 \times 7 \times 7=784$ 次标量加法，不属于上面的卷积MAC。若含BN、激活或训练反向，另外计算。

2×2 数值题中，stride2、 1×1 只采样左上角 $x=1$ 。两个输出分别2和-1。输入左上角梯度为 $2 \times 3 + (-1) \times 4=2$ ，另外三位置为0。两个投影参数梯度为 $3 \times 1=3$ 和 $4 \times 1=4$ 。投影参数有梯度，因此“捷径没有参数”只适用于恒等、或其他明确无参数的捷径，不适用于可学习投影。

6 任务C：参照的意义与限制

一个输入像素可能被许多滑窗使用，一个核参数被所有位置与样本共享。因此反向需要累加；覆盖赋值会丢失前面的路径。对卷积输入的反向也必须裁掉前向显式补的边框，仅返回原输入尺寸。

原版double中心差分最大误差约 1.45×10^{-9} ，框架/解析比对在更小浮点误差范围。误差阈值分别为中心差分 $1e-7$ 、直接比对 $1e-9$ ；没有在折点用差分逼近ReLU导数唯一化。步长太大会截断误差，太小会有相消舍入，改变步长应该画误差曲线，而不是假定单调改进。

整数、NaN、非法步幅、通道与上游形状错配均拒绝。布尔值在Python中是整数的子类，因此需要单独排除，不能仅判断`isinstance(x,int)`。python -O移除assert语句，却不会删除显式raise。

反例一： $F(x)=-x$ ， $y=x-x=0$ ，导数0。反例二：每层 $F(x)=x$ ， $y=2x$ ，十层导数 $2^{10}=1024$ 。残差可改善某些优化条件，但并不保证梯度范数稳定。

7 任务D：主模型账目

stem参数88，每块1184，头部18，合计 $106+1184B$ ， $B=2$ 得2474， $B=6$ 得7210。BN的gamma与beta是参数；`running_mean`、`running_var`和`num_batches_tracked`是状态缓冲区。

卷积后紧接BN时，训练态BN可消去逐通道常量平移，所以常去掉卷积bias以减少冗余；推理时运行统计固定，改变bias而不配套调整状态仍可能改变结果。不能把“通常不需要”说成任何模式下任意改bias都不影响输出。

同深度成对模型参数与缓冲区初始化完全相同，参数字节哈希相同；计算图不同，输出与后续梯度可以不同。相同种子也不是保证任意两个结构拥有相同对应权重，必须实际比较张量；本包两图的模块创建顺序相同、捷径本身不创建参数。

每次运行144次更新、4608次样本呈现；全部24次共3456次更新、110592次样本呈现。MAC是前向指定运算的计数，忽略BN、ReLU、池化、反向、评估和内存；墙钟时间与机器负载有关，不作为本次硬性公平预算。6块计算显著多于2块，不能用深浅对照单独分离深度效应与算力效应。

8 任务E：不利结果同样属于证据

浅层lr0.03的验证CE均值Plain为0.048823，Residual为0.051045，残差更差；深层对应0.047521与0.029849，残差更好。不同指标有不同排序，小差异应谨慎解释。

深层Plain低学习率最终训练CE约0.002540，未表现出不能拟合训练集；不能因测试低于浅层就宣布优化失败。高学习率所有运行最终完成且没有NaN/Inf，但中途eval CE可达数十万，是严重的暂态推理失稳，不能写成“完全稳定”。

固定梯度探针为前32条训练样本，eval状态、无参数更新。末端梯度较小可能只是交叉熵已经很低；还要对照损失、各层尺度、激活、BN状态和更早训练时刻。主对照控制可学习张量数、对应初始化、数据、顺序、更新数和优化器；捷径带来的函数参数化、加法与内存成本正是变化的一部分。成对不等于全部计算成本严格相同。

9 任务F：BN证据链

plain_b6_lr1_s47峰值出现在epoch2，原验证CE694684.625；同一训练小批eval CE795868、train CE0.286091149。保持权重不动，仅用训练数据重估运行统计，验证CE变成0.228225291。

train模式用本批统计，eval用历史运行统计，因此二者巨大差异说明状态切换很关键。重估实验不改权重，明显改善验证CE，为运行统计失配提供直接证据；它仍不证明所有失稳都来自BN，也不能排除不同权重轨迹造成失配的上游原因。大步长让特征分布快速改变，是与证据相容的解释，尚未通过独立学习率干预之外的完整机制分解证明。

诊断复制峰值检查点，重置所有BN统计，用8个训练批累积；参数逐项核对未变化。不使用测试数据，不将诊断分数替换正式分数。要把重估变成最终算法，应提前规定，重新走验证/测试边界。

10 任务G：全部正式测试结果

架构	seed11错误数	seed29错误数	seed47错误数	平均准确率
Plain 2块	2	3	7	99.2188%
Residual 2块	1	3	3	99.5443%
Plain 6块	4	4	8	98.9583%
Residual 6块	4	2	5	99.2839%

每个错误数的分母均512。相同种子的配对比较有助于减少初始化与数据顺序的噪声，但三个种子重复使用同一批测试样本；独立测试样本仍为512，而不是1536。未报告显著性结论，因为本讲没有设计跨数据拆分的总体推断研究。

Residual 6块seed47的5个错误必须全部展示，具体索引从results.json的mistakes读取。它们与predictions、真实test_y数组逐项比较一致；不能只展示一部分后写“全部”。其他模型完整错误也保留，图11仅是明确指定一个模型的全面错误视图。

示范结论：同宽同深对照中，残差在本次固定测试集提高平均准确率，深层验证CE也更低；但浅层验证CE略差，且深层普通网同样能拟合。大步长引起两图严重eval尖峰，固定权重重估BN显著恢复，支持运行统计失配的解释。三种子共享合成数据，不能据此推出真实图像、任意深度或等计算预算下残差普遍更优。

11 常见错误与修正顺序

- 加法成功但形状不对：先打印四维形状，禁止依赖隐式广播。
- 输入梯度只有一支：画出输入的所有使用点，在每个使用点收集贡献再求和。
- 纸笔梯度差一倍：检查半平方损失与样本平均的两个 $1/2$ ，确认是否重复平均。
- 训练loss很小而验证突然巨大：先核对train/eval与BN状态，再检查优化、数据尺度、数值有限性和分布差异。
- 参数量一样就宣称完全公平：补报MAC、加法、深度、实际步数、候选搜索预算和评估流程。
- 复现图一样但没重训：重启内核，查看连续执行计数与新输出，确认run()实际调用。
- 扩展后数据哈希不匹配：保留原数据，另建新版本，不用改哈希掩盖来源变化。

12 扩展题的合格设计

等MAC浅宽实验要先计算宽度改变带来的平方级卷积成本，再选择近似等预算网络；准确率比较要报告剩余预算差，不能把近似写成完全相等。预激活对照应改完整块顺序并明确投影来源，而非只删最后ReLU。零gamma初始化必须同步报告Plain相同处理是否使梯度路径退化，否则不是单一开关对照。

没有跑过的扩展不能写结果。好的研究结尾可以是“在当前预算和证据下不能判断”，前提是解释缺少哪一种对照，以及下一次实验怎样补上。