

044 深层卷积与残差网络

从一条额外路径出发，分清“梯度能传到”与“网络一定训得好”。

1 本讲要解决的真实问题

在043中，一个卷积核在不同位置反复使用；在035中，层层相乘的导数可能放大或缩小信号；在036中，归一化又使训练和推理使用的统计不同。本讲把三者接起来：相同的一组卷积层，仅增加逐元素相加的路径，会怎样改变前向、反向和实际训练？先修035、036、043。不了解卷积输出尺寸时，先回043，不能靠代码广播“补齐”形状。

学习终点不是背出“残差解决梯度消失”，而是能完成四件事：画清每一条梯度路径；在通道数和分辨率改变时正确设计投影；保持参数量、初始化和更新预算可比较；面对失败曲线，提出可以检验的解释。全讲不需要下载图像或预训练模型，CPU即可运行。

我们用六参数微型网络把两条样本、全部局部导数、路径求和和同步更新算到底，再训练真实的浅/深CNN与残差CNN。结果不会配合口号：浅层残差的平均验证交叉熵略差；深层残差在本次固定数据上更好，但深层普通网络也训练成功。大步长下两种架构都出现巨大的推理态损失尖峰，不能只凭一条曲线就归因于梯度爆炸。

2 一个加号究竟改变了什么

普通块把输入张量 x 映射为 $F_{\theta}(x)$ 。这里 x 是整块特征图，不是一个像素， θ 是该块全部可学习参数。最简单的残差块定义为

$$y = x + F_{\theta}(x).$$

相加逐元素进行，所以两个张量的每个维度都必须一致。它不是拼接：两支各有8个通道，相加后仍为8个通道。恒等捷径不含可学习参数，但仍有逐元素加法、内存读写和激活保存成本。说“零参数”可以，说“绝对零计算”不精确。

图1采用主实验实际使用的后激活结构：先做卷积与BN，支路末端相加，再做ReLU。普通对照保留同样的卷积、BN和末端ReLU，只去掉加法。主实验没有投影，因此两种架构可学习参数完全一样。




图1 普通块与残差块共享相同的可学习层。 u 是末端ReLU之后反传回加法节点的上游梯度，不能把 u 直接替换为输出梯度而漏掉门。

原始ResNet论文将目标映射写成输入加残差，并用视觉任务研究深度增加时的优化困难。这里沿用其问题意识，不复刻ImageNet结果，也不把本讲的小网络称为标准ResNet-18。He等，2015，§3

“残差”在这里指学习相对于输入的修正函数，不等于监督学习的预测误差 $\hat{y} - t$ ；它也没有要求每个残差特征很小。训练可以产生很大的 F ，不能把名称当成约束。

3 不跳步的残差反向传播

将一个样本的特征图按固定顺序展平为 m 维列向量，定义 $J_F = \partial F / \partial x \in \mathbb{R}^{m \times m}$ ， $g_y = \partial L / \partial y$ 。雅可比矩阵的第 (i, j) 项表示第 i 个输出对第 j 个输入的局部导数。工程实现通常不显式存储这个大矩阵，而是直接计算它与向量的乘积。

对一个输入坐标 x_j ，所有输出坐标的损失路径都要累加：

$$\frac{\partial L}{\partial x_j} = \sum_i \frac{\partial L}{\partial y_i} \left(\delta_{ij} + \frac{\partial F_i}{\partial x_j} \right).$$

δ_{ij} 在 $i = j$ 时为1，否则为0；它来自捷径 y_i 中直接出现的 x_i 。把两项分开，得到

$$g_x = g_y + J_F^T g_y, \quad g_\theta = J_\theta^T g_y.$$

参数只有残差支路使用，因此恒等捷径不额外产生参数梯度；输入被两条支路使用，因此输入梯度必须相加。遗漏一支的反向，前向图看起来仍然正确，训练却已经变了。

若块定义为 $y = \text{ReLU}(x + F(x))$ ，必须先经过末端门：令 $s = x + F(x)$ ， $u = g_y \odot \mathbf{1}[s > 0]$ ，再计算 $g_x = u + J_F^T u$ 。负的 s 会同时截断两条输入路径。本讲代码在零点采用导数0；数学上ReLU在零点不可微，中心差分不能在该点被当成唯一真导数。

多块无末端激活、同形状恒等捷径时， $x_{l+1} = x_l + F_l(x_l)$ 可展开成 $x_L = x_l + \sum_{k=l}^{L-1} F_k(x_k)$ 。展开式中的 F_k 仍然通过 x_k 依赖更早输入，不能将求和项视为互相独立的常数。反向是各块 $(I + J_{F_l})^T$ 的有序乘积。矩阵通常不可交换，不能随意调整顺序。He等，2016，§2

4 为什么“多了一个1”不是不消失保证

一维反例足以推翻绝对保证。若 $F(x) = -x$ ，则 $y = 0$ ，导数 $1 + F'(x) = 0$ ；直接路径与残差路径完全抵消。若 $F'(x) = 1$ ，每块导数为2，十块乘积为1024。后激活块还可能因ReLU门关闭而得到0。输入梯度存在直接项，不等于总梯度有非零下界，更不等于所有参数都有有用梯度。

合理解释是：在某些初始化和训练区域， J_F 的尺度较小， $I + J_F$ 可能比任意 J_F 更接近恒等映射，且“接近恒等的目标”可以通过让残差支路接近0实现。这是结构提供的便利，需要条件和实验证据。初始化、归一化、学习率、深度和数据都仍然重要。

深层模型训练误差更高时，应区分优化困难与泛化问题。训练误差已经下降而验证变差，可能涉及过拟合或分布差异；训练误差迟迟不降，首先检查优化与实现。训练态小批损失低、推理态整集损失高，还可能是BN运行统计问题。本讲会专门验证最后一种现象。

预激活块常将BN/ReLU放到卷积之前，使加法之后没有额外ReLU；这有利于讨论恒等路径。不能仅把一行ReLU移动后就声称复现完整预激活ResNet，首块、投影和最后分类头也需要一致设计。本讲主实验固定为后激活，预激活只作概念边界。


5 下采样与投影：先核对形状，再做加法

同形状块输入为 $N \times C \times H \times W$ ，两个 3×3 、stride 1、padding 1的卷积都保持空间尺寸。若第一层把通道改为 D 并使用stride 2，则输出高为

$$H' = \left\lfloor \frac{H + 2 - 3}{2} \right\rfloor + 1 = \left\lfloor \frac{H}{2} \right\rfloor.$$

宽同理。原始 x 不能直接与 $N \times D \times H' \times W'$ 相加。使用 1×1 、stride 2、无padding的投影 P ，得到 $s = P(x)$ ，输出尺寸也为 $\lceil H/2 \rceil$ 。输入13得到7，不是通过四舍五入随便选6或7。卷积接口采用互相关，维度约定为NCHW；参见[PyTorch 2.7.1卷积源码与接口说明](#)。

奇数尺寸也要实际代入输出公式： $\text{floor}((13+2-3)/2)+1 = 7$



反向输入必须相加： $g_x = J_F^T g_y + P^T g_y$ ；投影参数也接收梯度

图2 两条支路必须产生完全一致的形状。这里展示奇数13下采样到7，投影既改变通道也改变空间采样。图示省略BN与门，只突出形状和线性投影。

投影版本的无末端门输出是 $y = F_\theta(x) + P_\phi(x)$ 。输入反向变为 $g_x = J_F^T g_y + J_P^T g_y$ ，投影还得到 $g_\phi = J_\phi^T g_y$ 。 P^T 是前向线性算子的伴随，不意味着随意调用一个默认参数的转置卷积就一定恢复正确形状；stride、padding和输出尺寸必须对应。

忽略偏置和BN时，上图两层残差卷积参数分别为 $16 \cdot 8 \cdot 9 = 1152$ 与 $16 \cdot 16 \cdot 9 = 2304$ ；投影另有 $16 \cdot 8 = 128$ ，合计3584。每个空间位置先做相应乘加， 7×7 输出总卷积MAC为 $49(1152 + 2304 + 128) = 175616$ 。若投影后有BN，还要加32个可学习缩放/平移参数；运行均值方差是缓冲区，不算可学习参数。

步幅2也改变采样结构，即使形状匹配也不保证对任意1像素平移等变，043的边界与采样结论仍有效。用广播把通道1自动扩成16并不等于学会投影。本讲独立参照明确拒绝这种形状不一致。

6 用六个参数算完一次训练

纸笔网络是一通道、两个空间位置的微型残差模型。两个 1×1 卷积的共享参数为 (w, b) 和 (v, c) ，最后平均池化与仿射预测的参数为 (a, d) 。它有真实共享权重和恒等捷径，但没有BN，也没有加法后的ReLU；这是便于完整计算的独立小例子，不是后文CNN日志的缩写。

两条训练样本为 $A: x = (-1, 1), t = 0$ ， $B: x = (1, 2), t = 1$ 。参数固定顺序 $\theta = (w, b, v, c, a, d)$ ，初值 $(0.5, 0.25, 0.4, -0.1, 0.8, 0.1)$ 。对每条样本的每个位置 j 依次计算

$$z_j = wx_j + b, \quad h_j = \max(0, z_j), \quad F_j = vh_j + c, \quad s_j = x_j + F_j,$$

$$m = (s_1 + s_2)/2, \quad \hat{y} = am + d, \quad L = \frac{1}{2} \sum_{i=A,B} \frac{(\hat{y}_i - t_i)^2}{2}.$$

最后一个式子外面的 $1/2$ 是两样本平均；每个平方损失内部的 $1/2$ 是为了使局部导数成为误差。两者不能漏掉，也不能多除一次。




图3 样本A的完整前向。负的第一个z关闭残差内部的ReLU，但输入的恒等路径仍在；加法后没有ReLU，所以负的s可以到达池化。

节点	样本A	样本B
z	(-0.25, 0.75)	(0.75, 1.25)
h	(0, 0.75)	(0.75, 1.25)
F	(-0.1, 0.2)	(0.2, 0.4)
$s = x + F$	(-1.1, 1.2)	(1.2, 2.4)
m	0.05	1.8
$\hat{y}$	0.14	1.54
误差 $e = \hat{y} - t$	0.14	0.54
单样本损失 $e^2/2$	0.0098	0.1458
对平均损失的贡献 $e^2/4$	0.0049	0.0729

因此 $L_0 = 0.0778 = 389/5000$ 。例如样本B的第二位置先算 $z = 0.5(2) + 0.25 = 1.25$ ，再算 $F = 0.4(1.25) - 0.1 = 0.4$ ，加回输入2得到2.4。两个位置使用同一组 w, b, v, c ，不是各自一套参数。

7 从损失逐节点倒走，两支相加

记 $u_i = \partial L / \partial \hat{y}_i = e_i/2$ 。预测节点的局部导数为 $\partial \hat{y} / \partial a = m$ 、 $\partial \hat{y} / \partial d = 1$ 、 $\partial \hat{y} / \partial m = a$ 。池化对每个 s_j 的局部导数为 $1/2$ ，故

$$g_{m,i} = u_i a, \quad q_i = \partial L / \partial s_{ij} = u_i a / 2.$$

加法节点对 x_j 和 F_j 各给出局部导数1；乘法 vh_j 对 v 的导数为 h_j 、对 h_j 为 v ；ReLU 给出门 $\mathbf{1}[z_j > 0]$ ；仿射 $w x_j + b$ 对 w, b, x_j 的导数分别为 $x_j, 1, w$ 。因此

$$r_{ij} = \partial L / \partial z_{ij} = q_i v \mathbf{1}[z_{ij} > 0].$$

反向节点	样本A	样本B
$u = e/2$	0.07	0.27
$g_m = ua$	0.056	0.216
每个 s 的 $q = g_m/2$	0.028	0.108
$r = (\partial L/\partial z_1, \partial L/\partial z_2)$	(0, 0.0112)	(0.0432, 0.0432)
输入直接路径梯度	(0.028, 0.028)	(0.108, 0.108)
输入残差路径梯度 wr	(0, 0.0056)	(0.0216, 0.0216)
总输入梯度 $q + wr$	(0.028, 0.0336)	(0.1296, 0.1296)

样本A第一个内部门虽然关闭，但其输入梯度仍有0.028。样本A第二个输入梯度是 $0.028 + 0.0112(0.5) = 0.0336$ ，不能只保留0.0056，也不能把两条路径取平均。输入不是本轮训练参数，计算输入梯度是为了审查路径，不对输入做梯度下降。

六个参数的单样本贡献按既定顺序为

$$(\sum_j r_{ij}x_{ij}, \sum_j r_{ij}, q_i \sum_j h_{ij}, 2q_i, u_i m_i, u_i).$$

参数	A贡献	B贡献	批梯度
w	0.0112	0.1296	0.1408
b	0.0112	0.0864	0.0976
v	0.021	0.216	0.237
c	0.056	0.216	0.272
a	0.0035	0.486	0.4895
d	0.07	0.27	0.34

w 的B贡献是 $0.0432(1) + 0.0432(2) = 0.1296$ ，这是空间位置共享导致的求和；接着A与B的贡献再相加，这是样本共享导致的求和。 u 已经含有样本平均因子，因此最后一列不能再除以2。




图4 两个样本对六个共享参数的贡献。每一列相加得到同步更新所用的批梯度。

8 同步更新后必须重新前向

学习率取 $\eta = 0.1$ ，无正则化。先用旧参数算完全部梯度，再统一执行 $\theta_1 = \theta_0 - 0.1 \nabla L(\theta_0)$ 。结果为

$$(w, b, v, c, a, d)_1 = (0.48592, 0.24024, 0.3763, -0.1272, 0.75105, 0.066).$$

若先更新 a 再计算 w 梯度，反向中使用的新 a 与旧前向不一致，那不是同一个损失点的梯度。若每算完一条样本就更新，也已变成另一种训练算法。

新前向节点	样本A	样本B
z	(-0.24568, 0.72616)	(0.72616, 1.21208)
h	(0, 0.72616)	(0.72616, 1.21208)
F	(-0.1272, 0.146054008)	(0.146054008, 0.328905704)
s	(-1.1272, 1.146054008)	(1.146054008, 2.328905704)
m	0.009427004	1.737479856
$\hat{y}$	0.0730801513542	1.3709342458488
新平均损失贡献	0.00133517713049	0.03439805368585

两项相加得 $L_1 = 0.03573323081634$ 。例如B的新预测是 $0.75105(1.737479856) + 0.066$ ，不能使用旧的 $m = 1.8$ 。程序以Fraction进行纸笔账本的精确计算，表中小数只是显示近似。

再把同样的局部导数链作用于新节点，得到第二轮批梯度约

(0.08378858961, 0.05758021980, 0.14495780885, 0.16673850651, 0.32258985347, 0.22200719860)。

第二次同步更新后，参数约为

(0.47754114104, 0.23448197802, 0.36180421912, -0.14387385065, 0.71879101465, 0.04379928014)。

第三次前向预测为(0.03296899259, 1.26583551990)，损失 $L_2 = 0.01793886953$ 。完整第二轮逐样本贡献见解答与可执行账本。




图5 三次前向对应两次同步更新。这个小例子损失下降，不是对任意学习率的保证。

9 从标量账本到独立数值参照

reference.py另有纯NumPy四重滑窗参照：输入NCHW，核OIHW；前向逐位置取窗口乘核求和，反向在同一窗口累加输入梯度和核梯度。两层 3×3 支路加恒等或 1×1 投影，内部有ReLU，加法后无门。它与纸笔例子共同检查加法路径，但不冒充带BN的主模型。

数值检验使用double精度，与PyTorch自动微分比对输出、输入、两个卷积核和投影核的全部元素，再对全部输入与参数做中心差分。涵盖同形状 4×4 、奇数 5×5 步幅2投影和偶数 4×4 步幅2投影。有限差分前检查内部预激活远离0，步长 10^{-6} ，最大误差约 1.45×10^{-9} 。中心差分是另一个数值估计，不是数学证明；浮点舍入与ReLU折点都限制它。

此教学参照只支持有限、非空实数浮点四维张量、残差 3×3 核、可选 1×1 投影、stride为1或2、dilation与groups为1、零padding。整数数组、NaN、空维度、通道不一致、上游形状不一致和广播捷径明确报错；有限但过大的数值若使float64卷积、反向或加法溢出，也拒绝继续。它不是完整卷积库；不支持的功能不静默猜测。检查使用显式异常，所以python -O不会移除它们。

10 真正训练的CNN对照设计

任务是将原创 12×12 单通道图像分为水平条纹与竖直条纹。每张图仅有一条宽1像素、长度5到7、幅度0.7到1.3的线段，加标准差0.30的独立高斯噪声，位置变化。中心行、列分别从0起编号的3至8均匀抽取，标签0为横、1为竖。训练256张、验证128张、测试512张，均类别平衡，生成种子分别4400、4401、4402。没有真实个人或外部图片。相同生成机制下的独立样本只是一个简单封闭任务，不代表自然图像识别。

原创12×12合成条纹；位置、长度、幅度与噪声均改变




图6 训练集前12张图。灰度范围固定以便比较；显示截断不改变训练输入，模型实际接收未裁剪的float32数组。

模型共同使用1→8的 3×3 卷积、BN、ReLU作stem；之后是2块或6块，每块含两层8→8的 3×3 卷积与BN；全局平均池化后由8→2线性层输出logits。所有卷积padding 1、stride 1、无偏置；BN带缩放和平移；分类头有偏置。深浅模型分别有5和13个卷积层，另加一个线性层。“2块/6块”不是总层数。

条件	可学习参数	每样本卷积与线性前向MAC	额外捷径加法
Plain, 2块	2474	342160	0
Residual, 2块	2474	342160	2304
Plain, 6块	7210	1005712	0
Residual, 6块	7210	1005712	6912

stem参数为 $8 \cdot 1 \cdot 9 + 2 \cdot 8 = 88$ ；每块为 $2(8 \cdot 8 \cdot 9 + 2 \cdot 8) = 1184$ ；分类头为 $8 \cdot 2 + 2 = 18$ ，总数 $106 + 1184B$ 。BN缓冲区不计入参数。每次乘加记作一个MAC，不等同于一个FLOP；表中不包含BN、激活、池化、反向、评估和内存成本。浅深计算量不同，所以“相同步数”不是“等计算”。

每个深度、学习率和种子下，Plain与Residual逐张量相同初始化、相同样本顺序；不同之处仅为捷径开关。卷积使用He fan-in，BN的gamma=1、beta=0，不对残差单独使用末层BN零初始化。种子11、29、47共享同一数据拆分，表示初始化/顺序扰动，不能当作三份独立新数据。

优化器固定SGD，动量0.9，无weight decay、无梯度裁剪、无调度。两个预定学习率为0.03和1.0；每次18个epoch，每批32条，8次更新/epoch，共144次更新、4608次样本呈现。总共 $2 \times 2 \times 2 \times 3 = 24$ 次训练、3456次更新。每个架构按三个种子的最终验证交叉熵平均选择学习率；不选择最佳中间epoch，不因结果失败删除种子。

分类损失使用logits直接进入交叉熵，即单样本 $\ell = -z_t + \log \sum_k \exp z_k$ ，批内取平均；其对logit的梯度是 $(p_k - \mathbf{1}[k = t])/N$ 。不先softmax再传给CrossEntropyLoss。测试标签只在全部验证选择完成后读取，测试12个已选定最终模型。程序的文件公开，因此这是可复现的信息边界，不是外部保密盲测。

11 全部轨迹揭示的成功与失败

主实验每次更新保存小批损失、总参数梯度范数、stem与分类头梯度RMS；每个epoch以eval状态记录全训练集与验证集指标。另在固定32条训练样本上，以eval状态测所有卷积与分类头参数梯度RMS，测量不更新模型、不改变BN运行统计。不同层的参数化与尺度不同，梯度数值大不自动表示那层更重要。




图7 全24次训练的验证轨迹，每条线为一个种子。纵轴是对数尺度。高学习率的尖峰必须保留，末端成功不能抹掉中途不稳定。

块数与捷径	lr=0.03最终验证CE均值	lr=1.0最终验证CE均值	所选学习率
2块Plain	0.048823	0.050528	0.03
2块Residual	0.051045	0.061254	0.03
6块Plain	0.047521	0.051333	0.03
6块Residual	0.029849	0.052045	0.03

浅层残差的验证CE略高于普通网，因此不能声称所有比较都改善。低学习率下，6块普通网最终训练CE均值约0.002540，6块残差约0.001564；两者都能拟合。这份小任务没有重现“深层普通网必然退化”的故事，不能为了讲故事换掉不利数据。




图8 固定训练探针的参数梯度RMS，全部三个种子。初始化和训练末端分别显示；较小的末端梯度也可能仅因为损失已很小，不能直接诊断为梯度消失。

12 把失稳定位到可操作的机制

所有24次训练都完成，未出现非有限梯度或参数；但学习率1.0出现严重的推理态尖峰。例如6块 Plain、seed47在epoch2的验证CE为694684.625，不能因最终训练恢复就删掉。这次训练的最大单批梯度总范数约7.158，与巨大的验证损失并不是同一个量。

观察到尖峰后，我们进行事后机制检查，保留每次运行验证CE最高时的检查点用于诊断。在复制的模型上做两种操作，绝不改原训练或模型选择：第一，对同一32条训练样本分别使用eval和train状态，只切换BN统计；第二，保持全部可学习权重不动，重置BN运行统计，用全部训练数据按8批重新累积，再评估验证集。

seed47上述峰值的固定训练批CE在eval状态为795868，在train状态约0.286091；仅用训练数据重估BN后，验证CE降至0.228225。这个对照直接支持“运行统计与当前权重不匹配对本次尖峰有巨大贡献”，比只说梯度爆炸更精确。重新累积不是保证，有限批统计和深层统计依赖仍会影响结果；没有把诊断后的成绩替换为正式成绩。




图9 高学习率6块模型各自峰值的BN诊断。左图保持权重，仅用训练数据重估运行统计；右图同一训练小批切换状态。P/R分别表示普通/残差，数字为种子。

BN的运行缓冲区、状态切换与累积平均语义由PyTorch 2.7.1官方实现核对。这里调用train()做诊断不等于在验证集上训练：图9右边只用固定训练小批；左边重估只读训练输入。没有让验证或测试标签参与参数更新。真实部署若要使用重估BN的流程，必须预先定义数据来源、重估协议和独立验证，不能在看完测试结果后反复补救。

13 测试结果、错误样本与结论边界

四个架构均由验证选中学习率0.03。最终测试准确率按种子顺序11、29、47报告，避免均值遮住差异。

架构	seed11	seed29	seed47	均值
Plain 2块	99.6094%	99.4141%	98.6328%	99.2188%
Residual 2块	99.8047%	99.4141%	99.4141%	99.5443%
Plain 6块	99.2188%	99.2188%	98.4375%	98.9583%
Residual 6块	99.2188%	99.6094%	99.0234%	99.2839%




图10 每条线连接同一初始化和相同样本顺序的普通/残差结果。测试准确率刻度放大了小差别；不应忽略每张图只有512条固定测试样本。

本次同深度残差平均准确率都略高，但6块残差也没有超过2块残差。小数点后的精度来自有限样本计数，不意味着总体差异被估计得如此精确。三个种子共用测试数据，不能用1536个预测当成1536条独立测试样本，也不能据此声称统计显著或因果普遍有效。更广泛结论需要多数据拆分、更多任务、合适的配对不确定性分析以及更严格计算预算对照。



图11 Residual 6块、seed47的全部5个测试错误。其他11个正式模型的全部预测、logits、混淆矩阵与错误索引也保留在results.json。图像不能凭肉眼替代真实标签生成过程。

本讲可以得出的结论很具体：残差增加了一条结构化输入路径；形状改变时投影也需要训练与预算；在这份同宽同深对照中，残差的作用随深度、学习率与指标而变；归一化状态能造成看似“网络爆炸”的严重推理故障。它不能证明任何深度、任何数据上残差都更好，也没有比较预激活、瓶颈块、宽残差网、注意力或预训练模型。

14 阅读、复现与下一步

先独立完成lab.md，再用answers.md核对。experiment.ipynb在新Python内核完整重训24个候选并显示11张实际生成图；执行范围、环境与复现命令见README.md。

下一讲045讨论视觉输入与增强。等MAC浅宽、预激活和含投影网络都是新的实验问题，须另定协议，不能从本讲直接外推。一手来源见sources.md；本讲数据、推导与图均为原创。