

046 检测分割与结构化预测

从“图里有什么”走向“在哪里、占哪些像素”，先把预测对象与评价规则说清楚。

1 本讲的位置与目标

先修039、044、045：039解释损失、类失衡与决策阈值；044建立卷积特征与残差路径；045规定CHW图像、半开XYXY边缘坐标，以及几何增强必须同步更新标注。本讲不假设你已经训练过检测器。完成后，应能从标签结构选损失，手算IoU与一次像素模型更新，辨认训练匹配、预测去重和评估匹配的区别，并复查一个包含空目标与重叠目标的小型分割实验。

我们真正训练的是二值语义分割模型。检测部分有原创数值例子、NMS和AP的独立实现，但不把它包装成完整检测器训练，更不声称实现了官方COCO评估器。所有图片、掩码和图示均在本单元原创生成，无模型下载、GPU或付费API要求。

最值得记住的实际结果：全预测背景能得到89.84%的测试像素准确率，前景IoU却是0；一个无需神经网络的 3×3 均值阈值基线达到0.6207 IoU。小CNN更好一些，但亮背景偏移会使它明显退步。高指标必须连同预测对象、聚合规则和失败样本一起阅读。

2 同一张图，四种不同输出

整图分类输出一个类别，或一组是否出现的类别。检测输出可变长集合，每条记录含类别、框和分数；集合没有天然顺序。语义分割输出每个像素的类别，同类的两件物体允许合成同一个前景区域。实例分割还须区分每件物体的掩码，即使它们属于同一类。




图1 一张重叠目标图的三种监督。语义分割的并集不保留“两件物体”的身份；知道一个像素是前景，不意味着知道它属于哪个实例。

主实验把矩形的并集标成1，背景标成0；两个矩形的交叠处仍是1，不能加成2。这里不存在遮挡后的可见轮廓推断，矩形的并集就是生成器给定的任务。检测记录则可以保留两个重叠框。不能拿分割掩码连通域的数量直接当实例检测数量。

输入数组为 $N \times 1 \times 16 \times 16$ ，输出logit形状也为 $N \times 1 \times 16 \times 16$ 。logit是未过sigmoid的实数分数。目标掩码先存为整数0/1，计算BCE时转为同形状浮点张量。不是把 $N \times 16 \times 16$ 无意广播到额外轴上。

多类互斥语义分割常用 $N \times C \times H \times W$ 的logit与 $N \times H \times W$ 的整数类别；每像素softmax后概率之和为1。多标签像素任务允许多个类别同时成立，通常每类单独sigmoid。这两个任务不能只因数组尺寸接近就互换。

3 坐标合同：框是边缘，像素是单元

令 x 向右、 y 向下。宽 W 、高 H 图像的边缘范围为 $[0, W] \times [0, H]$ 。框写作 (x_1, y_1, x_2, y_2) ，对应半开区域 $[x_1, x_2) \times [y_1, y_2)$ ，宽 $x_2 - x_1$ 、高 $y_2 - y_1$ 。像素 (r, c) 的中心是 $(c + 1/2, r + 1/2)$ 。整数框 $[1, 2, 5, 7]$ 覆盖数组mask[2:7,1:5]，面积为20，不是30。

半开连续边缘公式没有“+1”。若来自另一套含端点整数坐标，必须显式转换；把不同约定混用，小框IoU尤其容易偏离。空目标图使用形状(0, 4)的空框数组，不用零面积框占位。我们的几何参照允许负坐标以便研究裁剪前几何，但实际合成数据的全部框都在图内；几何计算的合法域与数据集合法域是两层检查。

水平翻转后的边缘为 $(W - x_2, y_1, W - x_1, y_2)$ ，不能只对两个 x 各做 $W - x$ 而不交换左右。图像可用合适的连续插值；类别掩码使用最近邻以保留ID。预测logit是连续量，恢复到原图尺寸时可以插值logit后再阈值化，但插值模式和坐标映射必须固定。045的half-pixel约定在这里继续适用。

4 IoU：从交集面积开始逐段推导

两个合法框 A, B 的交叠宽高为

$$w_I = \max\{0, \min(x_{2A}, x_{2B}) - \max(x_{1A}, x_{1B})\},$$

$$h_I = \max\{0, \min(y_{2A}, y_{2B}) - \max(y_{1A}, y_{1B})\}.$$

先求两边缘的较小右界与较大左界，做差；差为负表示没有相交宽度，所以截为0。令 $I = w_I h_I$ ， $S_A = (x_{2A} - x_{1A})(y_{2A} - y_{1A})$ ， S_B 同理。并集不是两面积直接相加，因为交叠被算了两次：

$$U = S_A + S_B - I, \quad \text{IoU} = I/U.$$

对正面积框， $U > 0$ 。接触但没有正面积交叠时IoU为0；完全相同则为1。 $A = [0, 0, 2, 2]$ 、 $B = [1, 0, 3, 2]$ 的 $I = 2$ 、 $U = 4 + 4 - 2 = 6$ ，故IoU为1/3。这跟两个框中心相距多少不是同一个量。

为了看清分段导数，固定真框 $[0, 0, 2, 2]$ ，预测框为 $[s, 0, s + 2, 2]$ ，只平移、不改面积。令 $d = |s|$ ：当 $d < 2$ ， $I = 2(2 - d)$ 、 $U = 8 - I = 2(2 + d)$ ；当 $d \geq 2$ ， $I = 0$ 。于是

$$\text{IoU}(s) = \begin{cases} (2 - |s|)/(2 + |s|), & |s| < 2, \\ 0, & |s| \geq 2. \end{cases}$$

在 $0 < s < 2$ 的分支，用商法则得到 $[-(2+s) - (2-s)]/(2+s)^2 = -4/(2+s)^2$ ；在 $-2 < s < 0$ ，导数为 $4/(2-s)^2$ ；在 $|s| > 2$ ，导数为0。 $s = 0$ 与 $s = \pm 2$ 左右导数不一致，不能把中心差分平均值称为唯一导数。




图2 IoU由min、max和除法组成，在固定分支内可求导。完全不相交时，单用1-IoU并不能告诉预测框应向哪边移动。

一般框参数 u 在某个固定分支内满足

$$\frac{\partial(I/U)}{\partial u} = \frac{U \partial I / \partial u - I \partial U / \partial u}{U^2}, \quad \partial U = \partial S_A + \partial S_B - \partial I.$$

要继续展开，先确定哪一个边缘被min/max选中。比如 $x_{1A} > x_{1B}$ 且交叠宽度为正，则

$\partial w_I / \partial x_{1A} = -1$ ；反之若左边界由 B 控制，则此导数为0。边界相等处另行处理。自动微分只是采用实现约定，不会消除这些数学分段。

5 框回归：为什么用中心偏移与对数尺度

锚框是预测的参考位置。它的中心 (a_x, a_y) 、宽高 (a_w, a_h) 都已知且宽高为正。真框的中心、宽高写作 (g_x, g_y, g_w, g_h) 。一种常见目标编码为

$$t_x^* = (g_x - a_x)/a_w, \quad t_y^* = (g_y - a_y)/a_h, \\ t_w^* = \log(g_w/a_w), \quad t_h^* = \log(g_h/a_h).$$

偏移除以锚框尺寸，减少像素尺度对目标数值的直接影响；宽高用对数比值，使放大两倍与缩小两倍对应相反数。解码预测 t 时， $x = a_x + a_w t_x$ 、 $y = a_y + a_h t_y$ 、 $w = a_w \exp(t_w)$ 、 $h = a_h \exp(t_h)$ ，再取左右边缘 $x \pm w/2$ 。指数保证正尺寸，但大log-scale可能溢出；代码有明确范围限制，不能用无界指数掩盖异常输入。

锚框 $[0, 0, 2, 2]$ 与真框 $[1, 0, 5, 2]$ 分别有中心 $(1, 1)$ 与 $(3, 1)$ ，宽高 $(2, 2)$ 与 $(4, 2)$ 。逐项得到目标 $(1, 0, \log 2, 0)$ 。使用 `encode_boxes` 后再解码应还原真框；这一步比先训练更值得验证。

对一个编码残差 $r = t - t^*$ ，定义 $\beta > 0$ 的Smooth L1：

$$\rho_\beta(r) = \begin{cases} r^2/(2\beta), & |r| < \beta, \\ |r| - \beta/2, & |r| \geq \beta. \end{cases}$$

$$\rho'_\beta(r) = \begin{cases} r/\beta, & |r| < \beta, \\ \text{sign}(r), & |r| \geq \beta. \end{cases}$$

两支在 $|r| = \beta$ 处函数值和一阶导数连续。小残差像平方损失，大残差的单坐标梯度幅度为1。若四坐标取平均，每个导数再除以4；若按正锚框数平均，又需要说明坐标求和还是平均。不能看见相同损失名就假设缩放相同。




图3 回归损失作用在编码残差上。参数 β 改变分支转折位置，不是IoU门槛。

取预测编码 $(0.5, 0.2, 0, 0.1)$ ， $\beta = 1$ 。四残差为 $(-0.5, 0.2, -\log 2, 0.1)$ ，都在二次分支。平均损失为 $[0.125 + 0.02 + (\log 2)^2/2 + 0.005]/4 = 0.0975566$ ，对预测编码的梯度是 $(-0.125, 0.05, -0.1732868, 0.025)$ 。学习率0.4同步更新后编码为 $(0.55, 0.18, 0.0693147, 0.09)$ 。

若编码来自 $t_w = uh + v$ ，继续链式求导： $\partial L/\partial u = (\partial L/\partial t_w)h$ ， $\partial L/\partial v = \partial L/\partial t_w$ 。若损失直接作用于解码宽度，另有 $\partial w/\partial t_w = w$ 。不要把“编码损失”与“解码坐标损失”混为一条反向路径。以上编码与分类/回归分工可参照Faster R-CNN原文§ III-A；本讲数值例子与实现均为原创。

6 三种“匹配”必须分开

训练分配决定哪个预测位置接受哪个监督。有些锚框方案让多个锚框同时对应同一个真物体，并把中间IoU范围设为忽略。这不是评估时一物体只能计一次的规则。不同检测器也可采用集合匹配，不存在一套匹配规则适合所有架构。

推理阶段的非极大值抑制NMS不读取真值。对同一图像、同一类别，先按分数降序保留第一框，再删去与它IoU大于阈值的其他框，重复。我们的函数只处理已经分组好的单类一张图；相等分数保持原输入顺序；IoU恰好等于阈值时保留。这种严格大于的约定见Torchvision 0.22 NMS文档。官方同时提醒CPU/GPU对同分框的选择可能不同，本讲的稳定规则不代表任意实现都相同。




图4 同样有“去掉重复”，NMS与评估匹配使用的信息完全不同。高分错误框可能通过NMS压掉正确框；互相靠近的真实物体也可能受影响。

评估匹配在每个IoU门槛下，按预测分数处理当前图像当前类别的预测，找尚未使用的、IoU合格的真框。一旦匹配就记TP，不能再次使用该真框；重复预测计FP。未匹配真框最终是漏检。我们的教学实现选最高IoU，IoU同分选择较早真值；它不处理crowd、ignore、面积分组或maxDets。

例如两张图各一件物体，预测排序是“图A正确框、图A重复框、图B正确框”，TP序列就是(1, 0, 1)，并不是(1, 1, 1)。空图中的每个普通预测都是FP；真值不应被伪造为一个背景框。整个评估集合该类没有任何真值时，AP标为未定义并从类别平均中按声明规则排除，不能偷偷记成100%。

7 从Precision、Recall走到AP与mAP

排序前 k 条预测的累计TP为 T_k 、累计FP为 F_k ，总真目标数为 G 。定义 $P_k = T_k / (T_k + F_k)$ 、 $R_k = T_k / G$ 。重复预测增加分母却不增加召回；漏掉的真物体限制最终召回上限。未达到的召回区域必须贡献0。

常见插值包络是 $p_{\text{interp}}(r) = \max_{k: R_k \geq r} P_k$ ，若没有候选则为0。教学全点AP按每次召回增加的宽度乘上该区间的包络高度。前例的P为(1, 1/2, 2/3)、R为(1/2, 1/2, 1)，故AP为 $(1/2) \cdot 1 + (1/2) \cdot (2/3) = 5/6$ 。





图5 全点积分与101点采样不是完全相同的数字。相同预测必须在同一评估约定下比较。

若改在 $r = 0, 0.01, \dots, 1$ 的101个点平均，前51点为1，后50点为2/3，得到0.834983。AP50指IoU门槛固定0.50时的AP，不是“分数大于0.5的预测准确率”。mAP还必须说明跨哪些类别、哪些IoU门槛平均。目标检测没有一个可随意套用的、计数良好的“真负框全集”，所以也不能拿它与整图分类准确率直接比较。

COCO常用IoU 0.50至0.95、步长0.05，101个召回采样点，并有maxDets、面积、ignore/crowd等规则。需复核官方实现的完整设置；见COCO官方评估器源码。本讲只演示其部分思想，即使101点采样一致，也不称为“COCO mAP复现”。COCO JSON框的常见输入是XYWH，不能将其直接当本讲XYXY。

8 从局部特征到密集像素预测

分类头常把空间位置汇总成一个向量；分割头需要保留或恢复空间对应。一个 1×1 卷积在每个位置混合通道，不把不同位置混在一起。前面的 3×3 卷积可让该位置读取邻域。下采样扩大某些层的感受野并降低成本，也损失精细位置；上采样不会凭空恢复已经丢失的边界。



概念图：多尺度融合需要对齐空间位置。主实验没有下采样，也不是FPN / U-Net。

图6 多尺度概念示意。小目标在粗网格上可能只有很少位置；语义更强不等于空间细节更精确。

U-Net使用收缩和扩张路径，并将细节特征传入恢复过程；FPN把不同分辨率的特征结合用于多尺度预测。这些是值得进一步阅读的结构思路，不是本讲67参数CNN的别名。[U-Net原论文](#)、[FPN原论文](#)

主实验全程保持 16×16 ，不含池化、BN、残差、预训练或复杂解码器。我们把044的局部卷积知识用于密集输出，并刻意减少额外变量。后续研究若加入残差或多尺度，必须单独说明参数量、MAC、训练预算和对齐方式。

9 像素BCE：从局部导数到共享梯度

令像素logit为 z ， $p = \sigma(z) = 1/(1 + e^{-z})$ ，标签 $y \in \{0, 1\}$ 。单像素损失为 $\ell = -y \log p - (1 - y) \log(1 - p)$ 。先对 p 求导，再乘sigmoid导数：

$$\frac{\partial \ell}{\partial p} = -\frac{y}{p} + \frac{1-y}{1-p}, \quad \frac{\partial p}{\partial z} = p(1-p).$$

两项分别相乘得到 $-y(1-p) + (1-y)p = p - y$ ，故 $\partial \ell / \partial z = p - y$ 。若对 M 个有效像素取平均，每条路径是 $(p - y)/M$ 。图像大小不同时，先逐图平均再跨图平均，与把所有像素合并平均通常不是一个权重分配。

直接先计算极接近0或1的 p 再取对数可能溢出。对二值标签使用稳定形式 $\ell = \log(1 + e^z) - yz$ ，其中softplus再用稳定数值实现。独立参照采用`logaddexp`，并与框架在 $z = \pm 1000$ 等点核对。不要把已经sigmoid的概率送进`BCEWithLogitsLoss`。PyTorch 2.7官方接口

设卷积头 $z_{ij} = \sum_c v_c h_{cij} + b$ ，则 $\partial L / \partial v_c = \sum_{i,j} (\partial L / \partial z_{ij}) h_{cij}$ 。同一个 v_c 在所有图像与位置共享，梯度必须把全部使用路径相加。某一个像素犯错不意味着可以只更新“属于它”的一份独立卷积参数。

10 四个像素、两个参数：一遍不省的训练

使用两张仅有两个位置的灰度图： $A: x = (0, 1), y = (0, 1)$ ； $B: x = (1, 2), y = (1, 0)$ 。这里数值是教学特征，不限制在真实图像的0到1范围。共享 1×1 模型 $z = wx + b$ ，初值

$w = \log 2 = 0.69314718$ 、 $b = 0$ 。总损失为四个像素BCE的平均，也等于两张图各自像素平均损失再平均。

像素	x	y	z	p	单像素损失
A0	0	0	0	1/2	0.69314718
A1	1	1	$\log 2$	2/3	0.40546511
B0	1	1	$\log 2$	2/3	0.40546511
B1	2	0	$\log 4$	4/5	1.60943791

图A平均为0.54930614，图B平均为1.00745151，总 $L = 0.7783788273$ 。最后一个像素虽然更亮，却被指定为背景，使四个监督并非能被亮度完美分离；它会对共享权重产生与两个前景像素相反的压力。

接下来表中 $\partial L / \partial p$ 已经含四像素平均的1/4；不能在后面又除一次4。

像素	$\partial L / \partial p$	$\partial p / \partial z$	$\partial L / \partial z$	$\partial z / \partial w = x$	对w的贡献	对b的贡献
A0	1/2	1/4	1/8	0	0	1/8
A1	-3/8	2/9	-1/12	1	-1/12	-1/12
B0	-3/8	2/9	-1/12	1	-1/12	-1/12
B1	5/4	4/25	1/5	2	2/5	1/5

每行都有 $\partial z / \partial b = 1$ 、 $\partial z / \partial x = w$ 。所以输入梯度依次为 $(\log 2/8, -\log 2/12, -\log 2/12, \log 2/5)$ ，约 $(0.08664340, -0.05776227, -0.05776227, 0.13862944)$ 。这些输入不是可学习参数，不会在本例的SGD中被修改，但反向路径仍可核对。

先在每张图内累加：图A贡献 $(\partial L / \partial w, \partial L / \partial b) = (-1/12, 1/24)$ ；图B贡献 $(19/60, 7/60)$ 。再跨图相加得到

$$g_w = 0 - 1/12 - 1/12 + 2/5 = 7/30,$$

$$g_b = 1/8 - 1/12 - 1/12 + 1/5 = 19/120.$$

这里的“图A贡献”仍是对总损失的贡献，已经包含平均尺度；不要再与图A单独平均损失的导数混用。




图7 共享参数的一正多负贡献。SGD依据全部贡献之和；更新后每个像素都重新计算，不能沿用旧概率。

固定学习率 $\eta = 0.6$ ，两个参数都用旧参数下计算的梯度同步更新：

$$w' = \log 2 - 0.6(7/30) = 0.5531471806, \quad b' = -0.6(19/120) = -0.095.$$

重新前向，四个logit依次为 $(-0.095, 0.45814718, 0.45814718, 1.01129436)$ 。新的概率为 $(0.476267846, 0.612574544, 0.612574544, 0.733273381)$ ，单像素损失为 $(0.646774882, 0.490084640, 0.490084640, 1.321531045)$ 。图A损失反而升到0.568429761，图B降到0.905807843，总损失降到0.737118802。总目标下降不保证每个样本都改善。

第二轮的四个上游梯度为 $(0.119066961, -0.096856364, -0.096856364, 0.183318345)$ 。仍乘 x 后累加得 $g_w = 0.172923963$ ，直接累加得 $g_b = 0.108672579$ 。第二次同步更新得 $(w'', b'') = (0.449392803, -0.160203547)$ ；再前向的概率为 $(0.460034553, 0.571797638, 0.571797638, 0.676685714)$ ，总损失0.715830199。hand_ledger保留三轮每条局部导数，测试同时核对框架参数与输入梯度。

11 类失衡、Dice与有效像素

主实验只有约9.87%的训练像素是前景。全预测背景的损失和像素准确率可能看起来还可以，但任务要求找前景。一个选项是提高正类损失权重 q ：

$$\ell_q = -qy \log p - (1 - y) \log(1 - p),$$

$$\frac{\partial \ell_q}{\partial z} = qy(p - 1) + (1 - y)p.$$

正像素的导数是 $q(p - 1)$ ，负像素仍为 p ，不是把所有像素一律乘 q 。本实验只根据训练集计数设 $q = n_- / n_+ = 9.1323438466$ ，整个实验固定；不在验证或测试集重估。实际传入损失的pos_weight显式继承logit的float64类型；若只写torch.tensor(q)而沿用默认float32，q会先被舍入，后续双精度

运算不能恢复原值。真实训练入口回归测试会把默认dtype设为float32，再检查实际q、dtype和第一次参数更新与独立参照一致。loss仍除以总像素数，未改为权重和。因此损失尺度和梯度大小也改变，必须给加权方案相同且明确的学习率搜索预算。

如果真实条件正类概率为 π ，最小化理想加权条件风险的解为 $p^* = q\pi/(q\pi + 1 - \pi)$ ，即赔率扩大 q 倍。所以 $p^* \geq 1/2$ 对应 $\pi \geq 1/(q + 1)$ ，不代表原始分布概率已经校准。039关于权重、校准和阈值的区分仍然成立；实际有限模型不应未经核对就宣称减去 $\log q$ 必定完成校准。

另一个常见重叠目标是soft Dice。令 $A = 2 \sum_i p_i y_i + \epsilon$ 、 $B = \sum_i p_i + \sum_i y_i + \epsilon$ ， $L_D = 1 - A/B$ ，则

$$\frac{\partial L_D}{\partial p_j} = \frac{A - 2y_j B}{B^2}.$$

这是对所有选定像素耦合的损失：一个像素改变分母会影响别的位置。它不同于先阈值化后的硬Dice指标。 ϵ 、按图还是按批聚合、空掩码怎么办都要写清；加平滑常数并不能自动建立正确评价规则。主实验只用BCE及加权BCE，Dice为推导和扩展，不混进已冻结比较。

若标签含ignore区域，应只在有效集合 V 上求和并除以 $|V|$ 。 $|V| = 0$ 的批次需显式跳过或按既定规则处理；不能除以0，也不能把ignore ID 255当二值前景。本单元参照仅支持0/1无ignore，并拒绝其他数值，这是接口边界而非实现了所有任务。

12 分割评价：先计数，再平均

对阈值后的掩码， TP 是正确前景像素， FP 是假前景， FN 是漏前景， TN 是正确背景。前景IoU为 $TP/(TP + FP + FN)$ ，像素准确率为 $(TP + TN)/(TP + FP + FN + TN)$ 。硬Dice为 $2TP/(2TP + FP + FN)$ 。对同一非空计数，有 $\text{Dice} = 2 \text{IoU}/(1 + \text{IoU})$ ；它们不是可以任意互换的标尺。

micro前景IoU先跨图累加TP、FP、FN再相除，大区域对结果影响更大。macro逐图IoU先逐图计算再平均，每张图权重相同。我们规定逐图真值与预测都空时IoU为1，只要预测有前景、真值全空，就为0。整个集合前景并集为空时，micro也按1计；这是明确约定，不是0/0的数学定义。

两个类别的micro IoU平均，是前景micro IoU与背景micro IoU的算术平均，通常叫两类mIoU；它既不是前景IoU，也不是逐图macro。不存在某一类且所有预测也不存在时，本教学函数该类取1；外部基准可能忽略这一类，不能混报。我们同时记录所有计数，便于换约定后重新汇总。

另报“空图误报率”：有至少一个预测前景像素的空真值图比例。它是按图统计，不是空图的假阳性像素比例；单个散点就能让一张空图计为误报。空图很多时，仅用macro-empty1可能奖励一直输出空，单用micro又不能充分显示每图是否干净，因此同时阅读。

13 可重跑的真实固定实验

数据各用独立随机种子：训练64张、验证32张、同分布封存测试48张、背景偏移测试32张。每个拆分按空图、单目标、重叠目标、分离目标循环，四类各占四分之一。框先生成，掩码取并集；图像是随机背景亮度、前景对比度和逐像素噪声叠加后裁到0至1。偏移拆分把背景生成值增加0.16，使用独立图像，并非同一测试图的配对变亮副本。




图8 固定test-000至003及真值。输入中的亮噪声不全是前景，空图也有噪声；只查一张漂亮样本不足以验证数据管线。

训练方案为：逐像素线性头（2参数）； 3×3 卷积1到6通道、ReLU、 1×1 卷积到1通道的CNN（67参数）配普通BCE；完全相同CNN配训练集正类加权BCE。两CNN以同种子获得相同初始化。逐像素模型固定初始化(0.1, 0)，所以三种子运行完全一致，不能把它们当三份独立随机证据。

每种方案搜索学习率0.1与1.0，每个候选用种子11、23、37，执行100次全批SGD；无动量、调度、权重衰减、增强或早停。每种方案按三种子平均最终验证前景micro IoU选一个学习率，同分取较小者。固定logit ≥ 0 的阈值不参与选择。另有CNN普通BCE学习率10的三次预定压力实验，不进入候选选择。总计21次训练、2100次更新，失败不会删除。

这里是更新数与样本暴露数一致，不是FLOP相同：逐像素模型每图约256次乘加，CNN卷积乘加为 $16 \cdot 16(6 \cdot 9 + 6) = 15360$ ，另有偏置与激活。不能据此说“同等计算量CNN胜出”。普通和加权CNN则结构与主要计算相同。

强基线包括原始强度阈值、 3×3 边缘复制padding的均值滤波后阈值，分别搜索0.2至0.8的25个固定候选，只在验证集选择，同分取较小阈值。它们不需要梯度训练，验证搜索次数也与神经模型不相等；如实报告这种成本差异。所有50个分数、全部参数轨迹和验证logit均保留。




图9 全部21条验证曲线。小学习率CNN与逐像素头在100步预算内仍预测全背景；学习率10也停在零IoU附近，不能只挑成功曲线。

每个候选保存101个参数状态（初值和100次更新后）、每步目标损失与梯度范数、验证损失与IoU，以及最终完整验证logit。选择冻结后，九个模型在所有拆分保存逐像素logit及每图TP/FP/FN/TN。基线保存每像素二值预测。outputs/arrays.npz与outputs/results.json共同构成完整复查材料。

14 真实结果与能够支持的结论

方案	冻结选择	测试前景micro IoU	偏移前景micro IoU
全背景	无需选择	0.0000	0.0000
强度阈值	阈值0.525	0.4893	0.3121
3×3均值阈值	阈值0.425	0.6207	0.2269
逐像素线性	学习率0.1	0.0000（三次相同）	0.0000（三次相同）
CNN / BCE	学习率1.0	0.7004 / 0.6912 / 0.6395	0.3227 / 0.3287 / 0.4008
CNN / 加权BCE	学习率1.0	0.5700 / 0.6585 / 0.6546	0.1741 / 0.2059 / 0.2020

表内三值依次对应种子11、23、37。普通CNN平均测试IoU为0.6770，加权CNN为0.6277，均值阈值为0.6207。加权未在本次协议下胜出，种子11甚至低于非神经基线。三种子只描述初始化敏感性，不足以证明跨任务的统计显著性，也不能当成三份新测试数据。




图10 同分布和背景偏移结果。横向比较时注意不同模型容量与搜索成本；右图使用独立偏移样本，不是每张图的配对差值。

普通CNN的三个种子都在12张空图中的2张产生至少一个假阳性，空图误报率16.67%；加权方案为50.00%、41.67%、41.67%。它提高正类损失代价，可能推动更多位置越过固定阈值。这个结果与039的阈值讨论一致，但不能仅凭相关结果认定唯一机制；要验证阈值效应，应预先增加验证集阈值选择对照，并在新封存数据上评估。




图11 普通CNN种子11在四类固定样本上的输入、真值、概率与阈值预测。概率图不是掩码，边缘不确定性与散点误报必须单独检查。

学习率10的压力候选没有出现非有限数，却都在100步末得到验证IoU 0。称其“在固定任务指标上训练失败”有证据；称其“数值发散”没有证据。损失、梯度和参数轨迹允许后续检查激活门、阈值与优化路径，不能因为大步长就先贴上梯度爆炸标签。




图12 九个选定模型全部48张测试图的逐图IoU。空图正确预测为1会形成明亮条纹；因此这个图不能替代micro指标。




图13 两条基线的全部阈值候选与空图误报。阈值、损失和报告口径是三件事，任何改动都需要重新冻结协议。

15 从复现练习走到研究问题

第一个可检验问题是：普通CNN的优势来自局部平滑，还是可学习的边缘/上下文？ 3×3 均值阈值已经是机制相关的强基线；下一步可预注册一个 3×3 线性卷积，控制感受野并比较非线性的增量。当前结果没有回答这一点。

第二个问题是：加权BCE劣势有多少来自固定阈值？可以为每个方案配置同样的验证阈值网格，同时记录PR曲线和空图误报，再用新测试拆分评估。不能在本次已经查看过的测试结果上挑一个“修正后阈值”并称其独立测试成绩。

第三个问题是背景偏移。我们知道生成器改变了背景，这是受控变化；但本次不同拆分对象、噪声、尺寸也重新抽样，所以不是逐图因果差值。要做更强的配对研究，应固定掩码、对比度和噪声，只改变背景，然后区分裁剪饱和带来的额外变化。

真正面向自然图像或科学图像时，还要考虑标注者差异、边界歧义、ignore区域、对象层级、稀有尺度、设备或主体拆分、许可与部署代价。不要把这里的原创矩形数据、CPU耗时或0.6770 IoU外推成真实应用性能。

16 复查边界与学习检查点

reference.py不导入torch，独立计算稳定BCE、全卷积前后向、IoU、Smooth L1、NMS、教学AP和混淆计数。测试对67个CNN参数与24个输入元素做中心有限差分，并与框架全部梯度核对；最大误差约 1.8×10^{-10} 。另用整数像素单元集合的交并计数验证几何IoU，避免只拿同一公式的两份拷贝互相证明。

数值参照有意限制有限实数、数组不超过200万元素、绝对值不超过一百万；框边长至少为 10^{-6} 以避免下溢，编码结果也须在数值范围内；正类权重在 $(0, 1000]$ ，解码对数尺度绝对值不超过20，且解码结果仍需通过框范围检查。它不是高性能生产库、任意维度分割库或官方评测替代品。

练习结束前应能独立解释：为什么像素准确率高而前景IoU为0；为什么重叠目标在语义分割中只有一个前景值；为什么NMS不可用于计算真值匹配；为什么加权概率未必校准；为什么三种子不等于三份测试集；为什么空图约定必须写进报告。完整实验任务见lab，逐题推导与参考输出见answers。