

047 练习详解

先修关系仍是043与053。以下答案区分D=1手算子模型、D=8正式模型与资源估计，不把三者混为一谈。

1 patch位置与shape

8×8 、 $P=2$ 、 $C=1$ 时 $N=16$ ，每块4值，批量shape为 $B \times 16 \times 4$ 。前5块原图坐标：第0行0-1列0-1；第1行0-1列2-3；第2行0-1列4-5；第3行0-1列6-7；第4行2-3列0-1。

需要把空间分块轴移到通道/块内轴之前，再展平。直接reshape可能把原图一整行的连续值塞入同一块，shape仍然对而空间含义错。往返还原和独立切片两种核验要一起做。

2 投影参数与等价卷积

$C=3$ 、 $P=4$ ，块内维度 $F=3 \times 16=48$ 。D=12时共享投影有 48×12 权重加12偏置，共588参数。W为 48×12 ，等价Conv2d权重为W.T reshape成 $12 \times 3 \times 4 \times 4$ ，步幅4、无填充。

卷积输出的空间位置顺序必须与patch行优先序一致，再展平并转成 $B \times N \times 12$ 。两种操作的数学相等不代表所有底层实现逐字节完全相同，数值比较需合理浮点容差。

3 信息丢失发生在哪里

整除且保存全部值的patchify只是置换与重排，可以由unpatchify还原。若悄悄裁边则已丢失内容，本代码选择报错。线性嵌入是F到D的映射， $D < F$ 时不能在整个F维空间一一对应； $D \geq F$ 也需满列/行秩条件才可能保留全部输入信息。

学习得到的有损压缩仍可能保留任务相关信息，但这属于任务与训练结果，不能从shape直接推出。位置表加入编码也不能恢复已被投影丢掉的像素细节。

4 排列等变与位置

无位置时Z变RZ，Q/K/V也左乘R，分数变RSR转置。softmax按行归一化，行/列同步置换后仍得RAR转置，输出变RAV。故token输出等变，所有token均值不变。

若只重排内容而固定位置表， $RZ+P$ 一般不等于 $R(Z+P)$ ，所以原证明条件不成立。位置和内容同时重排则恢复同一编号变换。探针最大误差约 $4.44e-16$ 与 $2.22e-16$ 是浮点末位；固定位置下变化0.701645明显不是同一量级。

一像素移动一般会让像素跨越非重叠块边界，不能直接等同于R。还要考虑图边界与位置参数，不能把上述token排列性质说成任意图像平移性质。

5 两样本的完整初始前向

参数 $w=(0.5,-0.25)$ ，位置 $(0,0.25)$ ， $q=k=0.5$ ， $v=o=1$ ， $c=0$ 。样本1嵌入 $(0.5,0)$ ， $Q=K=(0.25,0)$ ， $V=(0.5,0)$ 。分数 $[[0.0625,0],[0,0]]$ ，注意力第一行约 $(0.515619916,0.484380084)$ ，第二行 $(0.5,0.5)$ 。上下文约 $(0.257809958,0.25)$ ，均值预测 0.253904979 。

样本2嵌入 $(-0.25,0.5)$ ， $Q=K=(-0.125,0.25)$ ， $V=(-0.25,0.5)$ 。分数 $[[0.015625,-0.03125], [-0.03125,0.0625]]$ ，注意力两行约 $(0.511716605,0.488283395)$ 与 $(0.476579651,0.523420349)$ 。上下文 $(0.116212546,0.142565262)$ ，预测 0.129388904 。

标签为1和0，残差约 -0.746095021 、 0.129388904 ，单例half-MSE 0.278328890 、 0.008370744 ，两例均值 0.143349817241 。预测上游是残差除以2，再经token均值除以2。两个平均因子来源不同，不能遗漏或重复。

softmax上游应为A逐元素乘 $[\text{barA减去每行A加权的barA均值}]$ 。随后 $\text{barQ}=\text{barS}\cdot K$ 、 $\text{barK}=\text{barS}$ 转置 $\cdot Q$ 、 $\text{barV}=\text{A转置}\cdot \text{barz}$ 。最后 $\text{barE}=q\cdot \text{barQ}+k\cdot \text{barK}+v\cdot \text{barV}$ ，三路径必须相加。

6 九参数贡献和归约

样本1的嵌入上游约 $(-0.195260419,-0.183613114)$ ，样本2约 $(0.032727611,0.034238136)$ 。共享 w 对两位置输入乘这些上游并相加；位置 p_0/p_1 各自收集对应位置在两样本的贡献。

九参数总梯度按 w_0 、 w_1 、 p_0 、 p_1 、 q 、 k 、 v 、 o 、 c 排列约为

$$(-0.161022284, -0.116647367, -0.162532808, -0.149374979, \\ -0.002345169, -0.002345169, -0.086347876, -0.086347876, -0.308353058).$$

例如 w_1 收到样本1第二patch的 -0.183613114 ，再收到样本2两个patch上游之和 0.066965747 ，得到 -0.116647367 ； p_1 则只收集第二patch，两例相加 -0.149374979 。它们不同恰好显示共享范围不同。

对原始像素， barX 行向量为 barE 乘旧 w ；不能在 w 更新后再计算旧损失的输入梯度。 q/k 以及 v/o 在这个标量结构里存在乘积尺度冗余，当前相同梯度不是复制错误，但也不表示一般多头参数一定具有相同导数。

7 同步更新与下一次前向

用学习率0.1统一更新，得到约

$$(0.516102228, -0.238335263, 0.016253281, 0.264937498, \\ 0.500234517, 0.500234517, 1.008634788, 1.008634788, 0.030835306).$$

新样本1e=(0.532355509,0.026602235), 新Q=K约(0.266302601,0.013307356), V约(0.536952286,0.026831939)。新注意力两行约(0.516836955,0.483163045)、(0.500841674,0.499158326)。上下文约(0.290480986,0.282321467), 新预测0.319709546, 残差-0.680290454, 损失0.231397551。

样本2e约(-0.222081982,0.542704463), Q=K约(-0.111093073,0.271479505), V约(-0.223999613,0.547390601)。新注意力两行约(0.510623692,0.489376308)、(0.474058162,0.525941838), 上下文(0.153500482,0.181706774), 预测0.199886155, 损失0.019977238。

两例平均0.125687394169低于旧值, 但样本2变差。共享参数优化的是总目标, 不保证每例同时下降。第二轮全部贡献与第二次更新见讲义和results; 第三前向预测0.371535307377、0.253748587374, 均值损失0.114839053867。

8 参数量与未匹配预算

CNN第一卷积 $8 \times (9+1)=80$, 第二 $8 \times (8 \times 9+1)=584$, 头 $8 \times 2+2=18$, 总682。

ViT patch投影 $4 \times 8+8=40$, 位置 $16 \times 8=128$ 。块内QKV $8 \times 24+24=216$, 输出 $8 \times 8+8=72$, 两前置LN各16共32, FFN($8 \times 16+16$)+(16 $\times 8+8$)=280, 合600。末端LN16, 头18, 总40+128+600+16+18=802。

混合stem $4 \times (9+1)=40$, patch输入16维, 投影 $16 \times 8+8=136$, 其余相同, 总40+136+128+600+16+18=938。

同一规模内图数、步数、学习率与选择规则相同, 参数、FLOPs、墙钟、初始化向量与各架构最优配方不同。不能把共享一个seed解释为同一个初始向量, 也不能用未参与预测的参数补齐数量来宣称匹配。

9 数据规模与暴露量

每规模3架构 $\times 3$ 种子 $\times 200=1800$ 更新。32图条件有57600次图呈现, 128图条件230400次, 合288000。每拟合初值到最终共201参数状态, 18次共3618。

所以两规模同时改变可用数据和每次梯度中的图数/总呈现量。它不是固定呈现预算的数据效率曲线。进一步研究可预先固定batch与总呈现数, 再改变训练池大小, 但也要解释重复次数和覆盖率的差别, 不能事后改称已经做过。

10 准确率、NLL与强规则参照

二分类只要正确类别分数稍大即可正确; 但分数差接近0时概率接近0.5, NLL接近log2。CNN在许多图上正负方向正确, 却没有形成大的置信间距, 因此高准确率与约0.687的NLL不矛盾。

事后邻接相关规则利用条形方向结构，在本数据达到100%；其意义是说明任务存在简单可行信号，当前神经失败不是任务必然不可预测。它不是预先冻结的第四神经臂，没有参与选择或重跑调参。未校准分数不能直接当logit与网络比NLL。

这份结果不能证明CNN普遍优于ViT，也不能证明局部归纳偏置是唯一原因。尤其小ViT若某种子训练NLL低而测试NLL高，还提示拟合与泛化问题，应保留逐种子训练/测试读数。

11 容量估计与显存

显式注意力张量元素数 BhN^2 。B32、h2、N16、float64时是 $16384 \text{元素} \times 8 = 131072 \text{字节} = 128 \text{KiB}$ 。固定P时图像长宽翻倍，N增4倍，容量增16倍；固定图像把P减半，同样增16倍。

224×224 、h12、B1、float32、无CLS：P16给N196， $12 \times 196^2 \times 4 = 1843968 \text{字节} \approx 1.759 \text{MiB}$ ；P8给N784， $29503488 \text{字节} \approx 28.137 \text{MiB}$ 。加入CLS要用 $(N+1)^2$ 。

CPU autograd保存张量的逻辑字节可能重复计算共享存储；去重storage仍包含输入/参数引用，不是纯激活或进程峰值。GPU峰值本次未测，应留null。实际显存还受优化器、dtype、后端、缓存和重计算影响，不能把一张矩阵的估计冒充完整训练显存。

12 自己的任务如何设计对照

先明确目标依赖局部纹理、跨区域关系还是两者，并选择允许的数据拆分单位。固定数据许可、输入分辨率、增强、预训练来源、选择预算和主要指标。对CNN/ViT报告参数数、图呈现、步数、算术/墙钟与内存实际口径，不以“同样epoch”代替全部公平性说明。

可比较一个局部CNN、一个明确大小的ViT和一个卷积stem混合结构；再做真正只改变一个因素的消融。若预算不足以调好每种模型，结论限定为该预算/配方下的结果。保留全部种子、失败、测试污染与事后诊断身份，不把自己的小规模曲线推成大规模规律。