

049 参考答案：计数、共享梯度与公平度量

先独立完成实验指导，再用本答案定位具体差异。最后一位浮点数可有环境差异；对象、维度、分母、边界和更新顺序不应含糊。

A 文字与ID

“材料A”有3码点、7字节；预组合café有4码点、5字节；分解形式cafe加U+0301有5码点、6字节；U+1F469+U+200D+U+1F52C有3码点、11字节；字面量“<PAD>”有5码点、5字节；空串为0和0。显示宽度、字素簇数没有从len(text)直接获得。

“材料A”的UTF-8为e6 9d 90 e6 96 99 41，纯字节ID依次为234、161、148、234、154、157、69；加边界为[1,234,161,148,234,154,157,69,2]。不是把汉字Unicode编号直接加4，而是每一个UTF-8字节加4。

ID259对应字节ff，不是合法UTF-8字节序列中的独立字符。ByteBPE().decode([1,259,2])抛UnicodeDecodeError是正确行为。反方向未配对代理码点也不应静默编码。普通“<PAD>”不能变成ID0，否则原始内容和控制命令将混在一起，往返还原也会失效。

本训练集码点词表对七个探针的UNK数依次为3、2、2、3、5、0、3。字节编码不产生UNK，但一些新字节嵌入没有经过训练。编码覆盖、表示学习和语义能力是三个不同问题。

B BPE逐轮结果

两篇abab各含(a,b)两次、(b,a)一次，总频次为4和2。先合并(101,102)→260，两篇都成为[260,260]；该对总频次2，第二轮合并为261。新片段依次是hex6162和61626162。新文本编码必须应用保存的规则顺序，不重新按该文本统计频次。

单篇aaaa的(a,a)频次3；左到右非重叠替换两次变成[260,260]，下一轮最高频次只有1，因停止规则终止。若错误地将重叠位置都替换，会重复消耗中间字符。两篇独立a和b没有文档内相邻对，因此不能学到ab。

两篇abac有(ab)、(ba)、(ac)各两次，ID对(101,102)按字典序最小，所以选ab。规则不是按字符显示排序，也不是依赖Counter碰巧先遇到哪个对。

真实训练合并第1项(36,119)表示“空格+s”，第2项(112,105)表示le；第9项生成hex8082，单独不能UTF-8解码。16次后V=276，内容token1458→1050；加48个EOS目标后是1098。固定表可从tokenizer_audit.bpe.merges完整恢复。

C 三个矩阵和分母

宽度5时，各行如下，顺序为[A,A,B]、[B]、空串：

```
x = [[1,4,4,5,0], [1,5,0,0,0], [1,0,0,0,0]]
y = [[4,4,5,2,0], [5,2,0,0,0], [2,0,0,0,0]]
m = [[1,1,1,1,0], [1,1,0,0,0], [1,0,0,0,0]]
lengths = [4,2,1], M = 7
```

注意这不是手算池化例的有效长度3、1。池化例只聚合内容；下一token训练还包含BOS→首内容以及尾内容→EOS，故每篇目标数等于内容token数+1。

把宽度5增加到9只增加四个PAD目标，mask全False，因此有效loss和全部数据梯度不变。PAD目标被ignore，不代表输出类别PAD从softmax分母里删除。对所有V类输出仍要归一化，PAD输出列收到相应的概率梯度。

假设一篇有3个目标，各loss=1；另一篇有1个目标，loss=5。统一token平均为(3+5)/4=2；文档平均再平均为(1+5)/2=3。都可以作为研究选择，但不可把一种代码解释成另一种公式。

$E[\text{PAD}]=0$ 经线性头仍输出b；若不mask，则它有交叉熵，反向可改变W/b。后续RNN也可能在零输入上继续更新状态，因此padding处理不能只靠嵌入行归零。

D 两轮完整数值账本

先约定参数顺序 $E[A], E[B], w, b$ ；PAD固定，其余未读特殊行没有数据梯度。初值 $[1/2, -1/4, 2, 1/10]$ 。两个预测残差同为-2/5，但中间均值分别为1/4和-1/4，所以w路径的符号不同。

第0轮， $L=2/25$ 。每个样本预测上游是-1/5；样本1每个位置上游是-2/15，样本2唯一位置为-2/5。贡献表为：

来源	$E[A]$	$E[B]$	w	b
样本1	-4/15	-2/15	-1/20	-1/5
样本2	0	-2/5	1/20	-1/5
合计	-4/15	-8/15	0	-2/5

$\eta=1/10$ 同时作用于所有坐标，新参数 $[79/150, -59/300, 2, 7/50]$ 。重新前向：样本1均值257/900，预测32/45，残差-13/45，loss169/4050；样本2均值-59/300，预测-19/75，loss361/11250；平均3737/101250。

第1轮样本1预测上游-13/90，乘w再除长度3，得到每个位置-13/135。A两次累加为-26/135；B此路径为-13/135。样本2预测上游-19/150，乘w得到B路径-19/75。B合计-236/675。头部梯度为

$$g_w = (-13/90)(257/900) + (-19/150)(-59/300) = -0.0163358024691,$$

$$g_b = -13/90 - 19/150 = -61/225.$$

第2组参数为[0.545925925926,-0.161703703704,2.001633580247,0.167111111111]。再前向所得均值[0.310049382716,-0.161703703704]，预测[0.787716367090,-0.156560452273]，残差[-0.212283632910,-0.156560452273]，单样本loss[0.022532170401,0.012255587608]，平均0.0173938790043。

Fraction账本中最后平均值为584960512972327937/33630250781250000000；不必手抄长分数，关键是每次都新参数从头计算。第二步w不再相消，说明第一步的零只是本例数值巧合。

常见错位诊断：E[A]少一半通常漏掉重复路径；所有梯度大一倍通常漏批次平均；B值错误但A对，多半漏跨样本累加；第二步只有w错，检查是否沿用了旧均值；短样本预测错，检查是否除以矩形宽。

E 分类梯度、有限差分与重排

一位置的loss是 $\log \sum \exp(z) - z_{\text{target}}$ ，因此对第v类logit导数为 $\text{softmax}(z)_v - 1[v=\text{target}]$ 。乘mask/M后，再经过 $z = hW + b$ 就得到讲义的gW、gb、dh。最后按输入ID加回E；目标ID和输入ID是两个不同角色，不能按目标ID回写嵌入梯度。

V=7、D=2时E有14、W有14、b有7，共35坐标。E[PAD]两坐标固定，中心差分检查其余33个坐标，包括未读行应为零的情况。测试的有限差分步长 $1e-6$ ，误差阈值 $3e-9$ ；它不是只抽几个看起来正确的坐标。

如果对参数做一致ID置换 π ，需满足 $E'[\pi(v)] = E[v]$ 、 $W'[:, \pi(v)] = W[:, v]$ 、 $b'[\pi(v)] = b[v]$ ，输入和目标都替换为 $\pi(\text{ID})$ 。PAD/BOS/EOS/UNK语义保持时，可以只重排普通内容ID。这个操作是类别重新命名，不是改变文字顺序。

固定E[PAD]意味着该行不是可自由优化的坐标，数值参照把其数据梯度置零。若故意在有效位置放PAD而又任意修改PAD行，就超出了本主实验的文档契约，不能拿自由变量有限差分来否定固定参数的实现。

F 六次固定训练与负面结果

训练输入相同48篇原文，两个词表的有效目标数为1506和1098；测试原文730字节，目标数754和554。全程六模型 $\times 120$ 更新=720；每模型保留初值和每次更新后的状态，共121，合计726。

词表	神经每token NLL均值	神经token PPL均值	神经bits/byte均值	unigram bits/byte
纯字节	4.518608	91.714217	6.733296	5.884620
字节BPE	4.837269	126.140911	5.296167	4.574682

先按单个模型算PPL再平均；不要把两个非线性操作交换。BPE的每token成本更高，但一个token平均承载更多字节，所以换成每字节后可能更低。固定文本的分母必须共用730，而不是用两套token数各自充当“长度”。

独立复算可遍历每篇编码序列的相邻ID对，取 $z=E[\text{input}]@W+b$ ，累加稳定NLL；不要包含补齐位置，不预测BOS。六个最终模型的每篇值都应保留记录一致。报告差异时先查词表合并顺序、UTF-8字节、EOS计数和参数重载，再考虑浮点误差。

unigram概率为 $(c+1)/(\text{训练目标总数}+V)$ ， c 只数训练目标；验证、测试不更新频率。神经模型均未超过对应基线，应如实报告。可能原因包括极小数据、有限优化预算和模型配方，但本次未进行因果消融，因此这些只是待检验解释，不能当成已证实原因。

G 研究记录示例与边界

可检验假设示例：“在冻结的两种tokenizer与相同训练原文上，把训练预算从相同更新数改为相同有效token呈现量，会改变六次模型的bits/byte差距。”先写明总token预算、最后不完整批次如何处理、种子、模型参数差异以及验证选择规则。完成后与原120步结果并列，不替换原记录。

NFC扩展要说明分母使用规范化前还是规范化后的字节，是否允许不同原文映射到同一规范文本。

RNN扩展要声明文档状态重置、截断反向范围、padding状态和目标mask。不能只在代码中加一层网络就认为实验协议没有变化。

本课的bits/byte只计算确定编码路径成本，包含EOS，不含模型与词表侧信息，不是所有文字路径的概率求和。没有测量吞吐、显存或真实压缩文件。三种子重复的是初始化，测试集固定，不能把三次运行当成三个独立自然语料样本。

验收底线

数值完整、失败保留、结果可重跑比“图看起来下降”更重要。若任一数据SHA、结果关联SHA、ID范围、有限性或mask契约不满足，应停止解释结果并修复输入，不用静默改数据或删除异常模型来让表格更漂亮。