

051 门控记忆与编码解码

门控改变信息通过的路径；编码解码把输入序列变成条件生成问题。能在真实前缀下预测，不等于自由生成整条序列成功。

1 从050出发：要解决哪两个问题

正式先修050。沿用独立序列 $h_0=0$ 、批次时间轴、状态冻结mask与loss mask分开的约定。049的PAD0、BOS1、EOS2、UNK3仍保留。本讲不把门控网络当成无需BPTT的新方法：时间展开、共享参数累加、梯度清零和同步更新都继续适用。

050的tanh RNN每步重算一个状态。门控网络增加可学习的保留、写入或暴露比例，使某些梯度路径不必在每一步都穿过同一种非线性。但“多一条路径”不保证任意长度都能记住，也不保证固定小预算里胜过普通RNN。

另一个问题是输入和输出长度、顺序不必对应。我们用一个encoder读完源序列，再以最终状态初始化decoder，逐项生成反序列。原始encoder-decoder与sequence-to-sequence工作见[S1,S2]；本课不是机器翻译复现，不使用注意力、预训练或语言文本。


2 GRU的四个量与明确的约定

本讲采用PyTorch GRUCell的reset-after约定，门顺序为r、z、n。[S3] 数学列向量写法是

$$\begin{aligned} r_t &= \sigma(W_{ir}x_t + b_{ir} + W_{hr}h_{t-1} + b_{hr}), \\ z_t &= \sigma(W_{iz}x_t + b_{iz} + W_{hz}h_{t-1} + b_{hz}), \\ q_t &= W_{hn}h_{t-1} + b_{hn}, \quad n_t = \tanh(W_{in}x_t + b_{in} + r_t \odot q_t), \\ h_t &= (1 - z_t) \odot n_t + z_t \odot h_{t-1}. \end{aligned}$$

r是重置门，调制候选状态中的旧状态仿射分支；z在这里是保留旧状态的比例。z接近1偏向保留，接近0偏向采用候选n。某些资料用相反的更新门命名或互换系数，阅读时先看公式，不能只对照字母。

每个门是H维向量，不是一整条序列共用一个开关。sigmoid输出在0至1之间，仍可有连续梯度；不是随机抽签，也不是硬删除。n经过tanh，状态由旧h和n逐坐标混合。当 h_0 在[-1,1]内时，这个更新让状态仍在该区间内，但有限幅度不等于保留无限信息。



reset-after约定： r 乘在 $U_n h + b_{hn}$ 整体上；图中公式明确保留旧 h 的直路

图1 GRU的门与候选分支。图中省略各仿射矩阵细节；最后相加才得到新状态。

注意 $r \odot (Uh + b)$ 通常不等于 $U(r \odot h) + b$ 。前者先混合隐藏坐标再逐输出坐标重置；后者先重置输入坐标再混合；偏置位置也不同。因此不能把经典论文和某框架的GRU权重仅按名称复制就认定相同。我们的单步前向、输入/状态梯度、全部权重与偏置梯度都与官方GRUCell逐项对照，且另有NumPy参照。


3 LSTM为什么分别有 c 和 h

标准无peephole、无projection的LSTM还有独立cell state c_t 。四条仿射生成输入门 i 、遗忘门 f 、候选 g 和输出门 o ； i 、 f 、 o 用sigmoid， g 用tanh，然后

$$c_t = f_t \odot c_{t-1} + i_t \odot g_t, \quad h_t = o_t \odot \tanh(c_t).$$

c 保存加性记忆， h 是向外暴露并反馈给下一步门控的状态，两者不能混成一个张量。与GRU相比，它显式分开遗忘、写入和输出暴露；二者并不形成对所有任务都成立的优劣顺序。框架的完整状态/shape定义见[S4]。

固定门值的标量演示：旧 $c=1.2$ ， $f=.8$ ， $i=.25$ ， $g=-.5$ ， $o=.6$ 。保留部分.96，写入部分-.125，新 $c=.835$ ， $h=.6 \times \tanh(.835)=.409890985386$ 。这里门值是人为指定的解析例，不是额外训练实验；测试将对应logit/atanh偏置写入LSTMCell，核对状态和直接导数。



LSTM分开保存 c 与 h ；这里固定门值用于解析演示，实际门也依赖 x 与旧 h

图2 LSTM加性记忆的数值流。实际模型中门依赖 x 与旧 h ，此图只演示给定门值时的合成。

固定各门时，直路上的 $\partial c_t / \partial c_{t-1} = f_t$ ；固定GRU各门与候选时，直路贡献为 z 。完整循环导数还包含旧状态对门和候选的影响，不能把总Jacobian简单写成 $\text{diag}(f)$ 或 $\text{diag}(z)$ 。门接近1能减少某条路径的衰减，但sigmoid饱和也可能让门参数本身难学。




图3 固定门的直路乘积。0.9经过100步约 $2.66e-5$ ；0.99经过100步约0.366。真实网络的门不固定，这只是解释性解析探针。

4 参数数、shape和实现选择

输入维 D 、状态维 H 时，一个GRUCell的输入权重 $3H \times D$ 、循环权重 $3H \times H$ 、两份偏置各 $3H$ ，总计 $3H(D + H + 2)$ 。若数学推导把两份偏置合成一份，参数坐标数会不同；在候选分支中，隐藏偏置还被 r 乘到，不能总把两个候选偏置合并为一个常数。

无投影LSTMCell对应 $4H(D + H + 2)$ ，tanh RNNCell为 $H(D + H + 2)$ 。这些公式不含嵌入和输出头，也不含多层、双向、peephole或投影参数。我们的主实验 $D=8$ 、 $H=12$ ，encoder和decoder各一个cell，参数互不共享；它们共享 $V=8$ 的嵌入表 E ，输出头为 12×8 加8偏置。

因此RNN总计 $64 + 2 \times 264 + 104 = 696$ 坐标，GRU为 $64 + 2 \times 792 + 104 = 1752$ ；其中 $E[\text{PAD}]$ 的8坐标固定。两模型同 H 、同样本和更新数，但参数量和计算量不同。本实验没有做等参数、等FLOPs或等时间比较，不把“相同hidden size”叫作完全公平。

代码采用批次行向量，仿射写作 $x@W.T$ ，和上方列向量定义一致。reset-after候选的hidden bias要先加再乘 r 。实现不调用nn.GRU执行主训练，使用基础矩阵算子显式展开，从而能把每条路径交给NumPy独立复核。

5 完整数值实例：两条独立序列

用 $D=H=1$ 的GRU处理样本1输入 $[1, -1]$ 、目标0.2，样本2输入 $[0.5]$ 、目标-0.1。两者各自 $h_0=0$ ；只在各自最后状态上输出 $\hat{y} = w_o h_T + b_o$ ，单样本 $\ell = \frac{1}{2}(\hat{y} - y)^2$ ，批次 L 为两者平均。

初始参数按组为：输入权重 $[.4, -.3, .5]$ ，循环权重 $[.2, .1, -.4]$ ，输入偏置 $[.1, -.2, .05]$ ，隐藏偏置 $[-.05, .1, .02]$ ，输出头 $[1.2, -.1]$ 。每个三元组顺序都是 r 、 z 、 n ，总共14个参数。输入是实值小例，不在此处额外训练嵌入，以便看清门控链。

样本1第1步： $r=\sigma(.45)=.610639234$, $z=\sigma(-.4)=.401312340$, $q=.02$,
 $n=\tanh(.55+r \times .02)=.509617382$, $h_1=.305101638$ 。第2步读 $x=-1$, $r=.428253678$, $z=.557373720$,
 $q=-.102040655$, $n=-.457147571$, $h_2=-.032289894$ 。最后预测 $-.138747873$, 残差 $-.338747873$ 。

样本2从新的 $h_0=0$ 开始, 只读 $x=.5$: $r=.562176501$, $z=.437823499$, $q=.02$, $n=.301567960$,
 $h_1=.169534421$; 预测 $.103441305$, 残差 $.203441305$ 。不要把样本1最终 h 当作样本2初值。平均损失
 $L=.0390346214$ 。

初始同一组参数，两条独立序列均从 $h_0=0$ 开始

	重置门 r	保留门 z	候选 n	新状态 h
样本1 t1	0.610639	0.401312	0.509617	0.305102
样本1 t2	0.428254	0.557374	-0.457148	-0.032290
样本2 t1	0.562177	0.437823	0.301568	0.169534

图4 初始参数下的全部三个时间位置。两条样本共享参数，不共享初始状态或已经算出的 h 。

6 GRU局部导数：每条路都要算

某时间步已从后续收到 $d = \partial L / \partial h_t$ 。先按乘加结构拆开： $g_n = d \odot (1 - z)$ 、 $g_z = d \odot (h_{t-1} - n)$,
 旧 h 直路贡献 $d \odot z$ 。通过 $\tanh$ 得 $a'_n = g_n \odot (1 - n^2)$ ；通过候选重置乘法得 $g_r = a'_n \odot q$ 。再通过
 sigmoid：

$$a'_r = g_r \odot r \odot (1 - r), \quad a'_z = g_z \odot z \odot (1 - z).$$

输入侧仿射上游是 $[a'_r, a'_z, a'_n]$ ，隐藏侧是 $[a'_r, a'_z, a'_n \odot r]$ 。分别乘输入或旧状态的转置得到各权重外积；对批次求和得到对应偏置梯度。对旧状态的完整反传为

$$g_{h_{t-1}} = d \odot z + W_{hr}^\top a'_r + W_{hz}^\top a'_z + W_{hn}^\top (a'_n \odot r).$$

对输入的梯度为 $W_{ir}^\top a'_r + W_{iz}^\top a'_z + W_{in}^\top a'_n$ 。所有时间步复用同一组参数，最终要把各时间外积相加，再跨样本相加。没有学习 h_0 时，传到 h_0 的梯度只作诊断，不用于更新某个不存在的初始状态参数。

7 从最终loss回到每个时间步

预测上游先包括批次平均：样本1为 $-.338747873/2=-.169373936$ ，样本2
 为 $.203441305/2=.101720652$ 。输出权重梯度各为上游乘最终 h ，偏置梯度为上游本身。再乘 $w_o=1.2$,
 最后隐藏状态的上游分别 $-.203248724$ 和 $.122064783$ 。

样本1第2步得到 $g_n = -.089963226$ 、 $g_z = -.154926179$ 、 $a'_n = -.071162360$ 、
 $g_r = .007261454$ 、 $a'_r = .001777985$ 、 $a'_z = -.038221567$ 。传回 h_1 的直路为 $-.113285497$ ，经门和候
 选的其他路径合计 $+.008723657$ ，总上游 $-.104561840$ 。

样本1第1步收到这个总上游，得到 $a'_r = -.000220365$ 、 $a'_z = .012802662$ 、 $a'_n = -.046342075$ ；输入梯度为 $-.027099982$ 。第2步输入梯度为 $-.023403516$ 。样本2独立一步得到 $a'_r = .000307083$ 、 $a'_z = -.009060399$ 、 $a'_n = .062381250$ ，输入梯度为 $.034031578$ 。




图5 样本1两个反向时间步的路径分解。只乘保留门z会漏掉可正可负的其他路径。

以 W_{in} 为例，样本1贡献是第1步 $(-.046342075) \times 1$ 加第2步 $(-.071162360) \times (-1) = .024820285$ ；样本2贡献 $.062381250 \times .5 = .031190625$ ，总计 $.056010910$ 。 W_{hn} 则在样本1第2步得到 $(a_n' r)h_1 = -.009298138$ ，其他位置 $h_0 = 0$ ，所以这两个位置的循环权重贡献为零，但循环偏置仍可能有贡献。

14个参数分两行展示：样本内先累加时间，样本间再相加；已含批平均

样本1	-0.0020	0.0510	0.0248	0.0005	-0.0117	-0.0093	0.0016
样本2	0.0002	-0.0045	0.0312	0.0000	0.0000	0.0000	0.0003
总梯度	-0.0018	0.0465	0.0560	0.0005	-0.0117	-0.0093	0.0019
	W_{ir}	W_{iz}	W_{in}	W_{hr}	W_{hz}	W_{hn}	b_{ir}

样本1	-0.0254	-0.1175	0.0016	-0.0254	-0.0588	0.0055	-0.1694
样本2	-0.0091	0.0624	0.0003	-0.0091	0.0351	0.0172	0.1017
总梯度	-0.0345	-0.0551	0.0019	-0.0345	-0.0237	0.0227	-0.0677
	b_{iz}	b_{in}	b_{hr}	b_{hz}	b_{hn}	w_{out}	b_{out}

图6 全部14个参数的样本贡献与总和，精确数值在hand_ledger.json中。不是按最后一步覆盖前面梯度。

8 所有参数同步更新，再做完整下一前向

学习率 $\eta = .2$ 。下表给出完整第一组梯度与更新后参数，均由同一组旧参数计算；显示值四舍五入，实际使用float64。

参数	初值	总梯度	第一次更新后
W_ir	0.400	-0.001844808	0.400368962
W_iz	-0.300	0.046494029	-0.309298806
W_in	0.500	0.056010910	0.488797818
W_hr	0.200	0.000542466	0.199891507
W_hz	0.100	-0.011661463	0.102332293
W_hn	-0.400	-0.009298138	-0.398140372
b_ir	0.100	0.001864703	0.099627059
b_iz	-0.200	-0.034479305	-0.193104139
b_in	0.050	-0.055123186	0.061024637
b_hr	-0.050	0.001864703	-0.050372941
b_hz	0.100	-0.034479305	0.106895861
b_hn	0.020	-0.023704559	0.024740912
w_out	1.200	0.022714218	1.195457156
b_out	-0.100	-0.067653284	-0.086469343

更新后必须重置两个 h_0 并重算全部门。样本1的 $h_1=.305750839$ 、 $h_2=-.018914300$ ，预测-.109080579；样本2的 $h_1=.172960816$ ，预测.120297902。新的平均loss=.0360154925。总loss下降，样本2残差却从.203441305增至.220297902，单样本变差；共享目标没有逐样本单调保证。

第二轮反向的14维总梯度按同样分组为：

```
g_Wi = [-.001595299, .040595124, .056188990]
g_Wh = [ .000473606, -.010329595, -.008536771]
g_bi = [ .001705772, -.031984986, -.040932764]
g_bh = [ .001705772, -.031984986, -.016318674]
g_head = [.021974474, -.044391338]
```

再同步减去.2倍梯度，得到第二次更新后的参数：

```
Wi = [ .400688021, -.317417831, .477560020]
Wh = [ .199796786, .104398212, -.396433018]
bi = [ .099285905, -.186707142, .069211190]
bh = [-.050714095, .113292858, .028004647]
head = [1.191062262, -.077591076]
```

第三次完整前向：样本1 $h_1=.304707948$ 、 $h_2=-.008111377$ ，预测-.087252231；样本2 $h_1=.174511823$ ，预测.130263371；平均loss=.0338837660。全部三轮的每个门、局部上游、逐时间参数贡献和输入梯度都保留在账本，并用70位Decimal前向、全部参数中心差分 and autograd 分别复核。




图7 两次同步更新后的损失。样本2持续变差是保留的真实现象，不是绘图遗漏。

9 encoder-decoder：条件生成而非位置——分类

主实验源内容是四种符号A、B、C、D的短序列，对应ID4..7。encoder依次读取BOS、内容、EOS，在每个独立样本从全零状态开始；只把最后有效状态h传给decoder，不传整个状态列表，也不使用注意力。decoder初始h等于encoder最后h，输入BOS后预测反序列首符号，继续预测其余符号和EOS。

例如输入A B C，目标C B A EOS，teacher forcing输入BOS C B A。输入右移一位，当前目标不能直接作为当前输入，否则发生标签泄漏。训练时每一步都把真实前一个目标喂回去，称为teacher forcing；它是计算条件序列似然的常用方式，不意味着模型推理时会得到真实前缀。

条件序列概率按链式法则分解为 $p_{\theta}(y | x) = \prod_{t=1}^{T_y} p_{\theta}(y_t | y_{<t}, c(x))$ ，其中 $c(x)$ 为encoder终态，y包含末尾EOS。teacher forcing用真实前缀计算这条金标路径的概率；它没有声称推理时也能取得这些真实前缀。

主训练目标是 $L = -\sum_{bt} m_{bt} \log p_{bt,y_{bt}} / M$ ， $M = \sum_{bt} m_{bt}$ ，包含EOS，不包含PAD。它是token平均，不是先对各序列平均再平均。每步输出logit为 $z_{bt} = h_{bt} W_o + b_o$ ，其上游 $g_{z,bt} = m_{bt}(p_{bt} - \text{onehot}(y_{bt})) / M$ ；先累加输出头梯度，再乘 $W_o^{\top}$ 进入decoder BPTT。decoder初始h的总梯度继续传到encoder最后有效h，两段查表梯度共同累加回E。




图8 编码和解码的两个循环。固定维上下文是结构性限制，但某次错误不能仅凭结构图归因为“瓶颈已满”。

只有固定维 h 连接两端，输出不同位置的信息需要从这个状态中逐步取出。原文输入与输出位置可能不对齐，下一讲052会让一个位置按内容读取其他位置。不能因为注意力提供更多访问路径，就预先宣布其对本任务一定更好；仍需固定对照。

10 mask、EOS与无金标长度的自由生成

批次右补齐时，状态更新采用 $h_t = m_t \tilde{h}_t + (1 - m_t) h_{t-1}$ 。反向也包含无效位置的恒等直路；loss mask只决定哪些目标计分。若只mask loss却让encoder继续处理padding，传给decoder的状态可能已不是原文最终状态。

本实验空内容也有明确语义：encoder读BOS、EOS；decoder读BOS，预测EOS。训练语料没有空内容，但接口及边界测试覆盖它。源内容只接受普通ID4..7，不让调用方偷偷插入PAD或边界控制符。

自由生成从BOS开始，之后输入自己的argmax输出，首个EOS立即终止；最多10个输出，超过则记录未结束，不用真实目标长度帮它停止。没有beam search、长度惩罚或输出类别过滤。若模型输出PAD/BOS/UNK，作为无效控制输出计入错误，而不是静默删除。已结束样本冻结状态，不再给它续写，其他样本继续。

因而评价同时报告：真实前缀下的NLL、token准确率；自由生成在金标位置上的token准确率；整序列exact（含EOS、顺序、长度）；EOS结束率；无效控制符率。自由位置准确率缺失位置算错，额外输出不在其分母内，但会让整序列exact失败，不能仅看前者。

11 一个容易被说错的teacher forcing结论

真实前缀下的NLL是合法的gold序列对数似然，不是错误评价。但它不能单独告诉我们greedy解码生成了什么。token准确率也不能直接等同于整条序列成功率；局部错误可能改变后续输入和状态。

更细的事实是：在确定性模型、相同argmax平局规则、相同初始状态、最大步数覆盖金标长度、严格EOS定义下，“teacher-forced所有位置argmax都正确”与“greedy整条序列完全正确”等价。证明用归纳：第一步相同；若此前全部正确，两个过程看到的前缀相同，下一步也相同。因此本次teacher-forced sequence exact与free sequence exact相等，并非漏做自由生成。

这个等价不适用于比较token准确率，也不自动适用于采样、beam、不同截断或输出过滤。自由前缀下错误传播通常值得关注，但也可能偶然让某些后续位置变对；本次RNN种子5113自由位置准确率.832215，反而略高于teacher-forced的.825503。不要把“自由token准确率必然更低”当成定理。

同长度范围测试集：柱为3种子均值，点为完整种子；token准确率不是序列成功率




图9 三种计分方式并排。六个种子的完整自由输出确实生成并保留，不能只由teacher-forced指标推断输出内容。

12 固定协议：所有模型都保留

从四符号长度2、3、4的全部336种内容序列中固定打乱，取96训练、32验证、64测试；精确源序列不重叠。另从长度5、6中固定取64作长度外推测试。相同符号片段可以重现，这是组合教学任务，不代表自然语言数据独立性。

两架构各用5111、5112、5113三个初始化种子；D=8、H=12，300次全批次SGD，学习率.5，完整全参数梯度L2范数超过1时统一缩放至1。无动量、weight decay、预训练、早停或验证选择。验证集只描述，所有模型都评终点。相同种子不保证不同形状模型的每个随机权重可逐项配对。

每次先用旧参数完整前向、反向，求所有参数的全局范数，再统一clip，最后同步更新并清空梯度。clip不是逐参数限幅，也不是修改隐藏状态。完整1800次更新、1806个参数状态和每次裁剪因子全部保留。NumPy显式BPTT对每次状态转换都能独立复算，不只检查最后loss。




图10 六次完整训练。RNN有明显波动，GRU也并非自动收敛得更好；不删除不平滑这些曲线。

13 实测结果与不能推出的结论

同长度范围测试，RNN三个种子平均teacher NLL=.517469、teacher token准确率=.809843、自由位置准确率=.769575、整序列exact=.317708；GRU分别为.816051、.663311、.504474、.078125。固定小预算下GRU没有赢过RNN；不在看到结果后追加GRU训练或只挑最好种子。

预先声明的诊断把训练后encoder上下文置零，再用同一decoder自由生成；RNN各种子exact为0、.015625、0，GRU全0。它说明该干预下性能很低，但不是重新训练的等容量基线，也不能单独解释每个隐藏维的因果含义。已知反转规则的程序当然可以100%正确，那是任务规格的oracle，不是学到该规则的神经对照。

测试集最前5项，不按成功或失败筛选；完整64项×6模型保留

编号	输入内容	正确目标	RNN seed5111	GRU seed5111
0	D A B C	C B A D E O S	C B A D E O S	C B A C E O S
1	C A C D	D C A C E O S	D C B E O S	C A C D E O S
2	D B B A	A B B D E O S	A B B D E O S	A B D E O S
3	A C B D	D B C A E O S	D B C A E O S	D C B E O S
4	D D D	D D D E O S	D D D E O S	D D D E O S

图11 固定测试编号最前5项的真实生成，不按成功与否选例。每个模型、每条序列的输出都在results.json保留。

长度5、6外推中，两模型全部六次运行的整序列exact都为0；RNN平均teacher NLL=2.720769，GRU=1.697518。GRU的长序列NLL较好不等于自由生成成功，更不能说明它具有无限记忆。RNN结束率约.994792，仍有未在上限前输出EOS的真实失败；GRU结束率1也没有带来一条完全正确的长输出。




图12 原始长度分组的准确率和长序列NLL。各长度样本数不同，且长度2..4与5..6来自两个测试划分；不把连接线当作自然语料缩放规律。

本实验没有分离容量、优化难度、学习率或瓶颈的因果效应，没有等计算预算搜索，也没有测试所有长度。可以提出新协议研究这些因素，但必须和当前结果分开保存。三初始化种子共享同一数据划分，不能当作三个独立真实任务。

14 支持域与复现边界

batch接受1至256条普通ID4..7的列表，每条内容长度0至32；补齐额外宽度0至32，不自动截断；布尔值和浮点ID拒绝。greedy步数必须整数1至64。参数键/shape必须完整，D、H范围1至64，实数参数明确CPU/NumPy float64、有限且绝对值不超过1e6，PAD嵌入行必须为零。此上界是教学接口资源与数值契约，不是训练推荐值；超范围明确拒绝。参考反向在溢出时抛错，训练检查loss和梯度有限性。

训练先完成全部计算和序列化，再逐文件原子替换输出。训练或数据SHA检查失败保留旧结果；多文件不是目录事务，结果中的压缩文件SHA用于发现混配。正常与-O及新核Notebook都应核对本固定CPU环境；不承诺任意硬件后端位级相同。

所有门的数学图、NumPy循环、官方cell参照、有限差分 and 完整结果彼此核对；这些作者检查仍不等于独立审核。读者应先按lab独立实现，再看答案，尤其检查reset位置、两份偏置、padding状态、EOS、自由生成和loss分母。

15 原始来源

[S1] [Cho et al. Learning Phrase Representations using RNN Encoder-Decoder, 2014](#), 门控与encoder-decoder研究背景。本文实现采用明确的PyTorch reset-after约定，不声称权重兼容。

[S2] [Sutskever, Vinyals, Le. Sequence to Sequence Learning with Neural Networks, 2014](#), 序列条件生成背景。本课不复现其翻译数据、模型规模或成绩。

[S3] [PyTorch 2.7 GRUCell文档](#)，本课对照的精确r/z/n公式与参数shape。

[S4] [PyTorch 2.7 LSTM文档](#)，标准门、c/h、shape与投影变体的区分。本课LSTM只有给定门值的解析核验，不另训练LSTM主实验。