

注意力逐项计算实验详解

第052单元 解答与失败诊断

此文件对应lab的A至H。先自行计算，再对照。lecture末尾提供同一实例三状态完整矩阵账本，outputs/results.json保留未舍入数值。这里重点解释为什么这样计算，以及错误解法如何被发现。所有显示小数均为阅读舍入，不回写程序计算。

A 加权和与shape

标量输出5.6。二维值的第1坐标仍为5.6，第2坐标为 $0.2 \times (-1) + 0.3 \times 3 + 0.5 \times 5 = 3.2$ ，所以输出(5.6,3.2)。对两个坐标使用同一候选权重，不是分别重新归一化。

B=2、L=3、S=4、dk=2、dv=3时：Q和GQ为 $2 \times 3 \times 2$ ；K和GK为 $2 \times 4 \times 2$ ；V和GV为 $2 \times 4 \times 3$ ；分数、A、GA、GS为 $2 \times 3 \times 4$ ；O和GO为 $2 \times 3 \times 3$ 。softmax沿最后key轴。GV和GK需要跨query累加，参数梯度再跨样本和位置累加；不同batch不互相成为key。

标量参照对每个b、i列出允许的j，逐坐标累加 $q \times k$ 得到分数，除以 $\sqrt{dk}$ ，减最大值，计算exp和分母，然后逐value坐标累加。它不调用主实现或矩阵乘法，减少与矢量实现共享同一种索引错误的可能。两份实现一起通过仍不是数学证明，所以还配手算和有限差分。

B 前向和完整Jacobian

样本1的S为[[0.5,0.25],[-0.5,-0.25]]，A为[[0.562176501,0.437823499],[0.437823499,0.562176501]]，O为(0.124353002,-0.124353002)。样本2的S为[[0,0],[0.75,0.5]]，A为[[0.5,0.5],[0.562176501,0.437823499]]，O为(0.5,0.437823499)。

四个误差平方求和后除以8得到0.016128563004。求导时平方带出2，与half相消，所以GO除以4，不是8。样本2第一个位置误差0，第二个位置误差非零；其key和value仍被第二个query使用，因此不能说“第一个位置所有梯度为0”。

对 $a=(0.2,0.3,0.5)$ ：

$$J = \begin{pmatrix} 0.16 & -0.06 & -0.10 \\ -0.06 & 0.21 & -0.15 \\ -0.10 & -0.15 & 0.25 \end{pmatrix}.$$

例如 $J_{12} = -0.2 \times 0.3 = -0.06$ ，表示增大第2分数会降低第1权重。每列和为0，因为所有输出权重总和恒为1；每行和也为0，对应所有输入分数一起平移不改变该权重。只保留对角会破坏这两个性质。

主例第一行Jacobian的对角0.246134083、非对角-0.246134083。

$GA = (-0.031411750, +0.031411750)$ ，左乘J得到 $GS = (-0.015463004, +0.015463004)$ 。若用逐元素VJP：先算内积 $c = \sum a_j GA_j$ ，再算 $a_j(GA_j - c)$ ，得到同值。c不是常数0，一般不能省略。

C 共享路径和同步更新

样本1两query对value1的贡献分别约-0.017658947和+0.013752802，和为-0.003906145。反向必须在同一状态累加它们。样本2两key梯度为+0.009604660和-0.009604660，两位置的输入特征1都为1，所以对WK第1坐标的样本2贡献恰好抵消；WK第2坐标则只有第一个位置的输入特征2为1，贡献+0.009604660。

初始每个参数的样本贡献：

坐标	样本1	样本2	合计
WQ1	-0.007731502	0.009604660	0.001873157
WQ2	0.007731502	0	0.007731502
WK1	-0.015463004	0	-0.015463004
WK2	0.015463004	0.009604660	0.025067664
WV1	-0.003906145	-0.078044125	-0.081950271
WV2	0.003906145	-0.043874573	-0.039968428

以WQ1为例，样本1位置1贡献 $1 \times (-0.007731502)$ ，位置2贡献 0×0.007731502 ；样本2位置1贡献 1×0 ，位置2贡献 1×0.009604660 。其余坐标同样按输入坐标乘本地投影梯度展开。不是按出现次数取平均，loss的平均已经在GO中。

参数与完整前向的更新核对

状态	WQ 两坐标	WK 两坐标	WV 两坐标	loss
0	0.500000000, -0.500000000	1.000000000, 0.500000000	1.000000000, -1.000000000	0.016128563004
1	0.499812684, -0.500773150	1.001546300, 0.497493234	1.008195027, -0.996003157	0.015241267063
2	0.499660916, -0.501550886	1.003079953, 0.495036094	1.015712725, -0.992437694	0.014489698297

状态1的四个输出依次为0.131662966、-0.119709851、0.510312427、0.448595597；状态2为0.138399612、-0.115598919、0.519726010、0.458434958。第二次更新必须使用状态1的梯度： $WQ=(0.001517681, 0.007777355)$ ， $WK=(-0.015336521, 0.024571393)$ ， $WV=(-0.075176983, -0.035654629)$ 。lecture账本列出各状态中间量及逐路径导数，不能用状态0梯度连减两次冒充两步SGD。

样本2位置1目标0.5，两个更新都使它变差。其他项的改善超过这一项的损失，故总loss仍下降。更大的学习率可能让总loss也变差；小例的下降不是收敛定理。

输入的四条路径

样本1位置1特征1，Q路径= $(-0.007731502) \times 0.5 = -0.003865751$ ，K路径= $(-0.015463004) \times 1 = -0.015463004$ ，V路径= $(-0.003906145) \times 1 = -0.003906145$ ，和为-0.023234901。特征2也要用各自W第二坐标重新计算，不能复制特征1。

若多个位置查同一个embedding行，就把这些位置的两个坐标梯度逐坐标相加到该行。padding_idx和loss_mask属于不同机制；即使某嵌入行固定，其他参数仍可能从无效query的错误loss获得梯度，所以仍需显式loss_mask。本主例没有嵌入训练，不更新输入X。

D 有限差分的独立性与误差

中心差分 $[\mathcal{L}(\theta + h) - \mathcal{L}(\theta - h)] / (2h)$ 近似局部导数。本例 $h=1e-6$ ，对六个W和八个X坐标全部测试，最大绝对误差约 $3.23214e-12$ ；手写反向和PyTorch autograd还分别对照W及三路合成的GX。

差分每次只改变一个坐标，其他参数、数据、mask、目标和归约保持不变。若先更新权重再用旧解析梯度比较，测的是不同点，数值当然可能不一致。h过大会截断误差，过小会有减法消去与浮点舍入；有限差分不能无限缩小h来追求“更精确”。

shape检查能发现部分转置错误，却不能发现两个同shape路径互换。手写NumPy、标量前向、PyTorch、差分的组合有互补性；它们不代替逐公式论证。全部测试使用unittest和显式异常，不依赖python assert，因此-O不会删掉验收逻辑。

E mask与空支持集

零起始四位置的因果允许矩阵：

$$C = \begin{pmatrix} 1 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 1 & 1 & 0 \\ 1 & 1 & 1 & 1 \end{pmatrix}.$$

只前三个key有效时，各行key_mask都是(1,1,1,0)。二者取交集的最后一行变成(1,1,1,0)。此时第四query仍会从前三个V取信息，其输出通常非零。把query_valid最后一项设False，本课明确将其A、O及该query反向路径归零；loss仍需使用有效query定义正确分母。

有效query的支持集为空应抛ValueError；无效query的零行是约定，不满足“概率和为1”。实现使用安全临时key再归零，是为了中间数值有定义，且输入必须有限。若其他位置的query还会用到这一位置作为key，key有效性应独立处理；query无效不自动使其key无效。

2.7.1+cpu本次观察：普通softmax全负无穷→NaN；SDPA全False→零；MHA need_weights=True→NaN，False→零。后两条的差别与实际调用路径相关，不能只背MHA一个统一答案。测试版本变更时应查看结果和文档，不能悄悄nan_to_num或修改预期让测试通过。

F 两种API的数值对照

本例 $Q = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$ ， $K = \begin{bmatrix} 1 & 0 \\ 0 & 2 \\ 2 & 1 \end{bmatrix}$ ， $V = \begin{bmatrix} 2 & -1 \\ 4 & 3 \\ 8 & 5 \end{bmatrix}$ 。第一query允许key0、2，分数为 $1/\sqrt{2}$ 、 $2/\sqrt{2}$ 。令 $p = 1/(1 + \exp(-1/\sqrt{2})) \approx 0.669761549$ ，其权重为 $(1-p, p)$ ，输出约 $(6.018569296, 3.018569296)$ 。第二query允许key1、2，分数顺序相反，权重为 $(p, 1-p)$ ，输出约 $(5.320953803, 3.660476901)$ 。禁止位置权重严格0。允许分数不相等，所以这个例子也能检出遗漏 $\sqrt{2}$ 缩放的错误。

SDPA传入allow；MHA attn_mask传入~allow，MHA key_padding_mask中的True同样表示忽略。MHA输入投影拼成三个 2×2 单位矩阵，输出投影也是单位矩阵，bias=False、heads=1、dropout=0，才能与现成QKV公式等价。

如果把SDPA mask错误取反，第一query只能拿key1，输出 $(4, 3)$ ；第二query只能拿key0，输出 $(2, -1)$ 。最大差约4.660476901，误差不是浮点噪声。仅屏蔽最后key的key_padding_mask时，第二query仍组合前两个key，所以非零；这说明key屏蔽不等于query归零。

G 未来注入和固定实验

因果输出前缀为位置0的 $(1, 0)$ ，位置1的 $(0.330238451, 0.669761549)$ ，修改未来后完全相同。无mask前缀从约 $(1.339523099, -0.118342082)$ 、 $(0.723380127, 0.642092180)$ ，变为 $(8.956406497, -6.961595323)$ 、 $(-5.933369618, 7.922901924)$ 。前缀最大变化7.616883398。因果与无mask的最后位置输出仍可能一起变化，因为那个位置有权看到前面的全部位置。

完整实验中 $\alpha=0$ 无mask取四值平均，它已包含目标 $x[t+1]$ ，所以测试MSE约0.77低于1并不奇怪，也不合法。 $\alpha=8$ 无mask把权重集中到未来目标，几乎直接读答案，低MSE来自泄漏。合法因果排除唯一高分位置，剩余全0分，所以两个 α 完全同一A。

独立重算不需要训练函数：对每条测试序列 x ，用保存的A求 $h = A \cdot x$ ，再用保存的c与b求预测 $c \cdot h + b$ ，逐位置与 $x[1:]$ 做平方误差，先每序列平均再跨512序列平均。固定长度下这等于所有1536目标平均。对三个种子和四配置全量重复，保留全部预测及误差。

合法模型三个种子均未胜过零基线。这符合有限训练样本拟合偶然相关的可能结果。不能把“没学会独立未来”说成注意力普遍无用，也不能把泄漏配置说成预测能力很强。未进行显著性检验；3种子均值是描述性结果。通过一个未来注入样例只排查所测通路，不证明整个数据管道安全。

H 非唯一性与研究方案

$A \cdot V = 0.4 \times 0 + 0.2 \times 1 + 0.4 \times 2 = 1$, $B \cdot V = 0.2 \times 0 + 0.6 \times 1 + 0.2 \times 2 = 1$ 。两组均严格正且和1, 取 $s_j = \ln a_j$ 即可产生A, 取 $\ln b_j$ 即可产生B。不同权重可给同输出, 故输出不能唯一识别权重; 这不证明某固定参数模型必然存在任意替代权重, 更不推出所有解释方法都无效。

一个合理扩展是独立保存AR(1)协议 $x_{t+1} = \rho x_t + \epsilon_t$, 预先指定 ρ 、噪声、长度和拆分, 比较零基线、线性AR基线与因果注意力, 按序列留出测试并保留所有种子。不能利用测试结果挑 ρ 再宣称普适提升, 也不能修改本次iid协议后覆盖原始负面结果。

故障定位速查

- 数值大一倍或小一倍: 查half-MSE和N, 不重复batch平均
- GA或GK错但shape能跑: 查最后两轴转置与query/key求和方向
- GX对不上: 查Q、K、V三路是否全部相加
- 第二步错: 查是否重新前向、是否残留grad、是否异步更新
- NaN: 先查非有限输入和有效query空支持, 不能清洗掩盖
- 图中文字缺失: 系统Noto字体缺失或路径错误, 非Python依赖自动安装
- Notebook只剩文本没有图: 检查实际display_data中的image/png, 不以文件链接冒充执行图
- 版本变化: 先记录设备、dtype、torch版本与调用参数, 再判断差异

本答案是原理与当前结果的解释。程序测试、作者视觉检查和独立科学审核属于不同证据, 不能相互冒充。