

注意力的逐项计算

第052单元 从加权取值到可验证的信息边界

一个位置怎样根据内容选择其他位置的信息？本讲把选择拆成三个可检查的步骤：计算查询与候选键的匹配分数，把允许候选的分数归一化，再用权重组合它们携带的值。注意力不是硬索引；多个位置可以同时贡献，最后得到向量而不是一个位置编号。

正式先修012、019、049。012提供行存储和向量雅可比，019提供有限概率分布及支持集，049提供词元、嵌入和补齐。本讲重新说明所有轴，不假设学过RNN、GRU或Transformer。主例是无偏置、单头、自注意力的回归计算器；平方损失让每条导数可手算，不代表注意力只能用于回归。多头、残差与位置编码的完整设计留给后续课程。

学习目标是独立写出前向与反向、解释共享参数如何累加梯度、完成同一参数组的两次更新、区分key与query padding，并通过只修改未来的测试发现信息泄漏。本次证据来自原创合成数据和CPU float64实验，不覆盖自然语言能力、GPU吞吐或长上下文。

一 从加权和认识Q K V

三个候选提供值2、4、8。当前查询给出权重0.2、0.3、0.5，输出为 $0.2 \times 2 + 0.3 \times 4 + 0.5 \times 8 = 5.6$ 。权重非负且和为1，标量输出位于最小值与最大值之间。候选提供向量时，同一权重分别组合所有坐标，输出位于值向量的凸包内；后续投影或残差不一定保留这个性质。

query描述当前用来找信息的特征，key描述候选用于匹配的特征，value是被带走的内容。这些名称是计算角色，不要求每个坐标都能用自然语言解释。内积是对应坐标乘积的和，受方向与长度共同影响；分数大不自动意味着语义相近，训练目标会影响这些表示。

第i个query是行向量 $q_i \in \mathbb{R}^{1 \times d_k}$ ，第j个key是 k_j ，value是 $v_j \in \mathbb{R}^{1 \times d_v}$ 。常用的scaled dot-product形式为：[1]

$$s_{ij} = \frac{\sum_{r=1}^{d_k} q_{ir} k_{jr}}{\sqrt{d_k}}, \quad a_{ij} = \frac{e^{s_{ij}}}{\sum_{u=1}^S e^{s_{iu}}}, \quad o_{ic} = \sum_{j=1}^S a_{ij} v_{jc}.$$

每次固定query i，只沿key j归一化。不能对整张矩阵做一次softmax。A的每行形式上是离散概率质量，但不是“这个词导致答案的概率”，也没有自动校准保证。V可以有负数，A仍为非负；不要混淆两者。




图1 Q与K先决定取值权重，再沿V路径组合实际内容。主例L=S；图中保留交叉注意力的一般轴名。每条箭头都有前向运算，反向则沿全部共享路径相加。

二 先固定形状再写公式

自注意力输入 $X \in \mathbb{R}^{B \times L \times D}$ 。B是样本数，L是位置数，D是每个位置的特征数。同一X走三个投影：

$$Q = XW_Q, \quad K = XW_K, \quad V = XW_V.$$

W_Q, W_K 的shape为 $D \times dk$ ， W_V 为 $D \times dv$ 。最后两轴做矩阵乘法，B轴不混合不同样本。三个投影是同一输入的分支，不是三份独立训练数据；所有样本和位置使用同一参数组。

交叉注意力允许query来自 $B \times L \times D_q$ ，key与value来自 $B \times S \times D_{kv}$ 。L与S可以不同，dk和dv也可以不同；必须保证Q、K最后一维相同，K、V位置数相同。

对象	形状	每个元素描述什么
Q	$B \times L \times dk$	当前query的特征
K	$B \times S \times dk$	候选匹配特征
V	$B \times S \times dv$	候选实际内容
分数S与权重A	$B \times L \times S$	每个query与每个key的关系
输出O	$B \times L \times dv$	每个query取得的内容

无mask时， $S = QK^T/\sqrt{d_k}$ ， $A = \text{softmax}_{\text{key}}(S)$ ， $O = AV$ 。转置只交换最后两个轴。三维NumPy数组不带轴参数的 `.T` 会翻转B轴，不能用它代替最后两轴交换。代码明确写 `swapaxes(1,2)` 或 `transpose(-1,-2)`。

三 缩放的动机与隐含前提

暂设所有 q_r, k_r 零均值、单位方差，两组彼此独立，各坐标也独立。那么 $E[q_r k_r] = 0$ ， $\text{Var}(q_r k_r) = E[q_r^2] E[k_r^2] = 1$ 。不同坐标的乘积协方差为0，故：

$$\text{Var} \left(\sum_{r=1}^{d_k} q_r k_r \right) = d_k, \quad \text{Var} \left(\frac{q \cdot k}{\sqrt{d_k}} \right) = 1.$$

除以 d_k 会让方差变为 $1/d_k$ ，不是这里保持量级的目标。分数差很大时softmax集中，Jacobian中的 $a(1-a)$ 项变小，分数变化可能难以改变输出。缩放缓和这个初始化量级问题；训练后的特征未必独立或单位方差，所以它不是不饱和的保证，更不是任意模型都提升性能的定理。

固定种子5210，生成256个query，每个对应16个key，比较 $d_k=1, 4, 16, 64$ 。每一维度两种方案复用相同QK。行熵单位为nat，最大值 $\ln 16$ ；熵低只表示集中，不表示检索正确。原始统计及每行熵均保留。




图2 独立高斯特征下，不缩放的分数量随维数增大；缩放后量级较稳定。右图是行熵均值，虚线为 $\ln 16$ ，不是准确率。只支持该生成条件下的量级结论。

稳定softmax先减行最大值 m : $e_j = \exp(s_j - m)$, $a_j = e_j / \sum_u e_u$ 。整行平移同一常数不改变比例。减最大值避免指数溢出，却不能修复内积中已经出现的Inf，也不能为全屏蔽行创造合法分母。

四 两份样本的一次完整前向

主例 $B=2$, $L=S=2$, $D=2$, $d_k=d_v=1$, 无mask、无偏置、无dropout。 $d_k=1$ 使手算缩放因子为1；后面的API检验使用 $d_k=2$ ，真实检查 $\sqrt{2}$ 缩放。

$$X_1 = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}, \quad X_2 = \begin{pmatrix} 1 & 1 \\ 1 & 0 \end{pmatrix}, \quad Y_1 = \begin{pmatrix} 0.25 \\ -0.25 \end{pmatrix}, \quad Y_2 = \begin{pmatrix} 0.5 \\ 0.75 \end{pmatrix}.$$

$$W_Q = \begin{pmatrix} 0.5 \\ -0.5 \end{pmatrix}, \quad W_K = \begin{pmatrix} 1 \\ 0.5 \end{pmatrix}, \quad W_V = \begin{pmatrix} 1 \\ -1 \end{pmatrix}.$$

样本1两行是基向量，所以 $Q_1=(0.5, -0.5)^T$ 、 $K_1=(1, 0.5)^T$ 、 $V_1=(1, -1)^T$ 。样本2第一行 $(1, 1)$ 同时使用两个参数，故 $Q_2=(0, 0.5)^T$ 、 $K_2=(1.5, 1)^T$ 、 $V_2=(0, 1)^T$ 。这里下标指样本。

样本1第一行分数 $(0.5, 0.25)$ ，第一个权重为 $1/(1 + e^{-0.25}) = 0.562176501$ 。输出为 $0.562176501 \times 1 + 0.437823499 \times (-1) = 0.124353002$ 。样本2第一query为0，两个分数都为0，等权输出0.5；这不证明两个词意义相同。




图3 两份样本完整的分数、权重与输出。读每行时固定query，读每列时跟踪同一key被多个query使用。不是跨样本归一化。图内位置0起，各子图独立色阶，以标注数字为准。

定义四个标量目标的half-MSE：

$$\mathcal{L} = \frac{1}{2N} \sum_{b=1}^B \sum_{i=1}^L (o_{bi} - y_{bi})^2, \quad N = BL = 4.$$

误差为(-0.125647, 0.125647, 0, -0.312177)，总loss=0.016128563。本实现对目标标量元素总数平均；如果 $d_v > 1$ ，N还包含输出坐标数。下述每个样本梯度贡献已经包含1/4，合并时只相加，不能再除以batch。

五 损失与加权求和的每条局部导数

记 $G_O = \partial \mathcal{L} / \partial O$ ，梯度数组与对象同shape。平方项导数为 $\partial[(o - y)^2 / (2N)] / \partial o = (o - y) / N$ ，所以本例 $G_O = (O - Y) / 4$ ，shape $2 \times 2 \times 1$ 。对于 $o_{ic} = \sum_j a_{ij} v_{jc}$ ：

$$\frac{\partial o_{ic}}{\partial a_{ij}} = v_{jc}, \quad \frac{\partial o_{ic}}{\partial v_{jc'}} = a_{ij} \mathbf{1}[c = c'].$$

每个value被所有query复用，必须跨i求和。每个样本的矩阵式是：

$$G_A = G_O V^T \in \mathbb{R}^{L \times S}, \quad G_V = A^T G_O \in \mathbb{R}^{S \times d_v}.$$

样本1第一行 $G_O = -0.031411750$ ，故 $G_A = (-0.031411750, +0.031411750)$ 。value1从query1收到 $0.562176501 \times (-0.031411750)$ ，从query2收到 $0.437823499 \times 0.031411750$ ，相加为-0.003906145。只保留当前query的一项会漏掉共享路径。

六 softmax的完整Jacobian

固定一行，令 $Z = \sum_u e^{s_u}$ 。分子对 s_k 求导为 $\mathbf{1}[j = k]e^{s_j}$ ，分母导数为 e^{s_k} 。商法则给出：

$$J_{jk} = \frac{\partial a_j}{\partial s_k} = a_j(\mathbf{1}[j = k] - a_k), \quad J = \text{diag}(a) - aa^T.$$

第j行是输出权重j对所有输入分数的偏导，遵循012的布局。对角为 $a_j(1 - a_j)$ ，非对角为 $-a_j a_k$ 。增大一个分数时，其他权重通常下降；不能把softmax当成独立sigmoid。J的行和、列和都为0，对应整行平移不改变A。

主例第一行 $a=(0.562176501, 0.437823499)$ 的完整Jacobian：

$$J = \begin{pmatrix} 0.246134083 & -0.246134083 \\ -0.246134083 & 0.246134083 \end{pmatrix}.$$

行式VJP为 $GS=GAJ$ 。第一项

$=(-0.031411750) \times 0.246134083 + (0.031411750) \times (-0.246134083) = -0.015463004$ ，第二项相反。这里漏掉非对角项会少一半，在一般数据上不能靠固定乘2修复。

展开后无需存完整Jacobian：

$$G_{S,ij} = a_{ij} \left(G_{A,ij} - \sum_u a_{iu} G_{A,iu} \right).$$

每行先求一个加权和再逐元素计算。教材保存小Jacobian用于理解，长序列不建议为每行建立 $S \times S$ 的导数矩阵。硬mask是固定离散约束，被排除key的权重及分数梯度均为0；Jacobian在允许支持集上构造，本例不对mask求导。




图4 对角和非对角导数共同组成竞争关系。两候选分数差大时导数趋近0。局部导数乘有限干预量只是近似，不是任意幅度变化的精确效果。

七 从分数回到共享参数与输入

点积局部导数为：

$$\frac{\partial s_{ij}}{\partial q_{ir}} = \frac{k_{jr}}{\sqrt{d_k}}, \quad \frac{\partial s_{ij}}{\partial k_{jr}} = \frac{q_{ir}}{\sqrt{d_k}}.$$

query接触所有key，key也供所有query使用，两个求和轴不同：

$$G_Q = G_S K / \sqrt{d_k}, \quad G_K = G_S^T Q / \sqrt{d_k}.$$

样本1第一query梯度= $(-0.015463004) \times 1 + 0.015463004 \times 0.5 = -0.007731502$ 。第一key梯度跨两个query相加： $(-0.015463004) \times 0.5 + (0.015463004) \times (-0.5) = -0.015463004$ 。两者即使同shape也不能互换公式。

投影 $q_{ir} = \sum_d x_{id} W_{Q,dr}$ 的局部导数为 $\partial q_{ir} / \partial W_{Q,dr} = x_{id}$ 、 $\partial q_{ir} / \partial x_{id} = W_{Q,dr}$ 。K与V投影完全类同。跨位置、样本累加：

$$G_{W_Q} = \sum_b X_b^T G_{Q,b}, \quad G_{W_K} = \sum_b X_b^T G_{K,b}, \quad G_{W_V} = \sum_b X_b^T G_{V,b}.$$

单个坐标为 $\sum_b \sum_i x_{bid} G_{Q,bir}$ 。位置的外积 $x_{bi}^T G_{Q,bi}$ 形成 $D \times dk$ 贡献，然后跨位置和样本相加。这里的“时间累加”是位置索引上的参数共享，不要求递归状态。不能先更新样本1，再用新参数计算样本2，把它称为同一批次梯度。

同一X同时产生Q、K、V，故三条输入路径相加：

$$G_{X,b} = G_{Q,b} W_Q^T + G_{K,b} W_K^T + G_{V,b} W_V^T.$$

样本1位置1特征1的三项为-0.003865751、-0.015463004、-0.003906145，总和-0.023234901。如果X来自049的嵌入查表，还要把GX累加到对应词元行，重复词元跨样本也相加。本例X是给定数据，只更新三个W；计算GX是验证路径，不把输入样本当作可训练参数。




图5 左侧跟踪同一输入特征的两条路径；右侧跟踪每份样本对六个共享参数的贡献。抵消不代表某一路不存在，总梯度小也不代表所有位置都不重要。

交叉注意力中, $G_{X^q} = G_Q W_Q^T$, $G_{X^{kv}} = G_K W_K^T + G_V W_V^T$ 。只有两份输入确实是同一计算节点才继续相加; 形状相同不等于是一变量。稠密注意力核心计算约为 $O(BLS(d_k + d_v))$, 还要另算投影; $L \times S$ 分数需要存储。复杂度公式不是实测峰值内存或速度。

八 两次同步更新和下一次完整前向

学习率固定0.1, 六个参数都从同一旧状态求导, 然后一起执行 $W^{(t+1)} = W^{(t)} - 0.1 G_W^{(t)}$ 。初始聚合梯度为:

$$G_{W_Q} = \begin{pmatrix} 0.001873157 \\ 0.007731502 \end{pmatrix}, \quad G_{W_K} = \begin{pmatrix} -0.015463004 \\ 0.025067664 \end{pmatrix}, \quad G_{W_V} = \begin{pmatrix} -0.081950271 \\ -0.039968428 \end{pmatrix}.$$

第一步得到 $W_Q = (0.499812684, -0.500773150)^T$, $W_K = (1.001546300, 0.497493234)^T$, $W_V = (1.008195027, -0.996003157)^T$ 。必须从头重算Q、K、V、S、A、O, 不能复用旧A。下一轮 $\text{loss} = 0.015241267$, 第二次更新后的完整前向 $\text{loss} = 0.014489698$ 。正文最后的账本列出三状态全部局部量和梯度。

总loss下降不意味着每项改善。样本2位置1原来恰好输出0.5, 第一次更新变成0.510312427, 第二次变成0.519726010, 反而离目标更远。共享参数优化会折中; 本例保留这个无提升项, 也不声称所有步长都保证总loss下降。

九 mask先定义信息集再写布尔值

对每个query先定义允许key集合 $\mathcal{A}_i$ 。集合非空时:

$$a_{ij} = \begin{cases} e^{s_{ij}} / \sum_{u \in \mathcal{A}_i} e^{s_{iu}}, & j \in \mathcal{A}_i, \\ 0, & j \notin \mathcal{A}_i. \end{cases}$$

加性mask在允许处加0、禁止处加负无穷, 与此定义等价。有限大负数只是近似屏蔽, 在极端分数或低精度下可能失效。本课自己函数统一规定 $\text{allow} = \text{True}$ 表示允许, 调用第三方API时转换。

因果自注意力允许 $j \leq i$ 。当前输入 x_i 、目标 x_{i+1} 时, 对角线允许, 因为 x_i 已知; 允许对角线不等于允许目标。必须同时核对049的输入/目标位移。如果输入已把答案拼到当前位置, 下三角mask仍会泄漏。

key padding删除无效候选列; query padding表示某些输出行没有任务含义。key padding不会自动把相应query输出置零: 无效query仍能平均有效V。通常既限制key, 也在loss中排除无效query。若下一层需确定的无效输出, 可显式置零; 偏置、残差可能再次带来非零值, mask仍须继续传递。




图6 1统一表示允许。因果与key有效性取交集；最后一幅额外展示无效query行归零约定，并不声称空支持集存在softmax。query有效性需要单独携带。

$B \times S$ 的key有效性可扩为 $B \times 1 \times S$ ，与 $1 \times L \times S$ 因果矩阵广播取交集。本教学函数要求传入精确 $B \times L \times S$ bool，避免错误轴广播后还能运行。多头广播与KV缓存不属于本实现的支持范围。

全屏蔽行与库实现的不同约定

允许集合为空时分母为0，不存在非负且和为1的权重，本讲不定义该softmax。全负无穷logit减最大值会得到负无穷减负无穷，普通softmax输出NaN。不能静默把NaN换成0来掩盖上游错误。

本课约定：有效query至少有一个key，否则抛ValueError；显式无效query令A、O为零，不计loss，梯度也为零。实现先为无效行临时放一个安全key，避免中间归一化未定义，再将整行A设0。这是声明的无效行约定，不是空集合的数学softmax；其行和为0。输入NaN/Inf一律拒绝，不靠这个约定清洗。

PyTorch 2.7.1+cpu、float64、单头identity投影、无dropout下的本次实测：原始softmax全负无穷为NaN；SDPA全False mask输出零；MHA need_weights=True输出NaN，need_weights=False输出零。它们是当前调用路径的观察，不承诺换版本或设备不变。[2][3] 测试保留四项诊断，不把NaN序列化合法数值。

PyTorch 2.7参数	True含义	本课转换
SDPA attn_mask	允许参与	allow
MHA attn_mask	禁止参与	~allow
MHA key_padding_mask	忽略该key	~key_valid

官方2.7文档明确上述bool语义。[2][3] MHA包含额外投影，不能直接拿随机初始化MHA与已投影QKV的SDPA比较；本课先设为单头identity投影。SDPA显式dropout_p=0.0，不假定外层eval会自动关闭传入的非零dropout。因果验证用方形显式下三角mask，不把非方形缓存对齐或is_causal提示当成已验证功能。

十 修改未来检测信息泄漏

固定四位置X, $Q=K=V=X$ 。保留位置0、1, 只替换位置2、3。预测时点1可用信息没变, 严格因果前缀应不变。本次最大绝对差为0; 去掉mask后前缀最大差7.616883398, 证明输出依赖未来。




图7 虚线右侧是被改动的未来。因果模型前两输出保持原样, 无mask前缀显著改变。曲线画第1输出特征, 标题最大差计算前缀全部特征。

通过一个样例不是整个系统绝无泄漏的证明, 还需覆盖长度、padding、位置编码、缓存和预处理; 失败却是直接反证。先关闭dropout、固定参数与前处理, 避免把其他随机变化误当成泄漏。单纯看训练loss或测试loss, 不能替代信息边界检查。

十一 固定协议的未来预测实验

运行前保存data/protocol.json。每个种子生成128条训练、512条测试序列, 每条4个独立标准正态值。位置 $t=0, 1, 2$ 预测 $x[t+1]$, 合法信息只有 $x[0]$ 至 $x[t]$ 。未来独立, 所以条件均值为0, 零基线总体最优MSE为1。这是可解析的诊断任务, 不是自然语言基准。

固定K为四维单位矩阵, query t 在坐标 $t+1$ 放 2α 。dk=4, 除以 $\sqrt{4}=2$ 后, 未来目标位置分数为 α , 其余为0。预先取 $\alpha \in \{0, 8\}$ 与{因果, 无mask}, 不根据测试选择。V为序列标量值, 注意力输出后只拟合一个系数和截距, 用训练384个目标一次最小二乘解出。每配置2个可训练标量。

QK是人为固定的未来选择器, 不是训练发现推理能力。 $\alpha=8$ 无mask可读取目标; 因果mask将它排除, 剩余分数全0, 所以 $\alpha=0$ 与8的因果模型完全相同。这是预先可推导且实测确认的无提升结果。

α	约束	三个种子的测试MSE	均值
0	合法因果	1.024268, 1.050165, 1.005111	1.026515
8	合法因果	1.024268, 1.050165, 1.005111	1.026515
0	无mask 有泄漏	0.754636, 0.799733, 0.755939	0.770103
8	无mask 有泄漏	3.39285e-7, 3.38849e-7, 3.39063e-7	3.39065e-7

零基线三份测试MSE为1.012838、1.043264、0.995612，均值1.017238。合法模型全部没超过零基线：最小二乘拟合了有限样本中的偶然相关。 $\alpha=0$ 的全序列平均也含未来目标，因此无mask即使分数均匀也不是合法基线。




图8 整条序列已拆分为训练和测试，无mask仍能读每条测试序列自己的未来答案。接近零的MSE来自错误信息集。对数纵轴，黑点保留全部三个种子。

保留原始值、拟合系数、全部测试预测和逐序列MSE，支持独立重算。三个种子只有描述性均值，没有显著性推断。同条序列三个目标存在共享结构，未来若做bootstrap，应按序列分组，不假设所有目标独立。不得删掉负面结果再宣称注意力优于基线。

十二 权重不能直接成为因果解释

A描述本次如何组合当前V，不是输入对最终输出的全部影响。词元还改变Q、K、V，多层、残差也带来其他通路。只读A会遗漏路径；梯度是某点局部敏感度，也不自动具备因果识别的干预假设。已有研究对“注意力即解释”的主张提出实证质疑，但不能把特定模型结果扩大成所有注意力都毫无解释用途。[4]

本课代数反例： $V=(0,1,2)^T$ ， $A=(0.4,0.2,0.4)$ ， $B=(0.2,0.6,0.2)$ ，都合法且输出1。任一严格正权重行取 $s=\ln a$ 即可由softmax实现。这证明仅凭输出不能唯一倒推权重；不证明真实受约束模型随时能自由替换成任意A。




图9 不同权重得到同一输出1。高亮某key不是其独立因果作用的证据。解释研究应另行声明干预对象、信息边界及评价标准。

研究解释时先说清解释哪个输出、对谁、在何种干预下。遮盖或替换可能制造分布外输入，也要报告。我们的泄漏实验只验证信息可用性，不是词语语义因果实验。

十三 支持域与复现边界

教学函数要求NumPy float64、有限值、非空三维QKV、各轴 ≤ 512 、输入绝对值 ≤ 10000 ，以及精确 $B \times L \times S$ bool mask。这些是控制教学资源 and 数值风险的人为边界，不是注意力理论限制。float32混入、空轴、NaN/Inf、错误shape、有效query空支持集都会明确拒绝。

脚本普通与-O模式、独立标量参照、完整Jacobian、14坐标中心差分、两次SGD及mask/未来注入均有真实测试；Notebook在新Python进程的真实IPython进程内核中顺序执行，PNG由当前数值绘制。浏览器UI、socket传输、GPU、半精度、dropout、长上下文与跨平台安装未测。完整Notebook和绘图依赖系统Noto CJK字体，Python环境文件不能保证字体；安装与检查见lab。

实验只有12个两参数最小二乘拟合，另有六参数手算与随机缩放诊断。runtime.json记录实际版本、线程和含写盘耗时，未测峰值内存，不把耗时当速度基准。后续研究先冻结新协议，再改变任务或学习QK，重新检验信息边界。

十四 完整逐项数值账本

下面9位小数用于阅读，JSON保留float64精度。t=0、1后更新；t=2为第二次更新后的完整前向，额外计算反向用于复核，不执行第三次更新。所有梯度已含总loss的1/4因子。每个位置的参数贡献是输入行与对应GQ/GK/GV的外积，先跨位置求和再跨样本相加。

状态 0

总loss=0.016128563004。两份样本自身的half-MSE为0.007893584082、0.024363541926，两者平均为总loss。

参数	第1行	第2行
WQ	0.500000000	-0.500000000
WK	1.000000000	0.500000000
WV	1.000000000	-1.000000000

样本位置	Q	K	V	O	目标	GO
1 1	0.500000000	1.000000000	1.000000000	0.124353002	0.250000000	-0.031411750
1 2	-0.500000000	0.500000000	-1.000000000	-0.124353002	-0.250000000	0.031411750
2 1	0.000000000	1.500000000	0.000000000	0.500000000	0.500000000	0.000000000
2 2	0.500000000	1.000000000	1.000000000	0.437823499	0.750000000	-0.078044125

样本1的分数与权重:

$$S_1 = \begin{pmatrix} 0.500000000 & 0.250000000 \\ -0.500000000 & -0.250000000 \end{pmatrix}, \quad A_1 = \begin{pmatrix} 0.562176501 & 0.437823499 \\ 0.437823499 & 0.562176501 \end{pmatrix}.$$

该样本两个位置的完整Jacobian:

$$J_1 = \begin{pmatrix} 0.246134083 & -0.246134083 \\ -0.246134083 & 0.246134083 \end{pmatrix}, \quad J_2 = \begin{pmatrix} 0.246134083 & -0.246134083 \\ -0.246134083 & 0.246134083 \end{pmatrix}.$$

样本2的分数与权重:

$$S_2 = \begin{pmatrix} 0.000000000 & 0.000000000 \\ 0.750000000 & 0.500000000 \end{pmatrix}, \quad A_2 = \begin{pmatrix} 0.500000000 & 0.500000000 \\ 0.562176501 & 0.437823499 \end{pmatrix}.$$

该样本两个位置的完整Jacobian:

$$J_1 = \begin{pmatrix} 0.250000000 & -0.250000000 \\ -0.250000000 & 0.250000000 \end{pmatrix}, \quad J_2 = \begin{pmatrix} 0.246134083 & -0.246134083 \\ -0.246134083 & 0.246134083 \end{pmatrix}.$$

局部反向。GA和GS每格为一整行两项。

样本位置	GA	GS	GQ	GK	GV
1 1	-0.031411750, 0.031411750	-0.015463004, 0.015463004	-0.007731502	-0.015463004	-0.003906145
1 2	0.031411750, -0.031411750	0.015463004, -0.015463004	0.007731502	0.015463004	0.003906145
2 1	0.000000000, 0.000000000	0.000000000, 0.000000000	0.000000000	0.009604660	-0.043874573

样本位置	GA	GS	GQ	GK	GV
2 2	0.000000000, -0.078044125	0.019209319, -0.019209319	0.009604660	-0.009604660	-0.034169552

位置已求和的样本贡献与总梯度：

参数坐标	样本1	样本2	总梯度
WQ[1]	-0.007731502	0.009604660	0.001873157
WQ[2]	0.007731502	0.000000000	0.007731502
WK[1]	-0.015463004	-0.000000000	-0.015463004
WK[2]	0.015463004	0.009604660	0.025067664
WV[1]	-0.003906145	-0.078044125	-0.081950271
WV[2]	0.003906145	-0.043874573	-0.039968428

输入两特征的三条路径及总和：

样本位置	Q路径	K路径	V路径	GX合计
1 1	-0.003865751, 0.003865751	-0.015463004, -0.007731502	-0.003906145, 0.003906145	-0.023234901, 0.000040394
1 2	0.003865751, -0.003865751	0.015463004, 0.007731502	0.003906145, -0.003906145	0.023234901, -0.000040394
2 1	0.000000000, 0.000000000	0.009604660, 0.004802330	-0.043874573, 0.043874573	-0.034269914, 0.048676903
2 2	0.004802330, -0.004802330	-0.009604660, -0.004802330	-0.034169552, 0.034169552	-0.038971882, 0.024564892

全部梯度完成后，六个坐标同步减去0.1倍总梯度，进入状态1；本状态反向不能混用更新后的参数。

状态 1

总loss=0.015241267063。两份样本自身的half-MSE为0.007744794095、0.022737740032，两者平均为总loss。

参数	第1行	第2行
WQ	0.499812684	-0.500773150
WK	1.001546300	0.497493234

参数	第1行	第2行
WV	1.008195027	-0.996003157

样本位置	Q	K	V	O	目标	GO
1 1	0.499812684	1.001546300	1.008195027	0.131662966	0.250000000	-0.029584258
1 2	-0.500773150	0.497493234	-0.996003157	-0.119709851	-0.250000000	0.032572537
2 1	-0.000960466	1.499039534	0.012191870	0.510312427	0.500000000	0.002578107
2 2	0.499812684	1.001546300	1.008195027	0.448595597	0.750000000	-0.075351101

样本1的分数与权重：

$$S_1 = \begin{pmatrix} 0.500585545 & 0.248653428 \\ -0.501547496 & -0.249131254 \end{pmatrix}, \quad A_1 = \begin{pmatrix} 0.562652003 & 0.437347997 \\ 0.437228869 & 0.562771131 \end{pmatrix}.$$

该样本两个位置的完整Jacobian：

$$J_1 = \begin{pmatrix} 0.246074726 & -0.246074726 \\ -0.246074726 & 0.246074726 \end{pmatrix}, \quad J_2 = \begin{pmatrix} 0.246059785 & -0.246059785 \\ -0.246059785 & 0.246059785 \end{pmatrix}.$$

样本2的分数与权重：

$$S_2 = \begin{pmatrix} -0.001439776 & -0.000961951 \\ 0.749238973 & 0.500585545 \end{pmatrix}, \quad A_2 = \begin{pmatrix} 0.499880544 & 0.500119456 \\ 0.561845036 & 0.438154964 \end{pmatrix}.$$

该样本两个位置的完整Jacobian：

$$J_1 = \begin{pmatrix} 0.249999986 & -0.249999986 \\ -0.249999986 & 0.249999986 \end{pmatrix}, \quad J_2 = \begin{pmatrix} 0.246175192 & -0.246175192 \\ -0.246175192 & 0.246175192 \end{pmatrix}.$$

局部反向。GA和GS每格为一整行两项。

样本位置	GA	GS	GQ	GK	GV
1 1	-0.029826702, 0.029466015	-0.014590439, 0.014590439	-0.007354356	-0.015336521	-0.002403989
1 2	0.032839470, -0.032442350	0.016063231, -0.016063231	0.008096721	0.015336521	0.005392267
2 1	0.000031432, 0.002599234	-0.000641951, 0.000641951	-0.000319366	0.009234872	-0.041046896
2 2	-0.000918671, -0.075968605	0.018475432, -0.018475432	0.009191402	-0.009234872	-0.031726097

位置已求和的样本贡献与总梯度：

参数坐标	样本1	样本2	总梯度
WQ[1]	-0.007354356	0.008872036	0.001517681
WQ[2]	0.008096721	-0.000319366	0.007777355
WK[1]	-0.015336521	-0.000000000	-0.015336521
WK[2]	0.015336521	0.009234872	0.024571393
WV[1]	-0.002403989	-0.072772994	-0.075176983
WV[2]	0.005392267	-0.041046896	-0.035654629

输入两特征的三条路径及总和：

样本位置	Q路径	K路径	V路径	GX合计
1 1	-0.003675800, 0.003682864	-0.015360236, -0.007629815	-0.002423689, 0.002394380	-0.021459726, -0.001552571
1 2	0.004046844, -0.004054620	0.015360236, 0.007629815	0.005436457, -0.005370715	0.024843537, -0.001795520
2 1	-0.000159623, 0.000159930	0.009249152, 0.004594286	-0.041383277, 0.040882838	-0.032293748, 0.045637055
2 2	0.004593979, -0.004602808	-0.009249152, -0.004594286	-0.031986094, 0.031599293	-0.036641266, 0.022402199

全部梯度完成后，六个坐标同步减去0.1倍总梯度，进入状态2；本状态反向不能混用更新后的参数。

状态 2

总loss=0.014489698297。两份样本自身的half-MSE为0.007629574296、0.021349822298，两者平均为总loss。

参数	第1行	第2行
WQ	0.499660916	-0.501550886
WK	1.003079953	0.495036094
WV	1.015712725	-0.992437694

样本位置	Q	K	V	O	目标	GO
1 1	0.499660916	1.003079953	1.015712725	0.138399612	0.250000000	-0.027900097

样本 位置	Q	K	V	O	目标	GO
1 2	-0.501550886	0.495036094	-0.992437694	-0.115598919	-0.250000000	0.033600270
2 1	-0.001889969	1.498116047	0.023275031	0.519726010	0.500000000	0.004931503
2 2	0.499660916	1.003079953	1.015712725	0.458434958	0.750000000	-0.072891261

样本1的分数与权重：

$$S_1 = \begin{pmatrix} 0.501199848 & 0.247350188 \\ -0.503095639 & -0.248285792 \end{pmatrix}, \quad A_1 = \begin{pmatrix} 0.563123805 & 0.436876195 \\ 0.436639988 & 0.563360012 \end{pmatrix}.$$

该样本两个位置的完整Jacobian：

$$J_1 = \begin{pmatrix} 0.246015385 & -0.246015385 \\ -0.246015385 & 0.246015385 \end{pmatrix}, \quad J_2 = \begin{pmatrix} 0.245985509 & -0.245985509 \\ -0.245985509 & 0.245985509 \end{pmatrix}.$$

样本2的分数与权重：

$$S_2 = \begin{pmatrix} -0.002831394 & -0.001895790 \\ 0.748550037 & 0.501199848 \end{pmatrix}, \quad A_2 = \begin{pmatrix} 0.499766099 & 0.500233901 \\ 0.561524185 & 0.438475815 \end{pmatrix}.$$

该样本两个位置的完整Jacobian：

$$J_1 = \begin{pmatrix} 0.249999945 & -0.249999945 \\ -0.249999945 & 0.249999945 \end{pmatrix}, \quad J_2 = \begin{pmatrix} 0.246214775 & -0.246214775 \\ -0.246214775 & 0.246214775 \end{pmatrix}.$$

局部反向。GA和GS每格为一整行两项。

样本 位置	GA	GS	GQ	GK	GV
1 1	-0.028338484, 0.027689108	-0.013783650, 0.013783650	-0.007002698	-0.015211754	-0.001039987
1 2	0.034128222, -0.033346175	0.016597724, -0.016597724	0.008432372	0.015211754	0.006740160
2 1	0.000114781, 0.005008990	-0.001223552, 0.001223552	-0.000605702	0.008901866	-0.038465608
2 2	-0.001696546, -0.074036581	0.017811185, -0.017811185	0.008817180	-0.008901866	-0.029494150

位置已求和的样本贡献与总梯度：

参数坐标	样本1	样本2	总梯度
WQ[1]	-0.007002698	0.008211477	0.001208779

参数坐标	样本1	样本2	总梯度
WQ[2]	0.008432372	-0.000605702	0.007826669
WK[1]	-0.015211754	0.000000000	-0.015211754
WK[2]	0.015211754	0.008901866	0.024113620
WV[1]	-0.001039987	-0.067959758	-0.068999745
WV[2]	0.006740160	-0.038465608	-0.031725447

输入两特征的路径及总和：

样本位置	Q路径	K路径	V路径	GX合计
1 1	-0.003498975, 0.003512210	-0.015258606, -0.007530367	-0.001056328, 0.001032123	-0.019813909, -0.002986035
1 2	0.004213327, -0.004229263	0.015258606, 0.007530367	0.006846067, -0.006689189	0.026317999, -0.003388085
2 1	-0.000302646, 0.000303791	0.008929283, 0.004406745	-0.039070007, 0.038174719	-0.030443370, 0.042885255
2 2	0.004405600, -0.004422264	-0.008929283, -0.004406745	-0.029957584, 0.029271106	-0.034481267, 0.020442097

一手来源

[1] Vaswani等, Attention Is All You Need, 2017。结构与缩放动机。 <https://arxiv.org/abs/1706.03762>

[2] PyTorch 2.7 SDPA官方文档。 https://docs.pytorch.org/docs/2.7/generated/torch.nn.functional.scaled_dot_product_attention.html

[3] PyTorch 2.7 MultiheadAttention官方文档。 <https://docs.pytorch.org/docs/2.7/generated/torch.nn.MultiheadAttention.html>

[4] Jain与Wallace, Attention is not Explanation, NAACL 2019。 <https://aclanthology.org/N19-1357/>

2026-10-05核对。全文推导、数值样本、图与数据为原创；全屏蔽行行为来自真实运行。