

Transformer块与位置习题解答

第053单元 逐步解题与验收解释

本答案可独立阅读。设残差流X的shape为 $B \times L \times D$ ，头数H，单头宽度 $d=D/H$ ，FFN宽度F。本单元自定义allow=True是允许，官方TransformerEncoderLayer的布尔src_mask=True是禁止。默认CPU float64、dropout=0；所有“相等”都允许浮点舍入。

一 元素顺序与归一化

练习1：原张量三行分别是0至7、8至15、16至23。头1取得每行后四维，所以三行是4至7、12至15、20至23。头1位置2为[20,21,22,23]。拆头后内存逻辑顺序是头优先；直接reshape会把头0的不同位置误拼为一个位置的特征。先transpose(1,2)，再contiguous().reshape(B,L,D)，即可逐元素恢复。测试故意同时断言正确合头相等、错误合头不等，避免只有单向证据。

练习2：均值2.5，方差 $(2.25+0.25+0.25+2.25)/4=1.25$ ；LN输出约(-1.341635,-0.447212,0.447212,1.341635)。D-1分母得到5/3，不符合本实现和官方LayerNorm，不能把样本方差估计公式直接搬来。[1]

D=4、F=7时：QKV三个 4×4 权重加 3×4 偏置，共60；输出投影 $16+4=20$ ；第一FFN $28+7=35$ ；第二FFN $28+4=32$ ；两次LN各4个gamma和4个beta，共16。总数163。固定D，仅改变合法H，不改变这些矩阵参数数目；会改变每头d及注意力分解。实际其他架构如多查询注意力不一定沿用这个计数。

二 手算例的完整前向

练习3：输入两行为(1,3)、(2,0)，均值分别2、1，方差都1。取 $a=1/\sqrt{1.00001}$ ，标准化两行为(-a,a)、(a,-a)。Q=K=V，分数对角为 $\sqrt{2}a^2 \approx 1.414199420$ ，非对角相反。每行softmax分别为(0.944191290,0.055808710)及其反序。

乘V得到两行(-0.888378139,0.888378139)、(0.888378139,-0.888378139)。加X得到(0.111621861,3.888378139)、(2.888378139,-0.888378139)。第二LN两行约(-0.999998598,0.999998598)及其反号。ReLU后乘0.2I，加回H，最终为(0.111621861,4.088377859)、(3.088377859,-0.888378139)。

三 梯度与更新不能省略哪条路径



目标两行为(0,2)、(2,0)，误差为(0.111621861,2.088377859)、(1.088377859,-0.888378139)。四个平方之和除8得到0.793445450。对Y求导后除4，得到(0.027905465,0.522094465)、(0.272094465,-0.222094535)。

设隐藏矩阵U，PyTorch权重以输出坐标为行，因此fc2.weight梯度为GY转置乘U。第一行第一列来自第二位置 $0.272094465 \times 0.999998598 \approx 0.272094083$ ；第一行第二列来自第一位置 $0.027905465 \times 0.999998598 \approx 0.027905426$ 。第二行为(-0.222094223,0.522093733)。fc2.bias梯度是两个位置相加，约(0.300000,0.300000)；这是原loss归约的结果，不能再除2。

残差有两条通向H的路径。用g表示Y的梯度，H得到直接的g加上FFN→LN回传的梯度；随后 $H=X+\text{Attn}(\text{LN}(X))$ 又让X得到直接路径和注意力路径。LN的均值、方差均依赖所有特征，不能把它当常数缩放。ReLU负激活坐标回传0。

同步SGD学习率0.05，第一步fc2.weight变为约[[0.186395296,-0.001395271],[0.011104711,0.173895313]]。其余所有参数也在同一时刻更新，不能只更新fc2然后声称复现整个账本。随包hand数组含每一步所有参数和梯度，可逐项检查 $\text{new}=\text{old}-0.05\text{grad}$ 。

第二次前向Y约为(0.140481847,3.816973773)、(2.921902811,-0.756550013)， $\text{loss}=0.592925194$ ；第二次更新后Y约为(0.148965094,3.612959565)、(2.789286500,-0.671756469)， $\text{loss}=0.462257387$ 。第一个标量目标0，其绝对误差三次逐步增大。多个误差共享参数，总体改进可以伴随部分误差恶化；不能修改目标或删除这条记录。



手算与更新复核图 每一步都重算整个块，未用第一步的隐藏表示代替后续前向。

反向详解一 从FFN沿归一化返回残差

下面继续同一个实例的完整反向。记F1、F2、Wo分别为PyTorch保存的fc1、fc2、proj权重，形状都是输出 $\times$ 输入。令Z1=LN1(X)，M=AV，H=X+proj(M)，Z2=LN2(H)，R=fc1(Z2)，U=ReLU(R)。每行是一个位置，每列是一个特征。没有省略任何参数支路。

$$G_U = G_Y F_2, \quad G_R = G_U \odot \mathbf{1}[R > 0], \quad G_{Z2} = G_R F_1.$$

权重梯度分别为 $G_{F2} = G_Y^T U$ 和 $G_{F1} = G_R^T Z2$ ，偏置是各自上游梯度沿位置求和。把上一页的GY乘0.2I，第一位置GU=(0.005581093, 0.104418893)。R第一坐标为负，故GR第一坐标清零；另一位置保留第一坐标。第二LN收到的GZ2就是GR，因为F1=I。

梯度对象	位置0的两个坐标	位置1的两个坐标
GU	(0.005581093, 0.104418893)	(0.054418893, -0.044418907)
GR和GZ2	(0, 0.104418893)	(0.054418893, 0)
LN2回到H	(-7.753e-8, 7.753e-8)	(4.041e-8, -4.041e-8)
GH=GY+LN2回传	(0.027905388, 0.522094542)	(0.272094505, -0.222094575)

对LN输入a，令 $s = \sqrt{v + \epsilon}$ 、 $\hat{a} = (a - \mu)/s$ 、 $u = g \odot \gamma$ ；完整反向为 $g_a = [u - \text{mean}(u) - \hat{a} \text{mean}(u \odot \hat{a})]/s$ ，均值沿特征轴。LN2把a=H、g=GZ2代入此式。这里每行仅二维，标准化向量接近 ± 1 ，很多方向会被居中和尺度消去，所以回到H的梯度很小；它并非精确零，epsilon仍参与导数。若手算时把 ± 0.999998598 硬替为 ± 1 ，容易误删这条小路径。

LN2的gamma梯度是 $\sum_i G_{Z2,i} \odot \hat{H}_i$ ，得到(0.054418817, 0.104418747)；beta梯度是 $\sum_i G_{Z2,i}$ ，得到(0.054418893, 0.104418893)。所有位置共享同一gamma/beta，不能保留两份独立参数。GH还含直接残差的GY，这使很小的LN支路梯度不意味着整个块的输入梯度也很小。

程序manual_backward用这些显式公式逐项计算，没有调用autograd求导；再把手推结果与真实loss.backward比较。三个参数状态都比较每个参数和X的梯度，最大误差在浮点舍入量级，详见hand内manual_autograd_max。

反向详解二 注意力的三条反向支路

输出投影把M映射为 $MW_o^T + b_o$ ，因此 $G_M = G_H W_o$ 、 $G_{W_o} = G_H^T M$ 。当前 $W_o=I$ ，GM数值等于GH。接着 $M=AV$ 使值路径与权重路径分叉：

$$G_V = A^T G_M, \quad G_A = G_M V^T, \quad G_S = A \odot [G_A - \text{rowsum}(A \odot G_A)].$$

最后一个rowsum保留单列，再沿行广播。这是softmax完整Jacobian的向量乘法，不能只乘 $a(1-a)$ 而丢掉非对角项。由于 $S = QK^T/\sqrt{2}$ ，继续有 $G_Q = G_S K/\sqrt{2}$ 、 $G_K = G_S^T Q/\sqrt{2}$ 。

对象	位置0的行向量	位置1的行向量
GV	(0.041533267, 0.480562308)	(0.258466626, -0.180562341)
GA	(0.494186684, -0.494186684)	(-0.494186609, 0.494186609)
GS	(0.052081443, -0.052081443)	(-0.052081435, 0.052081435)
GQ	(-0.073653914, 0.073653914)	(0.073653903, -0.073653903)
GK	(-0.073653909, 0.073653909)	(0.073653909, -0.073653909)

例如GV位置0第一坐标由所有query累加，约为

$0.944191290 \times 0.027905388 + 0.055808710 \times 0.272094505 = 0.041533267$ 。GA首行是GM首行点乘每一行V。GS的行和接近0，这是softmax对整行平移不敏感的结果，可作局部检查。

QKV共享Z1。若其三个PyTorch权重分别为 W_q 、 W_k 、 W_v ，则：

$$G_{Z1} = G_Q W_q + G_K W_k + G_V W_v.$$

本例三个权重为I，所以直接把上述三条路径相加，得到两行(-0.105774556, 0.627870131)、(0.405774437, -0.327870153)。只把值路径GV回传会漏掉“改变查询与匹配方式”的两条路径。

反向详解三 汇合到输入与全部参数

LN1接收GZ1，按照同一归一化导数回到X，约为(-3.668168e-6, 3.668168e-6)、(3.668168e-6, -3.668168e-6)。再与H=X+proj(M)的直接路径GH相加：

$$G_X = G_H + G_{LN1 \rightarrow X}.$$

最终GX两行为(0.027901720, 0.522098210)、(0.272098173, -0.222098243)。这完成了从loss到输入的所有连接。LN1的gamma梯度为(0.511546435, 0.955735505)，beta梯度为(0.299999882, 0.299999978)。二者看起来不小，而回到X的小梯度体现了归一化的几何作用，不能混为一类量。

Q、K、V投影各自的权重梯度是对应上游梯度转置乘Z1，偏置为上游沿位置求和。所有参数梯度如下，每个矩阵以“第一行；第二行”表示，均是PyTorch存储方向；数字显示9位附近，完整精度在JSON。

参数	权重或gamma梯度	偏置或beta梯度
fc2	(0.272094083, 0.027905426); (-0.222094223, 0.522093733)	(0.299999930, 0.299999930)
fc1	(0.054418817, -0.054418817); (-0.104418747, 0.104418747)	(0.054418893, 0.104418893)
输出投影	(0.216932274, -0.216932274); (-0.661121343, 0.661121343)	(0.299999893, 0.299999967)
Q投影	(0.147307081, -0.147307081); (-0.147307081, 0.147307081)	(-1.107e-8, 1.107e-8)
K投影	与Q权重梯度相同	(0, 0)，至舍入量级
V投影	与输出投影权重梯度相同	(0.299999893, 0.299999967)
LN2	(0.054418817, 0.104418747)	(0.054418893, 0.104418893)
LN1	(0.511546435, 0.955735505)	(0.299999882, 0.299999978)

这些相同梯度来自本例的单位矩阵和对称输入，不是一般性质。K偏置在纯点积注意力中给每行分数同一个平移，因此这里梯度接近0。更新仍对所有参数执行，包括数值为0的梯度。第一步、第二步都使用各自前向对应的完整反向链，不复用第一步的A或LN统计。

四 对齐和排列的答案

练习4: `norm_first`不一致时, LN位置不同, 函数一般不同, 即便参数完全相同也不能通过对齐。应逐一复制QKV、输出投影、两个FFN、两次LN, 包括偏置; 保持相同`eps`、激活、数据类型和`mask`。对输入分别建立独立可求导张量, 不能让一个计算图残留梯度污染另一个。

本次6配置最大前向/输入/参数梯度误差总计约 $1.78e-15$, 小于 $2e-10$ 。测试使用标量线性探针而非正好对称的求和, 减少某些错误被求和抵消的机会。有限配置不是全域证明, 公式推导与定向测试需要共同使用。

练习5: 无位置无`mask`时输出按输入同步重排, 最大误差约 $1.11e-16$ 。固定位置只交换词元时, 词元-位置配对改变, 差约1.61931。把 $X+P$ 整体交换则误差约 $4.44e-16$ 。固定因果`mask`时, 先后关系没有随`token`身份一起交换, 差约0.78972; 若`mask`两轴也按置换重排, 误差回到 $1.11e-16$ 。后者是图的重标号, 不是通常从左到右的生成顺序。

严格证明: Q 、 K 、 V 均变为 P 乘原值; 分数变为 PSP 转置; `softmax`逐行同时重排列与行, A 变为 PAP 转置; 乘 PV 得到 PAV 。LN、FFN逐位置共享, 继续保留等变。若有人把“等变”写成“输出不变”, 给出两位置输出交换的反例即可纠正。

练习6: 修改未来只允许从被修改位置传播到能读它的`query`。因果前3位置差0, 双向差约0.33306。前缀长度3与长度5比较, 因果差在舍入量级, 双向约0.22877。双向`softmax`分母新增候选, 即使新增`value`较小, 也可能改变权重和输出。错误的跨位置LN把所有位置纳入均值/方差, 即便注意力`mask`正确, 早位置也可依赖未来。

`key padding`屏蔽的是候选列, 不保证`padding query`输出0。`query`残差仍含输入, FFN仍会计算。因此评估仅选有效`query`, 或明确在块后置零并说明这是额外约定。本单元测试比较未补齐`query`, 不伪造`padding query`等于零的参考行为。

五 RoPE和证据范围

练习7: $q=k=(1,0)$, 旋转后 q 为 $(\cos p, \sin p)$, k 为 $(\cos t, \sin t)$ 。内积 $\cos p \cos t + \sin p \sin t = \cos(t-p)$ 。位置 $(0,1)$ 与 $(3,4)$ 都得到 $\cos 1 \approx 0.540302306$; $(0,2)$ 得到 $\cos 2 \approx -0.416146837$ 。二维旋转矩阵正交, 所以平方范数不变。高维逐对相加保留这个性质。

多频率情形是各对坐标在各自频率下的相对旋转, 不要求整个分数随距离单调减少。共同位置平移使每对的角度差不变; 若 q/k 本身随绝对位置或其他上下文改变, 不能再把它们当固定内容向量使用同一证明。

六 常见错误的最短修复

- 参数数对不上: 检查是否算入偏置、两次LN以及是否误把head分开重复计入整个 $D \times D$ 投影。
- 对齐只有 $1e-3$: 检查float32和float64是否混用、eps是否一致。不要先改阈值。
- softmax NaN: 打印每个query合法key数, 找空行。拒绝错误输入比把NaN替换为0更诚实。
- 交换后都相等: 检查是否实际同时交换了位置编码; 也检查投影是否全零造成退化。
- RoPE点积符号相反: 先统一列向量旋转约定与 $(t-p)$ 方向, 再核对相邻坐标配对。
- Run All没有图: 确认make_figures实际运行和CJK字体可读; 已执行Notebook应该包含真实image/png输出, 而不是仅含磁盘路径。

七 合格结论与不合格结论

合格: “所列CPU float64配置与参考层对齐; 因果干预、排列等变和RoPE代数性质在规定试验中成立。手算例两步总loss下降, 但一个坐标误差增加。”

不合格: “Transformer已经理解顺序” “pre-norm一定更好” “RoPE保证任意长上下文” “attention权重就是因果解释”。这些主张都超出了本实验可辨认的对象。

[1] PyTorch2.7 LayerNorm, <https://docs.pytorch.org/docs/2.7/generated/torch.nn.LayerNorm.html>。其余概念原始来源: Vaswani et al. 2017, <https://arxiv.org/abs/1706.03762>; Xiong et al. 2020, <https://arxiv.org/abs/2002.04745>; Su et al. 2021, <https://arxiv.org/abs/2104.09864>。数字来自随包代码, 非论文结果复刻。