

小型语言模型训练与规模解答

第055单元 用一致口径解释完整训练实验

本答案固定 $V=20$ 、最大序列长度7、两层pre-norm、四头、FFN宽度2D、零dropout、末端LN及不共享词表头。输入[BOS,六正文token]预测[六正文token,EOS]。所有指标来自12个CPU float32训练run，不是大模型缩放规律的验证。

一 样本与参数

练习1：假设颜色、动物、动作、物体的类别索引均为0，则颜色 $2=(0+0+0) \bmod 4=0$ ，正文为[蓝,猫,看,蓝,球,句号]。input=[BOS,蓝,猫,看,蓝,球,句号]，label=[蓝,猫,看,蓝,球,句号,EOS]。因果矩阵含对角线，位置 i 可读 $j \leq i$ 。标签已移位，不应再由loss函数移位。

练习2：D16时QKV权重768、偏置48；attention输出权重256、偏置16，共1088。FFN第一层 $512+32=544$ ，第二层 $512+16=528$ ，合1072。两次LN各gamma16和beta16，合64；一个块2224，两个4448。词嵌入320、位置112、末端LN32、词表头 $320+20=340$ ，总5252。

D32时一个块8544，两个17088，词嵌入640、位置224、末端LN64、词表头 $640+20=660$ ，总18676。参数矩阵大小按D而非H计，固定D、改变合法H不改变这些参数数。若输入嵌入与输出矩阵共享同一个Parameter，可少一个VD矩阵，不能只复制初始化就少算。

参数本体字节为 $5252 \times 4=21008$ 、 $18676 \times 4=74704$ 。若粗略加上梯度、Adam一阶矩、二阶矩四份float32数组，分别约84032、298816字节，仍未包括激活、临时张量、额外优化器状态和解释器。实际RSS数百MiB并不与这些小数字矛盾。

二 Token预算

练习3：每步 $16 \times 7=112$ ；80步8960有效token； $80 \times 16=1280$ 文档曝光。32池平均重复40次，128池重复10次。唯一文档内目标位置分别224、896。wordpiece种类数、文档数、目标位置数和重复曝光数是四个不同量。

有padding时有效数取loss mask之和。g次微批累积再step，要累计这些微批所有有效token，按总loss/总有效数缩放。固定微批步数而有效数不同，不是相同token预算；分布式还需明确全局还是每设备。

三 FLOPs逐项答案

练习4：矩阵 $m \times k$ 乘 $k \times n$ 的主要乘加约 $2mkn$ 。一个块QKV为 $6BLD^2$ ，输出投影 $2BLD^2$ ，FFN两层 $4BLDF$ ，QK转置和AV合 $4BL^2D$ 。n层加词表头 $2BLDV$ ，得到：

$$C_{fwd} \approx n(8BLD^2 + 4BLDF + 4BL^2D) + 2BLDV.$$

D16、B16、L7、F32、n2、V20：投影与FFN每层分别229376和229376，注意力两乘法每层50176；每层合508928，双层1017856，加词表头71680，总1089536。乘3估算训练3268608/步，80步261488640。

D32时前向4014080，训练估算12042240/步，80步963379200。大/小每步约3.684倍。未计算LN、softmax、ReLU、偏置、embedding查表、AdamW逐元素更新、内存传输与调度。这是主矩阵运算模型，不能称作实测总FLOPs。

$D16 \times 74$ 步=241876992； $D32 \times 20$ 步=240844800，差1032192，约为较小预算的0.43%。两者有效token分别8288与2240。等计算比较意味着不同训练曝光数，不能同时称作等token。

四 两步真实AdamW复算

练习5取D16、128文档、seed5501的head.bias[3]。原始梯度来自112个位置的softmax概率减one-hot目标，再求平均，第一次约-0.040450431，与直接计算-0.040450435一致到float32精度。全部参数范数1.103647232，比例约 $1/(\text{norm}+1e-6)$ ，裁剪后 $g=-0.036651563$ 。

第一步 $m=.1g=-0.00366515643$ ， $v=.001g^2=1.34333709e-6$ ； $mhat=m/.1=g$ ， $vhat=v/.001=g^2$ 。b先乘 $1-.003 \times .01=.99997$ ，再减 $.003 \times mhat/(\sqrt{vhat}+1e-8)$ ，由-0.102765769到-0.099762686。

第二步用新前向与新batch：原始梯度-0.027915739，范数1.044882536，裁剪后 $g=-0.026716603$ 。 $m=.9 \times \text{旧}m+.1g=-0.00597030111$ ； $v=.999 \times \text{旧}v+.001g^2=2.05577066e-6$ 。偏差校正分母变为 $1-.9^2=.19$ 和 $1-.999^2=.001999$ ，最终 $b=-0.096820138$ 。

如果把weight_decay乘theta加入g，会进入 m/v ，算的是另一种算法；如果把每个参数单独裁剪，选中坐标不会得到本例的g。测试分别核对CE梯度、全局裁剪比例、 m/v 递推及参数after，不能只检查最终loss。

五 测量答案与全部种子

练习6：前5步参与优化、计入8960总token，但从稳态吞吐排除； $75 \times 112 = 8400$ ，除以后75步训练段总秒数。训练段含取batch、清梯度、前向、loss、反向、裁剪和step；不含模型构造、验证、文件写入或进程启动。不能逐步吞吐简单平均，也不能用整轮wall_seconds与训练吞吐混算。

每个配置新子进程，Linux `ru_maxrss`乘1024得字节，包含解释器、库、训练与验证峰值；不是峰值激活大小。GPU字段null表示没有GPU测量，不是0字节。参数文件大小也不能替代峰值工作集。当前吞吐范围约20673至31268有效token/秒，仅适用当前CPU与负载。

练习7的第80步验证NLL原值如下。必须保留每个种子，不能只报最低值。

D	池大小	seed5501	seed5502	seed5503
16	32	1.173791	1.185691	1.173513
16	128	1.124627	1.141072	1.132441
32	32	1.455642	1.493102	1.387267
32	128	1.060750	1.059999	1.054648

分组均值依次1.177665、1.132714、1.445337、1.058465。样本标准差用 $\sqrt{\sum_i (x_i - \bar{x})^2 / (3 - 1)}$ ，依次0.006952、0.008226、0.053665、0.003327。不是置信区间，未覆盖不同数据划分。


训练NLL均值依次1.008050、1.093558、0.720835、1.004230。小池中大模型训练更低、验证更高，符合过拟合表现。大池中大模型验证较好。但这只是在同样80步、同样8960token下的比较，它付出了更多估算矩阵计算量。

近似等计算比较使用大池：小模型74步三值1.139532、1.166065、1.156360，均值1.153986；大模型20步三值1.411482、1.442127、1.415773，均值1.423127。较紧计算预算下小模型更好。两个比较的约束不同，不能择其一写成普适规模结论。

六 逐位置和缩放假设

练习8：大池大模型颜色2平均NLL约1.467887，而句号/EOS约0.02以内。颜色2虽然由前三个选择确定，仍未达到确定预测；总体loss降低不能证明规则已学会。四颜色均匀候选基线 $\ln 4 \approx 1.386294$ ，也提供比全词表均匀 $\ln 20$ 更针对性的参考。

完整均匀生成分布中，颜色1、动物、动作、物体四个自由选择各贡献 $\ln 4$ ；颜色2、句号、EOS若模型已知规则则贡献0。7个目标平均为 $4\ln 4/7 \approx 0.792168$ 。这是总体分布的信息论量，固定有限划分及有限重复训练池不必达到相同经验下界。32条训练样本被反复记忆，训练loss 0.72并不违反该公式。



逐位置复核图 关注颜色2与物体位置，而不是只看标点学得有多快。

练习9：两个宽度点无法可靠区分幂律、饱和或其他曲线， L_∞ 、 α 、 β 又互相影响；固定步长未必让两个规模优化充分。至少需要更多规模和预算点、独立数据划分、合理调参成本控制、留出规模点与残差/预测区间。任何外推要明确超出观测区间多少，不能用“规律”代替证据。

一个合理最终报告应保留训练池与曝光量、所有种子、等token与近似等计算的不同结论、测量边界、未测GPU、规则位置失败、测试未使用和不拟合缩放指数。没有自然语言性能或前沿模型能力结论。

七 故障判断

Future干预导致前缀变化时，应检查因果mask、位置编号和dropout，而非扩大训练；checkpoint回读不一致时，先核对键名、dtype、模型结构、是否eval及文件版本。若需断点续训，另需优化器、随机状态、数据游标和协议，本包npz只存模型数值。无效长度、非整数token或词表外ID应明确拒绝。

一手来源：Kaplan <https://arxiv.org/abs/2001.08361>；Hoffmann <https://arxiv.org/abs/2203.15556>；PyTorch2.7 AdamW <https://docs.pytorch.org/docs/2.7/generated/torch.optim.AdamW.html>；clip_grad_norm_ https://docs.pytorch.org/docs/2.7/generated/torch.nn.utils.clip_grad_norm_.html；Python resource <https://docs.python.org/3/library/resource.html>。全部本课数字为原创训练记录。