

生成解码与KV缓存参考答案

第056单元 手算与实测逐项核对

本答案对应20词元、2层、D16、H4、位置容量7的固定模型。读者只需本单元包，不必访问055。outputs/results.json保存完整160条生成与20轮固定工作量计时；正文中的时间是本次CPU记录，重跑不同不代表错误。

一 四词元分布的完整计算

1. 设 $z_i = \log p_i$ ，则 $\exp(z_i) = p_i$ ，四项和1，因此softmax=p。logit可以加任意共同常数，仍是同一个分布。
2. $T=0.5$ 时 $\exp(z_i/T) = p_i^2 = [0.16, 0.09, 0.04, 0.01]$ 。总和0.30，除后为 $[0.533333, 0.300000, 0.133333, 0.033333]$ 。
3. top-k2保留A与B，余项为0。剩余质量0.7，故新分布 $[4/7, 3/7, 0, 0]$ ，约 $[0.571429, 0.428571, 0, 0]$ 。
4. top-p0.6：累计A是0.4，不够；A+B是0.7，首次达到阈值。包含B，得到与上一问相同的集合及概率。按“累计值必须小于阈值”会只留下A，是常见错误。
5. 先 $T=0.5$ ，新分布前两项累计0.833333，仍保留A、B，但二次归一化为 $0.16/(0.16+0.09)=0.64$ ，B为0.36。集合相同，概率不同。
6. 原分布B的区间是 $[0.4, 0.7)$ ，0.65在其中，所以抽到B。一次抽到B并不表示B比A更可能。

可用概率比再核验温度：原A/B为4/3， $T=0.5$ 后变为 $(4/3)^2=16/9$ ，正是 $0.533333/0.3$ 。低温强化相对偏好，却没有校准答案真伪。

贪心的反例为A路径 $0.6 \times 0.4 = 0.24$ ，B路径 $0.4 \times 0.9 = 0.36$ 。第一步选A是局部最大，但两步联合最大可以经过B。模型概率与事实正确性仍是不同问题。

二 六次预测与EOS

长度2的prompt已经占据位置0、1。六次预测所用输入长度依次2、3、4、5、6、7；最后一次输出是第8个序列元素，尚未作为输入，因此不需要第8个位置嵌入。合法检查为 $2+6-1=7$ 。

若第三次输出EOS，新增列表长3，立刻退出，stop_reason=eos。若六次都不是EOS，新增列表长6，stop_reason=max_new_tokens。后者不是任务自然完成。本课并不对中途生成的格式错误自动修补，错误输出要留下来。

PAD和BOS的logit被设为负无穷，有限剩余项softmax后仍归一化为1。全负无穷时没有合法分布，代码报错。EOS没有被强制保留在top-k/top-p集合中，所以截断可能改变结束倾向。

三 非方形mask和维度答案

已有P=3, 当前C=2, B=2、H=4、d_h=4:

- 新Q为 $2 \times 4 \times 2 \times 4$; 新K/V同shape
- 历史K/V为 $2 \times 4 \times 3 \times 4$
- 拼接后K/V为 $2 \times 4 \times 5 \times 4$
- 分数QK转置为 $2 \times 4 \times 2 \times 5$
- 加权后为 $2 \times 4 \times 2 \times 4$, 合头后 $2 \times 2 \times 16$
- 新位置索引为3、4

allowed矩阵第一行为[1,1,1,0], 第二行为[1,1,1,1]。第一个新token只能看到已有三项和自己, 不能看第二个新token。用局部位置0、1做判断会错误屏蔽历史。

每层隐状态经过不同投影和残差变换, K/V的数值随层变化, 缓存必须按层存放。缓存路径测试还覆盖两个样本、先3后4的chunk拆分、未来token扰动、错误容量和错误prompt, 既检查数值也检查信息边界。

160条正式生成的缓存/无缓存token完全一致, 最大logit绝对差 $1.430511474609375e-6$, 小于 $2e-5$ 门限。这是本次float32、CPU、固定权重和种子的证据。改变软件、设备或遇到极近概率边界时, 不应要求永远逐位一致。

四 载荷与计算量

标准多头KV载荷 $M=2n\text{BTDs}$ 。本模型B1、T7、D16、n2、s4:

$2 \times 2 \times 1 \times 7 \times 16 \times 4 = 1792$ 字节=1.75KiB。

B2时为3584字节=3.5KiB, 代码对每层两张张量逐一统计得到同值。改成float16理论为896字节; 权重、attention临时张量、动态拼接、Python与分配器并不会自动全部减半, 不能把载荷比例当进程峰值内存比例。

从空历史逐项处理T=7时, 全前缀attention分数数目是 $1^2+2^2+\dots+7^2=140$; 单query缓存路径是 $1+2+\dots+7=28$, 每层每头减少为五分之一。但投影、FFN、softmax、缓存拼接和调用开销混在实际运行中, 墙钟时间不必达到五倍差距。

若prompt长P, 再生成G个输出, 其中最后输出无需回送, prefill处理P项, 后续只需G-1次新token前向。不要把输出数量直接当新增缓存数量。缓存长度与已处理的输入数量相同。

五 实测结果解释

本次五组结果依次如下: 贪心平均长度6、EOS100%、不同组合4; T0.7平均5.875、EOS100%、组合28; T1.3平均5.25、EOS62.5%、组合32; top-k3平均6、EOS100%、组合29; top-p0.8平均6、EOS100%、组合30。每组32次生成, 样本是4prompt各8seed, 不能把同prompt的重复输出当独立任务泛化证据。

贪心不使用随机抽样，所以8个seed不会改变相同prompt的输出。T1.3更分散，既可能过早抽到EOS，也可能一直没抽到EOS，最终被长度上限截断。因此平均长度较短和未结束比例较高完全可以同时出现。

序列“猫 猫 狗”的相邻重复次数是1，二元组为(猫,猫)和(猫,狗)，两个均只出现一次，所以重复二元组比例为 $1-2/2=0$ 。本次全部输出的重复二元组比例都是0，T1.3却出现8次相邻重复；这就是需要保留的指标盲区，而非清理掉的异常。

固定7输入位置、20轮交替测量的中位数为无缓存1.831861毫秒、缓存1.773243毫秒。比值约1.033；差值约0.058618毫秒。缓存只在这个局部测试中略快，差距很小，不足以作跨机器、长上下文或服务端吞吐主张。若自己的重跑顺序反过来，应如实报告而不是改协议追求理想结论。

六 合格报告应写出的边界

本实验核验了解码分布、因果缓存、位置容量和有限短句的输出行为。它没有测自然语言事实性、人工偏好、长上下文、GPU、并发服务或前沿模型。温度与top-p是分布干预，不能称为模型学习了新能力；缓存是计算复用，不能称为增强记忆或改善推理。

答案不是某一句“漂亮续写”。合格报告应让别人从源文件重新算出所有计数，能找到失败样本，知道时间包含哪些工作，并看到原始公式与实现使用同一个shape约定。

七 两维注意力与错误缓存的解释

三个缩放分数为 $[1/\sqrt{2}, 1/\sqrt{2}, 2/\sqrt{2}]$ 。先减最大值再指数，未归一化权重为 $[\exp(-1/\sqrt{2}), \exp(-1/\sqrt{2}), 1]$ ，约 $[0.493069, 0.493069, 1]$ 。归一化后约 $[0.248255, 0.248255, 0.503490]$ ，对应value加权和为 $[1.503490, 1.503490]$ 。只有通过本层其余运算及最终词表head，才能得到logit，再经softmax变成词元概率。

错用同形状缓存可能没有运行时异常，因为Tensor库只知道轴长度，不知道它来自哪个prompt。两个前缀的旧隐状态不同，缓存的key/value也不同；将B的新query与A的历史拼接，得到的是混合计算，不再是模型对B前缀的条件分布。错误注入实验若偶然数值接近，也不能证明允许复用。

缓存失效的情况包括旧token被修改、模型权重更新、适配器更换、位置编码策略改变，以及推理中存在会改变旧表示的随机或全局操作。设备或dtype变化也必须正确处理。eval负责模块行为，no_grad负责不记录梯度图，两者不能互相替代。

一个可审查的实现应保证缓存长度等于已经送进模型的输入长度，并把请求身份与缓存绑定。最后生成的EOS若不再送回，缓存可以比返回序列短1；这不构成缺失数据。

资料

算法背景参见Holtzman等的[原论文](#)及Hugging Face的[缓存文档](#)。本答案的手算、数值、反例和实验结果为本课程独立构造。