

# 语言模型实验与评价参考答案

## 第057单元 分母区间与失败样本的逐步核验

本答案对应正式120步、三个初始化种子的固定协议。题面和答案可以用作机制练习；看过公布结果后不能再把相同测试题称为对新设计完全未知。

### 一 为什么协议必须先于结果

研究对象是固定的合成组合任务，三个种子只改变模型初始化，批次生成器种子5790固定。120步模型是事先规定的最终模型，0、40、120步验证轨迹用于诊断。看到5703稍好后只给它延长训练会改变计算预算；拿同一测试集再次挑胜者又引入测试适配。探索可以做，但应明确标记，不能沿用“第一次封存评价”的说法。

每步16文档，每文档7有效目标，所以每run曝光 $120 \times 16 \times 7 = 13440$  token。三个run共40320 token，但它们来自重复使用的160训练文档，不能称为40320个独立新样本。记录步数、曝光和数据量三个量能避免混淆。

### 二 分组拆分与污染检查

三种输入类别各4种，组合数 $4^3 = 64$ 。每个组合搭配4种物体，文档数256。40训练组给出160文档，12验证组给出48文档，12测试组给出48文档。完整文本和前缀组交集都应为0；词表共享是预设任务条件。

若把一份训练文档追加到测试副本，`exact_document_overlap`为1，`prefix_group_overlap`也会变成1。后者按不同前缀集计数，不是按文档条数计数。因此把同组四份变体都追加，文档重复可以为4，而前缀组重复仍为1。

逐文档随机拆分可能将同组的“球”放训练、“书”放测试。两句完全不同，完整文本去重通过，但模型已见过同一颜色计算题。按组拆分先于训练，才符合本课未见规则前缀的研究问题。

group42的内容ID5、9、13分别对应类别2、2、2，规则类别 $(2+2+2) \bmod 4 = 2$ ，颜色ID $= 3+2 = 5$ ，即绿。直接用 $5+9+13$ 再 $\bmod 4$ 错误地混入不同类别的词表偏移。

### 三 困惑度手算与权重平均

$q=[1/2, 1/4, 1/8]$ 时，三项NLL为 $\log 2$ 、 $\log 4$ 、 $\log 8$ ，约0.693147、1.386294、2.079442。总和4.158883，除3得到1.386294， $\exp$ 还原为4。另一个验证是三项概率乘积 $1/64$ ，几何平均为 $1/4$ ，倒数也是4。

两个batch的有效token数分别2和1，平均loss分别1和3。它们的损失总和分别2和3，总和5除以总token数3，得到 $5/3 \approx 1.666667$ 。简单平均两个batch的均值会得到2，错误地给小batch过高权重。只有每批有效数完全相同，简单平均才等价。

正式测试48文档，每文档7项，共336。种子5701损失总和382.922974，除336约1.1396517，exp约3.125679。NLL先平均再取exp，不是把每份文档的PPL作算术平均。文档等长时文档NLL均值与token均值相同，变长时仍需按有效token加权。

PPL比较还依赖分词、上下文、EOS与padding规则。本课词表固定20，EOS计入目标，PAD未出现于有效目标；换成另一个分词器后的数值不能直接当能力提升。

## 四 为什么低loss仍然可以答错规则

七个预测目标依次是颜色1、动物、动作、颜色2、物体、句号、EOS。前三项带有条件不确定性，第四项是本课的规则焦点，第五项物体有四种可接受选择，末两项格式几乎固定。

种子5701在句号和EOS位置的NLL约0.0336、0.0312，规则位置约1.7786。对七位置求平均会包含这些容易项，因此总体loss降低与规则失败能够同时发生。教师强制给出的是真实前缀，自由生成又会把自己的错误回填，两者不能互相替代。

均匀基线的每个目标概率 $1/20$ ，所以 $NLL = \log 20 \approx 2.995732$ 。bigram只利用上一个token，用训练统计和加一平滑拟合，测试NLL $\approx 1.485876$ 。神经模型三种子约1.120840到1.153957，说明在本定义的token预测指标上较好；这不是规则成功、真实性或安全性的等价结论。

## 五 一条失败样本的完整判定

group42的prompt为[BOS,绿,鸟,找]。种子5701输出[蓝,书,.,EOS]，对应ID[4,16,19,2]。它有四项，第一项属于颜色，第二项属于物体，最后两项为句号和EOS，所以format\_correct=True。

正确颜色是绿，预测蓝，所以rule\_correct=False；两条件取与得到task\_success=False，错误类型是wrong\_rule。此例不能靠“输出流畅”改变判定。三个种子都在这题输出错误颜色，后面物体不同也不能修复规则错误。

错误分类先看格式：只要格式或停止不合约，归format\_or\_stop\_failure；格式正确后再看颜色，错为wrong\_rule，否则success。因此三类互斥且覆盖全部12组，计数总和必须是12。

## 六 EM为何天然只有四分之一上限

同一规则前缀有四份文档，对应球、书、盒、杯，四个物体均合法。贪心只生成一个物体，因此规则正确且格式合规时只能精确匹配四份中的一份。单参考EM以48文档为分母，上限 $12/48=25\%$ 。

5701成功1组：任务率 $1/12=8.333\%$ ，单参考EM $1/48=2.083\%$ ；5703成功2组： $2/12=16.667\%$ ，EM $2/48=4.167\%$ 。分数相差四倍来自评价定义。若改成“是否匹配任一合法参考”的多参考EM，则在这个任务里它等价于任务成功，但必须改指标名称和定义，不能混用。

## 七 Wilson区间的数值

取 $k=1$ 、 $n=12$ 、 $z=1.96$ ， $p_{\text{帽}}=1/12$ ， $z^2=3.8416$ 。公共分母 $1+z^2/n \approx 1.320133$ ；中心约0.184375，半宽约0.169511，所以区间约[0.014865,0.353886]。中心不必等于样本比例，区间也不必以 $p_{\text{帽}}$ 为中心。

$k=0$ 时，下限0，上限约0.242501；没有观察到成功不排除相当范围的可能概率。 $k=2$ 时，区间约[0.046964,0.448036]，仍然很宽。因此1/12和2/12不能支持精确的模型能力排名。

不能把三个模型的成功数1+1+2和题数12+12+12当作36个独立新题直接套同一公式。三个模型共用相同测试题，难题相关，且训练与测试都来自有限组合集合。区间在本课是近似同类机制抽样下的透明描述，不能保证现实语言任务覆盖率。

## 八 权重回读与盲评答案

NPZ使用`allow_pickle=False`，避免载入任意Python对象；`strict=True`检查权重键与shape。读取三个权重后在相同数据和代码上重新evaluate，可以核对保存结果是否真的对应所发布模型。仅检查JSON存在或训练loss下降，不能代替这个回读步骤。

评分表36行来自3模型 $\times$ 12题组，`candidate_id`固定打乱。人工评分列全空是诚实的“尚未开展”，不是缺失的成绩需要模型补齐。组织者持有映射，评价者先独立评分；如果两者同时看到模型映射，就不能继续称盲评。讨论后可增加裁定列，但应保留原始分数和理由。

真实开放任务还需核对事实证据、评分者一致性、模型裁判的位置和长度偏好等。本课不提供这些实测。论文链接只提供背景，不是已经跑过相应基准的证明。

## 九 一份可接受的结论

在固定64组合的组拆分下，三个从零训练的小decoder经过同样120步，在token NLL上优于均匀和bigram基线，所有测试输出符合格式；然而12个未见前缀组只成功1、1、2组，主要错误是规则颜色错误。近似区间很宽，不支持稳定能力或精确排名的主张。

结论应同时说明：数据为原创短合成符号句，没有评价自然语言知识、事实性、开放对话、长文本或安全性；没有人工/模型裁判分数；全部失败和原始权重被保留。下一次探索应作为新的实验登记，而不在看过测试后追改本次胜者。