

语言模型实验与评价实验手册

第057单元 从协议到错误清单的独立复现

本实验从随机初始化训练三个小型decoder，并逐项核对测试分母、基线、错误类型与近似不确定性。核心问题是：为什么测试NLL明显低于基线，规则任务成功却只有1/12到2/12？我们不要求你把分数调高，而要求你让每个结论都能回到原始记录。

先修是概率、交叉熵、分组拆分与基础训练循环。包内的合成数据可由make_data重新生成；模型从零开始，不下载权重、不使用外部数据、不调用人工或模型裁判服务。CPU即可，建议预留1GB可用内存，安装依赖的磁盘空间另计。

一 环境与运行顺序

终端切换到包含experiment.py的057目录，然后运行：

```
conda env create -f environment.yml
conda activate dl057
python test_experiment.py
python -O test_experiment.py
python experiment.py --output replay
python make_figures.py --results replay/results.json --output replay/figures
jupyter lab experiment.ipynb
```

Python3.12已有环境也可用python -m pip install -r requirements.txt。核心库按本次运行版本固定；torch实测为2.14.1+cpu，依赖固定到2.14.1允许CPU本地版本后缀。若安装遇到平台轮子问题，使用PyTorch官网安装说明选择CPU版本，不需要GPU。

Notebook清空输出后Run All会在notebook_replay重跑全部三种子，正式outputs不会被覆盖。每个种子训练限制120步及120秒，超过时间会明确失败，不自动加预算。通常CPU总运行几十秒内；繁忙机器可能更慢。测试不应通过删除检查来修复。

图中汉字使用Noto Sans CJK；其他系统可把DL_CJK_FONT设为可读字体文件绝对路径。随包PDF可以直接阅读；只有重建PDF才需要build-tools里的额外依赖和Noto Serif CJK字体。执行通过不代表浏览器Jupyter界面已经测过，验收记录明确采用新进程中的内核逐格执行。

二 训练前先写一张协议卡

在打开outputs/results.json之前，把下列项目记在自己的报告开头。此处协议已经公开，目的是学习预先固定，而非假装当前数据对你完全未知。

- 研究对象：原创20符号词表，固定六内容token及EOS
- 拆分单位：颜色1、动物、动作三元组，共64组，每组四个物体变体
- 训练预算：三个初始化种子5701、5702、5703，每个120步、batch16

- 固定优化器：AdamW，学习率0.003，weight_decay0.01，梯度范数裁剪1
- 验证时间：0、40、120步；最终模型固定120步，不按测试挑选
- 主要任务：给出BOS及前三个规则输入，贪心生成颜色2、物体、句号、EOS
- 报告指标：token NLL/PPL、格式比例、规则正确率、任务成功、单参考EM与所有错误

写下为什么不能看到测试失败后只增加5703训练步数，却仍称为“同一协议比较”。如果想探索新方法，应把探索单独记录，并为未来最终主张准备新的封存测试。

三 手算数据拆分与污染检查

颜色、动物、动作各有4类，因此有 $4 \times 4 \times 4 = 64$ 个前缀组。每组4个物体变体，共256文档。固定seed5700打乱组，分40/12/12组，得到训练160、验证48、测试48文档。

运行make_data，打印每个split的文档数与group集合；检验三个组集合两两无交。再对训练与测试调用contamination，核对exact_document_overlap与prefix_group_overlap为0。词汇重合不是错误，因为本任务测试组合泛化，不测试新词。

在内存副本中把训练文档第一项追加到测试列表，调用检查函数，确认完整文档重复数变成1。不要把这种错误注入写回正式corpus.json。解释只检查完整文本为何仍不够：同组三元组配不同物体是不同文本，却是同一道规则题。

把group42当手算案例：前三个内容ID是5、9、13，扣除各类别起始ID3、7、11，得到2、2、2。和为6，mod4为2，目标颜色ID应为5。完成这个转换再读预测，避免把词元ID直接相加产生错误规则。

四 NLL和困惑度的分母

先手算 $q=[1/2, 1/4, 1/8]$ 的三个负自然对数、总和、均值和PPL。再计算两个batch的例子：有效token数2和1，平均loss为1和3，说明整体平均为什么是5/3。

本课测试48文档，每文档7个有效目标，所以effective_tokens=336。取种子5701的逐文档sum_nll求和，除336，检查得到约1.139652；再取exp得到约3.125679。浮点累计顺序可能产生微小误差，使用绝对容差1e-5，不要求文本末位一致。

查看position_nll七项，指出第4个目标位置才是规则颜色，第6、7项是句号与EOS。解释为什么句末格式的低loss可以拉低总体平均，但不能证明规则已学会。画图时保持位置顺序，不按损失大小重排后忘记原任务含义。

五 生成评价与精确匹配

每个测试组只有一个prompt，代码最多贪心生成四个token。对全部12组逐一记录：prompt、正确颜色、生成列表、是否合格式、规则是否正确、任务是否成功、错误类型。不要只复制summary。

对于group42，种子5701生成[4,16,19,2]。把它翻译成符号，检查四个位置格式，再与手算颜色ID5比较。说明为什么这是wrong_rule，为什么不能因为输出完整就算任务成功。

每个prompt有四种合法物体参考，但单参考EM按48文档计分。证明正确且合格格式的输出对四份参考最多匹配1份，因此此EM上限25%。若有1组成功，任务成功为1/12，EM为1/48。把“多参考任务成功”和“逐文档单参考匹配”分开写清楚。

六 小样本区间与随机种子

用讲义的Wilson公式手算 $k=1$ 、 $n=12$ 、 $z=1.96$ 的中心与半宽，核对约 $[0.014865, 0.353886]$ 。再计算 $k=0$ 与 $k=2$ 。为什么0次成功的区间上限仍大于0？为什么2/12也不支持“稳定成功”？

将种子5701至5703的点估计和区间画在同一轴上，但不要把它们累加为36个独立新题。三个模型看到的是同一批12测试组，重复初始化产生的是算法随机性，不是新的题目抽样。

本数据来自有限64组合的一次固定拆分。写明本课区间是近似独立同类题机制下的描述，不是已经证明的现实任务总体覆盖率；有限总体与训练依赖会让严格推断更复杂。

七 原始权重和盲评练习

用`model.load_model`读取`outputs`里的三个NPZ，重新`evaluate`测试数据。NPZ载入明确`allow_pickle=False`，参数名和`shape`由`strict=True`检查。记录复算指标与原JSON的差，不能仅凭文件存在就断言训练可复现。

`blind_rating_sheet.csv`包含36个候选，评分列均为空。若进行课堂练习，由组织者保留`blind_key.json`，给评价者规则说明和评分表；评价者独立评分后再讨论分歧。不要伪造评分、不要把自动规则分写成人工分。若没有真实评价者，就在报告里写“未开展人工评价”。

这里任务可以由规则精确打分，人工表只是练习盲法与评分协议。自然语言任务的事实性、偏好和安全性需要不同标准；本课没有跑TruthfulQA、HELM或MT-Bench，也没有调用模型裁判。

八 提交物与验收

提交协议卡、拆分集合检查、NLL/PPL手算、全部12组逐项记录、三种子区间、四幅重画图 and 一页结论。保留完整JSON、权重和顺序执行Notebook。报告必须说出一个负面结果和一个不能外推的范围。

检查现象	优先诊断	验收要求
NLL相差四倍或七倍	sum与mean、token与group分母	从原始项重算
测试规则突然很好	组泄漏、测试后选模型	保留污染检查与协议
EM比任务率低四倍	四个合法参考、分母不同	解释设计上限
0次成功就写成功率为零	忽略抽样不确定性	同时报样本数和区间
Notebook运行有隐藏变量	未重启或乱序执行	清空后自顶向下
换机器计时不同	线程、负载和软件版本	保留环境，不改结果追平