

自编码器练习完整答案

第058单元 推导 数值与证据边界

题一 网络形状与参数

题目要求写出 $B=64$ 、 $D=8$ 、隐藏宽16、瓶颈 $K=2$ 时的前向形状，并解释为何压缩后还能产生八维输出。

输入 64×8 ，经第一Linear成为 64×16 ，ReLU不改shape；第二Linear得到 64×2 ，这是潜在表示。解码器Linear把 64×2 映成 64×16 ，ReLU后再映到 64×8 。输出的八个坐标由同一对潜在数共同决定，所以输出维数恢复为8并不意味着恢复了所有被丢弃的信息。二维平面上的点也可以嵌入八维空间，关键是可达到输出集合的结构受到限制。

每个含偏置的Linear(a,b)有 $ab+b$ 个参数。编码第一层 $8 \times 16 + 16 = 144$ ，第二层 $16 \times 2 + 2 = 34$ ，共178；解码第一层 $2 \times 16 + 16 = 48$ ，第二层 $16 \times 8 + 8 = 136$ ，共184；全网362。ReLU没有可训练参数。float32参数裸值大小 $362 \times 4 = 1448$ 字节，但模型文件还有键名与压缩格式，训练时还存在梯度、Adam状态和激活，因此该数不是运行内存。

一般瓶颈为 K 时，参数数为 $144 + (16K + K) + (16K + 16) + 136 = 296 + 33K$ 。 $K=2$ 给362， $K=8$ 给560。比较不同 K 时参数量也同时改变，报告中应承认这个因素，不能把所有差异都归因于维度本身。

评分要点： 五个shape、两个ReLU位置、无输出ReLU、362的逐层来源，缺一项都应指出。常见错误是把PyTorch权重的存储形状 16×8 直接当成批数据右乘矩阵，从而得到不合法乘法；实际前向使用权重转置。

题二 前向手算

给定 $x=(2,-1)$ ， $e=(0.5,-0.5)$ 的列向量， $d=(1,0)$ ，没有偏置或激活。潜在数 $z=2 \times 0.5 + (-1) \times (-0.5) = 1.5$ 。重构 $zd=(1.5,0)$ ，误差为 $(-0.5,1)$ 。损失为 $[0.25+1]/2=0.625$ 。

如果回答1.25，计算的是平方误差和；如果回答0.3125，多除了一次2。批大小只有1也仍需除以特征维度2。损失约定必须先写出，再求导，不能凭记忆把“二分之一平方和”的公式混入“所有元素mean”。

二 梯度一次更新与线性基准

题二续 全部链式导数

损失对预测的导数为 $(-0.5, 1)$ 。因为 $\hat{x}_j = z d_j$ ，解码梯度为 z 乘该向量，得到 $(-0.75, 1.5)$ 。对 z 求导需把所有输出路径相加： $-0.5 \times 1 + 1 \times 0 = -0.5$ 。又因为 $z = x_1 e_1 + x_2 e_2$ ，编码梯度为 $(2 \times -0.5, -1 \times -0.5) = (-1, 0.5)$ 。

学习率0.1的普通梯度下降得到 $e' = (0.6, -0.55)$ ， $d' = (1.075, -0.15)$ 。新 $z = 2 \times 0.6 + (-1) \times (-0.55) = 1.75$ ，新预测为 $(1.88125, -0.2625)$ 。新误差 $(-0.11875, 0.7375)$ ，平方分别为0.0141015625和0.54390625， $MSE = 0.27900390625$ 。损失下降说明这一步方向和步长在这个例子中有效，不保证任意学习率都下降。

不能先更新 d 再重新计算旧前向的 e 梯度；那变成另一种更新算法。测试用自动微分核对旧点梯度，另外的数值更新用于独立理解。主实验用Adam，不能要求它与本题普通梯度下降更新相同。

题三 PCA残差与适用条件

四个样本已中心化。 $X^T X$ 的对角为18和2，交叉项为0。第一奇异值平方18，第二平方2；秩1投影保留第一轴。重构为 $(3, 0)$ 、 $(-3, 0)$ 、 $(0, 0)$ 、 $(0, 0)$ ，总残差平方2，除以 4×2 得到0.25。

若用 $X^T X / N$ 定义协方差，两个特征值为4.5和0.5，丢弃特征值0.5再除 $D=2$ 得到同样的0.25。如果用无偏样本协方差分母 $N-1$ ，丢弃值为 $2/3$ ，必须再乘 $(N-1)/N$ 后除 D ，仍得到0.25。混用分母会得到看似接近却错误的结果。

自编码器与PCA相同的是特定线性、平方误差、合适容量并达到全局最优条件下的主子空间或重构。AE潜在坐标可以做可逆变换，未必正交，也不必按方差递减排列。加入ReLU后不能声称它严格等于PCA。本课PCA用SVD确定性计算，不依赖神经网络优化是否收敛。

评分要点：写出残差来源与分母，区分训练最优残差和测试误差，并解释“子空间相同”不等于“每个神经元就是一条主成分”。

三 去噪与稀疏约束的答案

题四 目标保持干净

基础AE输入为 x ，目标为 x 。DAE输入为 $x+\epsilon$ ，目标仍为 x ； ϵ 每坐标独立，标准差0.5。错误写法
`loss(model(corrupted), corrupted)`训练模型复制受扰输入。正确写法`loss(model(corrupted), clean)`要求模型从扰动中恢复干净样本。还需确保clean没有被原地加噪覆盖。

三个评价问题必须分开：干净重构比较`model(x)`与 x ；去噪比较`model(x+ $\epsilon_{\text{test}}$ )`与 x ；线性探测比较冻结`encoder(x)`读出的类别与 y 。DAE的训练mini-batch loss用受扰输入，而其`clean_validation_mse`用干净输入，所以二者不构成常见同分布训练/验证误差差。

raw恒等映射把附加噪声原样输出，因此误差就是噪声本身的平方均值，其期望为 $0.5^2=0.25$ 。实际 320×8 个坐标上得到0.243129是有限样本实现。DAE平均约0.099736，AE约0.113834，绝对下降约0.014098，相对下降约12.38%。PCA2约0.096840略优于DAE，报告不能省略。

“干净”目标仍包含数据生成时的测量噪声。DAE在本实验恢复的是未加额外 ϵ 的观测，不是潜在因素的完美真值。去噪指标改善也没有保证标签信息改善：DAE三种子探测平均48.02%，依然接近本平衡任务的0.5参照。

题五 L1活动惩罚及漏洞

$z=(2,-1)$ ， $\lambda=0.1$ ， $\text{mean}(\text{abs}(z))=1.5$ ，惩罚为0.15。如果用sum会得到0.3；若批次或K改变，未统一除数会改变相对强度。对非零 z ，惩罚梯度是 $\lambda/(BK)$ 乘符号；零点需次梯度约定。平均活动下降不证明出现精确0。

缩放问题如下：令编码器输出乘 $c>0$ ，同时将解码器第一层权重除以 c ，重构可以保持不变，但L1活动代价变为 c 倍。 c 趋近0时，解码权重可能爆大。仅观察活动惩罚下降，不能判断学到了有用稀疏特征。

至少同时报告重构误差、活动绝对值均值、指定阈值下的零活动比例、解码权重范数，以及固定下游探测。若增加权重范数限制或归一化，需写入协议，并保留 $\lambda=0$ 基准。本实验只实现并测试`sparse_penalty`算术，没有训练稀疏AE，因此不能伪造稀疏模型的结果或把它画成已完成对照。

四 线性探测与结果解释的答案

题六 完整的探测协议

冻结表示生成过程。只用训练集前128例的标签，先从这128例表示计算逐维均值与标准差；常数列的尺度用1。训练与测试都应用这组统计，然后追加全1截距列。解带岭惩罚的最小二乘，特征权重的惩罚系数为1，截距不惩罚；测试分数 ≥ 0 判为1。所有方法用相同的128例与相同的320例测试集。

使用测试表示一起求均值或标准差，会让测试分布参与训练流程，即使没有读取测试标签也违反本课预先设定的归纳边界。另一类泄漏是用测试准确率选岭系数、网络宽度或最佳种子。应在训练/验证信息中选择，最后再评估封存集；如果已反复看过测试反馈，应诚实称作探索，重新设定最终评价。

原始8维探测器有9个系数含截距，二维探测器只有3个。raw是保留全部观测的信息参照，不是等压缩维度对照。线性探测失败也可能意味着读出器受限，不严格证明潜在向量中不存在任何非线性可恢复信息。若要研究后者，需定义并控制另一类探测器的容量和标签预算。

题七 三种子结果与合格结论

AE准确率为150/320、151/320、158/320，即46.875%、47.1875%、49.375%，均值47.8125%。DAE为154/320、151/320、156/320，即48.125%、47.1875%、48.75%，均值48.0208%。PCA2为153/320=47.8125%；随机编码器为177/320、145/320、172/320，均值51.4583%。不要把不同模型的正确数简单相加后当成960个独立测试人，因为它们重复评价同样320例。

一份合格的200字内结论是：在该合成固定划分中，二维AE显著降低了重构数值，却未改善既定线性探测；DAE降低同类附加噪声下的恢复误差，但PCA仍略低。三种子只反映初始化变化，raw使用8维，线性探测也不能排除非线性标签信息；结果不能外推真实语义任务。

这里“显著降低”只表示数值幅度很大，并非统计显著性检验。正式报告更稳妥可写“从约1.5降至约0.043”。不能将接近50%的观测说成“证明完全独立”，也不能把低于50%解释成稳定的反向关系；需要预先设计的独立重复和统计方法才能判断这些命题。

五 扩展设计 复现与评分参考

题八 一个可执行的瓶颈实验设计

预先固定 $K \in \{1, 2, 3, 4, 8\}$ ，AE和DAE各三种子，共30个训练run。沿用固定640/160/320划分、每run250步、批64、学习率0.005、同一批次顺序、DAE噪声0.5、128标签探测与岭系数1。参数数按296+33K报告。每个run设120秒保护上限，总训练样本曝光为 $30 \times 250 \times 64 = 480000$ ，但独立训练样本仍是640个。

最干净的选择规则是预先报告所有K，不按测试表现推荐“赢家”。若确需选K，可按事先规定的干净验证重构选，但这样选择的目标仍是重构，不保证标签表现；若按验证分类选择，必须新增明确的探测验证标签预算与选择步骤，最终测试只做一次。不得把已经用于观察的测试标签图当成未见证据。

主观察包括每K的三种子干净重构、附加噪声恢复、线性探测、参数数和时间；重点看第三个低方差因素是否可能被更宽表示保留。K=3或更大并不保证网络在250步内找到想要的表征；若结果不如预期，应检查优化与读出约束，不事后无限追加步数。

停止条件是预先指定配置均完成，或遇到数值/时间预算错误后定位并记录原因。修复实现错误后要从受影响配置重新运行，不保留旧的有利结果和新的不利结果混拼。不得把扩展结果回填成原始固定协议的数字。

复现文件检查的标准答案

恢复权重时先创建相同结构，用`allow_pickle=False`读取npz。`input_mean`不是`state_dict`参数，需单独保存并从新输入中减去；其余数组按原键名加载。预测为中心化重构，需要原始单位时再加`mean`。探测器均值与尺度作用在表示空间，不是输入空间，二者不能混用。

Notebook应在新进程或Restart Kernel后从第一格运行到最后一格，重新生成完整结果并检查每个数值单元输出无error。计时允许变化，不把`wall_seconds`做字节一致性检查。普通Python和-O模式都须通过；所有六个checkpoint都应恢复而非只抽查一个。

建议评分与判定底线

形状与参数15分，前向和梯度20分，PCA15分，去噪与稀疏15分，探测信息边界15分，完整结果与结论10分，复现与扩展设计10分。评分重点是可核对步骤，不能用语言流畅替代算术与实测。

若使用测试集调参、把受扰输入当干净目标、删去不利种子、声称训练了未实现的稀疏AE，或只展示缓存Notebook而不能Run All，应先修复实验结论的可信性，再讨论高分。合格作品可以有与参考不同的小数末位，但必须解释环境、协议和差异，保留失败信息并使别人能够重新运行。